
Recomendador Multimodal de Juegos de Mesa y Diversificación MMR

Martín Cortés¹ Manuel Delpiano¹ Yampai Ludueña¹

Código y experimentos disponibles en: https://github.com/ManuelDelpiano/Entrega_Final_SisRec/blob/main/H1_BoardGames_RecSys_Entrega_Final.ipynb

Abstract

Los sistemas de recomendación para juegos de mesa han recibido escasa atención en comparación con dominios consolidados como el cine o la música, pese a que plataformas como BoardGameGeek (BGG) concentran millones de calificaciones sobre decenas de miles de títulos. En este trabajo proponemos y evaluamos un sistema de recomendación híbrido y multimodal para BGG que combina señales colaborativas (ALS con matriz de confianza), representaciones semánticas de texto (Sentence-BERT) y representaciones visuales de portadas (VGG19/CLIP) mediante dos estrategias de re-ranking: un ensamble en cascada de fusión tardía y un modelo neuronal DeepFM entrenado sobre candidatos generados por ALS. Adicionalmente, incorporamos mecanismos explícitos de control de diversidad para mitigar el sesgo hacia ítems de alta visibilidad. Sobre un dataset filtrado de más de 18.7M de interacciones, 272K usuarios y 21.9K juegos, nuestros experimentos muestran que las señales colaborativas siguen siendo el componente dominante en precisión ($\text{NDCG@10} = 0.159$ para ALS), mientras que DeepFM logra la mejor precisión absoluta ($\text{P@10} = 0.088$) al explotar interacciones multimodales de alto orden. La incorporación de MMR con $\lambda = 0.40$ permite retener más del 97% de la utilidad del mejor modelo mientras incrementa sustancialmente la diversidad intra-lista ($\text{ILD@10} = 0.944$) y la cobertura del catálogo, evidenciando que precisión y diversidad pueden balancearse de forma explícita sin sacrificios severos en este dominio.

1. Revisión del Estado del Arte

A diferencia de dominios consolidados como cine o música, los sistemas de recomendación (RS) para juegos de mesa siguen siendo un área poco explorada, pese a que

BoardGameGeek (BGG) concentra calificaciones de cientos de miles de usuarios sobre más de 120,000 juegos (11).

Burke (9) sistematizó las distintas formas de combinar técnicas de recomendación (ponderada, mixta, en cascada, entre otras), marco que sigue siendo la referencia estándar para justificar arquitecturas híbridas como la nuestra. En el dominio específico de juegos de mesa, Zalewski et al. (12) agruparon más de 3,000 juegos de BGG en seis clústeres vía PCA y construyeron perfiles de usuario a partir de ellos, identificando la escalabilidad como principal desafío. Sahinli et al. (13) compararon RS secuenciales frente a un CF general, encontrando que la complejidad adicional de modelar secuencialidad no se justificaba en este dominio. En una línea similar, un estudio con arquitecturas CNN sobre interacciones de BGG mostró mejoras incluso en escenarios de *cold-start*, a costa de mayor complejidad (15).

Más cercano a nuestro trabajo, Askeroth y Lindgren (11) estudiaron el efecto de k en un RS kNN ítem-a-ítem sobre BGG, mostrando mejoras solo marginales en MAE al aumentar k , y resultados de MAP/MAR muy sensibles a cómo se define un ítem “relevante” en la evaluación. Este último punto es transversal a la literatura del dominio: la falta de un protocolo de evaluación estandarizado dificulta comparar estudios entre sí (12; 13; 11), y todos comparten además restricciones de cómputo que obligan a reducir agresivamente los datasets.

En conjunto, el estado del arte en juegos de mesa se ha mantenido anclado en CF clásico o contenido tabular simple, sin explotar representaciones semánticas o visuales ricas. Esto contrasta con la recomendación multimodal general, donde incorporar embeddings visuales (16) y textuales vía *transformers* (17; 18) es ya una práctica consolidada, aunque estudios recientes matizan su beneficio real frente a modelos basados solo en identificadores (19). A esto se suma que la evaluación de la diversidad y la novedad, clave para nuestra etapa de post-procesamiento vía MMR, ha sido formalizada principalmente fuera del dominio de juegos de mesa (10), sin aplicarse aún de forma sistemática a este contexto.

2. Dataset y Análisis Exploratorio de Datos

El sistema de recomendación propuesto se alimenta del conjunto de datos público de BoardGameGeek (BGG), el cual representa la comunidad más grande e influyente de juegos de mesa a nivel mundial.

Las entidades de metadatos del catálogo de juegos se estructuran de la siguiente manera:

- **Juegos (`games.csv`):** Contiene atributos principales de 21,925 juegos de mesa, incluyendo identificadores únicos (BGGId), nombres, descripciones textuales y metadatos generales (año de publicación, número de jugadores, tiempo de juego, edad mínima recomendada).
- **Mecánicas (`mechanics.csv`):** Matriz binaria que mapea los juegos frente a 158 mecánicas de juego diferentes (e.g., *Dice Rolling*, *Hand Management*, *Worker Placement*).
- **Temáticas (`themes.csv`):** Matriz binaria que asocia los juegos con 218 conceptos temáticos (e.g., *Fantasy*, *Economic*, *Science Fiction*).
- **Subcategorías (`subcategories.csv`):** Clasificación del juego en 11 familias de juegos (e.g., *Strategy Games*, *Thematic Games*, *Family Games*).




Figure 1. Top 20 mecánicas más frecuentes en el catálogo.

2.1. Preprocesamiento y Filtrado K-Core

El dataset de calificaciones crudo (`user_ratings.csv`) contiene inicialmente 18,942,152 calificaciones de 411,374 usuarios únicos sobre 21,925 juegos, en una escala continua de 1.0 a 10.0. La densidad de esta matriz de interacciones es extremadamente baja (dispersión del 99.79%), lo cual representa un desafío para el entrenamiento estable de modelos de factores latentes.

Para mitigar el impacto del ruido y la escasez de datos, se aplicó un filtro *K-Core* iterativo de grado $K = 5$. Este proceso elimina recursivamente a aquellos usuarios con menos de 5 interacciones en la plataforma e ítems con menos de 5 calificaciones, convergiendo en una matriz densificada.

El filtro 5-Core descarta aproximadamente un tercio de los usuarios (33.84%), los cuales corresponden a perfiles con nula o muy baja actividad (menos de 5 calificaciones). No obstante, la pérdida en volumen de interacciones es marginal (solo -1.30%). Esto permite incrementar significativamente el número de calificaciones promedio por usuario activo de 46.05 a 68.69 ($+49.16\%$), garantizando señales más robustas para los modelos colaborativos.

2.2. Descubrimientos y Diagnóstico del EDA

El análisis exploratorio de datos reveló tres fenómenos estructurales clave que condicionan el diseño del sistema de recomendación híbrido:

1. **Estructura Long-Tail Extrema:** A pesar del filtrado, la distribución de interacciones por juego sigue una ley de potencia (*Power Law*). Un número muy reducido de juegos hiperpopulares (e.g., *Pandemic*, *Catan*, *Carcassonne*) acumula la gran mayoría de las calificaciones, mientras que miles de juegos de nicho (la cola larga) apenas tienen el mínimo de calificaciones para sobrevivir al filtro.
2. **Sesgo de Calificación Positiva:** La distribución del valor de las calificaciones revela un sesgo sistemático hacia valores altos, con una mediana de calificaciones situada en torno a 7.0. Basado en esto, se definió un umbral adaptativo para la construcción de perfiles de usuario: se considera que un usuario demuestra afinidad o preferencia positiva hacia un juego únicamente cuando le asigna una calificación igual o superior a 7.0. Calificaciones menores a este umbral se tratan como retroalimentación débil o negativa para evitar sesgar el vector de interés semántico/visual del usuario hacia juegos que no fueron de su agrado.

3. Metodología utilizada

El diseño experimental sigue una arquitectura *two-stage*: un modelo colaborativo genera una bóveda acotada de candidatos por usuario, sobre la cual operan re-rankers híbridos y, opcionalmente, mecanismos de diversificación. A continuación describimos, en ese orden, los baselines de referencia, el filtrado colaborativo base, las representaciones de contenido, la fusión en cascada, la diversificación post-ranking, el re-ranker DeepFM y el protocolo de evaluación.

3.1. Baselines y filtrado colaborativo

Como referencias de comparación empleamos tres baselines. **Random** genera listas aleatorias sin reemplazo sobre el catálogo, excluyendo ítems ya consumidos. **MostPopular** ordena por frecuencia de interacción en entrenamiento. **ContentBased-TFIDF** construye, para cada juego, un documento textual concatenando su descripción con tokens derivados de mecánicas, temáticas y subcategorías; ese documento se vectoriza con TF-IDF. El perfil de usuario se obtiene como media ponderada por rating de los vectores TF-IDF de su historial, y la recomendación se produce por similitud coseno. Este baseline no se fusiona con los modelos principales; el mismo espacio TF-IDF se utiliza únicamente para calcular la métrica ILD@10 (véase Section 3.6).

El componente colaborativo central es **Alternating Least Squares** (ALS) para feedback implícito (3), con $f = 100$ factores latentes y 10 iteraciones. Se consideran interacciones de entrenamiento aquellas con rating $r_{ui} \geq \tau$, con umbral $\tau = 7$. Tras un diagnóstico comparativo, reemplazamos la matriz binaria—que asigna el mismo peso a un rating de 7 y a uno de 10—por una **matriz de confianza**:

$$c_{ui} = 1 + \alpha \cdot \frac{r_{ui} - \tau}{10 - \tau}, \quad \alpha = 40, \quad (1)$$

donde c_{ui} es el peso de confianza asignado al par usuario-ítem (u, i) , $r_{ui} \in [\tau, 10]$ es el rating observado, τ es el umbral mínimo de interacción positiva y α controla la sensibilidad de la confianza respecto de la intensidad del rating. La variante binaria se conserva únicamente como ablación. En inferencia, ALS devuelve los $N_c = 200$ candidatos de mayor score colaborativo por usuario, excluyendo ítems presentes en entrenamiento; N_c denota el tamaño de la bóveda de candidatos.

3.2. Contenido textual y visual

Para enriquecer el re-ranking incorporamos tres representaciones precomputadas por juego, todas normalizadas en norma L_2 . **Sentence-BERT** (all-MiniLM-L6-v2, 384 dimensiones) codifica el perfil textual del juego. **VGG19** (512 dimensiones, pesos ImageNet) extrae características visuales de la portada; se emplea en la cascada y en la similitud intra-lista de MMR. **CLIP** (openai/clip-vit-base-patch32) aporta una representación visual-semántica alineada con lenguaje natural; se utiliza en DeepFM por su capacidad de capturar correspondencias entre apariencia visual y descripción textual. Los juegos sin representación disponible reciben similitud de contenido nula al re-puntuar, preservando la dimensionalidad del resto de señales.

3.3. Ensamble Cascade

La cascada implementa *late-fusion* sobre la bóveda de N_c candidatos ALS. Para cada usuario u se construye un perfil de contenido $\mathbf{p}_u$ como promedio ponderado por rating de los embeddings BERT y VGG19 de los juegos valorados en entrenamiento. Cada candidato i recibe similitudes coseno $\text{sim}_{\text{BERT}}(u, i)$ y $\text{sim}_{\text{VGG}}(u, i)$ respecto de $\mathbf{p}_u$. Los scores colaborativo $s_{\text{ALS}}(i)$, textual $\text{sim}_{\text{BERT}}(u, i)$ y visual $\text{sim}_{\text{VGG}}(u, i)$ se normalizan min-max dentro de la lista de candidatos del usuario, obteniendo $\hat{s}_{\text{ALS}}(i)$, $\hat{s}_{\text{BERT}}(i)$ y $\hat{s}_{\text{VGG}}(i)$, y se combinan linealmente:

$$s(i) = w_{\text{ALS}} \hat{s}_{\text{ALS}}(i) + w_{\text{BERT}} \hat{s}_{\text{BERT}}(i) + w_{\text{VGG}} \hat{s}_{\text{VGG}}(i), \quad (2)$$

donde $s(i)$ es el score final del candidato i , w_{ALS} , w_{BERT} y w_{VGG} son pesos no negativos de la fusión colaborativa, textual y visual, respectivamente, con $\sum_k w_k = 1$. Los pesos se seleccionan mediante *grid search* sobre una muestra de $N = 250$ usuarios y se confirman en la evaluación final con $N = 2000$; la configuración óptima resultó ser $(w_{\text{ALS}}, w_{\text{BERT}}, w_{\text{VGG}}) = (0.5, 0.3, 0.2)$.

3.4. DeepFM multimodal

DeepFM (7) actúa como re-ranker aprendido alternativo sobre los mismos candidatos ALS. El modelo recibe, para cada par (u, i) , los factores latentes de usuario e ítem obtenidos por ALS (100 dimensiones), embeddings de contenido BERT y CLIP (proyectados a 100 dimensiones) y *side features* categóricas del catálogo. Se entrena minimizando entropía cruzada binaria con *negative sampling*, optimizador Adam con tasa de aprendizaje 5×10^{-4} y parada temprana sobre pérdida de validación; por restricciones de cómputo se submuestran interacciones positivas y negativas. En inferencia, DeepFM re-ordena la bóveda ALS con el score de relevancia aprendido, sobre el cual se aplican opcionalmente las capas de diversificación descritas a continuación.

3.5. Diversificación: MMR y PopPenalty

Tras ordenar los candidatos por su score de relevancia $\text{rel}(i)$ (proveniente de la cascada o de DeepFM), se aplica opcionalmente **Maximal Marginal Relevance** (MMR) (8), seleccionando iterativamente el ítem que maximiza:

$$\text{MMR}(i) = \lambda \cdot \text{rel}(i) - (1 - \lambda) \cdot \max_{s \in S} \text{sim}(i, s), \quad (3)$$

donde C es el conjunto de candidatos, $S \subset C$ es la lista parcial ya seleccionada, $\text{sim}(i, s)$ mide la similitud de contenido entre los ítems i y s , y $\lambda \in [0, 1]$ balancea relevancia frente a diversidad intra-lista ($\lambda = 1$ recupera el ranking por relevancia pura). Definimos $\text{sim}(i, s) = w_{\text{bert}} \text{sim}_{\text{BERT}}(i, s) + (1 - w_{\text{bert}}) \text{sim}_{\text{VGG}}(i, s)$, con $w_{\text{bert}} \in [0, 1]$ el peso relativo de la similitud textual frente a la visual.

Complementariamente evaluamos **penalización por popularidad** (PopPenalty), que ajusta el score de relevancia según:

$$s_{\text{pop}}(i) = \hat{s}_{\text{rel}}(i) - \gamma \cdot \log(1 + \text{pop}_{\text{train}}(i)), \quad (4)$$

donde $\hat{s}_{\text{rel}}(i)$ es el score de relevancia normalizado, $\text{pop}_{\text{train}}(i)$ es la frecuencia del ítem i en entrenamiento, la barra indica normalización min-max sobre la lista de candidatos, y $\gamma \geq 0$ controla la intensidad de la penalización por popularidad.

MMR diversifica *dentro* de cada lista recomendada; PopPenalty mitiga el sesgo hacia ítems frecuentes a nivel de catálogo. Ambos mecanismos se aplican indistintamente sobre los scores de la cascada o de DeepFM, dando lugar a las variantes Cascade+MMR, Cascade+PopPenalty, DeepFM+MMR y DeepFM+PopPenalty.

Los hiperparámetros λ , w_{bert} y γ se eligen mediante barridos y un criterio ε -**constraint**: se maximiza diversidad (Novelty@10 o ILD@10) sujeto a

$$\text{nDCG@10} \geq (1 - \varepsilon) \text{nDCG}_{\text{max}}, \quad \varepsilon = 0.10, \quad (5)$$

donde nDCG_{max} es el mejor nDCG@10 observado en el barrido sin restricción de diversidad y ε tolera una pérdida máxima del 10% en relevancia.

3.6. Protocolo de evaluación

Formulamos el problema como recomendación top- K con $K = 10$. Evaluamos una muestra aleatoria de $N = 2000$ usuarios del conjunto de prueba, con semilla fija para reproducibilidad, excluyendo en cada lista los ítems presentes en entrenamiento. Un ítem es **relevante** si su rating en prueba alcanza el percentil 70 *global* del conjunto de test. Reportamos métricas de relevancia—Precision@10, Recall@10 y nDCG@10 —y métricas *beyond-accuracy*: Novelty@10 (sorpresa respecto de la popularidad en entrenamiento), ILD@10 (diversidad intra-lista, definida como uno menos la similitud coseno media entre pares de ítems recomendados en el espacio TF-IDF descrito en la primera subsección) y Coverage@10 (proporción del catálogo distinto recomendado en la muestra evaluada). Todos los modelos se evalúan en una única pasada sobre los mismos usuarios; los barridos de hiperparámetros emplean $N = 250$ usuarios como exploración, mientras que los resultados reportados corresponden a $N = 2000$.

4. Análisis de parámetros

4.1. Pesos del ensemble Cascade


Grid search sobre $(w_{\text{ALS}}, w_{\text{BERT}}, w_{\text{VGG}})$ con $\sum w = 1$, paso 0.1, evaluado en $N = 250$ usuarios. La Tabla 1 muestra las mejores configuraciones; (0.5, 0.3, 0.2) maximiza nDCG@10 en el grid.

Table 1. Top configuraciones Cascade (grid, $N = 250$).

Config.	nDCG@10	w_{ALS}	w_{BERT}	w_{VGG}
(0.5, 0.3, 0.2)	0.167325	0.5	0.3	0.2
(0.5, 0.1, 0.4)	0.166243	0.5	0.1	0.4
(0.3, 0.4, 0.3)	0.62867	0.3	0.4	0.3

4.2. Parámetro MMR (λ) y *trade-off* por backbone

La incorporación del algoritmo de reordenamiento Maximal Marginal Relevance (MMR) introduce un compromiso directo entre la precisión de la recomendación y la diversidad interna del catálogo sugerido al usuario. Al sintonizar el parámetro de control λ , que pondera la relevancia matemática del modelo frente a la similitud máxima entre ítems de la lista, se evidencia el trade-off clásico del filtrado: en el extremo de sintonía fina donde $\lambda = 1.0$, se maximiza la utilidad de recomendación (alcanzando un nDCG@10 de 0.168 en el modelo DeepFM), pero a expensas de la redundancia del catálogo (ILD@10 de 0.945). Por el contrario, forzar la diversificación hacia el extremo $\lambda = 0.0$ eleva la diversidad intra-lista (ILD@10 de 0.970), pero degrada críticamente la precisión (nDCG@10 de 0.064). De este modo, la selección óptima del hiperparámetro en torno a $\lambda = 0.40$ constituye un punto de operación equilibrado que rompe burbujas de filtrado homogéneas e incrementa la cobertura de mecánicas y temáticas del listado final sin incurrir en una degradación de la relevancia del sistema.



4.3. Dimensión del Conjunto de Candidatos (Tamaño de Bóveda N_c)

El tamaño del conjunto de candidatos o bóveda (N_c) determina el balance de carga entre la fase de pre-filtrado colaborativo rápido (ALS) y la fase de reordenamiento complejo (DeepFM Híbrido). El análisis experimental evaluó el impacto de este parámetro variando $N_c \in \{50, 100, 200, 400\}$. Los resultados indican que valores reducidos ($N_c \leq 100$)

limitan prematuramente el espacio de búsqueda, excluyendo elementos altamente relevantes en la fase inicial y mermando el $NDCG@10$ final. En contraste, fijar $N_c = 200$ proporciona un espacio de candidatos estadísticamente representativo, alcanzando un $NDCG@10$ óptimo de 0.098. Incrementar la bóveda a $N_c = 400$ no reporta incrementos significativos de precisión, puesto que la métrica de utilidad se satura e introduce ruido en el modelo neuronal, sin embargo, incrementa linealmente el costo computacional y la latencia de inferencia en la etapa profunda, consolidando a $N_c = 200$ como el punto de diseño óptimo.




Figure 3. Comparación métricas al cambiar N_c

4.4. Balance Multimodal en el Reordenamiento MMR

La similitud entre ítems utilizada por el algoritmo MMR se formuló como una combinación lineal ponderada por un parámetro $\alpha \in [0, 1]$, que balancea la similitud semántica del texto (BERT) frente a la similitud visual de las portadas (CLIP/VGG). El análisis experimental mediante un barrido sobre $\alpha \in \{0.5, 0.6, 0.8, 1.0\}$ demostró que el punto de operación óptimo se sitúa en $\alpha = 0.8$, donde la información textual de mecánicas y descripciones domina la penalización (80%), mientras que la componente estética visual actúa como un refinamiento secundario (20%). Reducir α hacia valores más equilibrados como 0.5 deteriora el $NDCG@10$, debido a que las características visuales de las portadas no guardan una correlación estricta con la afinidad mecánica de los juegos de mesa, induciendo penalizaciones erróneas. Por su parte, la exclusión de la componente visual ($\alpha = 1.0$) limita la capacidad de diversificación al ignorar la redundancia estética en la interfaz de recomendación.

5. Resultados obtenidos

En la Tabla 2 se encuentran los resultados finales de los principales modelos. Estos se encuentran ordenados de mayor a menor en términos de la métrica $NDCG$.

Como se puede observar el modelo ContentBased-TFIDF presenta el peor desempeño en métricas de utilidad, con un $NDCG@10$ bajo (0.0164). Esto evidencia que los metadatos léxicos son insuficientes para modelar preferencias complejas por sí solos. No obstante, este modelo registra la mayor novedad (15.5950) y la cobertura más alta (9.74%), lo cual indica que tiende a recomendar ítems sumamente raros y poco calificados del catálogo, sacrificando precisión por explorar la cola larga (*long-tail*).




Figure 4. Variación peso de Bert en modelo de Cascade

Table 2. Resultados finales

Modelo	P@10	R@10	NDCG@10	Nov@10	ILD@10	Cov@10
ALS	0.083159	0.180451	0.158786	9.829781	0.944479	0.051859
DeepFM.	0.087686	0.177259	0.158298	9.847074	0.945025	0.052725
Cascada + MMR	0.083074	0.171172	0.154821	9.905422	0.944363	0.053637
Cascada	0.084129	0.169070	0.153443	9.963524	0.935762	0.051904
DeepFM + PopPen	0.083444	0.169221	0.152447	9.816227	0.944352	0.051767
Casc. + PopPen	0.079301	0.164429	0.149619	9.989937	0.937090	0.054641
MostPopular	0.062576	0.124303	0.108044	7.979859	0.927249	0.002189
DeepFM + MMR	0.049419	0.118250	0.103407	10.085129	0.963355	0.054094
CB-TFIDF	0.006226	0.017997	0.016470	15.595013	0.683789	0.097469

Por otro lado, el modelo *ALS* (*confianza*) lidera en $NDCG@10$ (0.1587) y $Recall@10$ (0.1804), mientras que *DeepFM Híbrido* obtiene la precisión más alta de la comparativa ($P@10 = 0.0876$). Estos resultados demuestran la efectividad de sus respectivas aproximaciones: ALS explota óptimamente la intensidad de la señal implícita mediante la ponderación de confianza continua, mientras que DeepFM aprovecha con éxito las interacciones de características multimodales, lineales y no lineales de alto orden.

Complementando el análisis, la arquitectura *Cascade conf* + *MMR* ($\lambda = 0.40$) logra retener el 97.5% de la utilidad de los modelos líderes ($NDCG@10 = 0.1548$), incrementando al mismo tiempo la diversidad interna de las listas ($ILD@10 = 0.9443$) y superando la cobertura del catálogo de la cascada estándar. Este comportamiento valida la robustez de la cascada en dos etapas: permite inyectar embeddings densos (BERT/VGG) sobre un conjunto filtrado de candidatos para refinar el ranking en tiempo real, garantizando diversidad física y semántica con un costo computacional mínimo.

Por último, el baseline *MostPopular* registra una precisión moderada ($P@10 = 0.0625$), pero sufre de la novedad más baja del catálogo (7.9798) y una cobertura prácticamente nula (0.0021), limitando las sugerencias a un grupo minúsculo de títulos masivos de la plataforma. Por

su parte, configuraciones extremas de diversificación como *DeepFM + MMR* ($\lambda = 0.25$) logran el ILD más alto de la comparativa (0.9633), pero a costa de degradar la métrica $NDCG@10$ ($= 0.1034$).

En la Tabla 3 se muestran las recomendaciones generadas para el usuario del dataset 224104 utilizando el modelo de DeepFM con y sin la aplicación de MMR.

Table 3. Comparación del Top-10 de recomendaciones para el Usuario 224104.

#	DeepFM	DeepFM + MMR
1	Betrayal at House on the Hill	Betrayal at House on the Hill
2	Ticket to Ride	Catan
3	Catan	Ticket to Ride
4	Citadels	Citadels
5	Arkham Horror: The Card Game	Exploding Kittens
6	Arkham Horror	Takenoko
7	Elder Sign	Small World
8	Mansions of Madness: Second Edition	Fury of Dracula (Third/Fourth Edition)
9	Exploding Kittens	Zombie Dice
10	Small World	Arkham Horror: The Card Game

Como se aprecia en la Tabla 3 el MMR tiene el comportamiento esperado, dónde es capaz de no solo reordenar el top 10 para un usuario, si no que logra incorporar juegos que sin el MMR no se estaban recomendando, lo que hace la diferencia en términos de diversidad, como se observa en la métrica de ILD en la Tabla 2, dónde DeepFM junto con MMR obtiene el mejor valor para dicha métrica.

6. Conclusiones

Los resultados obtenidos permiten extraer conclusiones relevantes sobre el diseño de sistemas de recomendación multimodales en el dominio de juegos de mesa, tanto a nivel de arquitectura como de compromisos entre métricas.

En primer lugar, se concluye que las señales colaborativas continúan siendo el componente dominante para la predicción de preferencias en este dominio: la brecha de un orden de magnitud entre ALS/DeepFM y TF-IDF confirma que el comportamiento agregado de la comunidad captura mejor la afinidad usuario-juego que la similitud puramente textual. Esto sugiere que, en dominios donde la decisión de consumo está fuertemente mediada por la dinámica social y grupal (como ocurre con los juegos de mesa), los enfoques de contenido deben entenderse como un complemento y no como un sustituto de la señal colaborativa. Asimismo, el salto de desempeño obtenido al modelar la retroalimentación implícita mediante una matriz de confianza $C_{ui} = 1 + \alpha R_{ui}$ evidencia que el diseño de la función de ponderación de interacciones es, en la práctica, tan determinante como la elección del algoritmo de factorización en sí.

En segundo lugar, el desempeño superior de DeepFM frente a los modelos lineales valida la pertinencia de arquitecturas híbridas que combinan interacciones explícitas de bajo orden (vía FM) con relaciones no lineales de alto orden (vía

DNN) sobre embeddings multimodales densos (BERT y CLIP). Esto posiciona a los enfoques neuronales híbridos como la alternativa más sólida cuando se dispone de representaciones semánticas y visuales de calidad, y abre como línea de trabajo futuro la exploración de arquitecturas de atención cruzada entre modalidades, en lugar de una simple concatenación de embeddings.

En tercer lugar, el análisis de los mecanismos de post-procesamiento deja como conclusión central que la diversidad y la novedad no son propiedades gratuitas del sistema, sino objetivos que compiten directamente con la precisión y deben calibrarse explícitamente. MMR con $\lambda = 0.40$ demuestra que existe una región de operación donde es posible obtener ganancias sustanciales en diversidad (ILD@10) y cobertura con una degradación marginal del $NDCG@10$, lo que lo convierte en una estrategia recomendable para su uso en producción. En contraste, la penalización de popularidad, si bien mejora la exposición del *long-tail*, revela un límite estructural: los patrones de consumo en BoardGameGeek están fuertemente sesgados hacia títulos de alta visibilidad, por lo que forzar recomendaciones hacia el nicho entra en conflicto directo con las expectativas reales de los usuarios.

Finalmente, la arquitectura en cascada con retrieval vía ALS y re-ranking multimodal con $K = 200$ permite acotar el costo computacional de los modelos densos (DeepFM, MMR) sin sacrificar significativamente el techo de recall del sistema, habilitando así su viabilidad en escenarios de catálogos a gran escala. En conjunto, estos resultados sugieren que un sistema de recomendación multimodal efectivo en este dominio no depende de un único componente óptimo, sino de un equilibrio entre una señal colaborativa, enriquecimiento semántico-visual y control explícito de los objetivos de diversidad, todo ello bajo restricciones realistas de eficiencia computacional. Como trabajo futuro, queda abierta la evaluación online (A/B testing) de estas configuraciones y la incorporación de retroalimentación temporal para capturar la evolución de preferencias de los usuarios.

Referencias

- [1] Threnjen (2022). *Board Games Database from BoardGameGeek*. Kaggle. <https://www.kaggle.com/datasets/threnjen/board-games-database-from-boardgamegeek>
- [2] M. Kaminskis, D. Bridge (2016). Diversity, serendipity, novelty, and coverage: A survey and empirical analysis of beyond-accuracy objectives in recommender systems. *ACM TIS*, 7(1).
- [3] Y. Hu, Y. Koren, C. Volinsky (2008). Collaborative filtering for implicit feedback datasets. *Proc. IEEE ICDM*, 263–272.
- [4] N. Reimers, I. Gurevych (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proc. EMNLP-IJCNLP*, 3982–3992.
- [5] K. Simonyan, A. Zisserman (2015). Very deep convolutional networks for large-scale image recognition. *Proc. ICLR*.

- [6] A. Radford et al. (2021). Learning transferable visual models from natural language supervision. *Proc. ICML*, 8748–8763.
- [7] H. Guo et al. (2017). DeepFM: A factorization-machine based neural network for CTR prediction. *Proc. IJCAI*, 1725–1731.
- [8] J. Carbonell, J. Goldstein (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. *Proc. SIGIR*, 335–336.
- [9] R. Burke (2002). Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331–370.
- [10] S. Vargas, P. Castells (2011). Rank and relevance in novelty and diversity metrics for recommender systems. *Proc. ACM RecSys*, 109–116.
- [11] F. Askeroth, B. Lindgren (2024). Enhancing Board Game Recommendations: Leveraging K-nearest neighbors in Collaborative Filtering.
- [12] J. Zalewski, M. Ganzha, M. Paprzycki (2019). Recommender system for board games.
- [13] C. Sahinli, F. Debrauwer, L. Brugaletta, T. Martoja, V. Mishra, Y. Ruppenthal, C. Browne (2020). Recommender System for Board Games.
- [14] M. Ion, D. Sacharidis, H. Werthner (2020). Designing a recommender system for board games.
- [15] J. Kim, J. Wi, S. Jang, Y. Kim (2020). Sequential Recommendations on Board-Game Platforms.
- [16] R. He, J. McAuley (2016). VBPR: Visual Bayesian Personalized Ranking from Implicit Feedback.
- [17] N. Reimers, I. Gurevych (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.
- [18] F. Sun, J. Liu, J. Wu, C. Pei, X. Lin, W. Ou, P. Jiang (2019). BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer.
- [19] Y. Ye et al. (2025). Are Multimodal Embeddings Truly Beneficial for Recommendation? A Deep Dive into Whole vs. Individual Modalities.