
Sistema de Recomendación Conversacional (CRS): Evaluación de Representación de Dialogo y Tamaño de Contexto

Maximiliano Perry Jenaro Prieto

Abstract

Se propone un Sistema de Recomendación Conversacional (CRS) para películas basado en Generación Aumentada por Recuperación (RAG), que representa el historial de diálogo mediante *embeddings* densos (Sentence-BERT) para recuperar conversaciones similares y generar recomendaciones mediante un LLM. La propuesta se evalúa sobre el dataset ReDial, analizando la sensibilidad del sistema al tamaño del contexto conversacional (N) y al número de conversaciones recuperadas (K), obteniendo la mejor configuración en $N = \text{Full}$, $K = 50$. Los resultados muestran que el modelo propuesto supera ampliamente a *baselines* clásicos y a modelos basados en LLM de la literatura, alcanzando un HR@10 de 0.6363 y un MRR@10 de 0.3599. No obstante, se discute que el fuerte sesgo de popularidad del dataset podría explicar parte de esta mejora, más allá de una comprensión semántica superior del diálogo.

Introducción y Motivación

Los sistemas de recomendación tradicionales se basan en interacciones históricas estáticas, haciéndolos vulnerables al problema de *Cold-Start* y les impide capturar intenciones inmediatas de los usuarios. Los Sistemas de Recomendación Conversacional (CRS) mitigan esto al modelar dinámicamente las preferencias y en tiempo real mediante interacciones en lenguaje natural.

En el presente documento se establece la tarea experimental como **Recomendación de Ranking Top-K basada en el historial de diálogo**. Matemáticamente, esto se define de la siguiente manera.

Dado un usuario u , un catálogo global de películas I , y un historial de diálogo secuencial

$$D_u = \{t_1, t_2, \dots, t_n\}, \quad (1)$$

donde cada t_i representa un turno de la conversación, la tarea consiste en aprender una función de puntuación

$$f(D_u, i) \quad (2)$$

que ordene el catálogo. El sistema debe retornar un conjunto

$$P \subset I, \quad |P| = K, \quad (3)$$

con $K = 10$, maximizando la probabilidad de que el usuario acepte dichos ítems en el siguiente turno.

Con la finalidad de resolver dicha tarea, se utilizará Generación Aumentada por Recuperación (RAG). El sistema consultará un catálogo construido con la información de las películas (títulos, géneros y sinopsis). Para ello, el historial de diálogo D_u se transformará en *embeddings*, permitiendo encontrar recomendaciones que coincidan con el significado de la conversación.

0.1. Objetivos del Estudio

Para dar respuesta a esta problemática, se definen los siguientes objetivos:

- **Objetivo General:** Diseñar e implementar un CRS para películas basado en RAG, evaluando su desempeño dinámico mediante un Simulador de Usuario impulsado por LLMs, a través de las métricas HR@10, MRR@10 y Novedad.
- **Objetivos Específicos:**
 1. Evaluar el impacto del tamaño del contexto de memoria en la precisión del ranking.
 2. Mitigar el sesgo de popularidad (*Long-Tail*) inherente en las interacciones humanas mediante búsqueda semántica.
 3. Comparar el rendimiento de la arquitectura propuesta frente a *baselines* estáticos y léxicos.

Datos Utilizados

El análisis hace uso del set de datos **REDIAL** (Recommender Dialogue Dataset, (Li et al., 2018)). Este conjunto brinda la estructura conversacional necesaria para nuestro

modelo, incluyendo anotaciones explícitas de películas y respuestas polares (aceptación o rechazo).

Dicho dataset corresponde a una colección de conversaciones de recomendación de películas, en las cuales un usuario interactúa con un recomendador de manera conversacional. El dataset dispone de las siguientes métricas descriptivas, resumidas en la tabla 1:

Table 1. Estadísticas descriptivas del dataset ReDial.

MÉTRICA	VALOR
TOTAL DE CONVERSACIONES	11348
TOTAL DE TURNOS	206102
TURNOS POR CONVERSACIÓN (PROMEDIO)	18.16
TURNOS POR CONVERSACIÓN (MEDIANA)	17
TURNOS POR CONVERSACIÓN (DESV. ESTÁNDAR)	5.28
TURNOS POR CONVERSACIÓN (MÁXIMO)	116
TURNOS POR CONVERSACIÓN (MÍNIMO)	1
NÚMERO DE PELÍCULAS ÚNICAS MENCIONADAS	6637
PELÍCULAS MENCIONADAS POR CONVERSACIÓN (PROM.)	5.29

Además, el dataset presenta un fenómeno crucial al momento de realizar la recomendación: el fenómeno de **cola larga** (*long-tail*). Como se observa en la figura 1, el 81.4% de las menciones de películas se concentran en solo el 20% de los ítems del catálogo, mientras que el 80% restante de las películas son mencionadas de manera muy esporádica. Este desbalance implica que un sistema de recomendación entrenado sin considerar este fenómeno tenderá a favorecer sistemáticamente a los ítems populares, dejando de lado gran parte del catálogo. Por esta razón, se define como uno de los objetivos del presente trabajo el poder mitigar el efecto del fenómeno de cola larga, promoviendo recomendaciones que también consideren ítems menos populares sin sacrificar la relevancia para el usuario.




Figure 1. Distribución long-tail de las películas mencionadas en el dataset ReDial.

Asimismo, es posible apreciar que la mayoría de las conversaciones se concentra por debajo del valor promedio de turnos (18.16), lo que evidencia una asimetría en la distribución hacia diálogos generalmente breves, tal como se muestra en la figura 2.




Figure 2. Distribución del número de turnos por conversación en el dataset ReDial.

Metodología

Con el fin de evaluar los resultados obtenidos, se definen métricas y *pipelines* de comparación dentro del estudio, permitiendo contrastar el modelo propuesto y medir su valor agregado respecto a soluciones de complejidad creciente.

En primera instancia, se comparará el modelo propuesto con *baselines* simples:

- **Random:** recomienda ítems de manera aleatoria, sin considerar el historial de diálogo.

- **Most Popular:** recomienda los ítems más mencionados dentro del dataset, independientemente del contexto conversacional.
- **Retrieval BM25:** modelo clásico de recuperación de texto que utiliza el historial del diálogo del usuario como *query* para buscar coincidencias léxicas exactas en la metadata de las películas.

Posteriormente, se realizarán comparaciones con otros modelos de arquitectura similar a la propuesta, basados en Modelos de Lenguaje de Gran Escala (LLM).

Finalmente, las métricas utilizadas para evaluar el desempeño del modelo propuesto serán:

- **HR@10 (Hit Rate):** mide la proporción de veces en que al menos una película relevante para el usuario se encuentra dentro de las $K = 10$ recomendaciones entregadas por el sistema.
- **MRR@10 (Mean Reciprocal Rank):** mide qué tan arriba en el ranking aparece la primera película relevante, promediando el inverso de su posición dentro del top-10.

Caso Base

Los modelos fueron evaluados computacionalmente sobre una muestra de 1.000 sesiones (del total de 10.006) de diálogo reales del dataset. Los resultados se resumen en la tabla 2.

Modelo Baseline	HR@10	MRR@10
Random	0.00142	0.0036
Most Popular	0.2399	0.1214
Retrieval BM25	0.3271	0.1755
GPT-2 (Qiu et al., 2025)	0.147	0.051
Llama3.1-8B (Qiu et al., 2025)	0.188	0.078

Table 2. Rendimiento de los *Baselines* en REDIAL. Los resultados de GPT-2 y Llama3.1-8B corresponden a los reportados por Qiu et al. (2025).

Propuesta

Una vez establecidos los *baselines* de comparación, se procede a describir la arquitectura del sistema propuesto, basado en Generación Aumentada por Recuperación (RAG) conversacional.

A diferencia de los *baselines* léxicos o estáticos, la propuesta representa el historial de diálogo mediante *embeddings* densos generados con un modelo Sentence-BERT

(all-MiniLM-L6-v2), lo que permite capturar la similitud semántica entre conversaciones más allá de la coincidencia exacta de palabras.

El proceso de recomendación se estructura en las siguientes etapas:

1. **Codificación del contexto conversacional:** para cada conversación del conjunto de *test*, se extrae el texto correspondiente a los últimos N turnos del diálogo (ventana de contexto), el cual es transformado en un vector denso mediante el modelo Sentence-BERT.
2. **Recuperación de conversaciones similares:** el *embedding* de la conversación de *test* se compara, mediante similitud del coseno, contra los *embeddings* de todas las conversaciones del conjunto de *entrenamiento*, previamente codificadas de la misma forma. Se seleccionan las K conversaciones de entrenamiento más similares.
3. **Agregación de candidatos:** las películas mencionadas dentro de esas K conversaciones similares se recopilan y ordenan según su frecuencia de aparición, conformando así el conjunto de ítems candidatos a recomendar.
4. **Generación conversacional (LLM):** sobre la base de los ítems recuperados y el contexto del diálogo, un Modelo de Lenguaje de Gran Escala (LLM) genera una sugerencia en lenguaje natural, integrando las películas recuperadas dentro de una respuesta conversacional coherente con el flujo del diálogo.

Con el objetivo de estudiar el efecto de los principales hiperparámetros del sistema, se evalúa el desempeño de la propuesta variando tanto el tamaño de la ventana de contexto (N turnos considerados del historial de diálogo) como el número de conversaciones similares recuperadas (K). Esto permite analizar cómo la cantidad de contexto conversacional disponible, así como la amplitud de la recuperación, inciden en la calidad final de las recomendaciones generadas.

Los resultados obtenidos bajo esta metodología, junto con el código y los datos utilizados para su reproducción, se encuentran disponibles públicamente en el siguiente enlace:

https://github.com/Maximilianoperry/IIC3633_Proyecto/tree/main/notebooks/H3.

Resultados

Previo a la evaluación final del sistema, se realizó un análisis de sensibilidad sobre los principales hiperparámetros de la

propuesta, con el fin de determinar la configuración óptima del modelo. Este análisis buscó responder dos preguntas: (i) si conviene incluir la totalidad del contexto conversacional disponible o restringirlo a una ventana de turnos más acotada, y (ii) cuál es el valor óptimo del parámetro K (número de conversaciones similares recuperadas) para la generación de recomendaciones.

Respecto al tamaño de contexto, se observó que, en general, mientras mayor es la cantidad de turnos considerados (N), mejor es el rendimiento del sistema. Esto se explica probablemente porque, al utilizar contextos cortos, los efectos negativos asociados a considerar un historial de diálogo más extenso simplemente no alcanzan a manifestarse, dado que hay menos información acumulada que pueda introducir ruido en la recuperación.

En cuanto al parámetro K , se observó que el valor óptimo se encuentra cercano a $K = 50$. Esto se explicaría por la dominancia que ejercen los ítems populares dentro del dataset: valores de K pequeños no logran capturar suficiente diversidad de conversaciones similares, mientras que, superado este punto, el rendimiento comienza a empeorar, ya que se empiezan a incorporar diálogos de entrenamiento cada vez menos relevantes para el contexto de la conversación evaluada.

Este comportamiento se aprecia claramente en las figuras 3 and 4, donde se observa que las curvas correspondientes a ventanas de contexto más amplias ($N = 16$ y $N = \text{full}$) se estabilizan en valores considerablemente más altos que las de contexto reducido, y que el rendimiento de todas las curvas tiende a estabilizarse o incluso decaer levemente a partir de $K \approx 50$.




Figure 3. HR@10 en función de K , para distintos tamaños de contexto (N turnos).




Figure 4. MRR@10 en función de K , para distintos tamaños de contexto (N turnos).

Considerando lo anterior, la configuración final del sistema propuesto corresponde a utilizar el contexto conversacional completo ($N = \text{Full}$) junto con $K = 50$ conversaciones similares recuperadas. Los resultados obtenidos bajo esta configuración, en comparación con los *baselines* definidos previamente, se resumen en la tabla 3.

Table 3. Comparación de rendimiento entre los *baselines* y el modelo propuesto (Ours) en el dataset ReDial.

MODELO	HR@10	MRR@10
RANDOM	0.00142	0.0036
MOST POPULAR	0.2399	0.1214
RETRIEVAL BM25	0.3271	0.1755
GPT-2	0.147	0.051
LLAMA3.1-8B	0.188	0.078
OURS [N=FULL, K=50]	0.6363	0.3599

Discusión

Los resultados obtenidos muestran que el modelo propuesto supera ampliamente a todos los métodos comparados en la métrica HR@10, incluyendo tanto los *baselines* clásicos como los modelos basados en LLM reportados por Qiu et al. (2025). Sin embargo, esta diferencia de rendimiento debe interpretarse con cautela, ya que puede explicarse por diversos factores más allá de la calidad intrínseca de la propuesta.

En primer lugar, es probable que el **sesgo de popularidad** presente en el dataset ReDial haya influido significativamente en los resultados. Como se evidenció en el análisis de la distribución *long-tail* (figura 1), un pequeño porcentaje de películas concentra la gran mayoría de las menciones, lo que favorece a cualquier método que tienda a recomendar ítems populares. Esto se refleja claramente en que, incluso frente a modelos basados en LLM de mayor complejidad como GPT-2 y Llama3.1-8B, el *baseline* **Most Popular**

logra un desempeño competitivo, superando a ambos en HR@10. Esto sugiere que gran parte de la dificultad de la tarea en este dataset puede resolverse simplemente explotando la popularidad de los ítems, más que mediante una comprensión semántica profunda del diálogo.

En segundo lugar, el rendimiento superior de la propuesta también puede atribuirse a que se utilizó una **configuración paramétrica optimizada** ($N = \text{Full}$, $K = 50$), obtenida mediante el análisis de sensibilidad presentado previamente. Esta calibración específica para el dataset y la tarea evaluada representa una ventaja frente a los modelos de comparación, los cuales no necesariamente fueron ajustados bajo las mismas condiciones experimentales.

Por su parte, el bajo desempeño del *baseline* **Random** era un resultado esperado, dado que corresponde a la estrategia más simple posible, sin ningún tipo de señal proveniente del contexto conversacional ni de la popularidad de los ítems, sirviendo únicamente como cota inferior de referencia.

Adicionalmente, otro aspecto relevante a considerar es el **tamaño de la muestra de evaluación** utilizada. Los resultados fueron obtenidos sobre un subconjunto del dataset completo, lo cual, si bien permite una evaluación computacionalmente eficiente, puede introducir variabilidad en las métricas reportadas y limitar la robustez estadística de las comparaciones, especialmente para métodos con desempeño similar entre sí.

Finalmente, respecto al bajo rendimiento observado en los modelos LLM reportados por Qiu et al. (2025) (GPT-2 y Llama3.1-8B), es posible atribuirlo a una limitación inherente al enfoque de dichos modelos: al depender de generación en lenguaje natural sin una restricción estricta al catálogo de ítems disponibles, estos modelos son propensos a producir **recomendaciones alucinadas**, es decir, películas que no existen en el catálogo o que no coinciden exactamente con los ítems de referencia (*ground truth*). Este fenómeno, mencionado por los propios autores como una limitación conocida de los CRS basados en LLM sin conocimiento de dominio específico, penaliza directamente las métricas de HR@10 y MRR@10, ya que una recomendación alucinada no puede coincidir con ningún ítem del conjunto de verdad, independientemente de la calidad semántica de la sugerencia generada.

Agradecimientos

Los autores agradecen a la Pontificia Universidad Católica de Chile por brindar las herramientas pedagógicas y los conocimientos necesarios para su formación académica. Asimismo, se agradece especialmente al profesor del curso, Denis Parra, por su guía y acompañamiento a lo largo del desarrollo de este trabajo, así como al equipo de profesores auxiliares, cuyo apoyo e impulso constante contribuyeron

a la mejora continua del proyecto. Finalmente, se extiende un agradecimiento al Departamento de Ciencias de la Computación de la misma universidad, por el respaldo institucional y académico brindado durante el desarrollo de esta investigación.

Referencias

- Li, R., Kahou, S. E., Adi, H., Bateni, C., Pascanu, R., and Courville, A. Towards deeply-conversational recommendations. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, 2018. URL <https://arxiv.org/abs/1812.07617>.
- Qiu, Z., Luo, L., Zhao, Z., Pan, S., and Liew, A. W.-C. Graph retrieval-augmented LLM for conversational recommendation systems. *arXiv preprint arXiv:2503.06430*, 2025. Accepted by PAKDD 2025.