

Agentic Context Engineering para Recomendación Conversacional de Películas: Un Enfoque en Tiempo de Inferencia

Tomás Ariztía Rodrigo Meza Vicente Muñoz

Resumen

El fine-tuning de modelos de lenguaje de gran escala (LLMs) para sistemas de recomendación conversacional (CRS) requiere datos etiquetados y recursos computacionales significativos, mientras que las estrategias de prompting estático no acumulan aprendizajes entre conversaciones. Este trabajo evalúa si la ingeniería de contexto adaptativa en tiempo de inferencia puede mejorar la recomendación conversacional de películas sin modificar los pesos del modelo. Se adaptan e implementan cinco métodos con niveles progresivos de sofisticación en la gestión de memoria: Zero-shot Chain-of-Thought, Reflexion, Dynamic Cheatsheet, ACE y ACE + Tools, evaluados sobre los datasets ReDial y PEARL con un modelo Qwen3-8B cuantizado a 4 bits. Se emplean métricas de ranking (Recall@1, Recall@5, MRR), calidad textual (BERTScore), novedad (Novelty), echo rate y LLM-as-a-Judge con Gemma-4-31B-IT. Los resultados muestran que ACE alcanza el mejor recall en ReDial (Recall@5 de 0,429), pero también el mayor echo rate (27,7%), evidenciando que sus ganancias provienen de repetir títulos del diálogo que coinciden con el ground truth por construcción. En PEARL, donde el eco no infla las métricas, los cinco métodos obtienen resultados prácticamente indistinguibles (Recall@5 entre 0,023 y 0,033), y el juez LLM confirma que ACE no aporta ventaja en relevancia ni coherencia. La contribución central es un protocolo de evaluación que, mediante el reporte del echo rate y la triangulación con un juez LLM independiente del ground truth, revela que el recall exacto en CRS puede estar inflado por parroting, y que reportar esta métrica debería ser práctica estándar en la evaluación de estos sistemas. https://github.com/tariztia/RecSys_G14_2026.git

1. Introducción

El crecimiento acelerado de las plataformas de streaming, sitios de compra y otros servicios ha generado un problema de sobrecarga informativa para los usuarios, quienes enfrentan catálogos con miles de ítems disponibles. En este contexto, los sistemas de recomendación conversacional (CRS) han emergido como una alternativa prometedora frente a los sistemas tradicionales, en especial mediante el uso de modelos de lenguaje de gran escala (LLMs), ya que permiten capturar preferencias de

forma dinámica a través del diálogo natural, refinando las sugerencias turno a turno según el feedback del usuario [4].

Sin embargo, el desarrollo de CRS basados en LLMs enfrenta dos desafíos fundamentales. Por un lado, el fine-tuning de estos modelos requiere datos etiquetados específicos del dominio y recursos computacionales significativos, lo que lo hace poco viable en entornos con presupuesto limitado [2]. Por otro lado, las estrategias de prompting estático, como zero-shot o few-shot, tratan cada conversación de forma independiente, sin capacidad de acumular aprendizajes sobre la calidad de las recomendaciones previas, lo que limita su efectividad en escenarios multi-turno donde las preferencias del usuario se revelan progresivamente.

Recientemente, la ingeniería de contexto agéntica ha surgido como un paradigma intermedio que permite a los LLMs mejorar su desempeño episodio a episodio sin modificar sus pesos. En particular, el framework ACE (*Agentic Context Engineering*) [8] propone un sistema de memoria estructurada denominado *Playbook*, que se actualiza de forma incremental mediante componentes especializados de generación, reflexión y curación. Este enfoque ha demostrado resultados competitivos en dominios como la ejecución de APIs y la generación de código, superando a estrategias previas como Reflexion [5] y Dynamic Cheatsheet [6]. No obstante, ACE no ha sido evaluado en tareas de recomendación conversacional, un dominio donde la señal de supervisión es inherentemente más débil y la evaluación presenta desafíos particulares.

El objetivo general de este trabajo es evaluar si las estrategias de ingeniería de contexto adaptativa, que actualizan la memoria del modelo episodio a episodio en tiempo de inferencia, permiten mejorar la calidad de la recomendación conversacional de películas basada en LLMs sin modificar los pesos del modelo. Para ello, se adaptan e implementan cinco métodos con niveles progresivos de sofisticación en la gestión de memoria: Zero-shot Chain-of-Thought como *baseline* sin memoria, Reflexion con memoria episódica verbal, Dynamic Cheatsheet con notas acumulativas, ACE con su *Playbook* estructurado, y una extensión denominada ACE + Tools que incorpora metadata externa de películas (género, director y reparto) mediante consultas a la API de TMDb. Los cinco métodos se evalúan sobre dos datasets de diálogos de recomendación, ReDial [4] y PEARL [3], con un modelo

base Qwen3-8B cuantizado a 4 bits, empleando métricas de ranking (Recall@1, Recall@5, MRR), calidad textual (BERTScore), novedad (Novelty) y echo rate.

Un aspecto central de este estudio es el diseño de un protocolo de evaluación que permite validar la autenticidad de las recomendaciones generadas. Durante la experimentación se identificó que el *echo rate*, definido como la proporción de recomendaciones que repiten títulos ya mencionados en el diálogo, correlaciona fuertemente con las métricas de ranking en ReDial, sugiriendo que parte del recall reportado podría estar inflado por *parroting* en lugar de reflejar una recomendación genuina [2]. Para controlar este fenómeno, se contrasta el desempeño en PEARL, un dataset con bajo riesgo de eco, y se incorpora LLM-as-a-Judge [9] como métrica complementaria que evalúa la calidad de las recomendaciones sin depender del *ground truth* estático original.

Las contribuciones principales de este trabajo son las siguientes:

1. Se adaptan e implementan el framework ACE y cuatro métodos adicionales de ingeniería de contexto al dominio de la recomendación conversacional de películas, constituyendo la primera evaluación de estas técnicas de memoria adaptativa en CRS.
2. Se propone una extensión ACE + Tools que enriquece el contexto del generador con metadata estructurada de películas obtenida de fuentes externas.
3. Se diseña un protocolo de evaluación que integra el reporte del *echo rate* y la evaluación mediante LLM-as-a-Judge, permitiendo una validación más robusta de la calidad de las recomendaciones.
4. Se presenta evidencia empírica de que, bajo control de eco, las estrategias de memoria adaptativa no superan al prompting sin memoria en este dominio, lo que sugiere que la señal de supervisión en CRS *offline* es insuficiente para que estos mecanismos acumulen aprendizajes efectivos.

2. Estado del arte y trabajos relacionados

2.1. Sistemas de recomendación conversacional (CRS)

Los sistemas de recomendación conversacional (CRS) se distinguen de los tradicionales en que incorporan el diálogo natural como mecanismo central para capturar y refinar las preferencias del usuario de forma interactiva. Mientras que enfoques como el filtrado colaborativo o basado en contenido operan sobre señales estáticas del historial de interacciones o de los atributos de los ítems, los CRS permiten expresar restricciones, aclarar preferencias y dar feedback en tiempo real a lo largo de múltiples turnos, lo que los hace adecuados para dominios

donde las preferencias son difíciles de articular en una sola consulta, como la recomendación de películas.

Entre los trabajos principales, ReDial [4] introdujo un dataset de diálogos humanos de recomendación de películas y un modelo que combina generación de lenguaje con un recomendador basado en autoencoders. Posteriormente, KBRD [1] y KGSF [11] incorporaron grafos de conocimiento externos, como DBpedia, para enriquecer la representación de los ítems, mostrando que la información estructurada sobre relaciones entre entidades aporta señales complementarias al diálogo.

Con la aparición de los LLMs, diversos trabajos exploraron su fine-tuning para CRS. Sin embargo, He et al. [2] demostraron que los LLMs en configuración zero-shot ya alcanzan un desempeño competitivo frente a modelos entrenados específicamente, lo que cuestiona la relación costo-beneficio del fine-tuning, que además exige datos etiquetados del dominio y recursos computacionales significativos. Estas restricciones motivan alternativas que mejoren el desempeño en CRS sin modificar los pesos del modelo, como las estrategias de ingeniería de contexto en tiempo de inferencia que se describen a continuación.

2.2. Estrategias de prompting y memoria en LLMs

El prompting ha evolucionado desde instrucciones estáticas hacia sistemas de memoria adaptativa que acumulan experiencia a lo largo de múltiples episodios, progresión que puede entenderse como un espectro dentro del In-Context Learning (ICL) según su mecanismo de actualización del contexto. Chain-of-Thought (CoT) [8] representa el caso de *contexto fijo*: incorpora pasos de razonamiento intermedio en el prompt, pero trata cada consulta de forma independiente, sin transferir aprendizajes entre episodios. Reflexion [6] introduce una *actualización reactiva* mediante reflexión verbal acumulada, aunque solo ante fallos y sin estructura formal. Dynamic Cheatsheet [7] añade una *actualización acumulativa* que opera tanto sobre aciertos como sobre fallos, pero reconstruye el contexto completo en cada paso (reescritura monolítica), con un costo creciente y riesgo de perder aprendizajes previos. Como se describe en la sección siguiente, ACE propone una cuarta alternativa mediante *actualizaciones incrementales estructuradas* que buscan combinar las ventajas de los enfoques anteriores.

2.3. Ingeniería de contexto agéntica

ACE (*Agentic Context Engineering*) [8] propone un sistema de memoria estructurada, denominado *Playbook*, que se actualiza de forma incremental y con deduplicación mediante tres agentes especializados (Generator, Reflector y Curator). A diferencia de la reescritura monolítica de Dynamic Cheatsheet o de la reflexión no estructurada de Reflexion, sus actualizaciones acotadas buscan

evitar el *sesgo de brevedad* y el *colapso de contexto*, preservando los aprendizajes acumulados a medida que crece el número de episodios. En su formulación original, ACE muestra resultados competitivos en dominios agénticos como el uso de herramientas y APIs y la generación de código, pero no ha sido evaluado en recomendación conversacional, un dominio donde la señal de supervisión es más débil y la evaluación presenta desafíos particulares, brecha que este trabajo aborda directamente.

2.4. LLM-as-a-Judge en sistemas de recomendación

El uso de LLMs como evaluadores fue popularizado por Zheng et al. [9], quienes mostraron con MT-Bench y Chatbot Arena que modelos suficientemente capaces se aproximan a las preferencias humanas al juzgar respuestas. En evaluación de recomendación, este enfoque puede reconocer recomendaciones buenas que no figuran en el *ground truth* estático, algo que es fundamental para la evaluación de recomendaciones en lenguaje natural, ayudando a mitigar los falsos negativos. Al ser basado en LLMs, presenta sesgos conocidos como *position bias*, *verbosity bias* y *self-enhancement bias*.

3. Datasets utilizados

3.1. ReDial

ReDial (Recommendation Dialogues) [4] es uno de los recursos más utilizados en la investigación de sistemas de recomendación conversacional. Fue construido mediante *crowdsourcing* en Amazon Mechanical Turk, con pares de trabajadores en los roles de *seeker* y *recommender*, generando cerca de 10,000 diálogos naturales sobre películas, los títulos mencionados están vinculados a identificadores de bases de datos externas que permiten asociar su metadata. El *ground truth* (**gt_accepted**) corresponde a las películas que el *seeker* aceptó como relevantes, con un promedio de 2,48 por diálogo.

Su rasgo clave para este estudio es el alto riesgo de eco, como los títulos del *ground truth* fueron mencionados explícitamente durante la conversación, un modelo que repita películas ya discutidas puede inflar artificialmente el *recall* sin recomendar de forma genuina. Este fenómeno, que denominamos *parroting*, constituye una amenaza a la validez que se analiza en las secciones de resultados y discusión.

3.2. PEARL

PEARL [3] es un dataset de recomendación conversacional construido a partir de reseñas reales de usuarios. A diferencia del *crowdsourcing* en tiempo real de ReDial, ancla los diálogos a las preferencias documentadas de los usuarios y a perfiles de persona, produciendo cerca

Cuadro 1: Estadísticas comparativas de los datasets utilizados. Las métricas por diálogo se calculan sobre el split de *test*.

Característica	ReDial [4]	PEARL [3]
Tipo	Orgánico	Sintético
Diálogos (train / test)	8004 / 1342	50000 / 2277
Catálogo	6083	9633
Turnos por diálogo	17.8	9.6
Palabras por mensaje	7.2	34.7
Palabras de contexto	136	259
Películas del <i>seeker</i>	1.9	3.0
GT aceptadas / diálogo	2.48	1.00
% diálogos con GT	91.0	100.0
Riesgo de eco	Alto	Bajo
Evaluación / warmup	300 / 100	300 / 100

de 50,000 diálogos. Su *ground truth* es más acotado, un único título aceptado por diálogo (**gt_accepted**), lo que impone una señal de evaluación más estricta y reduce los aciertos por azar.

Su rasgo clave es el bajo riesgo de eco, como el *ground truth* no forma parte de los títulos mencionados en el diálogo, no es posible acertar repitiendo lo ya discutido. Esto convierte a PEARL en un dataset de control natural que aísla la calidad genuina de la recomendación del efecto de *parroting*.

3.3. Preprocesamiento y muestreo

Ambos datasets siguieron un mismo *pipeline* para garantizar la comparabilidad. De cada diálogo se extrajeron los mensajes con sus roles (*seeker* y *recommender*), el mapa de títulos (**title_map**), las películas del *seeker* (**seeker_movies**) y el *ground truth* de recomendaciones aceptadas (**gt_accepted**), los títulos se normalizaron, sin caracteres especiales, en minúsculas y con el año estandarizado, para el *matching* posterior. El contexto inyectado en el *prompt* corresponde al diálogo completo truncado justo antes del último turno del *recommender*, de modo que el modelo predice la recomendación sin haber visto la respuesta humana.

De los diálogos con *ground truth* no vacío se muestrearon, con semilla fija, $n = 300$ para evaluación y $n = 100$ adicionales para el *warmup* de las memorias adaptativas (Reflexion, Dynamic Cheatsheet y ACE), evitando así la contaminación entre las fases de acumulación de memoria y de testeo.

El Cuadro 1 resume las estadísticas principales de ambos datasets en el contexto de este estudio.

4. Metodología

Todos los métodos comparten el modelo base y el protocolo de inferencia, de modo que las diferencias de de-

sempaño sean atribuibles a la gestión de memoria y no al montaje experimental. El modelo base es Qwen3-8B cuantizado a 4 bits (nf4) con `bitsandbytes`, ejecutable en una GPU T4. El contexto de cada diálogo se construye con `build_context` (Sección 3.3) y la evaluación es *offline*, tratando cada diálogo como un episodio independiente. El *Generator* devuelve siempre un único objeto JSON con `message`, la recomendación principal con una justificación breve y cuatro alternativas, y `structured_recommendations`, una lista ordenada de cinco títulos en formato "Título (Año)"; una instrucción explícita que prohíbe recomendar títulos ya mencionados controla el eco. Los métodos con memoria (Reflexion, Dynamic Cheatsheet y ACE) se construyen en una fase de *textitwarmup* sobre 100 diálogos de *train* y se congelan para evaluar sobre los 300 de *test*.

4.1. Zero-shot Chain-of-Thought (control)

Zero-shot Chain-of-Thought [7] es la condición de control sin memoria adaptativa, sin *warmup* y sin herramientas externas. En una única llamada el modelo razona de forma explícita antes de recomendar. Primero, en texto plano, enumera los títulos ya mencionados en la conversación, infiere las preferencias del usuario (géneros, tono, época y restricciones explícitas) y selecciona cinco películas nuevas, y solo entonces emite el objeto JSON final del que se extrae la recomendación. El razonamiento se elicitaba mediante el *prompt* y no mediante el bloque de razonamiento interno del modelo. Al no acumular memoria entre episodios, CoT aísla el aporte del razonamiento paso a paso y fija la línea de referencia frente a los métodos que acumulan aprendizaje (Anexo A).

4.2. Reflexion

Reflexion [5] introduce una memoria episódica verbal con tres componentes. Un *Actor* produce las recomendaciones condicionado por un *buffer* de reflexiones acumuladas que se antepone al *prompt* del recomendador. Un *Evaluator* entrega una señal binaria de éxito o fallo, definida en este dominio como *hit@1*, donde la primera recomendación se considera acierto si su similitud coseno (*soft-match*, umbral 0,90) con algún título del *ground truth* supera el umbral. Un módulo de *Self-Reflection* se activa solo ante un fallo y redacta una lección verbal breve y transferible que se agrega al *buffer*. Como adaptación al escenario de CRS *offline*, la memoria se acumula entre diálogos durante un *warmup* dirigido por error sobre 100 diálogos de *train* y luego se congela para la evaluación, por comparabilidad con ACE. Una limitación heredada del diseño original es que Reflexion solo aprende de los errores y deja sin reforzar los patrones que condujeron a aciertos.

4.3. Dynamic Cheatsheet

Dynamic Cheatsheet [6], en su variante *Cumulative*, mantiene una memoria de texto libre (*cheatsheet*) que sintetiza estrategias transferibles entre casos. Un *Generator* recomienda apoyándose en la *cheatsheet* vigente y, tras cada caso, un *Curator* la reescribe por completo para incorporar las nuevas observaciones. A diferencia de Reflexion, el *Curator* no observa el *ground truth*, por lo que la memoria es autosupervisada y opera tanto sobre aciertos como sobre fallos. La *cheatsheet* se construye durante un *warmup* de 100 diálogos y se congela para la evaluación. Su reescritura completa en cada paso permite consolidar y reorganizar el conocimiento, pero introduce un costo computacional creciente y puede provocar la pérdida de aprendizajes previos si el modelo de reescritura no los preserva, limitación que motiva las actualizaciones incrementales y estructuradas de ACE.

4.4. ACE (Agentic Context Engineering)

ACE [8] estructura la memoria como un *Playbook*, una lista de *bullets* tácticos, cada uno con un identificador y contadores de utilidad (*helpful* y *harmful*). Opera con tres componentes sobre el mismo LLM base. El *Generator* recomienda apoyándose en el *Playbook* vigente y cita los *bullets* que efectivamente utilizó, lo que habilita la asignación de crédito causal. El *Reflector* extrae del *feedback* del episodio lecciones tácticas generales y opera tanto sobre aciertos como sobre fallos, permitiendo distinguir qué patrones fueron útiles. El *Curator* las integra mediante actualizaciones incrementales (*delta*) deterministas, acredita como *helpful* o *harmful* los *bullets* citados según el resultado del episodio, deduplica por similitud de *embeddings* (umbral 0,80) y ajusta por presupuesto (*grow-and-refine*). La señal de supervisión durante el *warmup* es el *feedback* de ejecución (*hit@1* por *soft-match* contra el GT) sobre 100 diálogos de *train*, y el *Playbook* resultante se congela para la evaluación.

4.5. ACE + Tools

ACE + Tools extiende el *Generator* con metadata estructurada de las películas ya mencionadas en el diálogo, obtenida de la API de TMDb. Antes de recomendar, un paso de extracción con el mismo LLM identifica los títulos presentes en el contexto y para cada uno consulta TMDb, recuperando género, director y reparto principal, con caché en memoria para evitar consultas repetidas. Esta metadata se antepone al *prompt* del *Generator* junto al *Playbook*, marcada explícitamente como información para comprender el gusto del usuario y no como candidatos. La idea es enriquecer el contexto con conocimiento externo estructurado que el modelo base podría desconocer o recordar de forma imprecisa. El resto del método es idéntico a ACE.

4.6. Métricas de evaluación

4.6.1. Métricas de Ranking (Soft-matching)

El acierto se determina por similitud semántica y no por coincidencia exacta de *strings*, dado que los títulos generados rara vez coinciden carácter a carácter con el *ground truth* (variaciones de año, artículos o puntuación). Cada título se codifica con **all-MiniLM-L6-v2** y se compara por similitud coseno; se considera acierto si la similitud máxima $\geq 0,90$, umbral elegido por ser suficientemente estricto para descartar películas distintas y tolerante a variaciones menores del título. Este procedimiento se usa en todas las métricas de ranking siguientes.

Recall@K y **MRR** se calculan sobre las $K = 5$ recomendaciones de cada diálogo. Se reporta Recall@1 (equivalente a HR@1) y Recall@5, junto con MRR, que pondera la posición del primer acierto.

4.6.2. Calidad textual (BERTScore)

BERTScore mide la similitud semántica entre el *message* generado y una referencia humana, construida concatenando los turnos del *recommender* humano que mencionan alguna película. Se emplea **roberta-base** y se reporta F_1 ; evalúa estilo y calidad de la formulación, no el acierto respecto al GT.

4.6.3. Novedad

Novelty mide la auto-información de los títulos recomendados según su frecuencia en el conjunto de *train*: para un título con frecuencia documental df sobre N diálogos, $-\log_2(\frac{df+1}{N+1})$ (suavizado de Laplace), promediada sobre las 5 recomendaciones y los diálogos, y normalizada a $[0, 1]$. Un valor alto indica preferencia por películas menos populares. Se reporta además la *unseen rate*: proporción de títulos no vistos en *train* (posibles alucinaciones).

4.6.4. Echo rate

Mide la proporción de recomendaciones que repiten títulos ya mencionados en el diálogo. Un valor alto señala *parroting* (repetir en vez de recomendar), y permite distinguir el recall genuino del inflado por eco. Es relevante en ReDial, ya que el GT proviene de títulos mencionados durante la conversación, visibles para el LLM.

4.7. LLM-as-a-Judge score

Como métrica complementaria que no depende del *ground truth* estático, se emplea un juez LLM [9] distinto y de mayor tamaño que el modelo evaluado, **gemma-4-31b-it**, con **temperature**=0 por reproducibilidad, mediante la API de Google Gemini. El juez recibe el historial completo del diálogo y el *message* generado, pero no el GT, y puntúa tres dimensiones en escala Likert

entera de 1 a 5: *relevance*, la recomendación *top-1*, frente a las preferencias expresadas por el usuario, *coherence*, el mensaje completo en su contexto, y *explainability* solo la justificación del primer título. Una regla *anti-eco* explícita fija *relevance*=1 cuando el título *top-1* ya había sido mencionado en el diálogo, vinculando el juicio con el *echo rate*, de modo que el *parroting* no obtiene crédito en la dimensión de relevancia (Anexo B).

5. Resultados

5.1. Resultados en ReDial

El Cuadro 2 presenta el desempeño de los cinco métodos en ReDial. En las métricas de *ranking*, ACE obtiene los mejores resultados, con un HR@1 de 0,286, un Recall@5 de 0,429 y un MRR de 0,345, muy por encima del *baseline* sin memoria (CoT: 0,093, 0,143 y 0,114). ACE + Tools se ubica en segundo lugar (0,150, 0,234, 0,181), mientras que Reflexion y Dynamic Cheatsheet no superan de manera consistente al CoT. En el *echo rate*, sin embargo, se observa el mismo ordenamiento: ACE registra el valor más alto (27,7%) y ACE + Tools el segundo (21,3%), por encima de CoT (9,7%), Reflexion (9,0%) y Dynamic Cheatsheet (4,0%). Esta coincidencia entre el ordenamiento por *recall* y por *echo rate* se analiza en detalle en la Sección ??.

Respecto a las métricas complementarias, BERTScore se mantiene prácticamente constante entre métodos (0,855–0,866), mientras que la *novelty* varía en un rango más amplio, Dynamic Cheatsheet alcanza el valor más alto (0,763) y ACE el más bajo (0,686). La interpretación de ambas métricas se aborda en la Sección ??.

Cuadro 2: Resultados en ReDial

Método	HR@1	Recall@5	MRR	BERT	Novelty	Echo
CoT	0.093	0.143	0.114	0.859	0.733	9.7
Reflexion	0.073	0.150	0.104	0.858	0.708	9.0
Dyn. Cheat.	0.050	0.093	0.066	0.855	0.763	4.0
ACE	0.286	0.429	0.345	0.866	0.686	27.7
ACE+Tools	0.150	0.234	0.181	0.863	0.711	21.3

5.2. Resultados en PEARL

En PEARL, el echo rate cae drásticamente respecto a ReDial, lo que convierte a este dataset en una comparación más limpia entre métodos, libre del sesgo por parroting. Bajo esta condición controlada, los cinco métodos obtienen resultados bastante similares: R@5 varía apenas entre 0.023 y 0.033, y HR@1 entre 0.0067 y 0.013. Las diferencias son tan pequeñas que no permiten establecer un ranking significativo entre las estrategias. BERTScore se mantiene estable en torno a 0.87 para todos los métodos, y Novelty varía marginalmente (0.66–0.69). El hallazgo clave es que ACE y ACE + Tools, que en ReDial

parecían superiores en recall, aquí no superan al simple Zero-shot CoT. Esto refuerza el argumento de que la ventaja aparente de los métodos con memoria adaptativa en ReDial correlaciona con su mayor echo rate, no con una mejora genuina en la calidad de recomendación. Cuando el eco deja de inflar las métricas, la memoria estructurada (Playbook de ACE) no aporta una ventaja medible sobre un prompt sin memoria.

Cuadro 3: Resultados en PEARL

Método	HR@1	R@5	MRR	BERT	Novelty	Echo
CoT	0.013	0.030	0.021	0.8764	0.67	2.2
Reflexion	0.010	0.023	0.014	0.8588	0.69	2.7
Dyn. Cheat.	0.013	0.033	0.021	0.8754	0.68	1.8
ACE	0.010	0.033	0.019	0.8761	0.6659	0.4
ACE+Tools	0.0067	0.0233	0.0124	0.8761	0.6617	0.4

5.3. Resultados de LLM-as-a-Judge

Cabe destacar que por limitaciones de cómputo y acceso a APIs de LLMs con costo asociado, solo se implementó un análisis sobre 60 muestras de las 300 obtenidas, sumado a que algunas no se concretaron en su totalidad, debido a solicitudes con respuesta de error a la API pese a implementar un máximo de 5 reintentos sobre cada muestra.

Dicho eso, en PEARL, las cinco variantes obtienen puntajes similares y altos en las tres dimensiones (*relevance* 4.11–4.48; *coherence* 4.30–4.58; *explainability* 4.43–4.77; $N = 38$ –60 según el método), aunque ACE tienen resultados sutilmente más altos.

Cuadro 4: Resultados PEARL LLM-judge.

Método	N	Relevance	Coherence	Explain.
CoT	60	4.15	4.30	4.43
DC	58	4.28	4.41	4.60
Reflexion	38	4.11	4.42	4.76
ACE_base	60	4.48	4.58	4.73
ACE_tools	57	4.42	4.56	4.77

En ReDial, los puntajes se dispersan considerablemente (*relevance* 2.57–4.05; *coherence* 2.33–4.22), y ACE_base obtiene los promedios más bajos en *relevance* y *coherence* del conjunto, mientras Reflexion y CoT lideran esas mismas dimensiones respectivamente. Llama la atención que, pese a ello, ACE_base obtiene el *explainability* más alto de ReDial (4.02): el juez puntúa esta dimensión únicamente sobre la cláusula justificativa del primer título, no sobre el acierto de la recomendación, por lo que ambos puntajes son en principio independientes en su cálculo. Al notar la tabla de resultados, se puede notar que tiene alta relación con las métricas de echo reportadas.

Cuadro 5: Resultados ReDial LLM-judge.

Método	N	Relevance	Coherence	Explain.
CoT	60	3.52	4.22	3.92
DC	58	3.79	2.47	3.55
Reflexion	60	4.05	2.58	3.55
ACE_base	46	2.57	2.33	4.02
ACE_tools	49	3.37	2.53	3.71

5.4. Análisis comparativo entre datasets

En PEARL los tres coinciden, ningún método se distingue bajo ninguna de las miradas, lo que indica que, sin eco de por medio, la memoria adaptativa no aporta una ventaja medible sobre el *prompt* sin memoria. En ReDial, en cambio, los criterios divergen justamente donde el eco es alto, ACE lidera las métricas de *ranking* pero registra el mayor *echo rate* y, a la vez, los puntajes más bajos del juez en *relevance* (2,57) y *coherence* (2,33). Como el juez no premia repetir títulos ya mencionados, su veredicto contradice el *ranking* por *recall* y se alinea con el *echo rate*.

A partir de esto, se puede confirmar que la aparente superioridad de ACE en ReDial es un efecto del *parroting* y no de una recomendación de mayor calidad. El caso de ACE es ilustrativo, obtiene el *explainability* más alto de ReDial (4,02), lo que solo evalúa la justificación de la primera película, junto al peor *relevance*, de modo que redacta buenas justificaciones para recomendaciones que, descontado el eco, no son pertinentes. Así, la comparación entre datasets respalda la contribución central del trabajo, reportar el *echo rate* y comparar con un juez independiente del GT es esencial para no confundir repetición con calidad.

6. Discusión

Los resultados de este estudio revelan una conclusión central: las estrategias de memoria adaptativa en tiempo de inferencia no producen una mejora genuina en la calidad de la recomendación conversacional de películas bajo el protocolo evaluado. Si bien ACE alcanza las mejores métricas de ranking en ReDial, la triangulación entre datasets, echo rate y LLM-as-a-Judge demuestra que esta ventaja es un artefacto del parroting y no refleja una capacidad superior de recomendación.

La evidencia más contundente proviene de la comparación entre ReDial y PEARL. En ReDial, el ordenamiento de los métodos según recall reproduce casi exactamente su ordenamiento según echo rate, y ACE lidera ambos rankings. Al pasar a PEARL, donde el ground truth no es susceptible de eco, las diferencias entre métodos se vuelven casi indistinguibles, y ACE pierde toda ventaja sobre el baseline sin memoria. Este patrón es consistente con la hipótesis de que el Playbook de ACE aprende durante el

warmup a reforzar títulos del contexto como estrategia ganadora, un comportamiento que produce aciertos en ReDial por construcción de su GT pero que no transfiere a un dataset donde dicha coincidencia no existe.

Los resultados del juez LLM refuerzan esta interpretación. En ReDial, ACE obtiene los puntajes más bajos en relevance y coherence pese a liderar el recall, lo que indica que el juez penaliza las recomendaciones repetidas mediante la regla anti-eco incorporada en su evaluación. En PEARL, donde el eco es marginal, el juez no distingue claramente entre métodos, alineándose con la convergencia observada en las métricas de ranking. El único resultado discordante es el alto puntaje de explainability de ACE en ReDial, lo que sugiere que **el Playbook sí aporta valor en la calidad de las justificaciones textuales, aunque no en la selección de títulos relevantes**. Esta disociación entre la capacidad de explicar y la capacidad de recomendar constituye un hallazgo relevante para el ámbito evaluado.

La comparación con los resultados originales de ACE expuestos en su paper respectivo tiene sentido ya que se establece en otros dominios contra los cuales CRS representa un escenario más difícil para estas técnicas. En tareas como la ejecución de APIs o la generación de código, la señal de supervisión es fuerte y verificable: el código compila o no, la API retorna el resultado esperado o no. En CRS, en cambio, la señal se reduce a la coincidencia con un ground truth estático que puede no contener todas las respuestas válidas, generando falsos negativos que debilitan el feedback disponible para los componentes de reflexión y curación.

En esta línea, la naturaleza subjetiva de la recomendación de películas introduce una dificultad que los dominios originales de ACE no presentan. Mientras que en la generación de código existe una solución correcta verificable, en CRS múltiples recomendaciones pueden ser igualmente válidas para un mismo usuario, y el ground truth estático captura solo una fracción de ellas. Esta ambigüedad limita la capacidad del Reflector para extraer lecciones transferibles, ya que un “fallo” según el GT no necesariamente indica una mala recomendación.

Por otra parte, el presente trabajo presenta varias limitaciones que deben considerarse al interpretar los resultados. En primer lugar, todos los experimentos se realizaron con un único modelo base (Qwen3-8B cuantizado a 4 bits), por lo que no es posible generalizar las conclusiones a otros modelos o escalas. En segundo lugar, el tamaño muestral de 300 diálogos por dataset, si bien suficiente para identificar tendencias claras, limita la potencia estadística para detectar diferencias más sutiles entre métodos. En tercer lugar, la evaluación de LLM-as-a-Judge se realizó sobre un subconjunto reducido de 60 muestras debido a restricciones de cómputo y errores en las llamadas a la API, lo que introduce variabilidad adicional en los puntajes reportados. En cuarto lugar, el ground truth estático de ReDial data de 2018, lo que

implica que recomendaciones válidas de películas posteriores a esa fecha se contabilizan como falsos negativos. Finalmente, la evaluación offline no captura la dinámica interactiva de un CRS real, donde el usuario puede reformular sus preferencias en respuesta a las recomendaciones recibidas.

A pesar de estas limitaciones, la combinación de echo rate y LLM-as-a-Judge proporciona una imagen más completa que cualquiera de las dos métricas por separado. El echo rate identifica *cuánto* repite un método, pero no puede determinar si una recomendación no repetida es buena; el juez LLM evalúa la calidad percibida, pero es susceptible a sesgos propios y requiere validación externa. Juntas, permiten considerar varios aspectos de la evidencia: cuando ambas señales coinciden en que un método no aporta valor, como ocurre con ACE en este estudio, la conclusión es considerablemente más robusta que la que ofrecería cualquiera de ellas de forma aislada.

7. Conclusiones y trabajo futuro

7.1. Conclusiones

Este trabajo presentó una evaluación de estrategias de ingeniería de contexto adaptativa aplicadas a la recomendación conversacional de películas, comparando cinco métodos con niveles progresivos de sofisticación en la gestión de memoria: Zero-shot CoT, Reflexion, Dynamic Cheatsheet, ACE y ACE + Tools. Los experimentos se realizaron sobre dos datasets (ReDial y PEARL) con un modelo Qwen3-8B cuantizado a 4 bits, empleando métricas de ranking, calidad textual, novedad, echo rate y LLM-as-a-Judge.

La contribución central de este estudio es la demostración empírica de que las ganancias de recall observadas en ReDial están infladas por parroting. La correlación entre echo rate y recall, la convergencia de todos los métodos en PEARL bajo condiciones de eco controlado, y la penalización del juez LLM a las recomendaciones repetidas de ACE constituyen tres líneas de evidencia independientes que convergen en la misma conclusión: la memoria adaptativa de ACE no mejora la calidad genuina de la recomendación en CRS offline, sino que aprende a explotar una coincidencia estructural entre el contexto conversacional y el ground truth de ReDial.

De este hallazgo se derivan dos conclusiones metodológicas relevantes para el campo de CRS. Primero, reportar el echo rate debería ser una práctica estándar en la evaluación de sistemas de recomendación conversacional, especialmente cuando el ground truth proviene de títulos mencionados durante el diálogo, ya que su omisión puede conducir a interpretaciones erróneas del desempeño. Segundo, la evaluación cruzada entre datasets con distintos niveles de riesgo de eco, complementada con un juez LLM que no dependa del ground truth estático, proporciona un protocolo de validación más robusto que el uso

aislado de métricas de matching exacto.

7.2. Trabajo futuro

Los hallazgos de este trabajo abren varias líneas de investigación. Extender los experimentos a múltiples modelos base de distintos tamaños y familias permitiría determinar si las conclusiones dependen del modelo específico o reflejan una limitación general de la memoria adaptativa en CRS offline, y aumentar el tamaño muestral de evaluación y de warmup podría revelar diferencias más sutiles entre métodos que el protocolo actual no tiene potencia estadística para detectar. En cuanto a la evaluación, validar los puntajes del juez LLM mediante anotadores humanos calibraría su confiabilidad y cuantificaría sus sesgos, y probar con distintos modelos juez de diferentes familias y tamaños aportaría evidencia sobre la robustez de los resultados frente a la elección del evaluador.

En el plano de los datos y el protocolo, evaluar sobre el dataset INSPIRED, que contiene recomendaciones con justificaciones explícitas, reduciría los falsos negativos del ground truth estático y ofrecería una señal de supervisión más rica para los mecanismos de memoria. Explorar controles de eco alternativos, como filtros duros que eliminan los títulos del contexto del espacio de candidatos antes de la generación, aislaría con mayor precisión el efecto del parroting, y evaluar los baselines con acceso a herramientas (CoT + Tools, Reflexion + Tools) permitiría una comparación más justa con ACE + Tools y desagregar el aporte de la memoria del de la metadata externa. Finalmente, la evaluación en un escenario online e interactivo, donde el usuario responde en tiempo real a las recomendaciones, es el paso necesario para determinar si la memoria adaptativa aporta valor en condiciones de uso real que la evaluación offline no puede capturar.

Referencias

- [1] Chen, Q., Lin, J., Zhang, Y., Ding, M., Cen, Y., Yang, H., & Tang, J. (2019). Towards Knowledge-Based Recommender Dialog System. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1803–1813.
- [2] He, Z., Xie, Z., Jha, R., Steck, H., Liang, D., Feng, Y., Majumder, B. P., Kallus, N. & McAuley, J. (2023). Large Language Models as Zero-Shot Conversational Recommenders. *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management (CIKM '23)*, 720–730. DOI: 10.1145/3583780.3614949.
- [3] Kim, M., Kim, M., Kim, H., Kwak, B., Chun, S., Kim, H., Kang, S., Yu, Y., Yeo, J., & Lee, D. (2024). PEARL: A Review-driven Persona-Knowledge Grounded Conversational Recommendation Dataset. *arXiv preprint arXiv:2403.04460*.
- [4] Li, R., Kahou, S. E., Schulz, H., Michalski, V., Charlin, L., & Pal, C. (2018). Towards Deep Conversational Recommendations. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.
- [5] Manzoor, A. & Jannach, D. (2022). INSPIRED2: An Improved Dataset for Sociable Conversational Recommendation. *arXiv preprint arXiv:2208.04104*.
- [6] Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 36.
- [7] Suzgun, M. & Kalai, A. T. (2025). Dynamic Cheatsheet: Agentic In-Context Learning via Dynamically Generated Cheat Sheets. *arXiv preprint arXiv:2501.14249*.
- [8] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q. V., & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems (NeurIPS)*, 35.
- [9] Zhang, Q., Hu, C., Upasani, S., Ma, B., Hong, F., Kamanuru, V., Rainton, J., Wu, C., Ji, M., Li, H., Thakker, U., Zou, J., & Olukotun, K. (2026). Agentic Context Engineering: Evolving Contexts for Self-Improving Language Models. *Proceedings of the 13th International Conference on Learning Representations (ICLR)*.
- [10] Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems (NeurIPS)*, 36.
- [11] Zhou, K., Zhou, Y., Zhao, W. X., Wang, X., & Wen, J.-R. (2020). Improving Conversational Recommender Systems via Knowledge Graph based Semantic Fusion. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 1006–1014.

A. Anexo A: Prompt del sistema Zero-shot CoT

You are a conversational movie recommender that reasons step by step.

CRITICAL RULE: Under NO circumstances may you recommend a movie that has already been mentioned by ANYONE (User or Assistant) anywhere in the conversation history. Every one of your 5 recommendations must be a movie NOT YET discussed in this conversation - genuinely new suggestions the user hasn't heard yet.

Follow exactly these steps in PLAIN TEXT (no JSON yet):

1. List the movie titles already mentioned by anyone (these are FORBIDDEN as outputs).
2. Infer the user's tastes: preferred genres, tone/mood, era, and any explicit constraints.
3. Pick 5 NEW movies that best match, none of them in the forbidden list, best match first.

After the reasoning, output EXACTLY ONE JSON object on its own line and nothing after it:

```
{"message": "I recommend [Title (Year)] because [brief reason]. You might also enjoy [T2], [T3], [T4], and [T5].", "structured_recommendations": ["Title (Year)", "T2", "T3", "T4", "T5"]}
```

Each recommendation must be formatted as 'Title (Year)'. Exactly 5, best match first.

B. Anexo B: Prompt del juez LLM-as-a-Judge

A continuación se presentan el prompt del sistema y el template de usuario empleados para la evaluación mediante LLM-as-a-Judge con el modelo Gemma-4-31B-IT.

Prompt del sistema

You are an expert evaluator of conversational movie recommender systems. You will be shown a conversation history between a user (seeker) and a recommendation assistant, followed by the assistant's final response: a natural-language message recommending a ranked list of titles.

Score the response on three dimensions, each a 1-5 integer. Use these anchors exactly.

Relevance (score ONLY the first recommended title, against preferences the user expressed in the conversation)

- 1 - Contradicts or ignores the user's stated preferences.
- 2 - Tangentially related; shares at most a superficial attribute, no real connection to what the user asked.
- 3 - Partially aligned; matches one explicit preference but ignores others mentioned.
- 4 - Aligned with the user's explicit stated preferences

(genre, actor, mood, etc.).

- 5 - Aligned with explicit preferences AND implicit signals in the conversation (tone, taste pattern, rejected alternatives).

ANTI-ECHO RULE: if the first recommended title was already mentioned earlier in the conversation (by either speaker), this is not a valid new recommendation. Score relevance = 1 regardless of topical fit.

Coherence (score the assistant's message as a whole, in context)

- 1 - Irrelevant to the last turn; ignores the conversation.
- 2 - Responds but breaks the flow.
- 3 - Coherent but generic; could fit almost any similar conversation.
- 4 - Clearly contextualized to the user's last turn.
- 5 - Natural continuation that also picks up on earlier signals, not just the last turn.

Explainability (score ONLY the justification clause for the first title -- the "because ..." part. Ignore the rest of the message.)

- 1 - No justification given.
- 2 - Generic justification, not tied to this user ("it's a great movie", "it's popular").
- 3 - Plausible reason, not explicitly linked to anything the user said.
- 4 - Reason explicitly linked to one concrete stated preference.
- 5 - Reason connects specific movie attributes to explicit preferences the user stated.

Ground truth is never provided and must not be assumed. Judge only from the conversation and response shown below. Provide a one-sentence reasoning per dimension before its score.

Template de usuario

Conversation history
{context}

Assistant's message
{message}

C. Anexo C: Prompts del método Reflexion

A continuación se presentan los prompts utilizados por los dos componentes del método Reflexion: el Actor (generador de recomendaciones) y el módulo de Self-Reflection (generación de lecciones verbales ante fallo).

Actor (generador)

El prompt del Actor se compone de dos partes: un prefijo opcional con las lecciones acumuladas en el buffer de reflexión, seguido de las instrucciones de recomendación. El buffer tiene un tamaño máximo de 15 reflexiones

(ventana deslizante).

Lessons you learned from previous recommendation attempts (apply them):

- {reflexión 1}
- {reflexión 2}
- ...

You are a conversational movie recommender.

CRITICAL RULE: Under NO circumstances may you recommend a movie that has already been mentioned by ANYONE (User or Assistant) anywhere in the conversation history. Every one of your 5 recommendations must be a movie NOT YET discussed in this conversation - genuinely new suggestions the user hasn't heard yet.

Recommend exactly 5 movies, best match first. Include the release year formatted exactly as 'Title (Year)'. Respond ONLY with valid JSON:

```
{"message": "I recommend [Title (Year)] because [brief reason]. You might also enjoy [T2], [T3], [T4], and [T5].", "structured_recommendations": ["Title (Year)", "T2", "T3", "T4", "T5"]}
```

No text outside the JSON.

Self-Reflection (solo ante fallo)

[System]
You are the SELF-REFLECTION module of a movie recommender that just FAILED.
Write a concise verbal lesson (2-3 sentences) diagnosing WHY the recommendation missed and a GENERAL strategy to do better next time.
Do NOT name the human target titles; keep the lesson transferable to other users.

[User]
User request:
{context}

You recommended: {movies}
The human target was: {gt_titles}

Write the reflection:

D. Anexo D: Prompts del método Dynamic Cheatsheet

A continuación se presentan los prompts utilizados por los dos componentes del método Dynamic Cheatsheet: el Generator (generador de recomendaciones condicionado por la cheatsheet) y el Curator (actualizador de la cheatsheet, label-free).

Generator

You are a conversational movie recommender. You may use the CHEATSHEET of strategies learned from previous cases.

CHEATSHEET:
{cheatsheet}

CRITICAL RULE: Under NO circumstances may you recommend a movie that has already been mentioned by ANYONE (User or Assistant) anywhere in the conversation history. Every one of your 5 recommendations must be a movie NOT YET discussed in this conversation - genuinely new suggestions the user hasn't heard yet.

Recommend exactly 5 movies, best match first. Include the release year formatted exactly as 'Title (Year)'. Respond ONLY with valid JSON:
{"message": "I recommend [Title (Year)] because [brief reason]. You might also enjoy [T2], [T3], [T4], and [T5].", "structured_recommendations": ["Title (Year)", "T2", "T3", "T4", "T5"]}
No text outside the JSON.

Curator (label-free)

El Curator no recibe el ground truth. Reescribe completamente la cheatsheet tras cada episodio, integrando las observaciones del caso nuevo. La cheatsheet se limita a un máximo de 20 bullets y se actualiza cada episodio.

[System]
You are the CURATOR of an evolving CHEATSHEET for a conversational movie recommender. Given a NEW case and the recommender's own answer, output an UPDATED cheatsheet of concise, transferable strategies: genre/tone mappings, how to read user cues, and common pitfalls.
Guidelines:
- Keep it compact: at most ~20 short bullet lines.
- Merge duplicates and drop low-value notes.
- Do NOT store one-off answers or specific titles as facts; store reusable tactics.
- Output ONLY the full updated cheatsheet text (no preamble).

[User]
CURRENT CHEATSHEET:
{cheatsheet}

NEW CASE - user request:
{context}

Recommender's answer:
{answer}

UPDATED CHEATSHEET: