



Recomendación Multimodal de Videojuegos en Steam: el Protocolo de Evaluación Decide Quién Gana

Benjamín Suazo¹ Pablo Lagos¹

Repositorio: <https://github.com/Benjaa7/Proyecto-RecSys>

Abstract

Comparamos recomendadores multimodales de videojuegos de distinto tipo (colaborativos como Most Popular, ALS y BPR; de contenido como CB-SBERT; de grafos de categorías como CP-GRec y su extensión CPGRec+; y *feature-based* como FM, DeepFM y DeepNN) sobre **tres datasets de Steam** de densidad contrastante (UCSD, Kozyriev y SCGRec), bajo **dos protocolos de evaluación** construidos sobre los mismos datos y modelos: un *protocolo común* honesto (*full-ranking* sobre todo el catálogo, split 80/10/10, sin *playtime* como *feature*) y la *reproducción del protocolo per-user* de Cheuque et al. (2019). Tres hallazgos: (i) el $NDCG@10 \approx 0,99$ que el protocolo per-user asigna a los modelos profundos se desploma a 0,01–0,14 bajo *full-ranking*; la descomposición en dos capas muestra que el **protocolo de evaluación explica el 67–91 % del efecto** y la fuga de *playtime* el resto, patrón que se repite en 6/6 combinaciones $\text{modelo} \times \text{dataset}$; (ii) bajo el protocolo común **ningún modelo gana en los tres datasets**: BPR y el GNN destacan en catálogos densos, mientras que **ALS (2008) es el techo en el catálogo grande y disperso**; (iii) la multimodalidad **no supera a la señal colaborativa en accuracy** y su aporte se concentra en diversidad. Concluimos que el diseño del protocolo de evaluación es una decisión de primera clase: *cómo se evalúa decide quién gana*.

¹Facultad de Ingeniería, Pontificia Universidad Católica de Chile, Santiago, Chile. IIC3633 – Sistemas Recomendadores, 2026-1.. Correspondence to: Benjamín Suazo <benjamin@trybulk.cl>.

1. Introducción

Steam tiene decenas de miles de juegos y cientos de millones de usuarios: descubrir el próximo juego es un problema de recomendación a gran escala con señales ricas pero ruidosas (qué se compra, cuánto se juega, qué se reseña) y un catálogo dominado por unos pocos *blockbusters*. La metadata disponible invita a la **multimodalidad**: hay señal *colaborativa* (interacciones y horas jugadas), de *contenido* (títulos, descripciones, *tags*) y de *estructura* (géneros, desarrolladores, editores).

Al comparar recomendadores multimodales en este dominio nos topamos con una anomalía: los números de la literatura de referencia no cuadran con los nuestros. Cheuque et al. (2019) reportan $NDCG@10 \approx 0,94\text{--}0,99$ para modelos profundos sobre Steam, mientras que en el mismo dataset base ninguno de nuestros modelos supera 0,06. La diferencia no está en los modelos sino en **cómo se evalúa**. Un $NDCG \approx 0,99$ en *full-ranking* sobre miles de ítems es implausible; dos decisiones de protocolo lo explican: (i) usar *playtime* como *feature* cuando el *label* se define con *playtime* (fuga de información), y (ii) evaluar por *re-ranking per-user* (ordenar solo los pocos ítems de test del propio usuario) en lugar del *full-ranking* sobre el catálogo.

El proyecto se reformula entonces en torno a cuatro preguntas: **RQ1** ¿el desempeño estelar de los modelos profundos es calidad del modelo o artefacto del protocolo?; **RQ2** bajo una evaluación honesta, ¿cómo se ordena el conjunto de modelos multimodales?; **RQ3** ¿el ganador depende del dataset (densidad del catálogo)?; **RQ4** ¿qué aporta cada modalidad (contenido, grafos) sobre la señal colaborativa pura?

Contribuciones. (1) Un *benchmark bajo protocolo común* (*full-ranking*, sin fuga, split 80/10/10) de diez modelos sobre tres datasets de Steam de densidad contrastante. (2) La *reproducción y disección* del protocolo de Cheuque et al.

(2019): recuperamos su $\approx 0,99$ y lo descomponemos cuantitativamente en dos capas (fuga de *playtime* y evaluación per-user), mostrando que la capa de protocolo domina (67–91 %). (3) La *reconstrucción de CPGRec* (Li et al., 2024) idéntica al repositorio oficial, validada sobre su dataset original, más una variante propia liviana de su rama de contenido (+PRG-SBERT) y un análisis de por qué la extensión PER no aporta con *ratings* proxy. (4) El *hallazgo del catálogo*: la ventaja del GNN sobre ALS depende de la densidad, con evidencia de mecanismo vía *long-tail*. (5) Reproducibilidad: notebooks, protocolo centralizado y semillas en el repositorio público¹.

De H2 a H3. En el informe intermedio evaluamos sobre un único dataset (Kozyriev) con *leave-one-out* temporal, submuestra del 10 % y evaluación acotada a 2.000 usuarios; el resultado central fue “ALS es el techo” más el colapso de la fusión temprana BPR+SBERT (resultado negativo que descartó esa vía de multimodalidad). Para esta entrega final: (i) centralizamos el rigor experimental en un módulo común (`recsys_protocol.py`: semillas, muestreo orden-independiente, *k*-core, splits y métricas idénticas entre notebooks); (ii) agregamos **dos datasets** (UCSD y SCGRec) y adoptamos el split aleatorio 80/10/10 de los papers que reproducimos, con evaluación hasta 200.000 usuarios; (iii) **reproducimos** Cheuque et al. (2019) bajo su propio protocolo y CPGRec sobre su dataset original; (iv) re-evaluamos BPR, CB-SBERT y los modelos profundos bajo el protocolo común (los números de H2 no son comparables con los de H3 por el cambio de split y evaluación); (v) incorporamos multi-seed donde los deltas son pequeños, métricas de diversidad por categoría, desagregación por actividad y ejemplos cualitativos.

2. Trabajo relacionado

Recomendación de videojuegos en Steam. Cheuque et al. (2019) comparan ALS contra modelos *feature-based* profundos (FM, DeepFM, DeepNN) sobre el dataset UCSD de Steam y reportan que los profundos dominan ampliamente ($\text{NDCG@10} \approx 0,94\text{--}0,99$ vs. $\approx 0,33$ de ALS). Su protocolo (filtro denso, *label* binario *playtime* ≥ 5 h, *playtime* entre las *features* y evaluación por re-ranking per-user con validación cruzada) es exactamente el que reproducimos y diseccionamos (Sec. 4). Yang et al. (2022) proponen SCGRec, un GNN social-contextual a gran escala cuyo dataset público usamos para la reproducción de CPGRec. Li et al. (2024) proponen CPGRec, un GNN orientado a balancear precisión y diversidad que construye grafos juego–juego desde categorías (género, desarrollador, editor) mediante cuatro módulos: SGC (grafos estrictos, precisión), CNA

(grafo laxo, diversidad), PENR (reponderación por popularidad) y NSR (fusión y pérdida BPR). CPGRec+ (Li et al., 2026) añade PER (*Preference-informed Edge Reweighting*: pesos de arista con signo desde *playtime* y *rating* vía test de Fisher) y PRG (representaciones de contenido generadas con un LLM y embebidas con *bge-m3*).

Baselines clásicos. ALS de *feedback* implícito con confianza $c_{ui} = 1 + \alpha \log(1 + \text{playtime})$ (Hu et al., 2008), BPR con pérdida *pairwise* de ranking (Rendle et al., 2009), y recomendación por contenido con embeddings de oraciones (Reimers & Gurevych, 2019). FM/DeepFM siguen a Guo et al. (2017).

Rigor en la evaluación. Ferrari Dacrema et al. (2019) muestran que buena parte de los métodos neuronales de recomendación no superan a baselines bien ajustados bajo evaluación justa; en la misma línea, Rendle et al. (2020) muestran que una factorización matricial bien ajustada iguala o supera al filtrado colaborativo neuronal. Nuestro trabajo aporta un caso de estudio en videojuegos donde, además, *cuantificamos por separado* las dos fuentes del optimismo (fuga de *feature* y protocolo permisivo). Dos proyectos previos del curso compararon modelos multimodales de videojuegos dentro de un único protocolo (Bueno et al., 2025; Saavedra et al., 2025); nuestro aporte distintivo es convertir el *protocolo mismo* en objeto de estudio.

3. Datasets

Elegimos tres datasets públicos de Steam por su **densidad contrastante** (Tabla 1), lo que habilita la pregunta RQ3.

Table 1. Los tres datasets bajo el protocolo común (F2). Los absolutos *no* son comparables entre datasets (distinto catálogo y positivos/usuario); se compara el orden relativo de los modelos dentro de cada uno.

	UCSD	Kozyriev	SCGRec
Señal (positivo)	<i>ownership</i>	review positiva	interacción
Crudo (usuarios)	70.912	13,78M	3,9M
Crudo (interac.)	5,15M	41,15M	95,2M
Filtro	5-core (5,5)	<i>k</i> -core (5,20)	oficial
Submuestra	—	500K usr	2M usr
Catálogo	9.198	22.590	2.675
Positivos/usuario	8,93	1,82	$\sim 2,3$
<i>Playtime</i>	minutos	horas	no trae
Rol	repr. Cheuque	ppal. (nuestro)	repr. CPGRec

UCSD/McAuley (*Australian Steam*) (Pathak et al., 2017; Wan & McAuley, 2018): bibliotecas de juegos (*ownership*) con *playtime_forever*, más catálogo con géneros, desarrollador, editor y *tags*. Es el dataset de Cheuque et al. (2019). **Kozyriev** (Kozyriev, 2023): 41M de reseñas con *is_recommended*, *hours* y fecha; no trae categorías,

¹<https://github.com/Benjaa7/Proyecto-RecSys> (incluye README.md con la estructura de archivos y cómo replicar cada experimento).

que completamos con un *join* por *app_id* al Steam Games Dataset de FronkonGames (Fronkon Games, 2023). Es nuestro dataset principal desde H1: catálogo grande y disperso. SCGRec (Yang et al., 2022): el dataset “Steam I” sobre el que CPGRRec reporta, con categorías idénticas a las del paper y split oficial 80/10/10; validamos la carga contra los conteos publicados (3.908.744 usuarios, 2.675 juegos, 95.441.434 interacciones).

3.1. Qué señal usa cada modelo.

La interacción usuario–juego alimenta a todos los modelos. El *playtime* entra de tres formas distintas, y esa distinción es el corazón del paper: como *peso de confianza* en ALS ($c_{ui} = 1 + \alpha \log(1 + h)$), como *peso del perfil* en CB-SBERT (media de embeddings ponderada por $\log(1 + h)$) o como *feature de entrada* de los modelos profundos en el protocolo per-user, donde el *label* es *playtime* ≥ 5 h. Las dos primeras formas son legítimas (el *label* es la interacción); la tercera constituye fuga de información. Las categorías (género/desarrollador/editor) definen los grafos SGC/CNA de CPGRRec y entran como *features varlen* en FM/DeepFM/DeepNN; el texto (título+descripción+tags) alimenta a CB-SBERT y a la rama PRG; y el *rating* global por juego (*positive_ratio* en Kozyriev y UCSD, *metascore* en SCGRec) alimenta al módulo PER. La matriz completa señal×modelo está en el Anexo F.

4. Metodología: dos protocolos sobre los mismos datos

Table 2. Contraste entre los dos protocolos de evaluación.

	Común (F2)	Per-user (F3)
Filtro	<i>k</i> -core (5/20; UCSD 5/5)	denso (≥ 100 ítems/usr, ≥ 200 usr/ítem)
Positivo / <i>label</i>	interacción	<i>playtime</i> ≥ 5 h (binario)
<i>Playtime</i>	solo peso (confianza / perfil)	<i>feature</i> de entrada
Candidatos	todo el catálogo (2,6K–22,6K)	solo ítems de test del usuario
Evaluación	<i>full-ranking</i>	re-ranking per-user (CV <i>k</i> -fold)
Métricas	R/NDCG/Hit/Prec @5,10 + diversidad	NDCG@10, MAP@10
Rango típico	0,01–0,4	0,7–0,99

Construimos **dos arneses de evaluación** sobre los mismos datasets y modelos (Tabla 2). El *protocolo común* (F2) responde “¿qué tan bueno es el modelo?”; el *protocolo per-user* (F3) reproduce fielmente a Cheuque et al. (2019) y responde “¿cuánto mueve la métrica el diseño de la evaluación?”. La distancia entre ambos es el resultado central. Cada número

es válido *dentro de su protocolo*; el punto es que no son comparables entre sí.

4.1. Protocolo común (F2)

(1) Filtro *k*-core iterativo (He & McAuley, 2016) (Tabla 1); SCGRec usa su filtro/split oficial. (2) Positivos: *ownership* (UCSD), *is_recommended* (Kozyriev), interacción (SCGRec); el *playtime* entra *solo* como peso, nunca como *feature*. (3) Split aleatorio 80/10/10 por interacción, elegido por comparabilidad con los protocolos de CPGRRec y Cheuque (la estrategia de partición condiciona el ranking de modelos (Meng et al., 2020); en H2 usamos *leave-one-out* temporal y lo abandonamos por esa razón). (4) Evaluación por **full-ranking**: para cada usuario se rankean *todos* los ítems del catálogo no vistos en train y el top-*k* se compara contra el *conjunto* de ítems de test (multi-relevante). (5) *eval_set* fijo de hasta 200.000 usuarios con semilla común entre modelos (UCSD: 57,4K, completo). (6) Métricas: Recall/NDCG/Hit/Precision @ {5,10}, diversidad por categoría (*Coverage* = n.º de categorías distintas en el top-10, *Entropy* de su distribución, comparables con las del paper de CPGRRec) y NDCG@10 desagregado por actividad del usuario (2–5 / 6–20 / 21–50 / 51+ interacciones).

4.2. Protocolo per-user (F3): reproducción de Cheuque

(1) Filtro denso de Cheuque et al. (2019): ≥ 100 ítems/usuario y ≥ 200 usuarios/ítem. En UCSD produce 14.405 usuarios, 2.584 juegos y densidad 7,66 % (24,7 % de positivos). En Kozyriev ese umbral colapsa a 0 usuarios (con señal de reseñas es *estructuralmente imposible* alcanzar esa densidad), por lo que usamos el subconjunto más denso viable (50,100): 28.311 usuarios, 4.865 juegos, 1,74 % (68,5 % de positivos; el barrido completo de umbrales está en el Anexo G). (2) *Label* binario *playtime* ≥ 5 h. (3) Dos variantes de *features*: *con playtime* (la configuración original, que constituye fuga porque la *feature* define el *label*) y *sin playtime*. (4) Split aleatorio estratificado 80/20 y evaluación por **re-ranking per-user**: se ordenan solo los ítems de test del usuario, un esquema de conjunto reducido de candidatos que distorsiona las métricas frente al ranking del catálogo completo (Krichene & Rendle, 2020). (5) ALS corre además como *contraste en full-ranking* dentro del mismo subconjunto denso, con la configuración exacta del paper. (6) Una corrida con CV *k*-fold (5 ALS, 3 profundos): el efecto es de orden de magnitud y robusto.

4.3. Modelos evaluados

Most Popular (piso por popularidad); **ALS** (Hu et al., 2008); **BPR** (Rendle et al., 2009) con matriz binaria (sin confianza por *playtime*, a propósito: mide ranking *pairwise* puro); **CB-SBERT**: embeddings all-MiniLM-L6-v2 (384 d) de título+descripción+tags, perfil de usuario = me-

dia ponderada por $\log(1+h)$, ranking por coseno; **CPGRec base** (Li et al., 2024) reconstruido de forma idéntica al repositorio oficial; **CPGRec +PER** y **+PER+PRG** (= CPGRec+ (Li et al., 2026)), donde PRG se aproxima con SBERT liviano (+PRG-SBERT: 384 d $\rightarrow$ PCA 64) en lugar del LLM del paper, decisión declarada de reproducibilidad; **FM / DeepFM / DeepNN** (Cheuque et al., 2019; Guo et al., 2017) vía `deeptctr-torch`, evaluados en F2 *sin playtime* como *feature* (honestos) y en F3 con/sin *playtime*. CB-SBERT no corre en SCGRec (el dataset no trae descripciones) ni BPR/CB-SBERT en F3 (no aportan a la disección de la fuga).

5. Análisis de parámetros y decisiones de configuración

Table 3. Configuraciones finales. En F3, ALS usa la configuración exacta de Cheuque et al. (2019); en F2, una configuración liviana idéntica entre los tres datasets.

Modelo	Configuración	Semillas
ALS (F2)	64 factores, 15 iter., reg. 0,1, $\alpha=40$	determinista
ALS (F3)	500 factores, 300 iter., $\alpha=40$, 5-fold CV	
BPR	64 factores, lr 0,01, reg. 0,01, 100 iter.	1
CB-SBERT	MiniLM-L6-v2 (384 d), $\log(1+h)$	perfil 1
CPGRec (3 var.)	emb. 32, lr 0,03, 1000 ép., $m=6,5$, $\gamma=80$, $\beta=0,1$	3 {42,1,2}
FM/DeepFM/DeepNN	emb. 32, BCE, neg. 4:1, 10–15 ép.	3 (UCSD) / 1

Semillas: multi-seed selectivo. Corremos 3 semillas pareadas (mismo split y `eval_set`) para las tres variantes de CPGRec, porque los deltas de sus extensiones caen dentro del ruido y la desviación estándar es el resultado (Tabla 5). Para BPR, CB-SBERT y los profundos de Kozyriev usamos 1 semilla: sus brechas son de orden de magnitud y las desviaciones observadas donde sí hubo multi-seed son diminutas (R@5 de CPGRec base: $\pm 0,0007$ a $\pm 0,0026$). Cada corrida incluye un *self-check* (MostPop/ALS idénticos al comparativo de referencia) que valida que el arnés es el mismo.

Convención de *playtime* (minutos vs. horas). UCSD trae *playtime* en minutos y Kozyriev en horas. Como la confianza de ALS es logarítmica, $\log(1 + \text{min}) \gg \log(1 + \text{h})$ sobre-pondera a los *heavy players*. Adoptamos **horas** como convención canónica: en UCSD mueve solo a ALS (R@5 0,087 $\rightarrow$ 0,105, +21 %) y no toca a los modelos que no usan *playtime*; los resultados principales sobreviven (ALS sigue bajo MostPop en UCSD, con brecha menor).

Hiperparámetros de CPGRec. Mantenemos los del repositorio oficial ($\gamma=80$, sin ajuste fino) para que la reproducción sea auditable; el residual frente al paper (Sec. 6.1) se debe en parte a ese punto de operación, al submuestreo (2M

de 3,9M usuarios) y a la convergencia (la pérdida aún caía $\sim 3\text{--}5\%$ en las últimas 100 épocas). En UCSD y Kozyriev el grafo laxo CNA sin tope de aristas agota la memoria; se acota con `OR_CAP=50`, igual en ambos.

Submuestreo. Kozyriev 500K usuarios (de 1,9M tras *k-core*) y SCGRec 2M (de 3,9M). Los diagnósticos con y sin submuestra mostraron variaciones dentro del ruido, y el muestreo (orden-independiente, semilla fija) preserva el espectro de actividad para el análisis *long-tail*.

6. Resultados

6.1. Protocolo común (F2): el ganador depende del catálogo

La Tabla 4 y la Figura 1 muestran el resultado agregado (tablas completas en el Anexo A; el reordenamiento del ranking, en la Figura 6). **Ningún modelo gana en los tres datasets** (RQ2, RQ3):

SCGRec (denso, catálogo chico): BPR $\approx$ CPGRec base $>$ ALS $>$ MostPop. BPR gana R@5 (0,4145 vs. 0,4080) y CPGRec NDCG@10 (0,3994 vs. 0,3968): en el dataset nativo del GNN, *un baseline de 2009 lo iguala*. La reproducción de CPGRec alcanza el 79–88 % de las métricas del paper y lo supera en Precision@5/10, lo que valida el arnés (el residual se discute en Sec. 5 y 8).

UCSD (medio): CPGRec base $\approx$ BPR (0,144 vs. 0,141) $>$ MostPop $>$ ALS $>$ FM $\approx$ DeepFM $>$ DeepNN $>$ CB-SBERT. Hallazgo propio: **ALS cae por debajo de Most Popular**, único caso en los tres datasets; la popularidad es un baseline difícil de batir en catálogos concentrados (Cañamares & Castells, 2018) y el mecanismo se ve en el *long-tail* (Sec. 6.3).

Kozyriev (disperso, catálogo grande): **ALS gana** (0,059) $>$ CPGRec (0,044) $>$ BPR (0,039) $>$ MostPop (0,029) $>$ DeepFM $>$ FM $>$ CB-SBERT $>$ DeepNN. Es el *hallazgo del catálogo*: en el catálogo abierto y disperso (nuestro régimen desde H1) un baseline de 2008 es el techo, y los profundos honestos caen *por debajo de Most Popular*.

Table 5. Deltas pareados de las extensiones de CPGRec+ (R@5 $\times 10^3$; media $\pm$ d.e. sobre 3 semillas con el mismo split), junto a la cobertura del *rating* que alimenta a PER.

	SCGRec	UCSD	Kozyriev
Cobertura del <i>rating</i>	rala	35,6 %	100 %
+PER – base	$-12,7 \pm 7,8$	$-6,3 \pm 3,2$	$-0,3 \pm 0,9$
+PER+PRG – +PER	$+0,1 \pm 12,1$	$+3,3 \pm 2,3$	$-3,1 \pm 2,9$

Extensiones de CPGRec+ (RQ4, parte GNN). Ni PER ni PRG mejoran la *accuracy* de la base en ningún dataset (Tabla 5), consistente con el propio paper (CPGRec+ $\approx$

Table 4. Resultados bajo el protocolo común (F2): Recall@5 / NDCG@10, *full-ranking*. Mejor de cada columna en negrita (excluye la fila de referencia del paper). CPGRec: media de 3 semillas (desv. est. $\leq 0,003$ en R@5, $\leq 0,007$ en las extensiones); baselines de UCSD en convención horas. CB-SBERT no aplica en SCGRec (sin texto); FM/DeepFM/DeepNN no se corren en SCGRec (su análisis corresponde a F3/UCSD/Kozyriev).

Modelo	UCSD (9.198 j)		Kozyriev (22.590 j)		SCGRec (2.675 j)	
	R@5	NDCG@10	R@5	NDCG@10	R@5	NDCG@10
Most Popular	0,119	0,166	0,029	0,028	0,213	0,207
ALS	0,105	0,144	0,059	0,056	0,375	0,355
BPR	0,141	0,187	0,039	0,038	0,415	0,397
CB-SBERT	0,013	0,017	0,016	0,014	—	—
CPGRec base	0,144	0,205	0,044	0,043	0,408	0,399
CPGRec +PER	0,138	0,197	0,044	0,043	0,395	0,383
CPGRec +PER+PRG	0,141	0,200	0,041	0,040	0,395	0,384
FM	0,091	0,138	0,024	0,023	—	—
DeepFM	0,092	0,141	0,026	0,026	—	—
DeepNN	0,040	0,077	0,009	0,010	—	—
CPGRec (paper, ref.)	—	—	—	—	0,517	0,455




Figure 1. Recall@5 bajo el protocolo común (F2). Cada panel usa su propia escala (los absolutos no son comparables entre datasets); el borde negro marca al mejor de cada panel. El modelo que destaca se desplaza de BPR/CPGRec en los catálogos densos hacia ALS en el catálogo grande y disperso.

CPGRec en *accuracy*). El patrón de PER es informativo: es neutro donde el *rating* tiene cobertura total (Kozyriev) y cuesta -3 a $-4,4$ % donde es raro (SCGRec, UCSD), porque el test de Fisher que clasifica aristas se degenera con *ratings* imputados. Además, el PER original usa un *rating personal* usuario–juego que ningún dataset provee; lo alimentamos con un proxy global por juego. La conclusión no es “PER es malo” sino **“PER depende de la cobertura y granularidad del rating”**. PRG-SBERT solo aporta señal positiva clara sobre +PER en UCSD ($+2,4$ %, 3/3 semillas), el dataset con texto más rico (*tags*; deltas completos en el Anexo I).

6.2. Protocolo per-user (F3): la métrica se mueve 7×

Table 6. Protocolo per-user (F3), NDCG@10. “Con/sin pt” = con/sin *playtime* como *feature*. ALS se evalúa en *full-ranking* dentro del mismo subconjunto denso (configuración exacta de Cheuque), como contraste.

Modelo	UCSD		Kozyriev	
	con pt	sin pt	con pt	sin pt
FM	0,992	0,708	0,999	0,905
DeepFM	0,992	0,715	0,998	0,909
DeepNN	0,992	0,731	0,999	0,925
ALS (<i>full-ranking</i>)	0,414		0,140	

Bajo el protocolo per-user **recuperamos fielmente el resultado de Cheuque et al. (2019)**: los tres profundos alcanzan $\text{NDCG@10} \approx 0,99$ en ambos datasets (Tabla 6), mientras el ALS de contraste en *full-ranking* queda en 0,41 (UCSD)




Figure 2. El mismo modelo, tres números: NDCG@10 de FM/DeepFM/DeepNN bajo re-ranking per-user con *playtime* como *feature*, per-user sin *playtime*, y *full-ranking* bajo el protocolo común (F2). El paso per-user → *full-ranking* mueve la métrica mucho más que quitar la *feature*, en ambos datasets.

y 0,14 (Kozyriev). La brecha “deep $\gg$ ALS $\sim 8\times$ ” surge de comparar dos tareas distintas: re-ranking de pocos ítems con la *feature* dominante, contra ranking de todo el catálogo sin ella.

Descomposición en dos capas (RQ1). La Figura 2 separa el efecto. *Capa 1 (fuga de playtime)*: quitar la *feature* baja el NDCG@10 de 0,99 a 0,71–0,73 en UCSD, pero solo a 0,91–0,92 en Kozyriev, donde la tasa base de positivos (68,5 %) sostiene el re-ranking per-user casi sin señal. *Capa 2 (per-user → full-ranking)*: el mismo modelo sin fuga cae a 0,077–0,141 (UCSD) y 0,010–0,026 (Kozyriev) bajo el protocolo común. Sobre la caída total, **la capa de protocolo explica el 67 % en UCSD y el 91 % en Kozyriev** (DeepFM; el patrón se repite en los 6 pares modelo×dataset). Tener dos datasets de tasa base muy distinta (24,7 % vs. 68,5 %) muestra que el efecto no es un accidente del dataset; los seis casos, con los deltas por capa, están en el Anexo B. Nota de honestidad: la columna “sin *playtime*” no es el número honesto (sigue siendo per-user); el número honesto es el de F2.

6.3. Más allá de la *accuracy*: diversidad y *long-tail*

Table 7. Diversidad a nivel de categoría en el top-10 (F2): Cov = n.º de categorías distintas (escala con el catálogo: no comparable entre datasets); Ent = entropía de géneros. Mejor por columna en negrita.

Modelo	Cov_total@10			Ent_gén@10		
	UCSD	Koz.	SCG.	UCSD	Koz.	SCG.
Most Popular	17,5	29,2	4,1	2,45	3,16	0,31
ALS	22,0	31,9	20,0	2,51	2,72	1,77
BPR	20,1	33,0	14,5	2,27	2,92	1,29
CB-SBERT	25,6	31,7	—	2,50	2,84	—
CPGRec base	19,5	31,6	14,0	2,38	2,65	1,34
FM / DeepFM	18,3 / 17,7	28,2 / 27,9	—	1,98 / 1,95	2,08 / 2,14	—
DeepNN	16,8	32,9	—	2,03	2,85	—

Diversidad (RQ4). La Tabla 7 matiza la lectura “multi-modalidad = diversidad”: el modelo más diverso *también* cambia por dataset. El contenido (CB-SBERT) lidera solo en UCSD; en Kozyriev el más diverso es BPR y en SCGRec, ALS, ambos colaborativos. CPGRec queda por debajo de ALS en cobertura en los tres datasets, de modo que el balance precisión–diversidad que promete el GNN no es Pareto-dominante sobre ALS. Los *feature-based* son consistentemente los menos diversos (salvo DeepNN en Kozyriev, que es diverso por ser casi aleatorio: el *tradeoff* en su forma extrema). En Kozyriev, ALS gana *accuracy* y está arriba en diversidad (tablas completas en el Anexo D; el trade-off se visualiza en la Figura 4).

Long-tail: el mecanismo. La Figura 3 muestra *dónde* se gana y se pierde. En SCGRec y UCSD, **ALS colapsa en los usuarios más activos** (SCGRec 51+: 0,100, bajo MostPop 0,133; UCSD 51+: 0,111), mientras BPR (0,180 / 0,154) y CPGRec (0,210 / 0,205) no. Como UCSD concentra el 44 % de su población en el segmento 51+ (datos de *ownership*), ese colapso explica que ALS caiga bajo MostPop en el agregado. En Kozyriev la situación se invierte: ALS domina usuarios fríos y medios (el 91 % de la población evaluada tiene ≤ 20 interacciones) y CPGRec solo lo alcanza en el segmento 51+. El hallazgo del catálogo no es un promedio opaco: se observa en qué segmento de usuarios vive la ventaja de cada modelo (valores exactos en el Anexo C; la composición por actividad, en la Figura 5).

6.4. Ejemplos cualitativos

Tres casos ilustran qué “entiende” cada modelo (top-5, protocolo común; listas completas en el Anexo H). (1) *Coherencia de saga* (SCGRec): para un perfil Valve/Half-Life (Team Fortress Classic, Day of Defeat...), CPGRec y BPR aciertan *Counter-Strike* y *Left 4 Dead 2*; ALS recomienda




Figure 3. NDCG@10 por nivel de actividad del usuario (interacciones en train), protocolo común. El mecanismo del hallazgo del catálogo: en los catálogos densos ALS colapsa en los usuarios más activos (donde BPR y CPGRec no), mientras que en el catálogo disperso ALS domina usuarios fríos y medios y CPGRec solo lo alcanza en el segmento 51+.

Unreal Tournament y *Call of Duty*, incoherentes con el perfil, un ejemplo de la debilidad de ALS en usuarios activos. (2) *Contenido coherente pero impreciso* (Kozyriev): para un perfil *Fallout/Borderlands*, CB-SBERT recomienda *Borderlands Pre-Sequel*, *Fallout 4* y *Fallout 76*, temáticamente impecables, pero el test era *Life is Strange Ep. 1*, que ALS sí acierta: el contenido es interpretable, la conducta la captura la señal colaborativa. (3) *Perfiles blockbuster* (UCSD): para un usuario frío con *CS:GO* en test, MostPop y ALS aciertan y CB-SBERT falla con juegos de nicho: en catálogos hiperconcentrados la popularidad es una señal muy difícil de batir.

7. Discusión

El hallazgo del catálogo (RQ3). La ventaja del GNN es *condicional a la densidad*: con catálogo chico/denso los grafos de categoría tienen señal abundante que propagar y CPGRec/BPR dominan toda la curva de actividad; con catálogo grande/disperso el *full-ranking* sobre 22,6K ítems vuelve ralo al grafo y la confianza colaborativa de ALS generaliza mejor. El cruce CPGRec $\leftrightarrow$ ALS ocurre entre $\sim 9K$ (UCSD, gana el GNN) y $\sim 22,6K$ candidatos (Kozyriev, gana ALS). Esto refina el reflejo “GNN = estado del arte $\Rightarrow$ gana siempre”: en nuestro régimen de catálogo abierto, un método de 2008 es el techo.

Por qué BPR iguala al GNN en denso. No es casual: el módulo NSR de CPGRec entrena con *pérdida BPR*, de modo que en un catálogo denso el aparato adicional (grafos SGC/CNA, PENR) aporta poco sobre un BPR desnudo. El resultado “CPGRec gana en SCGRec” se refina a “CPGRec $\approx$ BPR $>$ ALS”. Además BPR, al no ponderar por *playtime*, no sobre-ajusta a los *heavy players* y no colapsa donde ALS sí.

El protocolo como variable explicativa (RQ1). La descomposición de la Sec. 6.2 muestra que el componente dominante del optimismo no es la fuga (que era la sospecha inicial) sino la *tarea de evaluación*: re-ranear los ítems de test del propio usuario es órdenes de magnitud más fácil que ranear el catálogo. Con tasa base alta, el per-user da $NDCG \approx 0,9$ *aunque el modelo casi no tenga señal*. Es el mismo mensaje de Ferrari Dacrema et al. (2019), con una cuantificación explícita por capas. Respecto de Cheuque et al. (2019), el encuadre justo es de **comparabilidad, no de refutación**: bajo su protocolo reproducimos fielmente sus números; bajo el protocolo común, FM/DeepFM quedan $\approx$ ALS y bajo el GNN en UCSD, y bajo Most Popular en Kozyriev. Ambos números son válidos y cada uno responde una pregunta distinta; para decidir qué modelo desplegar, la relevante es la del *full-ranking*.

¿Aporta la multimodalidad? (RQ4). La respuesta honesta es matizada y más bien moderada. En *accuracy*, ninguna modalidad extra bate a la señal colaborativa pura: el contenido (CB-SBERT) es el piso; los grafos de categoría solo ganan en catálogo denso (donde un BPR sin grafos los iguala); PER no aporta con *ratings* proxy; PRG apenas mueve la aguja; y la fusión temprana CF+contenido colapsó en H2. En *diversidad*, el contenido sí paga (CB-SBERT lidera cobertura en UCSD y es top-3 en Kozyriev), pero no la monopoliza: ALS y BPR son los más diversos en SCGRec y Kozyriev. Un sistema “multimodal” evaluado con un protocolo permisivo confunde sofisticación con desempeño; el protocolo común revela dónde y en qué eje paga cada modalidad.

8. Limitaciones

Las declaramos como parte del aporte de honestidad. (1) *Convención de playtime en UCSD*: el comparativo publicado del GNN corrió en minutos y los baselines nuevos

en horas (canónico); solo afecta a ALS (+21 % R@5) y está declarado por tabla. (2) *Densidad no emparejable en F3-Kozyriev*: 1,74 % vs. 7,66 % de UCSD, estructuralmente imposible de igualar con señal de reseñas; comparamos el patrón, no los absolutos. (3) *Semillas asimétricas*: 3 para CPGRec, 1 para baselines nuevos y profundos de Kozyriev (deltas grandes y robustos); anotado por tabla. (4) *Submuestras* (Kozyriev 500K, SCGRec 2M): los diagnósticos indican efecto dentro del ruido, pero no es el universo completo. (5) *PER con proxy*: rating global por juego en lugar del rating personal del paper; PER no puede exhibir su ganancia reportada. (6) *Reproducción de CPGRec al 79–88 %*: submuestra, γ sin ajustar y convergencia residual; supera al paper en Precision y el ordenamiento entre modelos es robusto a ese residual. (7) *Positivo = ownership en UCSD*: tener un juego no implica jugarlo; es una propiedad de la fuente. (8) En F2-SCGRec falta CB-SBERT (el dataset no trae texto).

9. Conclusiones y trabajo futuro

(1) El NDCG@10 $\approx$ 0,99 de los modelos profundos en Steam es un artefacto del protocolo de evaluación, no calidad del modelo: bajo *full-ranking* sin fuga cae a 0,01–0,14, y el componente dominante (67–91 %) es la evaluación per-user, no la *feature* filtrada (RQ1). (2) Bajo el protocolo común no existe “el mejor modelo”: BPR y CPGRec destacan en catálogos densos y ALS es el techo en el catálogo grande y disperso; la ventaja del GNN depende de la densidad y se explica por el comportamiento en los extremos de actividad (RQ2, RQ3). (3) La multimodalidad no supera a la señal colaborativa en *accuracy* y su aporte, real pero acotado, vive en la diversidad (RQ4). (4) Meta-conclusión: el diseño del protocolo es una decisión de primera clase; el resultado que se reporta dice tanto del protocolo como del modelo.

Trabajo futuro. Modelos *secuenciales* (SASRec, GRU4Rec) bajo el mismo protocolo común: explotan una señal (orden temporal) que ninguno de nuestros modelos usa y son la vía más prometedora para superar a ALS sin relajar la evaluación. Fusión *tardía* $\beta s_{CF} + (1 - \beta)s_{contenido}$ como híbrido robusto al colapso observado en H2. Barrido de umbrales de *k-core* para mapear a qué densidad exacta cruza CPGRec $\leftrightarrow$ ALS. Novelty@10 y un análisis de diversidad más profundo. CB-SBERT en SCGRec si se incorpora texto externo.

Uso de IA

Se utilizó el autocompletado de Google Colab y consultas a Gemini para depurar errores de código y de redacción (H1–H2; conversación: <https://gemini.google.com/share/6d0e14510b0d>). En H3 se usó además asisten-

cia de Claude (Anthropic) para depurar notebooks, generar los scripts de figuras (`generar_figuras.py`) y revisar la redacción del paper. Todos los resultados reportados provienen de los notebooks ejecutados incluidos en el repositorio.

Referencias

- Bueno, N., Fuentes, F., Jacque, J., and Solís, F. Análisis comparativo de modelos multimodales aplicados a la recomendación de videojuegos. https://github.com/PUC-RecSys-Class/RecSysPUC-2025-2/blob/master/proyecto/proy_finales_2025-2/Paper-G03.pdf, 2025. Proyecto Final IIC3633, Pontificia Universidad Católica de Chile.
- Cañameres, R. and Castells, P. Should I follow the crowd? A probabilistic analysis of the effectiveness of popularity in recommender systems. In *Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, pp. 415–424. ACM, 2018. doi: 10.1145/3209978.3210014.
- Cheuque, G., Guzmán, J., and Parra, D. Recommender systems for online video game platforms: the case of STEAM. In *Companion Proceedings of The 2019 World Wide Web Conference (WWW '19 Companion)*, San Francisco, CA, USA, 2019. ACM. doi: 10.1145/3308560.3316457.
- Ferrari Dacrema, M., Cremonesi, P., and Jannach, D. Are we really making much progress? A worrying analysis of recent neural recommendation approaches. In *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys)*, pp. 101–109. ACM, 2019.
- Fronkon Games. Steam Games Dataset. Kaggle. <https://www.kaggle.com/datasets/fronkongames/steam-games-dataset>, 2023. Dataset.
- Guo, H., Tang, R., Ye, Y., Li, Z., and He, X. DeepFM: A factorization-machine based neural network for CTR prediction. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 1725–1731, 2017.
- He, R. and McAuley, J. Ups and downs: Modeling the visual evolution of fashion trends with one-class collaborative filtering. In *Proceedings of the 25th International Conference on World Wide Web (WWW)*, pp. 507–517. ACM, 2016. doi: 10.1145/2872427.2883037.
- Hu, Y., Koren, Y., and Volinsky, C. Collaborative filtering for implicit feedback datasets. In *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining (ICDM)*, pp. 263–272. IEEE, 2008.
- Kozyriev, A. Game Recommendations on Steam. Kaggle. <https://www.kaggle.com/datasets/antonkozyriev/game-recommendations-on-steam>, 2023. Dataset.
- Krichene, W. and Rendle, S. On sampled metrics for item recommendation. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 1748–1757. ACM, 2020. doi: 10.1145/3394486.3403226.
- Li, X., Ma, J., Liu, K., Feng, S., Zhang, H., and Wang, Y. Category-based and popularity-guided video game recommendation: A balance-oriented framework. In *Proceedings of the ACM Web Conference 2024 (WWW '24)*, Singapore, 2024. ACM. doi: 10.1145/3589334.3645573. arXiv:2604.14598.

- Li, X., Yang, A., Ma, J., Liu, K., Feng, S., Zhang, H., and Zhao, Y. CPGRec+: A balance-oriented framework for personalized video game recommendations. *ACM Transactions on Information Systems*, 44(3), 2026. doi: 10.1145/3789264. arXiv:2604.14586.
- Meng, Z., McCreddie, R., Macdonald, C., and Ounis, I. Exploring data splitting strategies for the evaluation of recommendation models. In *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys)*, pp. 681–686. ACM, 2020. doi: 10.1145/3383313.3418479.
- Pathak, A., Gupta, K., and McAuley, J. Generating and personalizing bundle recommendations on Steam. In *Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 1073–1076. ACM, 2017.
- Reimers, N. and Gurevych, I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 2019.
- Rendle, S., Freudenthaler, C., Gantner, Z., and Schmidt-Thieme, L. BPR: Bayesian personalized ranking from implicit feedback. In *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*, pp. 452–461, 2009.
- Rendle, S., Krichene, W., Zhang, L., and Anderson, J. Neural collaborative filtering vs. matrix factorization revisited. In *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys)*, pp. 240–248. ACM, 2020. doi: 10.1145/3383313.3412488.
- Saavedra, R., Olguín, C., and Coli, G. Recomendación de videojuegos: Análisis comparativo de modelos. https://github.com/PUC-RecSys-Class/RecSysPUC-2025-1/blob/master/proyecto/proy_finales_2025/Paper-G09.pdf, 2025. Proyecto Final IIC3633, Pontificia Universidad Católica de Chile.
- Wan, M. and McAuley, J. Item recommendation on monotonic behavior chains. In *Proceedings of the 12th ACM Conference on Recommender Systems (RecSys)*, pp. 86–94. ACM, 2018.
- Yang, L., Liu, Z., Wang, Y., Wang, C., Fan, Z., and Yu, P. S. Large-scale personalized video game recommendation via social-aware contextualized graph neural network. In *Proceedings of the ACM Web Conference 2022 (WWW '22)*, Lyon, France, 2022. ACM. doi: 10.1145/3485447.3512273.

Anexos

Material complementario referenciado desde el cuerpo del paper; no cuenta para el límite de páginas. Todas las cifras provienen de los notebooks ejecutados listados en el `README.md` del repositorio.

A. Tablas completas de *accuracy* (protocolo común, F2)

Las Tablas 8, 9 y 10 amplían la Tabla 4 del cuerpo con seis métricas por dataset. Para las variantes de CPGRRec se reporta media $\pm$ desviación estándar sobre 3 semillas pareadas; el resto de los modelos corre con 1 semilla (ALS y Most Popular son deterministas dado el split). Mejor valor de cada columna en negrita (excluye la fila de referencia del paper).

B. Descomposición completa del efecto del protocolo

La Tabla 11 descompone, para los seis pares modelo $\times$ dataset, la caída del NDCG@10 desde el protocolo per-user con *playtime* (F3) hasta el *full-ranking* honesto (F2). Δ_{fuga} = quitar *playtime* como *feature* (dentro de F3); Δ_{prot} = pasar de re-ranking per-user a *full-ranking* (F3 sin fuga $\rightarrow$ F2). En los seis casos domina la capa de protocolo (67–93 % de la caída total; con DeepFM: 67 % en UCSD y 91 % en Kozyriev, los valores citados en el cuerpo). En F3, el MAP@10 con fuga de los tres profundos es $\approx 0,99$ en ambos datasets; el ALS de contraste en *full-ranking* obtiene MAP@10 = 0,255 (UCSD) y 0,062 (Kozyriev).

Table 8. UCSD (9.198 juegos; $n_{\text{eval}} = 57.390$; *full-ranking*). Baselines MostPop/ALS/BPR/CB-SBERT en convención horas; CPGRec y los profundos provienen del comparativo multi-seed (insensibles a la convención de *playtime*).

Modelo	R@5	NDCG@5	R@10	NDCG@10	Hit@10	Prec@10
Most Popular	0,1191	0,1672	0,1622	0,1655	0,5752	0,0908
ALS	0,1050	0,1246	0,1684	0,1443	0,5606	0,0837
BPR	0,1405	0,1793	0,1962	0,1871	0,5854	0,0984
CB-SBERT	0,0128	0,0152	0,0190	0,0168	0,0846	0,0090
CPGRec base	0,1440 $\pm 0,0011$	0,2030 $\pm 0,0016$	0,2043 $\pm 0,0013$	0,2046 $\pm 0,0015$	0,6561 $\pm 0,0026$	0,1166 $\pm 0,0009$
CPGRec +PER	0,1377 $\pm 0,0031$	0,1943 $\pm 0,0040$	0,1970 $\pm 0,0045$	0,1966 $\pm 0,0043$	0,6438 $\pm 0,0090$	0,1127 $\pm 0,0027$
CPGRec +PER+PRG	0,1411 $\pm 0,0009$	0,1980 $\pm 0,0009$	0,2004 $\pm 0,0010$	0,2002 $\pm 0,0009$	0,6490 $\pm 0,0023$	0,1144 $\pm 0,0006$
FM	0,0905 $\pm 0,0013$	0,1333 $\pm 0,0015$	0,1371 $\pm 0,0016$	0,1375 $\pm 0,0015$	0,5252 $\pm 0,0031$	0,0827 $\pm 0,0004$
DeepFM	0,0919 $\pm 0,0011$	0,1363 $\pm 0,0016$	0,1412 $\pm 0,0013$	0,1408 $\pm 0,0014$	0,5353 $\pm 0,0025$	0,0852 $\pm 0,0003$
DeepNN	0,0402 $\pm 0,0002$	0,0720 $\pm 0,0004$	0,0731 $\pm 0,0010$	0,0768 $\pm 0,0007$	0,3720 $\pm 0,0044$	0,0579 $\pm 0,0008$

 Table 9. Kozyriev (22.590 juegos; $n_{\text{eval}} = 200.000$; *full-ranking*).

Modelo	R@5	NDCG@5	R@10	NDCG@10	Hit@10	Prec@10
Most Popular	0,0289	0,0207	0,0500	0,0282	0,0797	0,0083
ALS	0,0586	0,0436	0,0931	0,0559	0,1452	0,0194
BPR	0,0392	0,0295	0,0618	0,0375	0,0978	0,0104
CB-SBERT	0,0159	0,0123	0,0217	0,0143	0,0324	0,0033
CPGRec base	0,0440 $\pm 0,0007$	0,0320 $\pm 0,0005$	0,0740 $\pm 0,0009$	0,0427 $\pm 0,0006$	0,1189 $\pm 0,0013$	0,0127 $\pm 0,0002$
CPGRec +PER	0,0436 $\pm 0,0004$	0,0317 $\pm 0,0002$	0,0744 $\pm 0,0004$	0,0426 $\pm 0,0002$	0,1190 $\pm 0,0005$	0,0127 $\pm 0,0001$
CPGRec +PER+PRG	0,0406 $\pm 0,0028$	0,0292 $\pm 0,0023$	0,0700 $\pm 0,0042$	0,0396 $\pm 0,0027$	0,1119 $\pm 0,0062$	0,0118 $\pm 0,0007$
FM	0,0239	0,0169	0,0416	0,0232	0,0672	0,0069
DeepFM	0,0263	0,0186	0,0460	0,0255	0,0742	0,0077
DeepNN	0,0092	0,0064	0,0181	0,0096	0,0323	0,0033

 Table 10. SCGRec (2.675 juegos; $n_{\text{eval}} = 200.000$; *full-ranking*). La última fila reproduce los valores reportados por el paper de CPGRec (fila de *trade-off*) como referencia; nuestra reproducción alcanza el 79–88 % en Recall/NDCG y lo supera en Precisión.

Modelo	R@5	NDCG@5	R@10	NDCG@10	Hit@10	Prec@10
Most Popular	0,2128	0,1728	0,3104	0,2068	0,4670	0,0683
ALS	0,3752	0,3270	0,4520	0,3554	0,6375	0,0899
BPR	0,4145	0,3725	0,4885	0,3968	0,6758	0,1039
CPGRec base	0,4080 $\pm 0,0026$	0,3721 $\pm 0,0030$	0,4917 $\pm 0,0024$	0,3994 $\pm 0,0029$	0,7007 $\pm 0,0030$	0,1084 $\pm 0,0008$
CPGRec +PER	0,3953 $\pm 0,0067$	0,3576 $\pm 0,0096$	0,4729 $\pm 0,0083$	0,3830 $\pm 0,0102$	0,6759 $\pm 0,0115$	0,1030 $\pm 0,0022$
CPGRec +PER+PRG	0,3953 $\pm 0,0061$	0,3575 $\pm 0,0060$	0,4763 $\pm 0,0080$	0,3841 $\pm 0,0064$	0,6795 $\pm 0,0112$	0,1041 $\pm 0,0022$
<i>CPGRec (paper, ref.)</i>	<i>0,5168</i>	<i>0,4320</i>	<i>0,5990</i>	<i>0,4547</i>	<i>0,7292</i>	<i>0,0922</i>

Table 11. Descomposición por capas del NDCG@10 (seis casos). “% prot.” = fracción de la caída total explicada por el cambio de protocolo.

Dataset	Modelo	per-user con pt (F3)	per-user sin pt (F3)	<i>full-ranking</i> (F2)	$\Delta_{\text{fuga}} / \Delta_{\text{prot}}$	% prot.
UCSD	FM	0,992	0,708	0,138	−0,284 / −0,571	67 %
UCSD	DeepFM	0,992	0,715	0,141	−0,277 / −0,574	67 %
UCSD	DeepNN	0,992	0,731	0,077	−0,261 / −0,654	71 %
Kozyriev	FM	0,999	0,905	0,023	−0,094 / −0,882	90 %
Kozyriev	DeepFM	0,998	0,909	0,026	−0,089 / −0,883	91 %
Kozyriev	DeepNN	0,999	0,925	0,010	−0,074 / −0,915	93 %

C. Long-tail: valores exactos

Las Tablas 12–14 dan los valores exactos de la Figura 3, junto al tamaño de cada segmento de actividad (n usuarios evaluados) y las variantes de CPGRec+.

Table 12. SCGRec — NDCG@10 por actividad del usuario.

	2–5	6–20	21–50	51+
n usuarios	36.313	100.298	41.012	22.377
Most Popular	0,274	0,220	0,157	0,133
ALS	0,593	0,400	0,175	0,100
BPR	0,627	0,431	0,228	0,180
CPGRec base	0,598	0,430	0,251	0,210
CPGRec +PER	0,583	0,411	0,241	0,191
CPGRec +PER+PRG	0,578	0,413	0,245	0,195

Table 13. UCSD — NDCG@10 por actividad. MostPop/ALS/BPR provienen del run en horas (n por segmento: 1.715 / 12.219 / 18.403 / 25.087); CPGRec y los profundos, del comparativo multi-seed (n : 1.750 / 12.122 / 18.396 / 25.122).

	2–5	6–20	21–50	51+
Most Popular	0,224	0,177	0,156	0,163
ALS	0,200	0,190	0,154	0,111
BPR	0,325	0,251	0,177	0,154
CPGRec base	0,221	0,213	0,197	0,205
CPGRec +PER	0,217	0,204	0,187	0,199
CPGRec +PER+PRG	0,223	0,209	0,192	0,201
FM	0,154	0,130	0,127	0,148
DeepFM	0,163	0,133	0,128	0,153
DeepNN	0,055	0,042	0,051	0,114

Table 14. Kozyriev — NDCG@10 por actividad.

	2–5	6–20	21–50	51+
n usuarios	88.748	93.068	15.310	2.874
Most Popular	0,029	0,028	0,026	0,024
ALS	0,053	0,059	0,055	0,053
BPR	0,037	0,038	0,036	0,045
CPGRec base	0,039	0,045	0,049	0,054
CPGRec +PER	0,040	0,044	0,048	0,051
CPGRec +PER+PRG	0,038	0,041	0,043	0,046

D. Diversidad completa por categoría

Las Tablas 15–17 amplían la Tabla 7 con cobertura total y de género en ambos cortes (@5/@10) y la entropía de géneros. Cov = n.º de categorías distintas en el top- k (escala con el catálogo: no comparable entre datasets).

Table 15. UCSD — diversidad por categoría.

Modelo	Cov_total		Cov_gén		Ent_gén	
	@5	@10	@5	@10	@5	@10
Most Popular	11,19	17,50	5,41	7,00	2,19	2,45
ALS	13,09	21,96	5,57	7,37	2,18	2,51
BPR	11,84	20,10	4,89	6,53	1,93	2,27
CB-SBERT	14,97	25,64	5,85	7,66	2,25	2,50
CPGRec base	11,89	19,50	5,37	6,84	2,11	2,38
CPGRec +PER	11,45	19,13	5,25	6,79	2,08	2,36
CPGRec +PER+PRG	11,45	19,05	5,18	6,75	2,06	2,36
FM	10,72	18,33	4,21	5,70	1,64	1,98
DeepFM	10,20	17,66	4,03	5,60	1,58	1,95
DeepNN	8,96	16,78	3,70	5,97	1,44	2,03

Table 16. Kozyriev — diversidad por categoría.

Modelo	Cov_total		Cov_gén		Ent_gén	
	@5	@10	@5	@10	@5	@10
Most Popular	13,23	29,24	4,02	10,84	1,74	3,16
ALS	18,48	31,91	6,73	9,37	2,39	2,72
BPR	19,29	33,02	8,76	12,84	2,55	2,92
CB-SBERT	18,26	31,72	7,78	11,22	2,48	2,84
CPGRec base	18,28	31,56	6,25	8,36	2,36	2,65
CPGRec +PER	18,56	31,61	6,06	8,02	2,32	2,60
CPGRec +PER+PRG	18,20	31,17	6,11	8,11	2,33	2,61
FM	15,61	28,20	5,00	7,98	1,54	2,08
DeepFM	15,37	27,90	4,75	7,41	1,63	2,14
DeepNN	18,32	32,90	6,98	10,13	2,45	2,85

Table 17. SCGRec — diversidad por categoría.

Modelo	Cov_total		Cov_gén		Ent_gén	
	@5	@10	@5	@10	@5	@10
Most Popular	3,13	4,14	1,09	1,69	0,06	0,31
ALS	11,08	19,97	3,32	4,89	1,34	1,77
BPR	8,67	14,51	2,66	3,77	0,96	1,29
CPGRec base	8,03	13,99	2,53	3,98	0,88	1,34
CPGRec +PER	8,18	14,39	2,65	4,11	0,92	1,37
CPGRec +PER+PRG	7,97	13,71	2,57	3,97	0,87	1,30

E. Figuras adicionales

La Figura 4 visualiza el trade-off *accuracy*↔diversidad por dataset; la Figura 5, la composición de la población evaluada por nivel de actividad (el porqué de los agregados de la Tabla 4); y la Figura 6, el reordenamiento del ranking al crecer el catálogo.




Figure 4. Trade-off $accuracy \leftrightarrow$ diversidad (Recall@5 vs. Cov_total@10, protocolo común). El más diverso también cambia por dataset: CB-SBERT en UCSD, BPR en Kozyriev y ALS en SCGRec. En Kozyriev, ALS gana $accuracy$ y está arriba en diversidad; DeepNN es diverso por ser casi aleatorio (el *trade-off* en su forma extrema).




Figure 5. Composición de la población evaluada por nivel de actividad. UCSD (*ownership*) está volcado a usuarios muy activos (44 % en 51+); Kozyriev (reseñas), a usuarios fríos (44 % en 2-5). La masa de usuarios cambia por dataset y, con ella, el ganador promedio de la Tabla 4.




Figure 6. Reordenamiento del ranking (por Recall@5) al crecer el catálogo: ALS sube del 3.º/4.º lugar al 1.º; BPR y CPGRec descenden. El modelo que destaca depende de la densidad del catálogo.

F. Matriz señal $\times$ modelo

La Tabla 18 detalla cómo entra cada señal disponible en cada modelo. La fila de *playtime* resume el argumento central del paper: la misma columna es señal legítima (peso de confianza o de perfil) o fuga de información (*feature* de un modelo cuyo *label* se define con *playtime*) según cómo

Table 18. Qué señal usa cada modelo y cómo. “—” = no la usa. Los profundos F2 y F3 son los mismos modelos (FM/DeepFM/DeepNN) bajo distinto protocolo.

Señal	MostPop	ALS	BPR	CB-SBERT	CPGRec (+ext.)	Profundos F2	Profundos F3
Interacción (u, i)	conteo train	matriz $u \times i$	matriz binaria	define el perfil	bipartito GNN	<i>sparse</i> u/i	<i>sparse</i> u/i
<i>Playtime</i> / horas	—	peso $1 + \alpha \log(1 + h)$	—	peso del perfil	<i>feature</i> de PER	excluida	<i>feature</i> (fuga)
<i>is_recommended</i>	(positivo)	(positivo)	(positivo)	(positivo)	(positivo)	<i>sparse</i>	<i>sparse</i>
Género / dev / editor	—	—	—	(vía texto)	grafos SGC/CNA	<i>varlen</i>	<i>varlen</i>
<i>Rating</i> global	—	—	—	—	<i>rating</i> de PER	<i>dense</i>	<i>dense</i>
Texto (título+desc+tags)	—	—	—	SBERT (núcleo)	SBERT (rama PRG)	—	—
Derivadas (count, reccount)	—	—	—	—	—	<i>dense</i>	<i>dense</i>

G. Filtro denso de Cheque en Kozyriev

La Tabla 19 muestra el barrido de umbrales del filtro denso en Kozyriev que respalda la Sec. 4.2: el umbral exacto de Cheque et al. (2019) colapsa a 0 usuarios y ningún umbral alcanza la densidad de UCSD (7,66 %): con señal de reseñas, $(50,100) = 1,74$ % es el subconjunto más denso viable. La imposibilidad refuerza el argumento: el régimen denso del protocolo original depende de la señal de *ownership*.

Table 19. Barrido de umbrales ($\geq$ ítems/usuario, $\geq$ usuarios/ítem) del filtro denso en Kozyriev.

Umbral	Usuarios	Juegos	Interac.	Densidad
$(100, 200) = \text{Cheque}$	0	0	0	colapsa
$(50, 100) \leftarrow \text{usado}$	28.311	4.865	2.40M	1,74 %
(20, 50)	205.697	11.944	7,96M	0,32 %
(10, 30)	674.126	17.611	14,3M	0,12 %
(5, 20)	1.905.447	22.676	22,3M	0,05 %
UCSD (100, 200), ref.	14.405	2.584	—	7,66 %

H. Ejemplos de recomendación detallados

Top-5 de tres usuarios de UCSD (semilla 42, protocolo común; ✓ = ítem del conjunto de test):

Usuario frío (2–5; test: *Garry’s Mod* y app 223530). Most Popular: CS:GO, *Garry’s Mod* ✓, Unturned, app 223530 ✓, Left 4 Dead 2 ($R@5 = 1,0$). DeepFM: app 223530 ✓, PAYDAY 2, War Thunder, app 72850, *Garry’s Mod* ✓ ($R@5 = 1,0$). ALS y CPGRec aciertan *Garry’s Mod* ($R@5 = 0,5$). En perfiles “blockbuster” el top popular cae dentro de la biblioteca: por eso MostPop es tan fuerte en *ownership*.

Usuario medio (6–20; perfil Left 4 Dead 2, Portal 2, CoD MW2; test: app 223530, *Trove*, *Codename CURE*). CPGRec acierta *Trove*; MostPop, FM y DeepFM aciertan app 223530 ($R@5 = 0,33$ cada uno); ALS no acierta ninguno.

Usuario activo (21–50; perfil Left 4 Dead 2, CS:GO, *Garry’s Mod*, *Saints Row 2*; test: *Super MNC*, app 238960, *Turbo Dismount*). Solo ALS acierta (*Super MNC*, $R@5 = 0,33$); MostPop, CPGRec y los profundos fallan los tres.

A nivel individual los modelos se parecen en perfiles populares; las diferencias agregadas de la Tabla 4 viven en la

población (en UCSD, en los usuarios muy activos, donde ALS colapsa y CPGRec sostiene). Los ejemplos cualitativos de SCGRec (coherencia de saga Valve: CPGRec y BPR aciertan *Counter-Strike* y *Left 4 Dead 2* donde ALS propone *Unreal/CoD*) y de Kozyriev (CB-SBERT recomienda *Fallout/Borderlands* temáticamente coherentes pero falla el test *Life is Strange*, que ALS acierta) se describen en la Sec. 6.4.

I. Detalle multi-seed de las extensiones de CPGRec+

La Tabla 20 completa la Tabla 5 del cuerpo con los deltas pareados en tres métricas y el conteo de semillas con delta positivo. Lectura: +PER nunca mejora a la base (0/3 en SCGRec y UCSD; 1/3 y ≈ 0 en Kozyriev, donde el *rating* tiene cobertura total); el único delta consistentemente positivo es +PRG sobre +PER en UCSD (3/3), el dataset con texto más rico.

Table 20. Deltas pareados completos ($\times 10^3$; media $\pm$ d.e. sobre 3 semillas con el mismo split). “+” = semillas con delta positivo. Se discute en el Anexo I.

Delta	$\Delta R@5$	$\Delta N@5$	$\Delta N@10$	+
SCGRec (rating ralo)				
+PER — base	$-12,7 \pm 7,8$	$-14,5 \pm 10,1$	$-16,3 \pm 10,5$	0/3
+PER+PRG — base	$-12,7 \pm 7,5$	$-14,6 \pm 8,7$	$-15,3 \pm 8,9$	0/3
+PER+PRG — +PER	$+0,1 \pm 12,1$	$-0,1 \pm 13,5$	$+1,1 \pm 14,7$	2/3
UCSD (rating con cobertura 35,6 %)				
+PER — base	$-6,3 \pm 3,2$	$-8,7 \pm 4,0$	$-8,1 \pm 4,3$	0/3
+PER+PRG — base	$-3,0 \pm 1,5$	$-5,0 \pm 1,9$	$-4,4 \pm 1,8$	0/3
+PER+PRG — +PER	$+3,3 \pm 2,3$	$+3,7 \pm 3,2$	$+3,6 \pm 3,4$	3/3
Kozyriev (rating con cobertura 100 %)				
+PER — base	$-0,3 \pm 0,9$	$-0,3 \pm 0,7$	$-0,1 \pm 0,7$	1/3
+PER+PRG — base	$-3,4 \pm 2,3$	$-2,8 \pm 1,9$	$-3,1 \pm 2,2$	0/3
+PER+PRG — +PER	$-3,1 \pm 2,9$	$-2,5 \pm 2,3$	$-3,0 \pm 2,8$	1/3