

Multimodalidad: Recomendación de Películas

Florencia Schiappacasse
Pontificia Universidad Católica de
Chile
Santiago, Chile

Gustavo Gonzalez
Pontificia Universidad Católica de
Chile
Santiago, Chile

Alinna Vidal
Pontificia Universidad Católica de
Chile
Santiago, Chile

Abstract

El crecimiento exponencial de contenido digital ha generado un problema de sobrecarga de información, dificultando que los usuarios encuentren contenido relevante. Los sistemas de recomendación basados en filtrado colaborativo abordan este problema, pero presentan limitaciones como la dispersión de los datos (*sparsity*) y el problema de *cold-start*. En este trabajo evaluamos el impacto de incorporar información multimodal –texto e imagen– en sistemas de recomendación de películas. Utilizamos el dataset MovieLens 1M enriquecido con sinopsis y pósters obtenidos desde The Movie Database (TMDB), representando el texto y la imagen mediante embeddings de CLIP ViT-B/32. Comparamos modelos de recomendación (LightFM y DeepFM) entrenados con distintas combinaciones de features –géneros, sinopsis y póster– frente a baselines clásicos (Random, Most Popular, FunkSVD). Los resultados muestran que la sinopsis es la fuente multimodal que más contribuye a mejorar Recall@10 y Precision@10, especialmente en LightFM, mientras que la incorporación del póster no mejora la precisión pero sí aumenta la diversidad y novedad de las recomendaciones, particularmente en DeepFM.

El código utilizado en este trabajo se encuentra disponible en este repositorio público de GitHub: <https://github.com/fschiappacasse/RecomendadoresCodigo>.

1 Introducción

El crecimiento exponencial de contenido digital ha generado un problema de sobrecarga de información, donde los usuarios enfrentan dificultades para encontrar contenido relevante. Los sistemas de recomendación surgen como una solución a este problema, permitiendo filtrar información y entregar contenido personalizado. En particular, los sistemas de recomendación basados en filtrado colaborativo utilizan interacciones usuario-ítem, como calificaciones, para predecir preferencias.

Sin embargo, estos enfoques presentan limitaciones importantes, tales como la dispersión de los datos (*sparsity*) y el problema de *cold-start*, donde no existe suficiente información para nuevos usuarios o ítems. En este contexto, los sistemas de recomendación multimodales han surgido como una alternativa prometedora, integrando múltiples fuentes de información –texto, imágenes y datos estructurados– para capturar mejor las características de los ítems y mejorar la calidad de las recomendaciones. [1]

El objetivo de este trabajo es analizar el impacto de la multimodalidad en sistemas de recomendación de películas, comparando modelos entrenados solo con metadatos estructurados (géneros) frente a modelos que incorporan progresivamente sinopsis (texto) y pósters (imagen).

2 Revisión del estado del arte

Al momento de entrenar recomendadores uno de los elementos más cruciales son los datos utilizados, ya que sin ellos no hay nada que un modelo pueda aprender. La multimodalidad nos da la oportunidad de aprovechar información de diversas modalidades, la cual se complementa con el objetivo de generar una mejor recomendación.

Se pueden observar aplicaciones reales de la multimodalidad en la industria del cine y películas. Un claro ejemplo de esto es Netflix el cual utiliza MediaFM, un modelo de compresión de contenido generado por ellos para entender el contenido de una película o escena. Este utiliza información auditiva, visual y texto (subtítulos). [2].

Inicialmente se necesita extraer las features de las fuentes de información multimodal, estos se suelen dividir por el tipo de información. Algunos destacados son ViT [3] para la información visual, BERT [4] para la textual y GRU para información auditiva (originalmente para secuencias pero adaptado al audio). [5]

Al usar modelos multimodales es estándar encontrar alguna manera de combinar los embeddings, a este proceso se le llama fusión multimodal. Actualmente existen diversas estrategias con respecto a cuando se realiza esa fusión, esta puede ser temprana (antes del encoder) o tardía. [6]

Al momento de combinar los vectores existen dos opciones principales. La primera es la concatenación de los embeddings, que luego es usada directamente por los modelos. La otra opción es Element-wise, donde los embeddings se mezclan (puede existir multiplicación, suma, promedio u otros). Además la combinación de pesos puede seguir una estrategia Heurística (pesos fijos y definidos anteriormente) o Atenta (pesos aprendidos por el modelo).

Se identifican como estado del arte un amplio conjunto de modelos de recomendación multimodal, los trabajos más recientes incorporan modelos de lenguaje de gran escala y técnicas de difusión, como MENTOR [7] y SMORE [8]. Los autores señalan que esta evolución refleja una transición desde arquitecturas de factorización matricial hacia redes de grafos, y desde el uso de una sola modalidad hacia la integración conjunta de información visual y textual. [9]

3 Solución al problema trabajado

Para evaluar el aporte de cada modalidad, entrenamos cada modelo (LightFM y DeepFM) sobre tres configuraciones incrementales de features de ítem:

- **Base:** solo géneros codificados en *one-hot* a partir de los metadatos de MovieLens.
- **Base + póster:** se agregan los embeddings visuales del campo *overview* de TMDB.
- **Base + sinopsis:** se agregan los embeddings semánticos del campo *overview* de TMDB.
- **Base + sinopsis + póster:** se agregan además los embeddings visuales del póster oficial de la película.

Esta comparación incremental permite aislar el efecto de cada modalidad sobre las métricas de calidad de la recomendación, en lugar de solo comparar un modelo multimodal contra uno no multimodal.

4 Dataset

Se utilizaron dos fuentes de datos:

- **MovieLens 1M**: conjunto de datos de recomendación que contiene calificaciones de usuarios sobre películas, utilizado como base para el entrenamiento y evaluación del sistema [10].
- **The Movie Database (TMDB)**: base de datos en línea de películas utilizada para enriquecer MovieLens con información multimodal, como sinopsis y pósters oficiales [11].

El cruce entre ambas fuentes logró una cobertura de 94,1% de las películas de MovieLens (3654 de 3883), con sinopsis disponible para el 94,1% (3654 películas) y póster disponible para el 93,9% (3650 películas).

La fase de análisis del conjunto de datos nos llevó a los siguientes gráficos:




Figure 1: Distribución de Calificaciones




Figure 2: Número de calificaciones por película

Como se puede observar, el intervalo con más películas está entre 3.5 y 4 de calificación.

Por otro lado, la mayoría de las películas tienen entre 0 y 500 calificaciones, mientras más aumenta el número de calificaciones es menor la cantidad de películas. Esto es coherente con el fenómeno documentado de *long tail* en películas donde pocos ítems populares acumulan la mayor parte de las interacciones y una gran cantidad de ítems reciben pocas vistas e interacciones. Esto se relaciona con el sesgo de popularidad, donde es más probable que un usuario interactúe con ítems populares (como películas recomendadas por los medios, redes sociales o sus propios pares) [12].

5 Metodología utilizada

5.1 Representación de los ítems

Como *features* de ítem se utilizan tres fuentes de información:

- **Géneros codificados** en *one-hot* a partir de los metadatos de MovieLens.
- **Embeddings semánticos de la sinopsis**, obtenidos procesando el campo *overview* de TMDB mediante el encoder de texto del modelo CLIP ViT-B/32 de OpenAI, que produce vectores de 512 dimensiones en un espacio semántico compartido.
- **Embeddings visuales del póster**, extraídos procesando las imágenes descargadas de TMDB mediante el encoder de imagen del mismo modelo CLIP ViT-B/32, que produce vectores de 512 dimensiones en el mismo espacio vectorial.

CLIP ViT-B/32 es un modelo multimodal basado en la arquitectura Contrastive Language–Image Pretraining (CLIP) de OpenAI, adaptado al formato de Sentence Transformers. Utiliza un Vision Transformer Base (ViT-B) con tamaño de parche 32×32 píxeles para codificar imágenes y un codificador de texto entrenado conjuntamente mediante aprendizaje contrastivo. Gracias a este entrenamiento, imágenes y textos relacionados se proyectan en un mismo espacio de embeddings, permitiendo medir su similitud semántica. En este proyecto, el modelo se emplea para generar representaciones vectoriales de los pósters de las películas, que

posteriormente se utilizan como características visuales dentro del sistema de recomendación [13].

5.2 Fusión multimodal

Para combinar los embeddings de texto e imagen se exploró un esquema basado en *self-attention* y *cross-attention*. El *self-attention* es un mecanismo en el que cada elemento (*token*) de una secuencia calcula su representación considerando todos los demás elementos de la misma secuencia. El *cross-attention*, en cambio, es un mecanismo en el que las *queries* (Q) provienen de una secuencia distinta a aquella de donde se obtienen las *keys* (K) y *values* (V), permitiendo que una secuencia consulte información relevante de otra [14].

Este esquema de *cross-attention* se implementó utilizando BLIP (*Bootstrapping Language-Image Pre-training*), un modelo preentrenado de visión y lenguaje que, a diferencia de CLIP, incorpora un *image-grounded text encoder*: un codificador de texto cuyas capas de *cross-attention* atienden directamente a los mapas de características visuales de la imagen, produciendo una representación textual condicionada por el contenido visual [15]. Concretamente, se utilizó el checkpoint `blip-itm-base-coco`, mediante la clase `BlipForImageTextRetrieval`, preentrenada para la tarea de *Image-Text Matching* (ITM). Para cada ítem se procesaron conjuntamente el póster y la sinopsis, y la representación fusionada (`fused_emb`) corresponde al *token* [CLS] de la salida `question_embeds` del modelo, es decir, la representación textual obtenida tras aplicar *cross-attention* sobre los mapas de características visuales del póster. Cuando no había póster disponible, `fused_emb` se calculó únicamente a partir del codificador de texto de BLIP, sin componente visual. En ambos casos la representación se truncó a 512 dimensiones y se normalizó en la esfera unitaria.

En nuestro esquema, el *cross-attention* aporta una fusión semántica más rica cuando el texto es informativo, mientras que el embedding de imagen aporta robustez cuando el texto falla o es poco descriptivo. Por ello, la representación final del ítem se obtiene promediando ambas señales: $(\text{img_emb} + \text{fused_emb})/2$.

5.3 Modelos utilizados

- **LightFM**: pérdida *warp*, con *learning rate* de 0.05, 64 componentes latentes y 30 épocas.
- **DeepFM**: optimizador Adam, función de pérdida *Binary Cross-Entropy*, métricas *Binary Cross-Entropy* y AUC, 40 épocas, 0.1 de *validation split*.

Ambos modelos se entrenaron con tres configuraciones de datos: *base* (solo géneros de MovieLens), *base + sinopsis* (texto) y *base + sinopsis + póster* (texto + imagen). Como baselines se utilizaron modelos Random, Most Popular y FunkSVD.

6 Análisis de parámetros

Dado que el objetivo principal de este trabajo fue evaluar el impacto de la incorporación de información multimodal sobre la calidad de las recomendaciones, y no la optimización exhaustiva de los modelos, no se realizó una búsqueda sistemática de hiperparámetros para LightFM y DeepFM. En su lugar, se seleccionaron configuraciones estándar recomendadas en la literatura y en la documentación oficial de cada framework, manteniéndolas fijas a través de las distintas combinaciones de features para asegurar que las diferencias

observadas en las métricas fueran atribuibles exclusivamente a la modalidad incorporada, y no a variaciones en la configuración del modelo.

LightFM. Se utilizó la función de pérdida *WARP* (Weighted Approximate-Rank Pairwise) en lugar de alternativas como *logistic* o *BPR*, dado que WARP generalmente presenta mejor desempeño que la más popular pérdida BPR (Bayesian Personalised Ranking), a menudo por un margen amplio, y a diferencia de BPR, los ítems negativos no se eligen mediante muestreo aleatorio sino entre aquellos que violan el ranking deseado dado el estado actual del modelo, aproximando una forma de aprendizaje activo. Esto es coherente con las métricas evaluadas (Recall@10 y Precision@10), ya que WARP maximiza el rango de los ejemplos positivos y resulta útil cuando solo se dispone de interacciones positivas y se busca optimizar el tope de la lista de recomendación [16]. Se utilizaron 30 épocas que eran las adecuadas por nuestra disponibilidad computacional, y 64 componentes latentes como balance entre capacidad de representación y riesgo de sobreajuste dado el tamaño acotado del dataset (3654 películas).

DeepFM. Se utilizó el optimizador *Adam*, dado que combina las ventajas de RMSProp y AdaGrad, siendo directo de implementar, computacionalmente eficiente y con bajos requerimientos de memoria, además de que exhibe invarianza al reescalamiento diagonal de los gradientes, adaptándose a la geometría de la función objetivo, lo que favorece una convergencia estable en modelos con componentes profundos y dispersos como DeepFM [17]. La arquitectura DeepFM en sí misma justifica la combinación con *Binary Cross-Entropy* y AUC como métrica de validación, ya que combina la capacidad de las máquinas de factorización para recomendación con el aprendizaje profundo para extracción de features en una nueva arquitectura de red neuronal, compartiendo un input común entre sus partes “wide” y “deep”, sin necesidad de *feature engineering* adicional más allá de las features crudas [18]. Se entrenó durante 40 épocas —más que en LightFM— debido a que esta arquitectura híbrida requiere más iteraciones para ajustar adecuadamente los pesos de ambos componentes (el de factorización y el de la red profunda). El *validation split* de 0.1 permitió monitorear el sobreajuste sin reducir excesivamente el conjunto de entrenamiento.

Limitaciones: Al no realizar una búsqueda de hiperparámetros, no es posible descartar que configuraciones alternativas pudieran mejorar los resultados obtenidos, particularmente en las configuraciones que incorporan pósters o sinopsis, donde el alto costo computacional de procesar embeddings de imagen y texto limitó la exploración adicional. Futuras iteraciones podrían incorporar *Bayesian Optimization* para determinar si el aporte de cada modalidad se mantiene o se amplifica bajo configuraciones óptimas.

7 Resultados obtenidos

7.1 Modelos baseline

Table 1: Resultados de los modelos baseline.

Modelo	Recall@10	Precision@10	ILS@10	Novedad@10
Random	0,0023	0,0068	9,8877	9,2556
Most Popular	0,0489	0,0888	18,1664	5,8831
FunkSVD	0,0111	0,0240	7,8995	9,8448

7.2 Modelos multimodales

Table 2: Resultados de LightFM y DeepFM con distintas combinaciones de features. B: base (géneros); +S: + sinopsis; +S+P: + sinopsis + póster.

Modelo	Recall@10	Prec.@10	ILS@10	Novedad@10
LightFM B	0,0179	0,0456	22,5176	7,9375
LightFM +S	0,0464	0,0911	23,2112	7,1727
LightFM +P	0,0428	0,0856	23,2658	7,3817
LightFM +S+P	0,0401	0,0823	23,3385	7,4490
DeepFM B	0,6339	0,6792	20,2687	12,0164
DeepFM +S	0,6346	0,6813	20,4636	12,3524
DeepFM +P	0,6356	0,6831	17,4763	12,4132
DeepFM +S+P	0,6343	0,6804	17,7876	12,3699




Figure 3: Recall@10 de modelos




Figure 4: Recall@10 de modelos Deep




Figure 5: ILS@10 de modelos

ILS mide qué tan similares son entre sí los ítems dentro de una lista de recomendación, calculando el promedio de similitud coseno entre todos los pares posibles de ítems recomendados. Este es inverso a la diversidad.

Novedad mide qué tan novedosos son los ítems recomendados a nivel global, usando la fórmula $\log(1/\text{popularidad})$ promediada sobre la lista.

Los resultados muestran que consistentemente DeepFM hace mejores recomendaciones que LightFM, esto se puede deber a su capacidad para representar interacciones más complejas y ajustar pesos dinámicamente.

El mejor resultado tanto en precisión como en recall se puede encontrar en DeepFM con solo pósters, esto se puede deber a que estos entregan una mayor cantidad de información adicional que las sinopsis, ya que a través del póster se puede encontrar información implícita acerca de la antigüedad de la película, directores o estudios particulares y el tono de la película.

El resultado de DeepFM agregando únicamente la sinopsis también entrega buenos resultados (mejores que DeepFM con el set de datos base), esto se debe a que la sinopsis proporciona una descripción detallada de la trama, los personajes, el género implícito y otros aspectos semánticos de la película que no están presentes únicamente en los géneros, permitiendo construir representaciones más discriminativas de los ítems.

En LightFM ocurre lo contrario, al agregar únicamente las sinopsis se ve una mayor mejora que al agregar los pósters. Esto se puede deber a que LightFM puede representar relaciones menos complejas y solo de forma lineal, por lo que los embeddings de una imagen pueden ser muy complejos como para aprovechar toda la información dentro de ellos. Es importante mencionar que el aumento de precisión y recall en ambos casos es de más del doble, por lo que a pesar de la complejidad el modelo sí pudo extraer una cantidad importante de información nueva.

Tanto en DeepFM como en LightFM, usar únicamente fused_emb produjo el peor resultado, por esa razón lo promediamos de la forma: $(\text{img_emb} + \text{fused_emb}) / 2$, lo que mejoró el desempeño pero sin alcanzar a las modalidades puras. Esto nos indica que fused_emb no está entregando información adicional y está empeorando la recomendación, lo que se puede deber a que al tener pocos ítems para ser entrenado, cross attention no logra aprender una transformación útil, lo que agrega ruido que empeora las predicciones. Además el nuevo embedding pudo haber cambiado las propiedades que aseguraba CLIP anteriormente.

En DeepFM, la mejora de precisión al incorporar la sinopsis o los pósteres es relativamente pequeña (especialmente al compararla con LightFM), lo que puede deberse a que el modelo ya posee una alta capacidad para aprender interacciones complejas entre las características de usuarios e ítems mediante su componente profundo, capturando gran parte de las relaciones relevantes incluso utilizando únicamente las características base.

En DeepFM la diversidad mejora al agregar los pósteres tanto en el modelo + P como en el +S +P (Un menos ILS implica una mayor diversidad). Esto no se debe a que los embeddings sean más diversos, ya que se comparan todos con la misma base (de los embeddings fusionados). Esto implica que agregar los pósteres le permiten al modelo elegir ítems distintos entre sí, capturando información nueva que no estaba presente en los otros datos.

7.3 Casos particulares

Para analizar en profundidad al recomendador se seleccionó un usuario en particular en los modelos, permitiendo observar las diferencias entre los modelos recomendadores.

Para DeepFM se seleccionó al usuario de id 23, este tiene una larga lista de ítems calificados positivamente (la lista completa se puede ver en GitHub), de las cuales se destacan "Star Wars", "Súperman", "The Godfather", "Back To The Future", entre otras.

Table 3: DeepFM base

#	Película	Hit
1	The Godfather	Sí
2	Blade Runner	Sí
3	Godfather: Part II	Sí
4	A Close Shave	–
5	The Thing	–
6	E.T.	Sí
7	Rope	–
8	Dogma	Sí
9	The Professional	–
10	The Odd Couple	–
Total hits		5/10

Table 4: DeepFM text

#	Película	Hit
1	Close Shave, A	–
2	The Killer	Sí
3	The Godfather	Sí
4	Wallace & Gromit	Sí
5	Rope	–
6	Hard-Boiled	Sí
7	Star Trek: First Contact	Sí
8	The Professional	–
9	From Russia with Love	Sí
10	Stock Lock & 2 Barrels	Sí
Total hits		7/10

Table 5: DeepFM img

#	Película	Hit
1	The Godfather,	Sí
2	The Killer	Sí
3	Hard-Boiled	Sí
4	Blade Runner	Sí
5	Godfather: Part II	Sí
6	Wallace & Gromit	Sí
7	Rope	–
8	Close Shave, A	–
9	Speed	Sí
10	The Professional	–
Total hits		7/10

Table 6: DeepFM fused

#	Película	Hit
1	The Godfather	Sí
2	A Close Shave	–
3	Godfather: Part II	Sí
4	The Killer	Sí
5	Rope	–
6	Wallace & Gromit	Sí
7	The Mummy	Sí
8	Escape from New York	Sí
9	Retroactive	–
10	Bound	Sí
Total hits		7/10

Se observa una menor cantidad de aciertos en el modelo DeepFM base, mientras que los otros empatan con 7 aciertos. Además, se puede ver que en DeepFM con pósteres los aciertos se concentran en la parte superior del ranking.

Además, el modelo base recomienda películas más populares y no logra capturar el nicho del noir de Hong-Kong (Hard-Boiled y The Killer), que si capturan los otros modelos. Esto se debe a que es

un tema muy específico que no se ve reflejado en el género o en las relaciones usuario ítem pasadas, pero si en el póster y en la sinopsis. Esto también nos da la intuición de que en ciertos casos tanto las sinopsis como los pósters nos entregan información similar, llevando a recomendaciones similares mediante datos distintos.

El modelo de imágenes es el único en recomendar blade runner (que fué un acierto). Podemos explicar eso con la similitud visual del póster de blade runner con otras películas calificados positivamente por el usuario.



Figure 6: Blade Runner



Figure 7: The killer



Figure 8: Hard Boiled

Se observan similitudes, en paleta de colores, poses, composición y presencia de armas entre otros.

En LightFM se analiza el usuario 9, este calificó positivamente películas como Jumanji, Magic Hunter, Dumbo, The princess bride, entre otras, se puede ver la lista completa en el repositorio de GitHub. Algo relevante es que el usuario tiene un historial amplio, además suele ver comedias y dramas.

Table 7: LightFM base

#	Película	Hit
1	Kim	–
2	Suture	–
3	Yankee Zulu	–
4	Terminal Velocity	–
5	Full Tilt Boogie	–
6	Who's Afraid of Virginia Woolf?	–
7	Indian Summer	–
8	Hour of the Pig, The	Sí
9	Prom Night IV	–
10	Jefferson in Paris	–
Total hits		1/10

Table 8: LightFM text

#	Película	Hit
1	Unhook the Stars	Sí
2	Suture	–
3	Happiest Millionaire, The	Sí
4	Toy Story	Sí
5	Hour of the Pig, The	Sí
6	Gremlins	Sí
7	Kim	–
8	Friday the 13th Part 3: 3D	–
9	Drive Me Crazy	–
10	Billy's Hollywood Screen Kiss	–
Total hits		5/10

Table 9: LightFM img

#	Película	Hit
1	Unhook the Stars	Sí
2	Hour of the Pig, The	Sí
3	Who's Afraid of Virginia Woolf?	–
4	Yankee Zulu	–
5	Century of Cinema, A	–
6	Something to Sing About	Sí
7	M*A*S*H	–
8	Speed 2: Cruise Control	Sí
9	Falcon and the Snowman, The	–
10	Leave It to Beaver	–
Total hits		4/10

Table 10: LightFM fused

#	Película	Hit
1	Kim	–
2	Leave It to Beaver	–
3	Unhook the Stars	Si
4	Yankee Zulu	–
5	Female Perversions	–
6	Who's Afraid of Virginia Woolf?	–
7	Terminal Velocity	–
8	Jefferson in Paris	–
9	Hour of the Pig, The	Si
10	One Tough Cop	Si
Total hits		3/10

Como se puede observar, el modelo base es el de menos aciertos, seguido por el fusionado, el de pósteres y por último el de sinopsis. Esto es consistente con los resultados obtenidos anteriormente.

El modelo base tiene un único acierto: "The Hour of the Pig", el cual es un drama, además los otros ítems recomendados suelen ser comedias o dramas, lo que apunta a que el modelo está basándose fuertemente en el género, lo cual explica la baja diversidad vista en incisos anteriores.

En el modelo de pósteres se pueden ver aciertos que no observamos en los modelos que no consideran la imagen, estos son "Speed 2: Cruise Control" y "Something to Sing About". Esto sugiere que agregar los pósteres entrega información adicional para el modelo, distinta a la que entrega el conjunto de datos original o a la sinopsis. Al tener un historial muy amplio es difícil encontrar a un único responsable de esta recomendación, a continuación se ve "Speed 2: Cruise Control" y algunos candidatos.

**Figure 9: Speed 2: Cruise Control****Figure 10: G.I. Jane****Figure 11: Bound**

8 Conclusiones

Este trabajo evaluó el impacto de incorporar información multimodal en sistemas de recomendación de películas mediante embeddings de texto e imagen.

Los resultados fueron mixtos, para DeepFM la fuente que más contribuye son los pósteres, mientras que para LightFM fueron las sinopsis.

Asimismo, se comprobó que DeepFM supera ampliamente a LightFM en las métricas de precisión y recuperación, evidenciando una mayor capacidad para modelar las preferencias de los usuarios.

La incorporación de imágenes incrementa la precisión y recall en DeepFM, además de esto permite obtener recomendaciones más diversas y novedosas, lo que representa una ventaja desde la perspectiva de la experiencia del usuario. Todo esto apunta a que entrega información relevante no presente en las sinopsis ni en el conjunto de datos base.

Por último, el uso de cross attention para generar un modelo mixto que considere pósteres y sinopsis no generó resultados mejores que las implementaciones individuales. Esto puede ser resultado de la implementación actual, por lo que es relevante probar otras formas para fusionar los embeddings, evitando la generación de ruido y la disminución de la precisión. Una opción para hacer esto es MLP (Perceptrón Multicapa)

Referencias

- [1] Pan, L. Pan, Z., Cai, F., Chen, H. (2026). Multimodal recommender systems: A survey of representation, modeling, and optimization. Information Fusion, 128, 103991 <https://www.sciencedirect.com/science/article/abs/pii/S156625352501053X>
- [2] Saluja, A., Castro, S., Yan, B., Rastogi, A. (2026, febrero 24). MediaFM: The multimodal AI foundation for media understanding at Netflix. Netflix Technology Blog. <https://netflixtechblog.com/mediafm-the-multimodal-ai-foundation-for-media-understanding-at-netflix-e8c28df82e2d>
- [3] Xu, J., Chen, Z., Yang, S., Li, J., Wang, W., Hu, X., ... Ngai, E. (2026). A survey on multimodal recommender systems: Recent advances and future directions. IEEE Transactions on Multimedia.
- [4] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in International Conference on Learning Representations, 2020
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," arXiv preprint arXiv:1810.04805, 2018
- [6] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., Bengio, Y. (2014, October). Learning phrase representations using RNN encoder-decoder for statistical machine translation. In Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP).
- [7] Giah, R., Yao, K., Kolipara, S., Zhao, K., Mirjalili, V., Xu, J., ... Achan, K. (2025, September). V1-clip: Enhancing multimodal recommendations via visual grounding and llm-augmented clip embeddings. In Proceedings of the Nineteenth ACM Conference on Recommender Systems (pp. 482-491).
- [8] J. Xu, Z. Chen, S. Yang, J. Li, H. Wang, and E. C.-H. Ngai, "Mentor: Multi-level self-supervised learning for multimodal recommendation," arXiv preprint arXiv:2402.19407, 2024.

- [9] R. K. Ong and A. W. Khong, "Spectrum-based modality representation fusion graph convolutional network for multimodal recommendation," arXiv preprint arXiv:2412.14978, 2024.
- [10] Kaggle. MovieLens 1M Dataset <https://www.kaggle.com/datasets/odedgolden/movielens-1m-dataset>
- [11] TMDb <https://developer.themoviedb.org/docs/append-to-response>
- [12] Klimashevskaya, A., Jannach, D., Elahi, M., & Trattner, C. (2024). *A Survey on Popularity Bias in Recommender Systems*. User Modeling and User-Adapted Interaction, 34(5), 1777–1834
- [13] sentence-transformers/clip-ViT-B-32 · Hugging Face. (2021, 26 febrero). <https://huggingface.co/sentence-transformers/clip-ViT-B-32>
- [14] AIML.com. (2025). Cross-Attention vs Self-Attention Explained. AIML.com. <https://aiml.com/explain-cross-attention-and-how-is-it-different-from-self-attention/>
- [15] Hugging Face. 2022. BLIP model documentation and Salesforce/blip-itm-base-coco checkpoint. https://huggingface.co/docs/transformers/model_doc/blip#transformers.BlipForImageTextRetrieval
- [16] Lyst. Learning-to-rank using the WARP loss — LightFM documentation. https://making.lyst.com/lightfm/docs/examples/warp_loss.html
- [17] Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1412.6980>
- [18] Guo, H., Tang, R., Ye, Y., Li, Z., & He, X. (2017). DeepFM: A Factorization-Machine based Neural Network for CTR Prediction. *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence (IJCAI-17)*, 1725–1731. <https://arxiv.org/abs/1703.04247>