



SEMINARIO · SISTEMAS RECOMENDADORES

Large Language Models meet Collaborative Filtering


Un sistema recomendador eficiente y “all-round” basado en LLM (A-LLMRec)

Kim, Kang, Choi, Kim, Yang & Park
KAIST · NAVER Corporation — KDD 2024

Curso: Sistemas Recomendadores Integrantes Paula Elicer, Ian Fuenzalida, Maximiliano Navia 04/06/2026


Escenario: Película Nueva (Cold-start)

- Pocas o nulas interacciones previas.
- El filtrado colaborativo tradicional falla por falta de datos.
- **Potencial:** Información textual rica (título, descripción, género).
- **Solución LLM:** Interpreta el contenido para realizar recomendaciones iniciales.




Escenario: Películas Populares (Warm)

- Miles de interacciones reales disponibles.
- El filtrado colaborativo es altamente preciso.
- Supera a modelos basados puramente en texto.
- **Desafío:** No perder este conocimiento al integrar LLMs.



Escenario: Película Nueva (Cold-start)


- Pocas o nulas interacciones previas.
- El filtrado colaborativo tradicional falla por falta de datos.
- **Potencial:** Información textual rica (título, descripción, género).
- **Solución LLM:** Interpreta el contenido para realizar recomendaciones iniciales.



A - LLMRec

Escenario: Películas Populares (Warm)

- Miles de interacciones reales disponibles.
- El filtrado colaborativo es altamente preciso.
- Supera a modelos basados puramente en texto.
- **Desafío:** No perder este conocimiento al integrar LLMs.



Integración de Filtrado Colaborativo y LLMs

Filtrado Colaborativo (CF)

Basado en **patrones de interacción** usuario–ítem.

Éxito en escenarios Warm: Cuando existe suficiente historial.

Problema: Cold-start. El rendimiento cae drásticamente ante falta de datos iniciales.

LLMs

Uso de **información textual** (títulos, descripciones, atributos).

Fortaleza en Cold-start: Representa mejor ítems poco observados.

Interpretan contenido y se adaptan vía **prompts o fine-tuning**.

Cold-start vs. Warm

❄ Escenario COLD (frío)

Los modelos basados en **texto o LLMs** mejoran el desempeño en escenarios cold.

Limitación: No necesariamente mantienen un buen rendimiento en escenarios warm.

Es ideal cuando hay poca información de interacción disponible.

🔥 Escenario WARM (cálido)

Los modelos tradicionales de **Filtrado Colaborativo (CF)** siguen siendo muy fuertes en warm.

Capturan patrones colaborativos directos que el texto no siempre refleja.

Es fundamental cuando existe suficiente historial de interacciones.

Hasta ~90% de las interacciones y de los ingresos vienen de ítems warm.

El Problema: Enfoques previos privilegian un lado u otro, pero no los integran de manera efectiva. El objetivo es resolver la brecha entre el conocimiento textual y el colaborativo.

Motivación: cerrar la brecha de conocimiento

Recomendación secuencial: predecir el próximo ítem


¿Qué se recomienda?

Objetivo: predecir cuál será el siguiente ítem con el que interactuará

Entrada: la secuencia ordenada de ítems con que un usuario ha interactuado.

Salida: el próximo ítem que probablemente consumirá.

Se observa el historial del usuario y se asigna mayor probabilidad al próximo ítem correcto



Ej: viste Toy Story → Buscando a Nemo → ¿qué sigue?

A-LLMRec: un recomendador “all-round”

Idea central: dejar que un LLM use directamente el conocimiento colaborativo de un CF-RecSys ya entrenado, sin hacer fine-tuning ni del CF ni del LLM. Solo se entrena una red de alineamiento.



Model-agnostic

Cualquier CF-RecSys existente puede integrarse; actualizarlo es solo reemplazarlo.



Eficiente

La red de alineamiento es lo único entrenable: ~2,53× más rápido en entrenamiento que TALLRec.



Cold + Warm

Supera al CF en warm y a los LLM en cold: bueno en todos los escenarios.

Model-agnostic: independiente del modelo CF concreto que se use **Red de alineamiento:** redes pequeñas (MLP) que conectan CF y LLM **Fine-tuning:** reentrenar los pesos de un modelo grande (costoso)

Tabla comparativa de enfoques

Enfoque	Información que usa	Ventaja	Limitación	Mejor escenario
Collaborative Filtering	IDs + historial usuario–ítem	Capta conocimiento colaborativo	Falla sin interacciones	Warm
Modality-aware	Texto/imagen del ítem	Aprovecha la modalidad	Pierde señal colaborativa	Cold
LLM-based	Texto + razonamiento del LLM	Comprensión semántica rica	Caro (fine-tuning); flojo en warm	Cold · Cross-domain · Few-shot
A-LLMRec	CF (embeddings) + texto + LLM	Alinea CF↔LLM sin fine-tuning	Depende de un buen CF base	Cold y Warm (all-round)

Cross-domain: entrenar en un dominio (películas) y evaluar en otro (videojuegos) **Few-shot:** entrenar con muy pocos usuarios **All-round:** funciona bien en todos los escenarios



A-LLMRec

Aprender y predecir siguiente ítem dado comportamiento secuencial del usuario

$$\max_{\Theta} \prod_{u \in \mathcal{U}} \prod_{k=1}^{|S^u|-1} p(i_{k+1}^u \mid S_{1:k}^u; \Theta)$$

$\mathcal{D} = (\mathcal{U}, \mathcal{I}, \mathcal{T}, \mathcal{S})$: dataset histórico con usuarios, items, textos y secuencias


$\mathcal{S}^u = (i_1^u, i_2^u, \dots, i_{|S^u|}^u)$: secuencia de interacciones del usuario u

$\mathbf{E} \in \mathbb{R}^{|\mathcal{I}| \times d}$: matriz de embeddings de items

$\mathbf{E}_{1:k}^u = (\mathbf{E}_{i_1^u}, \dots, \mathbf{E}_{i_k^u}) \in \mathbb{R}^{k \times d}$: embeddings de la secuencia hasta el paso k

A-LLMRec

Vista general del modelo




(a) Framework Overview

1. Recepción de secuencia de ítems de usuario
2. Secuencia entra al CF-SysRec (ya entrenado)
3. A-LLMRec (dos etapas de pre-entrenamiento)
4. Input de prompt
5. Prompt ingresa a LLM

Token space: espacio vectorial donde el LLM representa palabras/tokens **Congelado:** con pesos fijos, no se reentrena **SBERT:** único componente que se afina durante el entrenamiento

A-LLMRec

Etapa 1: Alineación Colaborativa-Textual



a. **SBERT** fine-tuneado para extracción de embeddings

b. **Encoders:** items y texto a espacio latente

$$f_I^{enc}: \mathbb{R}^d \rightarrow \mathbb{R}^{d'}$$

$$f_T^{enc}: \mathbb{R}^{768} \rightarrow \mathbb{R}^{d'}$$


Item/Texto embedding latentes:

$$e_i = f_I^{enc}(E_i)$$

$$q_i = f_T^{enc}(Q_i)$$

A-LLMRec

Etapa 1: Alineación Colaborativa-Textual



c. **Space matching** en espacio latente

$$\mathcal{L}_{\text{matching}} = \mathbb{E}_{\mathcal{S}^u \in \mathcal{S}} \left[\mathbb{E}_{i \in \mathcal{S}^u} [MSE(e_i, q_i)] \right]$$

Representación codificada:

$$Q_i = SBERT(\text{"Title : } t^i, \text{ Description : } d^i\text{"})$$



A-LLMRec Etapa 1: Alineación Colaborativa-Textual

d. **Decoders:** evitar over-smoothed representation (evitar colapso de representaciones al minimizar MSE)

$$\mathcal{L}_{\text{item-recon}} = \mathbb{E}_{\mathcal{S}^u \in \mathcal{S}} \left[\mathbb{E}_{i \in \mathcal{S}^u} [MSE(E_i, f_I^{dec}(f_I^{enc}(E_i)))] \right]$$

$$\mathcal{L}_{\text{text-recon}} = \mathbb{E}_{\mathcal{S}^u \in \mathcal{S}} \left[\mathbb{E}_{i \in \mathcal{S}^u} [MSE(Q_i, f_T^{dec}(f_T^{enc}(Q_i)))] \right]$$



A-LLMRec Etapa 1: Alineación Colaborativa-Textual

e. **Pérdida de Recomendación:** distinguir entre interacciones positivas y negativas

$$\mathcal{L}_{\text{rec}} = - \sum_{\mathcal{S}^u \in \mathcal{S}} [\log(\sigma(s(\mathbf{x}_{|\mathcal{S}^u|-1}^u, f_I^{\text{dec}}(f_I^{\text{enc}}(E_{i_{|\mathcal{S}^u|}^u})))) + \log(1 - \sigma(s(\mathbf{x}_{|\mathcal{S}^u|-1}^u, f_I^{\text{dec}}(f_I^{\text{enc}}(E_{i_{|\mathcal{S}^u|}^{u,-}}))))]$$

$\mathbf{x}_{|\mathcal{S}^u|-1}^u = \text{CF-RECSYS}(\mathcal{S}_{1:|\mathcal{S}^u|-1}^u) \in \mathbb{R}^d$: representación del usuario extraída de CF-RecSys, después de haber interactuado con el último ítem de la secuencia

$E_{i_{|\mathcal{S}^u|}^{u,-}}$: embedding de un ítem negativo



A-LLMRec Etapa 1: Alineación Colaborativa-Textual

f. Pérdida Total Etapa 1:


$$\mathcal{L}_{\text{stage-1}} = \mathcal{L}_{\text{matching}} + \alpha \mathcal{L}_{\text{item-recon}} + \beta \mathcal{L}_{\text{text-recon}} + \mathcal{L}_{\text{rec}}$$

Importante: encoder de items queda entrenado para producir **joint collaborative-text embedding**

$$e_i = f_I^{\text{enc}}(E_i)$$

$$q_i = f_T^{\text{enc}}(Q_i)$$

A-LLMRec Etapa 2: Alineación con LLM




1. Proyección de embeddings al espacio de LLM

$$\mathbf{O}_u = F_U(\mathbf{x}^u) \in \mathbb{R}^{d^{\text{token}}}$$

$$\mathbf{O}_i = F_I(\mathbf{e}_i) \in \mathbb{R}^{d^{\text{token}}}$$

Embedding proyectado de usuario u y de los joint collaborative-text embedding del item i se pueden usar como inputs en LLM

A-LLMRec Etapa 2: Alineación con LLM



2. Diseño de prompt

Se integran directamente las representaciones del usuario O_u y el joint collaborative-text embeddings O_i en el texto del espacio de token.

LLM
Input:

[User Representation] is a user representation.
 This user has watched [HISTORY (Item Titles, Item Emb)]
 in the past. Recommend a movie for this user to watch
 next from the following set of movie titles,
 [CANDIDATE (Item Titles, Item Emb)]. The
 recommendation is

LLM
Output:

[Next Item Title]



A-LLMRec Etapa 2: Alineación con LLM

3. Objetivo de aprendizaje Etapa 2

$$\max_{\Theta} \sum_{S^u \in S} \sum_{k=1}^{|y^u|} \log(P_{\theta, \Theta}(y_k^u | p^u, y_{<k}^u))$$

θ : parámetros aprendibles F_U F_I y^u : título del siguiente ítem del usuario u

Θ : parámetros congelados de LLM y_k^u : k-ésimo token de y^u

p^u : input prompt $y_{<k}^u$: tokens prev y_k^u ; a

Datasets, métrica y protocolo

4 datasets de Amazon (McAuley) con título y descripción de ítems:

Dataset	#Usuarios	#Ítems	#Interacc.	Long. prom.
Movies and TV	297.498	59.944	3.409.147	11,46
Video Games	64.073	33.614	598.509	8,88
Beauty	9.930	6.141	63.953	6,44
Toys	30.831	61.081	282.213	9,15

Movies/Games = gran/media escala (warm).
Beauty = pequeño y frío.
Toys = más ítems que usuarios. Variar la estadística estresa al modelo en condiciones distintas.

Entrena sobre Movies and TV

Métrica: Hit@1

- ¿El ítem correcto quedó en el puesto #1?
- Promedio sobre todos los usuarios (0–1).
- Hit@1 mayor = más aciertos exactos = mejor.


Protocolo de evaluación

- Último ítem → test
penúltimo → validación
resto → entrenamiento.
-
- En Test: 1 ítem positivo vs. 19 negativos (ranking entre 20).

Hit@1: tasa de veces que el ítem correcto queda en el puesto 1 **Baseline:** modelo de referencia con que se compara **Long. prom.:** número medio de ítems por secuencia de usuario

A-LLMRec gana en (casi) todos los escenarios

Desempeño general — Hit@1 (Tabla 1)



General

Mejor o casi mejor Hit@1 en los 4 datasets; supera a LLM-Only y a TALLRec.



Cold y Warm

Único que gana en ambos (Movies cold 0.57 vs SASRec 0.26; warm 0.69).



Cold user · Few-shot · Cross-domain

Lidera con pocos datos; la variante SBERT brilla cuando faltan interacciones.

Lectura: alinear embeddings de alta calidad con el LLM resuelve cold y warm a la vez.

Hit@1: fracción de aciertos en la posición 1 **A-LLMRec (SBERT):** variante que usa el encoder de texto para ítems sin historial **Cross-domain:** entrenado en Movies, evaluado en Video Games

Eficiencia, ablations y propiedad model-agnostic

⚡ Eficiencia vs. TALLRec

2,53×

más rápido en entrenamiento

1,71×

más rápido en inferencia


Porque NO hace fine-tuning del LLM: solo entrena la red de alineamiento.

🧪 Ablation studies

- Quitar cualquier pérdida de Stage 1 baja el Hit@1.
- Sin L matching o sin reconstrucción → caída fuerte.
- Sin joint embedding en el prompt → gran pérdida (Movies 0.62→0.12).
- Embedding aleatorio empeora: la señal colaborativa importa.

🔌 Model-agnostic

Hit@1 en Toys — el CF base sube al integrarlo:



- 1: NCF (Neural Collaborative Filtering)
2: GRU4Rec (secuencial, basado en redes recurrentes)
3: NextItNet (secuencial, basado en convoluciones)
4: SasRec (secuencial, basado en self-attention)

Ablation study: quitar componentes para medir su aporte **Inferencia:** fase de predicción ya entrenado el modelo **Model-agnostic:** sirve con cualquier CF base; al cambiarlo mejora el modelo



CONCLUSIONES

Combinar lo colaborativo con lo textual, sin reentrenar todo el LLM

- A-LLMRec deja congelados el CF-RecSys y el LLM, y solo entrena redes de alineamiento.
- Proyecta usuarios e ítems al espacio del LLM → buen desempeño en cold y warm a la vez.
- Eficiente y model-agnostic (reemplazable por mejores CF).

Uso de IA

Claude cowork

Generación de Presentación <https://claude.com/product/cowork>

Referencias principales (rol en el paper)

[20] SASRec — Kang & McAuley (2018)

Modelo de filtrado colaborativo secuencial base de A-LLMRec

[2] TALLRec — Bao et al. (2023)

LLM con fine-tuning (rival frente al cual es más eficiente)

[18] SBERT — Reimers & Gurevych (2019)

Encoder de texto que genera los embeddings de las descripciones de los items

[18] LoRA — Hu et al. (2022)

Fine-tuning eficiente usado por TALLRec y que ALLREC evita

[13, 32] Amazon datasets — McAuley et al.

Fuente de los 4 datasets de evaluación.