

Aligning Distillation for Cold-start Item Recommendation

Un framework de destilación de conocimiento para alinear ítems fríos con ítems cálidos en sistemas de recomendación

AUTORES Feiran Huang · Zefan Wang · Xiao Huang · Yufeng Qian · Zhetao Li · Hao Chen

PUBLICADO EN Conferencia internacional ACM SIGIR celebrada del 3 al 5 de junio de 2023 · Taipei, Taiwán

El problema del cold-start

Los sistemas de recomendación modernos aprenden embeddings a partir del historial de interacción usuario-ítem. Pero cada segundo se generan miles de ítems nuevos sin historial (videos, streams, publicaciones) que el sistema no sabe cómo evaluar.



ÍTEMS WARM (CÁLIDOS)

Tienen historial de interacción

Embeddings precisos

Aprendidos del comportamiento real de los usuarios.

Recomendación robusta

El sistema sabe a qué usuarios mostrarlos.



ÍTEMS COLD (FRÍOS)

Sin interacciones registradas

Solo características de contenido

Tags, descripciones, atributos del ítem.

Recomendación incierta

El sistema no conoce la intención del usuario.

Definición formal del problema

NOTACIÓN

 $\mathcal{U}, \mathcal{I}$

Conjuntos de usuarios e ítems

 $\mathcal{I}_w, \mathcal{I}_c$

Ítems warm (con historial) / cold (sin historial)

 eu, ei

Embeddings de comportamiento aprendidos

 ci

Características de contenido del ítem i

TRES TAREAS DE EVALUACIÓN

Recall (Overall)

Ranking conjunto de ítems warm y cold

$$\text{rank}(\{\hat{y}_{u,i}^{(w)}, \forall i \in \mathcal{I}_w\} \cup \{\hat{y}_{u,i}^{(c)}, \forall i \in \mathcal{I}_c\}, K)$$

Recall (Warm)

Ranking solo de ítems con historial

$$\text{rank}(\{\hat{y}_{u,i}^{(w)}, \forall i \in \mathcal{I}_w\}, K)$$

Recall (Cold)

Ranking solo de ítems sin historial

$$\text{rank}(\{\hat{y}_{u,i}^{(c)}, \forall i \in \mathcal{I}_c\}, K)$$

Dos familias, dos limitaciones

Los modelos actuales abordan el cold-start, pero no la diferencia inherente entre recomendar por comportamiento vs. por contenido.



MODELOS GENERATIVOS

DeepMusic · MetaEmb · GAR

IDEA

Generan embeddings sintéticos para ítems cold a partir de sus características de contenido.



LIMITACIÓN

Tratan warm y cold de forma independiente: la distribución de scores no coincide y el sistema sobre-recomienda ítems warm o cold de forma sesgada.



MODELOS DE DROPOUT

DropoutNet · Heater · CLCRec

IDEA

Durante el entrenamiento descartan aleatoriamente los embeddings de comportamiento para forzar robustez al frío.



LIMITACIÓN

Sacrifican el rendimiento en ítems warm: el dropout altera embeddings precisos que el backbone ya había aprendido bien.

LA BRECHA Ninguno modela las diferencias inherentes entre recomendar por **comportamiento** (warm) vs. por **contenido** (cold).

ALDI: Aligning Distillation

Una propuesta que no sustituye al teacher: lo alinea con un nuevo student



RESULTADOS QUE LA EVIDENCIA RESPALDA

+12%

Mejora en recomendación overall

vs. mejor baseline en CiteULike (MF)

3

Backbones probados

Matrix Factorization, NCF, LightGCN

2

Datasets evaluados


CiteULike y XING

ARQUITECTURA DE ALINEACIÓN





Teacher: Predice relaciones basándose en embeddings de comportamiento real.

$$\hat{y}_{u,i}^{(t)} = e_u^T \cdot e_i$$



Estudiante (Student): Predice usando solo características de contenido.

$$\hat{y}_{u,i}^{(s)} = f_U(e_u)^T \cdot f_I(c_i)$$



TRES DIFERENCIAS INHERENTES

1. Distribución de Ratings

Los **teachers** distinguen claramente entre pares positivos y negativos. Los **students** suelen tener distribuciones solapadas.

2. Diferencia de Ranking

La capacidad de puntuar un ítem positivo por encima de uno negativo varía entre ambos modelos.

3. Capacidad de Identificación

Los **teachers** identifican fácilmente patrones de interés; los **estudiantes** basados en contenido son menos efectivos.


TRES DIFERENCIAS INHERENTES

1. Distribución de Ratings


Los **teachers** distinguen claramente entre pares positivos y negativos. Los **students** suelen tener distribuciones solapadas.



TEACHER




STUDENT



TRES DIFERENCIAS INHERENTES



TEACHER




2. Diferencia de Ranking

La capacidad de puntuar un ítem positivo por encima de uno negativo varía entre ambos modelos.




STUDENT




TRES DIFERENCIAS INHERENTES



TEACHER



STUDENT



3. Capacidad de Identificación

Los **teachers** identifican fácilmente patrones de interés; los **estudiantes** basados en contenido son menos efectivos.

| FUNCIONES DE PÉRDIDA ALDI

El objetivo es minimizar la pérdida básica más las tres componentes de destilación:

$$\min L_{\text{basic}} + \alpha L_{\text{rate}} + \beta L_{\text{rank}} + \gamma L_{\text{iden}}$$

| FUNCIONES DE PÉRDIDA ALDI

El objetivo es minimizar la pérdida básica más las tres componentes de destilación:

$$\min L_{\text{basic}} + \alpha L_{\text{rate}} + \beta L_{\text{rank}} + \gamma L_{\text{iden}}$$

➤ **L_rate:** Sincroniza las distribuciones de ratings para evitar sobre-recomendación de un tipo de ítem.

$$\text{Dis}(\mathcal{D}_{\mathcal{B}_I}^{(t)}, \mathcal{D}_{\mathcal{B}_I}^{(s)}) = \frac{1}{|\mathcal{B}|} \sum_{(u,i,j) \in \mathcal{B}} \left| \hat{y}_{ui}^{(t)} - \hat{y}_{ui}^{(s)} \right|^2,$$

$$\text{Dis}(\mathcal{D}_{\mathcal{B}_J}^{(t)}, \mathcal{D}_{\mathcal{B}_J}^{(s)}) = \frac{1}{|\mathcal{B}|} \sum_{(u,i,j) \in \mathcal{B}} \left| \hat{y}_{uj}^{(t)} - \hat{y}_{uj}^{(s)} \right|^2,$$

$$\mathcal{L}_{\text{rate}} = \text{Dis}(\mathcal{D}_{\mathcal{B}_I}^{(t)}, \mathcal{D}_{\mathcal{B}_I}^{(s)}) + \text{Dis}(\mathcal{D}_{\mathcal{B}_J}^{(t)}, \mathcal{D}_{\mathcal{B}_J}^{(s)}),$$

| FUNCIONES DE PÉRDIDA ALDI

El objetivo es minimizar la pérdida básica más las tres componentes de destilación:

$$\min L_{\text{basic}} + \alpha L_{\text{rate}} + \beta L_{\text{rank}} + \gamma L_{\text{iden}}$$

> **L_rank:** Utiliza la discrepancia BPR para alinear la capacidad de ordenamiento.

$$\begin{aligned} r_{uij}^{(t)} &= \sigma \left(\hat{y}_{ui}^{(t)} - \hat{y}_{uj}^{(t)} \right), \\ r_{uij}^{(s)} &= \sigma \left(\hat{y}_{ui}^{(s)} - \hat{y}_{uj}^{(s)} \right), \end{aligned} \quad \sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\mathcal{L}_{\text{rank}} = - \sum_{(u,i,j) \in \mathcal{B}} \left(r_{uij}^{(t)} \ln r_{uij}^{(s)} + (1 - r_{uij}^{(t)}) \ln(1 - r_{uij}^{(s)}) \right).$$

| FUNCIONES DE PÉRDIDA ALDI

El objetivo es minimizar la pérdida básica más las tres componentes de destilación:

$$\min L_{\text{basic}} + \alpha L_{\text{rate}} + \beta L_{\text{rank}} + \gamma L_{\text{iden}}$$

> **L_iden:** Mide la distancia entre embeddings de ítems positivos vs. promedios de muestreo negativo.

$$d_{ij}^{(t)} = \sigma(\mathbf{e}_i^\top \cdot (\mathbf{e}_i - \mathbf{e}_j)),$$

$$d_{ij}^{(s)} = \sigma(f_I(\mathbf{c}_i)^\top \cdot (f_I(\mathbf{c}_i) - f_I(\mathbf{c}_j))),$$

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\mathcal{L}_{iden} = - \sum_{i \in \mathcal{B}_I} \sum_{j \in \mathcal{B}_J} \left(d_{ij}^{(t)} \ln d_{ij}^{(s)} + (1 - d_{ij}^{(t)}) \ln(1 - d_{ij}^{(s)}) \right),$$

| FILTRADO DE MAESTROS POCO CONFIABLES

No todos los ítems warm son buenos maestros. Aquellos con pocas interacciones tienen embeddings ruidosos.

Solución: Pesos dinámicos basados en la frecuencia de interacción (tanh variante):

$$w_i = \frac{2}{1 + e^{-\omega N_i / N}} - 1$$

EVALUACIÓN EXPERIMENTAL



CiteULike

- Recomendación de artículos académicos (basado en texto y citas).
- 5,551 usuarios, 16,980 artículos académicos.
- Embeddings de 300 dimensiones.



XING

- Plataforma profesional para recomendación de empleos (alta escala y datos tabulares).
- 106,881 usuarios, 20,519 empleos.
- Embeddings de 2,738 dimensiones.



Backbones

Para probar que ALDI funciona en cualquier sistema, se integró en: MF (Factorización de Matrices), NCF (Redes Neuronales) y LightGCN (Estado del arte en Grafos)

Métricas de Evaluación:

Recall@20, Capacidad de encontrar ítems relevantes.

NDCG@20 , Capacidad de poner los ítems relevantes en los primeros lugares.

En **tres escenarios**: Mixtos (Overall), Conocidos (Warm) y Nuevos (Cold).


RESULTADOS DE RENDIMIENTO

Comparativa de rendimiento sobre el dataset CiteULike (usando MF como modelo base):

Método	Overall NDCG	Overall RECALL	Cold NDCG	Cold RECALL
DeepMusic	0.0789	0.0956	0.1262	0.2141
DropoutNet	0.0670	0.0794	0.1356	0.2268
CLCRec	0.0992	0.1269	0.1347	0.2295
ALDI	0.1204	0.1618	0.155	0.2684

Mejora significativa: ALDI logra una **mejora promedio del 7.5%** sobre el mejor competidor en Recall frío, y una **mejora promedio del 4.8%** en NDCG frío, **mejorando a su vez el rendimiento general (Overall)**, resolviendo el problema histórico del "versus" entre ítems viejos y nuevos.

VISUALIZACIÓN DE LA ALINEACIÓN



(c) Identification difference comparison.

Comparación de Diferencias: Evalúa la distancia matemática exacta entre las representaciones latentes del Teacher y del Student en el espacio de características.

Reducción de la Brecha Latente: La gráfica demuestra cómo la curva de ALDI reduce drásticamente el desplazamiento de distribuciones, logrando una mímica casi perfecta de la variabilidad del espacio cálido.

Poder de Generalización: Al mapear la geometría profunda subyacente de los ítems en lugar de solo copiar los puntajes de salida, el modelo evita el sobreajuste y aprende a generalizar con robustez ante cualquier ítem nuevo inédito.

CONCLUSIONES CLAVE



De "Sustituir" a "Alinear"

El mayor aporte conceptual es no obligar al modelo a memorizar características (sustitución), sino enseñarle a imitar el comportamiento de recomendación (alineación).



Universalidad

ALDI no es un algoritmo que obligue a tirar el trabajo previo a la basura. Es un "envoltorio" que mejora cualquier arquitectura preexistente en una empresa.



Triple Alineación

Se demostró que para integrar un ítem frío se necesita alinear tres cosas juntas: el Rating (puntaje absoluto), el Ranking (posición relativa) y la Identificación (características internas).

Referencias y Trabajo Futuro

Referencias clave

Base Principal: Huang et al. (2023). Aligning Distillation for Cold-start Item Recommendation. SIGIR.

Backbone de Grafos: He et al. (2020). LightGCN: Simplifying and Powering Graph Convolution Network.

Baseline Histórico: Volkovs et al. (2017). DropoutNet: Addressing Cold Start in Recommender Systems.

Trabajo Futuro

Integración con LLMs: Utilizar Modelos de Lenguaje Grandes (ChatGPT, Llama) para extraer embeddings de texto mucho más ricos de la descripción de los ítems nuevos.

Cold-Start de Usuarios: Adaptar esta misma lógica de "maestro-estudiante" para cuando entra un usuario nuevo sin historial de compras.

¿Preguntas?