




Catalog-Native LLM: Speaking Item-ID Dialect

Paper: Shirkavand et al., ICLR 2026

Autores: Reza Shirkavand, Xiaokai Wei, Chen Wang, Zheng Hui, Heng Huang, Michelle Gong

Afiliaciones: University of Maryland, Roblox, University of Cambridge

arXiv: 2510.05125v2 [cs.CL], 11 Apr 2026

Presentan: Agustin Llambias, Amaya Quero, Larry Uribe



Martes 09 de Junio 2026

Filtrado colaborativo y LLM's

Los usuarios ya no solo quieren una lista de sugerencias estáticas; esperan agentes conversacionales que entiendan instrucciones en lenguaje natural, como explorar opciones o planificar compras.

En particular se busca fusionar dos mundos:


- **Filtrado Colaborativo (CF):** Eficientes procesando historiales de usuarios mediante secuencias de IDs abstractos, pero no pueden entender un ítem a partir de texto
- **Large Language Models (LLMs):** Modelos pre-entrenados que tienen un razonamiento semántico rico y entienden texto a la perfección, pero malos para encontrar patrones de comportamiento a partir de un historial del usuario



¿Como funciona un LLM?

1. Incrustaciones



Proceso que transforma el texto en una representación numérica con la que el modelo puede trabajar




¿Como funciona un LLM?

2. Bloque transformador

capa de autoatención multi-cabeza




capa de perceptrón multicapa



¿Como funciona un LLM?

3. Probabilidades de salida

Después de que la información pasó por los bloques transformadores, el modelo necesita convertir ese razonamiento profundo en una respuesta concreta.



Predicción del siguiente Item

Sea $\mathcal{U}$ un conjunto de usuarios e $\mathcal{I}$ un conjunto de ítems. Un usuario $u \in \mathcal{U}$ posee una secuencia histórica de interacciones $S = (i_1, i_2, \dots, i_t)$, donde cada $i \in \mathcal{I}$ está asociado a atributos textuales A_i (e.g., título, categoría). El objetivo formal es maximizar la verosimilitud logarítmica de predecir el próximo token objetivo i_{t+1} condicionado al prefijo de la secuencia multimodelo (texto e IDs):



$$\mathcal{L}(\Theta) = \sum \log P_{\Theta}(i_{t+1} | S_{1:t}, A_{1:t})$$

Problema central: entanglement

Al intentar fusionar estos mundos, trabajos previos expandieron el vocabulario de los LLMs para incluir tokens de IDs.

Sin embargo, al inyectar señales matemáticas de consumo y reglas gramaticales humanas en los mismos parámetros de la red neuronal (específicamente en la capa MLP/FFN), se produce una interferencia destructiva o "entanglement".

El modelo colapsa: pierde precisión al recomendar y degrada su capacidad para hablar fluidamente.



Otros modelos

Modelos secuenciales Base

- GRU4Rec, SASRec y BERT4Rec. introdujeron la autoatención a las recomendaciones
- son incapaces de soportar lenguaje natural.

LLM's en Recomendacion

- P5: transformo los catálogos en texto puro, lo cual es altamente ineficiente (desperdicia tokens) e ignora las señales puras de Filtro Colaborativo
- CoVE integraron tokens de ID pero utilizaron arquitecturas densas estándar, sufriendo la colisión semántica descrita en el problema.

Mixture of Experts (MoE)

- Se diseñó puramente para aumentar la capacidad de los modelos sin elevar el costo computacional, activando sub-redes mediante compuertas dinámicas.

Aporte frente a otros trabajos

Contexto Integrado

- Los autores mantienen la capa de Autoatención Multicabeza (Self-Attention) 100% compartida. Esto es vital para que las "Consultas" (Q) y "Claves" (K) del texto y los IDs se crucen

Procesamiento Profundo Aislado

- Se reemplaza la Red Perceptrón Multicapa (MLP/FFN) monolítica tradicional por una arquitectura Mixture-of-Experts (MoE) con dos sub-redes: un "Experto de Texto" (la red pre-entrenada original) y un "Experto de Ítems" (dedicada exclusivamente a los patrones de recomendación).

Enrutamiento Estático

- Descartan el enrutamiento dinámico estocástico usado en la industria por uno estático que separa explícitamente cada vector.
- Si el vector corresponde a un token lingüístico, entra al Experto de Texto; si es un token de ID, entra al Experto de Ítems.

IDIOMoE: separar texto e ítems en Transformer

Arquitectura propuesta

IDIOMoE parte desde un LLM decoder-only preentrenado y lo adapta para recomendación agregando tokens especiales de ítems.

La modificación principal ocurre dentro de cada bloque Transformer:

Componentes compartidos



- Self-Attention: compartida para todos los tokens.
- LayerNorm: compartida.
- Esto permite que texto e ítems se miren entre sí dentro de la misma secuencia.

Componentes separados

- Text Expert: conserva la FFN original del LLM y procesa lenguaje natural.
- Item Expert: nueva FFN especializada en Item IDs y patrones colaborativos.
- Token-Type Gate: decide el experto según el tipo de token.

Regla de routing

- Token de texto → Text Expert
- Token de ítem → Item Expert



Datasets Utilizados

Amazon datasets públicos

Se evalúa en seis catálogos pequeños de Amazon: Games, Instruments, Arts, Sports, Beauty y Toys. Estos datasets contienen secuencias históricas usuario-ítem y atributos textuales como título y categoría.

Versiones grandes 2023

También se evalúa en Beauty(23), Books(23) y Toys(23), que tienen vocabularios de ítems mucho más grandes.

Dataset industrial propietario

Además, los autores evalúan en un dataset interno de gran escala, con millones/cientos de millones de usuarios y decenas de miles de ítems. Este dataset es importante porque se acerca más a un escenario real de producción, pero no es reproducible públicamente.

Evaluacion: Baselines y modelos comparados

Modelos secuenciales clásicos

GRU4Rec, BERT4Rec y SASRec: aprenden patrones desde secuencias de ítems, pero no manejan lenguaje natural.

Modelos fuertes de recomendación moderna

HSTU: modelo secuencial basado en Transformers usado como baseline fuerte.

LLMs para recomendación

P5 / P5-CID, VIP5, E4SRec, ReAT y CoVE: adaptan LLMs a recomendación mediante prompts, adapters, alineamiento o expansión del vocabulario.

Controles del paper

ID Transformer, Text-Attr LLM, Item-LLM e IDIOMoE: sirven para aislar si la mejora viene de usar IDs, usar texto, agregar parámetros o separar expertos.

Resultados

Method	Games		Instruments		Arts		Sports		Beauty		Toys	
	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10
GRU4Rec ^{1,2}	0.0453	0.0895	0.0857	0.1207	0.0690	0.1088	0.0110	0.0204	0.0137	0.0283	0.0084	0.0176
Bert4Rec ^{1,2}	0.0366	0.0725	0.0739	0.1081	0.0575	0.0922	0.0099	0.0191	0.0170	0.0347	0.0099	0.0203
FDSEA ^{1,2}	0.0509	0.0988	0.0859	0.1249	0.0695	0.1190	0.0156	0.0288	0.0208	0.0407	0.0189	0.0381
S3-Rec ^{1,2}	0.0468	0.0903	0.0743	0.1123	0.0630	0.1030	0.0240	0.0385	0.0327	0.0647	0.0376	0.0700
TIGER ^{1,2}	0.0453	0.0857	0.0950	0.1221	0.0806	0.1167	0.0225	0.0400	0.0384	0.0648	0.0432	0.0712
VQ-Rec ¹	0.0329	0.0679	0.0891	0.1357	0.0844	<u>0.1386</u>	-	-	-	-	-	-
MISSRec ¹	0.0499	0.1048	0.0880	0.1361	0.0815	0.1321	-	-	-	-	-	-
P5-CID ¹	0.0454	0.0824	0.0704	0.1119	0.0662	0.0994	-	-	-	-	-	-
VIP5 ¹	0.0418	0.0758	0.0872	0.1071	0.0635	0.0859	-	-	-	-	-	-
MQLAGRec ¹	0.0548	0.1033	0.1060	<u>0.1375</u>	<u>0.0950</u>	0.1327	-	-	-	-	-	-
ReAT ²	-	-	-	-	-	-	0.0232	0.0422	0.0535	0.0722	0.0461	0.0776
E4SRec ²	-	-	-	-	-	-	0.0237	0.0410	0.0435	0.0758	0.0479	0.0798
IDGenRec ²	-	-	-	-	-	-	<u>0.0372</u>	0.0574	0.0541	0.0814	<u>0.0551</u>	0.0870
CoVE ³	-	-	-	-	-	-	0.0359	<u>0.0624</u>	<u>0.0593</u>	0.1009	0.0595	0.0986
SASRec	0.0547	0.0997	0.0749	0.1256	0.0927	0.1290	0.0289	0.0531	0.0541	<u>0.0945</u>	0.0542	<u>0.0958</u>
HSTU	0.0609	<u>0.1089</u>	0.0712	0.1214	0.0941	0.1301	0.0287	0.0515	0.0474	0.0863	0.0536	0.0933
ID Transformer	0.0392	0.0669	0.0709	0.0761	0.0824	0.1025	0.0081	0.0122	0.0314	0.0503	0.0271	0.0405
Text-Attr LLM	0.0464	0.0862	0.0778	0.1133	0.0938	0.1374	0.0251	0.0497	0.0390	0.0761	0.0502	0.0895
Item-LLM	0.0407	0.0734	0.0943	0.1095	0.0901	0.1272	0.0211	0.0369	0.0449	0.0738	0.0410	0.0704
IDIOMoE	<u>0.0605</u>	0.1102	<u>0.1054</u>	0.1385	0.1029	0.1409	0.0391	0.0674	0.0665	0.1104	0.0531	0.0927

Tabla de comparacion de resultados, muestra una clara mejora del sistema sobre los demas modelos


Resultados

Method	Beauty		Books		Toys	
	NDCG@10	HR@10	NDCG@10	HR@10	NDCG@10	HR@10
SASRec	0.0051	0.0101	0.0064	0.0128	0.0122	0.0245
HSTU	0.0130	0.0247	<u>0.0211</u>	<u>0.0410</u>	0.0149	0.0332
ID Transformer	0.0068	0.0095	0.0224	<u>0.0295</u>	0.0048	0.0079
Text-Attr LLM	0.0105	0.0163	0.0195	0.0290	0.0164	0.0300
Item-LLM	0.0082	0.0119	0.0174	0.0261	0.0079	0.0148
IDIOMoE	<u>0.0119</u>	<u>0.0228</u>	0.0224	0.0419	0.0186	0.0361

Tabla de comparacion de resultados, muestra solo las categorias con un mayor numero de usuarios e interacciones

Resultados

Tabla muestra la diferencia entre modelos de igual tamaño que utilizan la arquitectura MoE



Resultados

Resultados de dataset industrial

Method	Industrial $\Delta(\%)$		
	NDCG@10	HR@10	MRR
SASRec (baseline)		—	
HSTU	+10.5%	+2.7%	+13.2%
ID Transformer	+21.1%	+8.9%	+23.1%
Title-LLM	-81.8%	-87.6%	-98.4%
Text-Attr LLM	+25.4%	+14.1%	+25.9%
Item-LLM	+23.5%	+13.0%	+24.3%
IDIOMoE	+27.1%	+16.6%	+31.2%

Tabla de comparacion de resultados, compara de manera proporsional las mejoras en comparacion con el sistema Item-LLM

Resultados

En el dataset industrial propietario, IDIOMoE obtiene las mayores mejoras sobre SASRec:

* +27.1% NDCG@10

* +16.6% HR@10

* +31.2% MRR

Interpretación:

Este resultado es importante porque muestra que separar texto e IDs mediante expertos no solo funciona en benchmarks pequeños, sino también en un escenario industrial de gran escala.

Resultados

Al comparar los resultados, IDIOMoE muestra un desempeño competitivo y consistente tanto en catálogos pequeños como en catálogos de mayor tamaño. En los datasets pequeños de Amazon, el modelo propuesto supera a varias baselines clásicas y LLM-based, especialmente en métricas de ranking como HR@10 y NDCG@10.

En los catálogos grandes, IDIOMoE se posiciona como el modelo basado en LLM más fuerte: en Books y Toys obtiene los mejores resultados globales, mientras que en Beauty queda segundo detrás de HSTU.

Además, el paper verifica mediante ablations que la mejora no se explica simplemente por tener más parámetros. Para esto compara contra variantes con capacidad similar, como Wide-FFN, LoRA y capas adicionales, mostrando que la ganancia proviene principalmente de la separación entre texto e ítems mediante expertos especializados.

Referencias

- Cao, Y., Mehta, N., Yi, X., Keshavan, R. H., Heldt, L., Hong, L., Chi, E. H., & Sathiamoorthy, M. (2024). Aligning large language models with recommendation knowledge. arXiv. <https://doi.org/10.48550/arXiv.2404.00245>
- Cho, A., Kim, G. C., Karpekov, A., Helbling, A., Wang, Z. J., Lee, S., Hoover, B., & Chau, D. H. (2024). Transformer explainer: LLM transformer model visually explained. <https://poloclub.github.io/transformer-explainer/>
- Fedus, W., Zoph, B., & Shazeer, N. (2022). Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 23(120), 1–39.
- Geva, M., Schuster, T., Berant, J., & Levy, O. (2022). Transformer feed-forward layers build predictions by promoting concepts in the vocabulary space. *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Geng, S., Zhang, Z., Liu, Y., Wang, Y., Xu, Y., & Chen, Y. (2022). Recommendation as language processing (P5). *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Kang, W.-C., & McAuley, J. (2018). Self-attentive sequential recommendation. *Proceedings of the 2018 IEEE International Conference on Data Mining (ICDM)*.
- Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, 42(8), 30–37.
- McAuley, J., Pandey, R., & Leskovec, J. (2015). Inferring networks of substitutable and complementary products. *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.
- Ni, J., Li, J., & McAuley, J. (2019). Justifying recommendations using distantly-labeled reviews and fine-grained aspects. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- Shirkavand, R., Wei, X., Wang, C., Hui, Z., Huang, H., & Gong, M. (2026). Catalog-native LLM: Speaking item-ID dialect with less entanglement for recommendation. *International Conference on Learning Representations (ICLR)*.
- Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019). BERT4Rec: Sequential recommendation with bidirectional encoder representations. *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*.