Generate What You Prefer: Reshaping Sequential Recommendation via Guided Diffusion

Zhengyi Yang, Jiancan Wu, Zhicai Wang, Yancheng Yuan, Xiang Wang, Xiangnan He

Damián Gubbins
Benjamín Huenchuñir
Nicolás Fernández

01

Contexto

Recomendación Secuencial

Recomendación Secuencial

Qué es

Recomendar el próximo ítem que coincida con el interés o la preferencia del usuario, basándose en la secuencia histórica de ítems con los que este ha interactuado

Relevancia

Fundamental en diversas plataformas en línea, tales como el comercio electrónico, medios de streaming y redes sociales.

Limitaciones

No sigue el comportamiento humano

Un usuario podría imaginar un "ítem oráculo" ideal y luego seleccionar ítems potenciales que se acerquen a ese ideal

Dependencia muestreo negativo

- Clasificación limitada al pool de candidatos
- Diluye las señales de preferencia
- Puede ser difícil elegir las muestras negativas

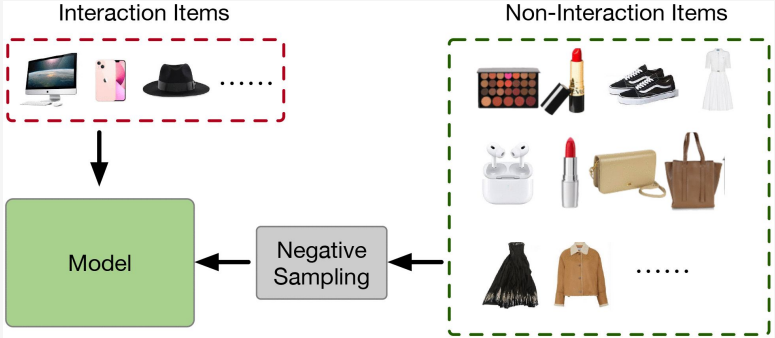

02

Problema de recomendación

Recomendación Secuencial

Definición formal

Tradicionalmente

Dada una secuencia histórica de interacciones $[v_1, v_2, ..., v_{n-1}]$, predecir el próximo ítem v_n.

Predecir si un ítem existente en el conjunto candidato es positivo o negativo

Nueva Propuesta

Generar directamente el “ítem oráculo”

$P_\theta(e_n^0|e_{1:n-1})$ -> la distribución subyacente de probabilidad del embedding del ítem oráculo condicionado al historial de usuario.

03

Contribución

Cambio de paradigma

Contribución

Cambio de paradigma con DreamRec

De *learning-to-classify* a *learning-to-generate*

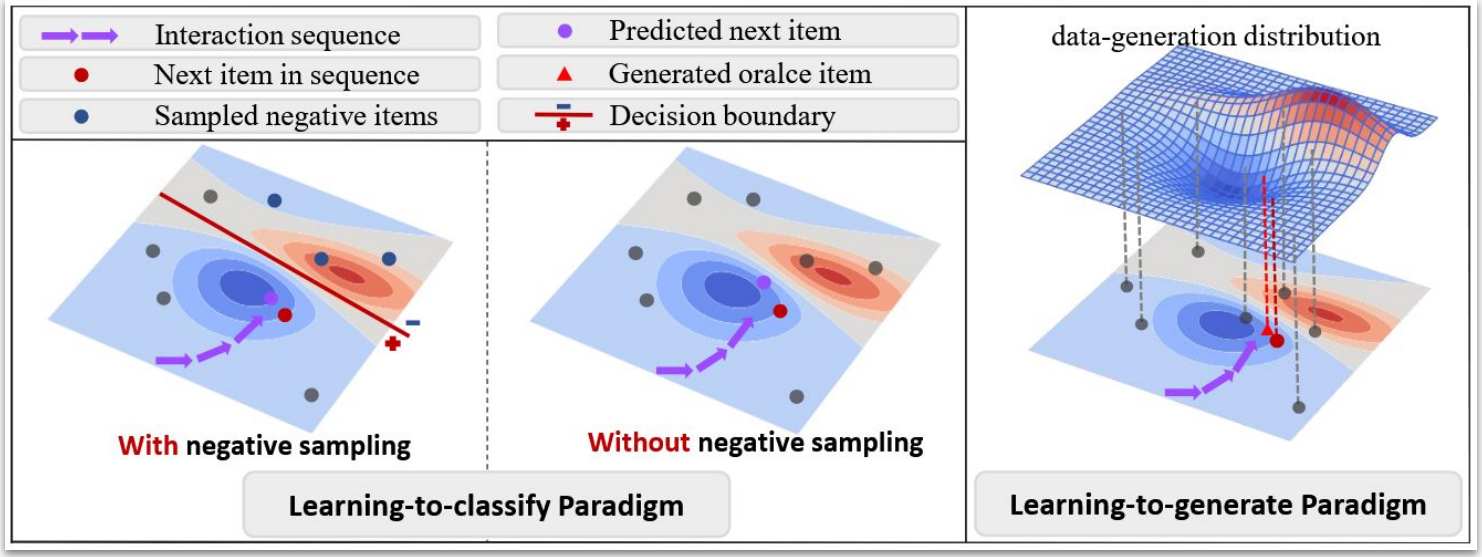

04

Estado del arte y marco teórico

DDPM

DDPM: Denoising Diffusion Probabilistic Models

Sea p(x) el espacio de todos los ítems posibles

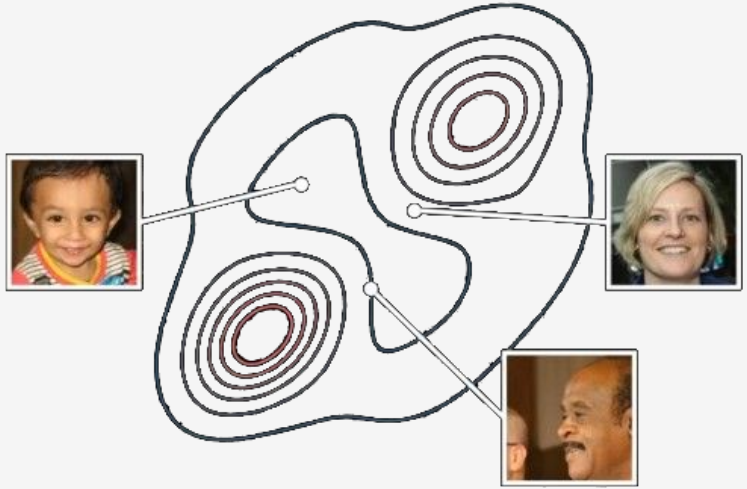

Por ejemplo, para imágenes

Es imposible tener una expresión para p(x)

Luego el desafío es cómo crear nuevos ítems sin tener una expresión definida de p(x)

DDPM: Denoising Diffusion Probabilistic Models

Idea ir agregando ruido al ítem hasta obtener ruido puro
Luego entrenar un modelo que pueda hacer el proceso inverso

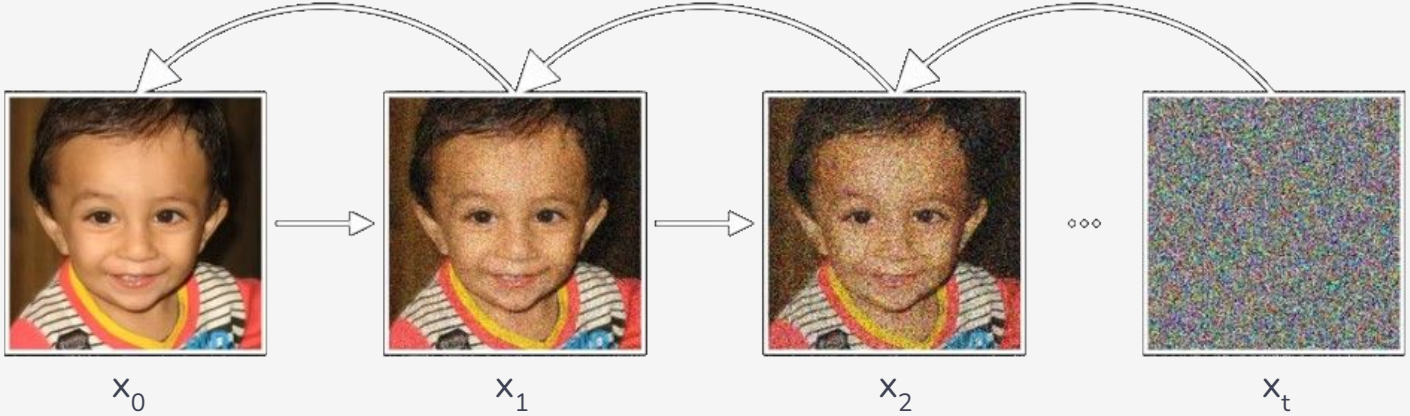

DDPM: Denoising Diffusion Probabilistic Models

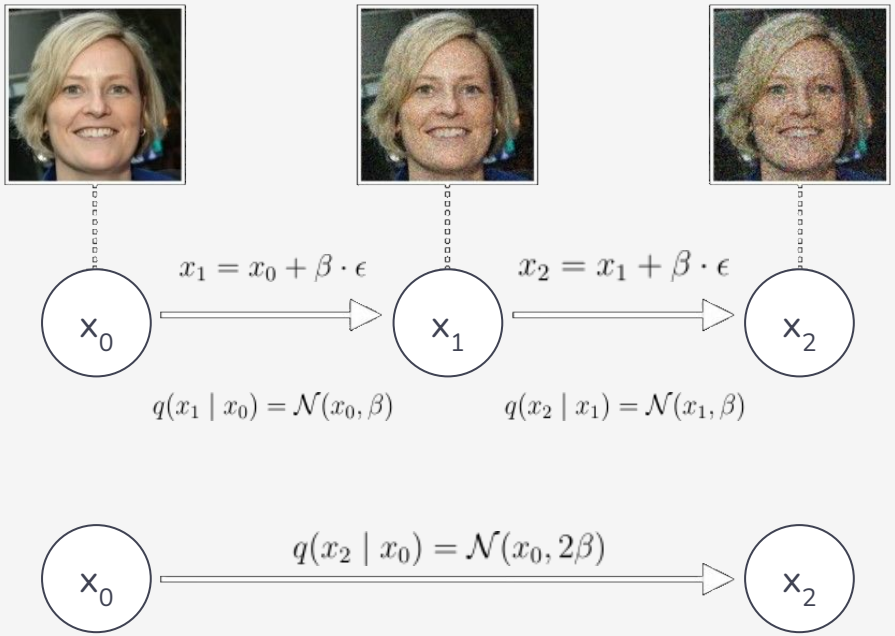

En cada paso sumamos una cantidad fija $\boldsymbol{\beta}$ de ruido $\boldsymbol{\epsilon}$

Luego para ir directo a t

$$x_t = x_0 + t\beta \cdot \epsilon$$

PROBLEMA: no converge a N(0,1)
La varianza explota

DDPM: Denoising Diffusion Probabilistic Models

$$\bar{\alpha}_t = (1-\beta)^t$$

$$q(x_t \mid x_0) = \sqrt{\bar{\alpha}_t}\, x_0 + (1-\bar{\alpha}_t) \cdot \epsilon$$

Ahora suponga que $\boldsymbol{\beta}$ ya no es fija, sino depende de cada paso

$$\bar{\alpha}_t = \prod_{i=1}^{t} (1-\beta_i)$$

DDPM: Denoising Diffusion Probabilistic Models

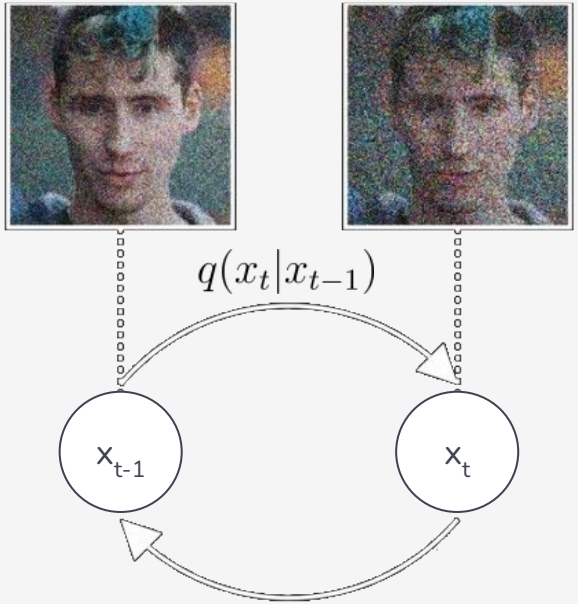

Podemos simplificar por cadena de Markov

$$q(x_1, \ldots, x_T|x_0) = q(x_1|x_0)q(x_2|x_1, x_0) \ldots q(x_T|x_{T-1}, \ldots, x_0)$$

$$q(x_1, \ldots, x_T|x_0) = q(x_1|x_0)q(x_2|x_1) \ldots q(x_T|x_{T-1})$$

$$q(x_{1:T}|x_0) = \prod_{t=1}^{T} q(x_t|x_{t-1})$$

DDPM: Denoising Diffusion Probabilistic Models

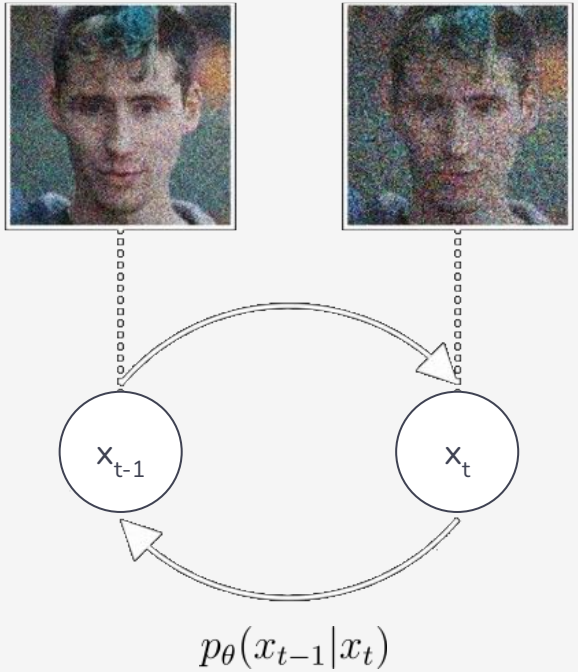

Para el proceso inverso definiremos

$$p_\theta(x_{0:T}) = p_\theta(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1}|x_t)$$

La probabilidad de una secuencia completa de *denoising* es el producto de la probabilidad de cada paso ($p_\theta(x_t-1 | x_t)$) comenzando desde el ruido puro inicial $p_\theta(x_T)$.

Se entrena un modelo neuronal que minimiza

$$-log(p_\theta(x_0))$$

p_θ representa ¿qué tan probable es que esta imagen real (x_0) haya sido generada? -> maximizar $p_\theta(x_0)$

DDPM: Denoising Diffusion Probabilistic Models

1. Queremos minimizar esto

$$-\log p_\theta(x_0) = \int p_\theta(x_{0:T}) dx_{1:T}$$

Sería muy costoso!

2. Encontrar una cota (Evidence Lower Bound, ELBO)

$$-\log p_\theta(x_0) \leq \mathbb{E}_q \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} \right]$$

Minimizamos un límite inferior

3. Reescribir el ELBO

$$\mathbb{E}_q \left[D_{KL}(q(x_T|x_0) \parallel p(x_T)) + \sum_{t>1} D_{KL}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) - \log p_\theta(x_0|x_1) \right]$$

En lugar de 'limpiar la imagen' de una sola vez, lo divido 'limpiar un poquito el ruido en el paso 1', 'limpiar un poquito en el paso 2', etc."

DDPM: Denoising Diffusion Probabilistic Models

4. Simplificar el ELBO

$$\mathbb{E}_q \left[\sum_{t>1} D_{KL}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) \right]$$

Nos quedamos solo con el término de la mitad

5. Usar Gaussiano

$$\mathbb{E}_q \left[\sum_{t>1} \frac{1}{2\sigma_t^2} \|\tilde{\mu}_t - \mu_\theta(x_t, t)\|^2 \right]$$

Como ambas distribuciones son Gaussianas se convierte en un simple Error Cuadrático Medio (MSE)

6. Reparametrizar

$$\mathbb{E}_q \left[\sum_{t>1} \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \|\epsilon - \epsilon_\theta(x_t, t)\|^2 \right]$$

En lugar de predecir la media, predecir el ruido

DDPM: Denoising Diffusion Probabilistic Models

Paso final

$$\mathbb{E}_q \left[\sum_{t>1} \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1-\bar{\alpha}_t)} \left\| \epsilon - \epsilon_\theta(x_t, t) \right\|^2 \right]$$

Costoso sumar todos los t

Mejor elegimos un t aleatorio para cada muestra
-> Con una cantidad grande de muestras esto convergerá a N(0,1)

$$\mathbb{E}_{q,t} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1-\bar{\alpha}_t)} \left\| \epsilon - \epsilon_\theta(x_t, t) \right\|^2 \right]$$

DDPM: Denoising Diffusion Probabilistic Models

$$\mathbb{E}_{q,t}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\left\|\epsilon-\epsilon_\theta(x_t,t)\right\|^2\right]$$

La parte más importante es esta $\left\|\epsilon-\epsilon_\theta(x_t,t)\right\|^2$

ϵ: ruido real, vector de ruido puro que se usó para corromper la imagen original

$\epsilon_\theta(x_t,t)$: es el ruido predicho, la salida de la red neuronal (θ). El modelo mira la imagen ruidosa (x_t) en un paso de tiempo (t) e intenta adivinar qué ruido (ϵ) se añadió.

// ... // 2: es el Error Cuadrático Medio, mide la diferencia o "distancia" entre el ruido real y el ruido que predijo el modelo.

05

Detalle solución

DreamRec

Framework

DDPM + Contexto

Un DDPM por sí solo no es suficiente para la generación de un ítem oráculo.

Se utiliza

$$\mathbf{c}_{n-1} = \textbf{T-enc}(\mathbf{e}_{1:n-1}).$$

para guiar el *denoising* con

$$\mathbf{e}_{1:n-1} = [\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_{n-1}]$$

una secuencia de *embeddings*

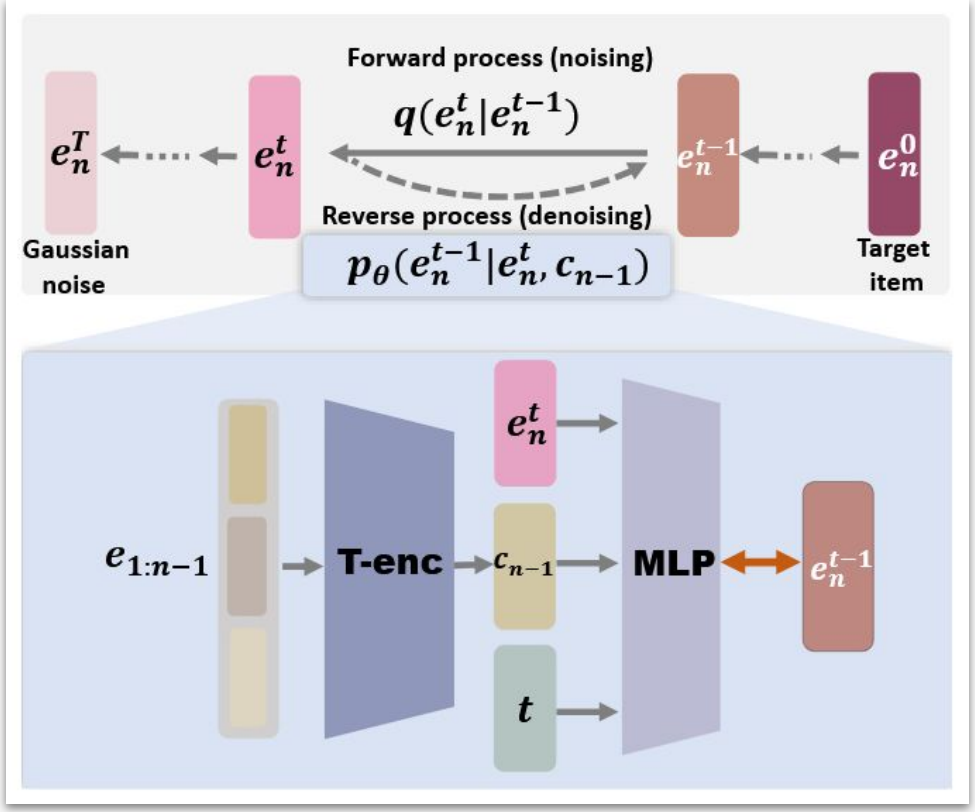

Entrenamiento

Algorithm 1 Training phase of DreamRec

repeat
  $\mathbf{e}_n^0, \mathbf{e}_{1:n-1} \sim \mathcal{D}$ ▷ Sample and embed a data from training set.
  $\mathbf{c}_{n-1} = \text{T-enc}(\mathbf{e}_{1:n-1})$ ▷ Encode interaction sequence.
  With probability p_u: $\mathbf{c}_{n-1} = \Phi$ ▷ Perform unconditional training with probability p_u.
  $t \sim \text{Uniform}(\{1, \ldots, T\})$ ▷ Sample diffusion step.
  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ▷ Sample Gaussian noise.
  $\mathbf{e}_n^t = \sqrt{\bar{\alpha}_t}\mathbf{e}_n^0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}$ ▷ Corrupt the traget item with Gaussian noise.
  $\theta = \theta - \mu \nabla_\theta \left\| \mathbf{e}_n^0 - f_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) \right\|^2$ ▷ Take gradient descent step, μ is the step size.
until converged

$$\alpha_t = 1 - \beta_t$$

$$\bar{a}_t = \prod_{s=1}^{t} \alpha_s$$

$$\epsilon \sim \mathcal{N}(0, \mathbf{I})$$

Generación

Algorithm 2 Generation phase of DreamRec

1: $\mathbf{e}_{1:n-1} \sim \mathcal{D}_t$ ▷ Sample and embed a data from testing set.
2: $\mathbf{e}_n^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ▷ Sample Gaussian noise.
3: $\mathbf{c}_{n-1} = \text{T-enc}(\mathbf{e}_{1:n-1})$ ▷ Encode interaction sequence.
4: **for** $t = T, \ldots, 1$ **do** ▷ Denoise for T steps.
5: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$ ▷ Sample denoising variance.
6: $\tilde{f}_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) = (1+w)\, f_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) - w\, f_\theta(\mathbf{e}_n^t, \Phi, t)$ ▷ Control the strength of guidance.
7: $\mathbf{e}_n^{t-1} = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \tilde{f}_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \mathbf{e}_n^t + \sqrt{\tilde{\beta}_t}\mathbf{z}$ ▷ Denoise for one step.
8: **end for**
9: **return** $\mathbf{e}_n^0$

$$\alpha_t = 1 - \beta_t$$

$$\bar{a}_t = \prod_{s=1}^{t} \alpha_s$$

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

06

Evaluación

YooChoose, KuaiRec & Zhihu

Objetivos

1. Resultados

Demostrar que DreamRec presenta un framework *learning-to-generate* poderoso para recomendaciones secuenciales.

2. Exploración

Demostrar que DreamRec explora de mejor manera el espacio de items sin necesidad de *negative sampling*.

3. Guiado

Demostrar que guiar el proceso de difusión con interacciones históricas es importante para la recomendación personalizada.

Datasets

01 YooChose

Secuencias de compras (RecSys challenge 2015)

02 KuaiRec

Recomendaciones de una app para compartir videos

03 Zhihu

Plataforma social de *knowledge-sharing*

Table 2: Statistics of datasets.

Dataset	YooChoose	KuaiRec	Zhihu
#sequences	128,468	92,090	11,714
#items	9,514	7,261	4,838
#interactions	539,436	737,163	77,712

Se eliminaron ítems con menos de 5 interacciones y secuencias de largo menor que 3

1. Resultados

Table 1: Overall performance comparison. The boldface denotes the best performance while the underline indicates the second best. The experiments are conducted 5 times and the average and standard deviation are reported.

	YooChoose		KuaiRec		Zhihu	
	HR@20(%)	NDCG@20(%)	HR@20(%)	NDCG@20(%)	HR@20(%)	NDCG@20(%)
GRU4Rec	3.89±0.11	1.62±0.02	3.32±0.11	1.23±0.08	1.78±0.12	0.67±0.03
Caser	4.06±0.12	1.88±0.09	2.88±0.19	1.07±0.07	1.57±0.05	0.59±0.01
SASRec	3.68±0.08	1.63±002	3.92±0.18	1.53±0.11	1.62±0.01	0.60±0.03
IPS	3.81±0.05	1.73±0.03	3.73±0.03	1.40±0.05	1.66±0.04	0.64±0.02
AdaRanker	3.74±0.06	1.67±0.04	4.14±0.09	1.89±0.05	1.70±0.04	0.61±0.02
CL4SRec	4.45±0.04	1.86±0.02	4.25±0.10	2.01±0.09	2.03±0.06	0.74±0.03
DiffRec	4.33±0.02	1.84±0.01	3.74±0.08	1.77±0.05	1.82±0.03	0.65±0.09
DreamRec	**4.78**±0.06	**2.23**±0.02	**5.16**±0.05	**4.11**±0.02	**2.26**±0.07	**0.79**±0.01

2. Exploración

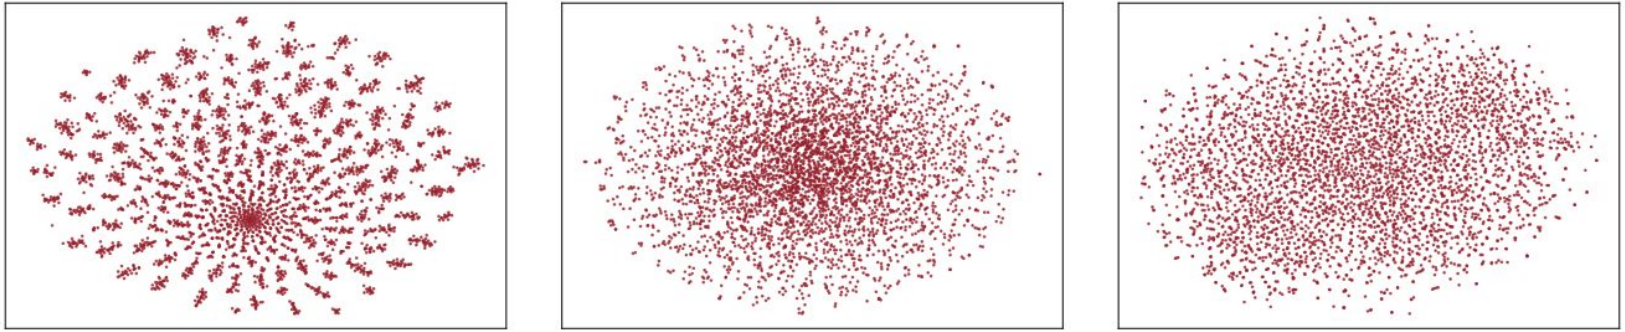

(a) SASRec (no negative sampling). (b) SASRec. (c) DreamRec.

Figure 3: Visualization of the learned item embeddings on Zhihu dataset using T-SNE, where red points represent items. Figure 3a shows that without negative sampling, the item embeddings of SASRec are crowded in limited discrete zones. Figure 3b shows that With negative sampling, the item embeddings of SASRec concentrate on only part of the item space. Figure 3c shows that DreamRec explores most of the item space without requiring negative sampling.

3. Guiado

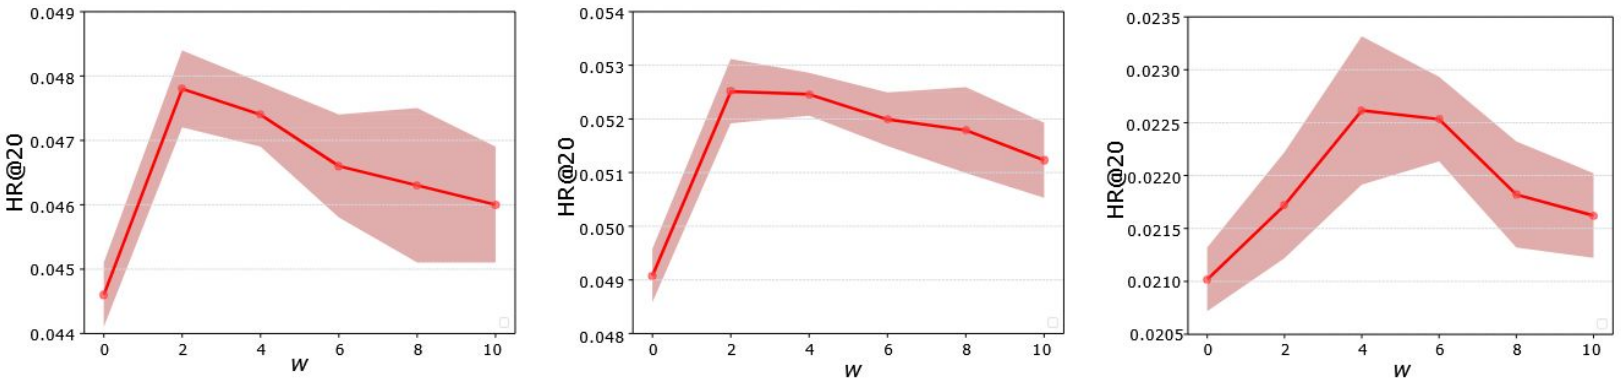

(a) YooChoose. (b) KuaiRec. (c) Zhihu.

Figure 4: Ablation study of classifier-free guidance by adjusting the guidance strength w on YooChoose (subfigure 4a), KuaiRec (subfigure 4b) , and Zhihu (subfigure 4c) datasets.

Limitaciones

Muestreo

Se requieren de muchos pasos de difusión inversa para generar el ítem oráculo.

Entrenamiento

El tiempo y costo del entrenamiento es superior en comparación a los otros modelos *baseline*.

Referencias

1. Yang, L., He, Z., Chen, L., Wang, Z., & Zhang, Z. (2023). *Generate what you prefer: Reshaping sequential recommendation via guided diffusion*. In *Advances in Neural Information Processing Systems (NeurIPS 2023)*.
2. Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk. Session-based recommendations with recurrent neural networks. In ICLR, 2016.
3. Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In ICDM, pages 197–206, 2018.
4. Zhenlei Wang, Shiqi Shen, Zhipeng Wang, Bo Chen, Xu Chen, and Ji-Rong Wen. Unbiased sequential recommendation with latent confounders. In WWW, pages 2195–2204, 2022.
5. Xinyan Fan, Jianxun Lian, Wayne Xin Zhao, Zheng Liu, Chaozhuo Li, and Xing Xie. Adaranker: A data distribution adaptive ranking paradigm for sequential recommendation. In SIGIR, pages 1599–1610, 2022.
6. An Zhang, Wenchang Ma, Xiang Wang, and Tat-Seng Chua. Incorporating bias-aware margins into contrastive loss for collaborative filtering. In NeurIPS, 2022.
7. Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In NeurIPS, 2020.
8. Zihao Li, Aixin Sun, and Chenliang Li. Diffurec: A diffusion model for sequential recommendation. CoRR, abs/2304.00686, 2023.
9. Hanwen Du, Huanhuan Yuan, Zhen Huang, Pengpeng Zhao, and Xiaofang Zhou. Sequential recommendation with diffusion models. CoRR, abs/2304.04541, 2023.
10. Yu Wang, Zhiwei Liu, Liangwei Yang, and Philip S. Yu. Conditional denoising diffusion for sequential recommendation. CoRR, abs/2304.11433, 2023.