




Heterogeneous Graph Contrastive Learning for Recommendation (HGCL)

Clemente Campos
Álvaro Restuccia
Max Reyes

IIC3633


Contexto

- El filtrado colaborativo clásico se limita a interacciones directas y localizadas, ignorando los patrones de conectividad estructural de alto orden.
- Las Redes Neuronales de Grafos (GNN) solucionaron esto al propagar y agregar características a través de múltiples saltos en grafos bipartitos usuario-ítem.
- En la práctica, las interacciones observadas son extremadamente escasas. Incorporar la información heterogénea es clave para mitigar esta escasez de etiquetas de entrenamiento.




Problema de Recomendación

- En este paper se intenta mejorar resultados ante el problema de datos sparse para obtener más y mejores relaciones usuarios items.
- La incorporación de factores externos como vínculos sociales suelen causar ruido.
- Se plantea incorporar estas relaciones de manera personalizada para evitar este ruido.
- Se utilizaron los dataset Ciao, Epinions y Yelp. Donde los 3 dataset contiene su propia “red social” que permite relacionar usuarios.



Contribución de HGCL

- HGCL propone un flujo que aprovecha conocimiento relacional heterogéneo lateral (redes sociales y semántica) en el modelado de interacción usuario-ítem bajo un esquema de multi-vista.
- Demuestra mejoras significativas frente a 16 modelos en datasets reales (Ciao, Epinions, Yelp), manteniendo una precisión alta incluso con interacciones extremadamente escasas.





Estado del arte

- **GNN Homogéneas (ej. NGCF, LightGCN):** Se limitan a grafos bipartitos usuario-ítem. Colapsan ante la falta de señales de interacción densas.
- **Redes de Grafos Heterogéneos (ej. HAN, HGT):** Usan meta-caminos semánticos. Problema: Son "label-hungry" y propagan ruido mediante caminos densos predefinidos
- **Aprendizaje Contrastivo en Grafos (GCL) (ej. SGL, HeCo, SMIN):** Introducen tareas auxiliares para alinear vistas del mismo nodo, mitigando la dependencia de etiquetas.


Marco Teórico (Contrastive Learning)

- El objetivo es maximizar la concordancia entre dos representaciones del mismo nodo (pares positivos) y alejar las de nodos distintos.

$$\mathcal{L}_{cl}^u = \sum_{u \in \mathcal{V}_u} -\log \frac{\exp \left(s(\mathbf{e}_{uu}^M + \mathbf{e}_{uu}, \mathbf{e}_u) / \tau \right)}{\sum_{u' \in \mathcal{V}_u} \exp \left(s(\mathbf{e}_{uu}^M + \mathbf{e}_{uu}, \mathbf{e}'_u) / \tau \right)}$$

Marco Teórico (Meta-Networks)

- Cada usuario tiene sus propios comportamientos y reacciones ante ciertos estímulos o contextos.
- Las Meta-Networks aparecen con la intención de ayudar a los modelos a comprender estos comportamientos de manera personalizada.
- Por ejemplo tomando factores como que tan influenciable es un usuario por sus vínculos en redes.





Inicialización Relation-Aware

Buscamos aprender los embeddings

$$E_u^0 \in \mathbb{R}^{m \times d}, E_i^0 \in \mathbb{R}^{n \times d}$$

Inicializados aleatoriamente, controlando escala

$$E_{uu}^0 = E_u^0 \odot \sigma(E_u^0 W_g^u + b_g^u)$$

$$E_{ii}^0 = E_i^0 \odot \sigma(E_i^0 W_g^i + b_g^i)$$

W, b : parámetros aprendibles.

Vista

usuario-ítem

usuario-usuario

ítem-ítem



Message Passing

Vista

Cada nodo obtiene información sobre sus vecinos

$$e_u^{l+1} = \sum_{i \in \mathcal{N}_u} (\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|})^{-1} e_i^l$$

$$e_i^{l+1} = \sum_{u \in \mathcal{N}_i} (\sqrt{|\mathcal{N}_i|} \sqrt{|\mathcal{N}_u|})^{-1} e_u^l$$

usuario-ítem

Promedio ponderado que castiga popularidad

$$e_{uu}^{l+1} = \sum_{v \in \mathcal{M}_u} (\sqrt{|\mathcal{M}_u|} \sqrt{|\mathcal{M}_v|})^{-1} e_{vv}^l$$

usuario-usuario

$$e_{ii}^{l+1} = \sum_{j \in \mathcal{K}_i} (\sqrt{|\mathcal{K}_i|} \sqrt{|\mathcal{K}_j|})^{-1} e_{jj}^l$$

ítem-ítem

Similar a LightGCN: no hay transformación ni activación no lineal



Agregación de información heterogénea

Como paso intermedio, integramos la información de las vistas secundarias a la principal

$$\hat{E}_u^{l+1} = f(E_u^{l+1}, E_{uu}^{l+1})$$

└─→ Input de la siguiente
└─→ capa usuario-ítem

$$\hat{E}_i^{l+1} = f(E_i^{l+1}, E_{ii}^{l+1})$$

f: promedio simple

$$E_* = E_*^0 + \sum_{l=1}^L \frac{E_*^l}{\|E_*^l\|}$$

Agregación final: se combina información propia y de los vecinos

* = u, i, uu, ii

Meta-Conocimiento

Armamos las matrices de meta-conocimiento

$$E_u || E_{uu} || \sum_{i \in \mathcal{N}_u} e_i = M_{uu} \xrightarrow{\text{perceptrón}} \overset{(m \times d \times k)}{W_{uu}^{M1}}, \overset{(m \times k \times d)}{W_{uu}^{M2}}$$

Generamos pares de **tensores de rango $k < d$** que contienen una matriz personalizada para cada usuario

$$E_{uu}^M = \sigma(W_{uu}^{M1} W_{uu}^{M2} E_{uu}) \quad \text{Embedding personalizado}$$

$$E_{uu}^F = \alpha_u * E_u + (1 - \alpha_u) * (E_{uu} + E_{uu}^M) \quad \text{Embedding final}$$

Procedimiento análogo para E_{ii}^F

Aprendizaje contrastivo

$$\mathcal{L}_{cl}^u = \sum_{u' \in \mathcal{V}_u} -\log \frac{\exp(s(e_{uu}^M + e_{uu}, e_u)/\tau)}{\sum_{u' \in \mathcal{V}_u} \exp(s(e_{uu}^M + e_{uu}, e'_u)/\tau)} \quad \mathcal{L}_{cl}^i \text{ análoga}$$

Función de pérdida **contrastiva**: buscamos que los embeddings auxiliares sean similares al principal y distintos a los de otros ítems/usuarios

$$\mathcal{L}_{cl} = \alpha_1 * \mathcal{L}_{cl}^u + \alpha_2 * \mathcal{L}_{cl}^i$$

Balanceamos con hiperparámetros


$$\mathcal{L} = \mathcal{L}_{bpr} + \beta \mathcal{L}_{cl}$$

Función de pérdida final

$$\hat{y}_{u,i} = e_u^{F\top} e_i^F$$

Score

Flujo Final



Evaluación

Setup Experimental y comparación con baselines

Table 2: Statistics of experimented datasets

Dataset	User #	Item #	Interaction #	Sparsity
Ciao	6776	101415	265308	99.9614%
Epinions	15210	233929	630391	99.9823%
Yelp	161305	114852	957923	99.9948%

Métricas: HR@10 y NDCG@10

Evaluación: 1 ítem positivo + 99 negativos por usuario

Baselines: 15 métodos, incluyendo NGCF, KGAT, HAN, HGT, HeCo, MHCN y SMIN

Table 1: Performance comparison of all methods on different datasets in terms of NDCG and HR.

Data	Metric	SAMN	DGRec	ETANN	NGCF	KGAT	MKR	GraphRec	DANSER	HERec	MCR	HAN	HeCo	HGT	MHCN	SMIN	HGCL
Ciao	H@10	0.6576	0.6653	0.6738	0.6945	0.6601	0.6793	0.6825	0.6730	0.6800	0.6772	0.6589	0.6867	0.6939	0.7053	0.7108	0.7376
	N@10	0.4561	0.4953	0.4665	0.4894	0.4512	0.4589	0.4730	0.4521	0.4712	0.4708	0.4469	0.4867	0.4869	0.4928	0.5012	0.5261
Epinions	H@10	0.7592	0.7603	0.7650	0.7984	0.7510	0.7647	0.7723	0.7714	0.7642	0.7630	0.7505	0.7998	0.8150	0.8201	0.8179	0.8367
	N@10	0.5614	0.5668	0.5663	0.5945	0.5578	0.5669	0.5751	0.5741	0.5495	0.5326	0.5275	0.5910	0.6126	0.6158	0.6137	0.6413
Yelp	H@10	0.7910	0.7950	0.8031	0.8265	0.7881	0.8005	0.8098	0.8077	0.7928	0.7869	0.7731	0.8359	0.8364	0.8344	0.8478	0.8712
	N@10	0.5516	0.5593	0.5560	0.5854	0.5501	0.5635	0.5679	0.5692	0.5612	0.5590	0.5604	0.5847	0.5883	0.5799	0.5993	0.6310



Evaluación

Ablation study

Table 3: Ablation study on key components of HGCL

Data	Ciao		Epinions		Yelp	
Metric	HR	NDCG	HR	NDCG	HR	NDCG
w/o-cl	0.7124	0.5015	0.8176	0.6166	0.8471	0.6030
w/o-meta	0.7215	0.5135	0.8247	0.6282	0.8585	0.6218
w/o-ii	0.7116	0.5055	0.8245	0.6317	0.8573	0.6188
w/o-uu	0.7149	0.5047	0.8285	0.6266	0.8533	0.6208
HGCL	0.7376	0.5261	0.8367	0.6413	0.8712	0.6310

w/o-cl: Sin incluir Contrastive learning


w/o-meta: Sin incluir Meta Network

w/o-ii: Sin incluir grafo item-item


w/o-uu: Sin incluir grafo user-user

Evaluación


Performance variando Data Sparsity



(a) Yelp HR@10



(b) Epinions HR@10



(c) Ciao HR@10

HGCL mantiene ventaja incluso con usuarios de baja actividad

Evaluación

Análisis de hiperparametros




Figure 3: Hyperparameter study of the HGCL.

- Mejor dimensión de embedding $d = 32$
- Mejor número de capas GNN = 2
- Mejor dimensión low-rank $k = 3$

Evaluación

Evaluación cualitativa

User Cases from Ciao Dataset




Figure 4: Case study on Ciao dataset to visualize the learned contrastive transformation matrices sampled from different users to reflect the diverse social influence. (a): Four users who are more likely to be influenced by their social relations; (b): Four users who are less likely to be influenced by their social relations. (c): The embeddings generated from auxiliary view will be transformed for representation contrasting for self-supervision augmentation of user-item interaction modeling.



Referencias

HGCL

Chen, M., Huang, C., Xia, L., Wei, W., Xu, Y., & Luo, R. (2023). Heterogeneous graph contrastive learning for recommendation. In *Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining* (pp. 544–552). Association for Computing Machinery. <https://doi.org/10.1145/3539597.3570484>

GCL

Chen, R., Chen, J., & Gan, X. (2024). Multi-view graph contrastive learning for social recommendation. *Scientific Reports*, 14, Article 22643. <https://doi.org/10.1038/s41598-024-73336-5>

LightGCN

He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and powering graph convolution network for recommendation. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 639–648. <https://doi.org/10.1145/3397271.3401063>

SMIN

Long, X., Huang, C., Xu, Y., Xu, H., Dai, P., Xia, L., & Bo, L. (2021). Social recommendation with self-supervised metagraph informax network. In *Proceedings of the 30th ACM International Conference on Information & Knowledge Management* (pp. 1160–1169). Association for Computing Machinery. <https://doi.org/10.1145/3459637.3482480>

HAN

Wang, X., Ji, H., Shi, C., Wang, B., Cui, P., Yu, P. S., & Ye, Y. (2019). Heterogeneous graph attention network. In *The World Wide Web Conference* (pp. 2022–2032). Association for Computing Machinery. <https://doi.org/10.1145/3308558.3313562>