Large Language Models are Zero-Shot Rankers for Recommender Systems

Vicente Correa
Alberto Maturana
Mariela Zambrano

(Hou et al., 2024)

Contenido

1. Contexto

2. Problema de recomendación

3. Conceptos claves y estado del arte

4. Modelo propuesto

5. Resultados

6. Conclusión

7. Referencias

Contexto

En los sistemas de recomendación, los **modelos** entrenados con datos de comportamiento del usuario **sufren dos problemas**:

1. **Dificultad** de capturar las preferencias a partir de comportamientos históricos.
2. **Carecen** de un conocimiento previo o sentido común.

Por otro lado, los **PLM** necesitan ser **ajustados** para funcionar bien en una tarea específica, a pesar de entender el lenguaje y tener conocimiento previo.

Problema de recomendación

El estudio analiza la capacidad de los LLMs para actuar como **modelo** de **ranking zero-shot**.

Para eso, se debe clasificar la lista ***C*** basandose en ***H***.

- ***H***: historial de interacciones secuenciales del usuario.
- ***C***: items que deben ser clasificados.

¿Qué factores afectan el rendimiento?

¿En que datos se basan los LLMs para hacer la recomendación?

Contribución del paper

- Identifica que los LLMs tienen **problemas para percibir el orden**.
- Identifica que los LLMs tienen problemas de **sesgo de posición y popularidad**.
- Muestra que los problemas se pueden aliviar usando ***bootstrapping*** y ***prompting***.

Conceptos clave

Zero-Shot

Significa realizar una tarea **sin haber sido entrenado** para ella. En este caso, a los LLMs se les dan ***prompts*** (instrucciones) y se espera que se **resuelva la tarea de ranking**.

Generación de candidatos

Para **no revisar todos los ítems** existentes para cada usuario, se selecciona un **conjunto relevante** de ítems [1].

Estado del arte

Modelos full

Son modelos entrenados con el dataset. Mencionan el modelo **SASRec** [2] (inspirado en los Transformers) y el modelo **BPRMF** [3] (ranking personalizado bayesiano con retroalimentación implícita).

Modelos zero-shot

Son modelos que no fueron entrenados con el dataset. Mencionan el modelo **BM25** [4] (similitud textual y el historial), y el modelo **UniSRec** [5] (PLM para recomendación secuencial).

Framework General

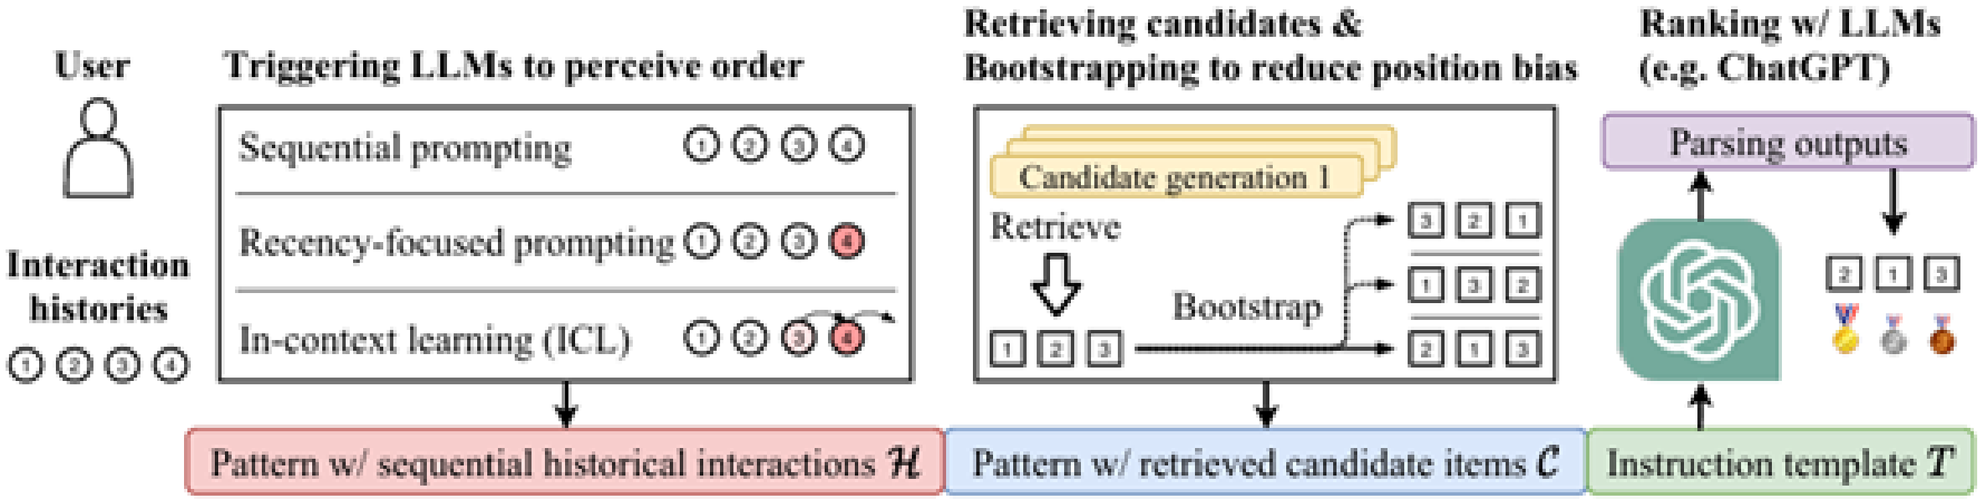

Prompt = Historial (texto) + Candidatos (texto) + Instrucción (texto).

LLM are Zero-Shot Rankers for Recommender Systems

"I've watched the following movies in the past in order:
[historial de películas vistas]
Now there are **[número]** candidate movies that I can watch next:
[lista de películas candidatas]
Please rank these **[número]** movies by measuring the possibilities that I would like to watch next most, according to my watching history. Please think step by step.
Please show me your ranking results with order numbers. Split your output with line break. You MUST rank the given candidate movies. You can not generate movies that are not in the given candidate list."

Solución Prompting

Recency-focused prompting

"I've watched the following movies in the past in order: '0.Multiplicity', '1.JurassicPark', ... Note that my most recently watched movie is Dead Presidents. ...".

In-context Learning

" If I've watched the following movies in the past in order: '0.Multiplicity', '1.JurassicPark', ..., then you should recommend Dead Presidents to me and now thatI've watched Dead Presidents, then ..."

Solución Sesgos

Posición

- **Problema**: El LLM favorece lo que lee primero en la lista de candidatos.

- **Solución**: Bootstrapping. Reordenación al azar de candidatos y rankear 3 veces, luego combinar

[Shrek, Toy Story, Cars]

[Toy Story, Cars, Shrek]

[Shrek, Cars, Toy Story]

Solución Sesgos

Popularidad

- **Problema**: LLMs aprenden de internet y de varias otras fuentes, tienden a recomendar lo que es famoso, no necesariamente lo que es mejor para ti
- **Solución**: Usar historiales más cortos para enfocarse en el gusto personal. Obliga a concentrarse en tus gustos específicos del momento, en lugar de recurrir a su conocimiento general sobre los 'grandes éxitos'.

Evaluación

Datasets

MovieLens-1M

Interacciones entre usuarios y películas mediante ratings

Amazon Games

Interacciones entre usuarios y juegos mediante ratings

Dataset	#Users	#Items	#Interactions	Sparsity	Avg. $\lvert\mathcal{H}\rvert$	Avg. $\lvert t_i \rvert$
ML-1M	6,040	3,706	1,000,209	95.53%	46.19	16.96
Games	50,547	16,859	389,718	99.95%	7.02	43.31

Métricas

La tarea de recomendación es de ordenar los candidatos provistos según la probabilidad de que sean el próximo ítem de interés del usuario.

El rendimiento se mide con la métrica **NDCG@K.**

Para la fase de testeo, el *ground truth* es el último ítem del historial del usuario.

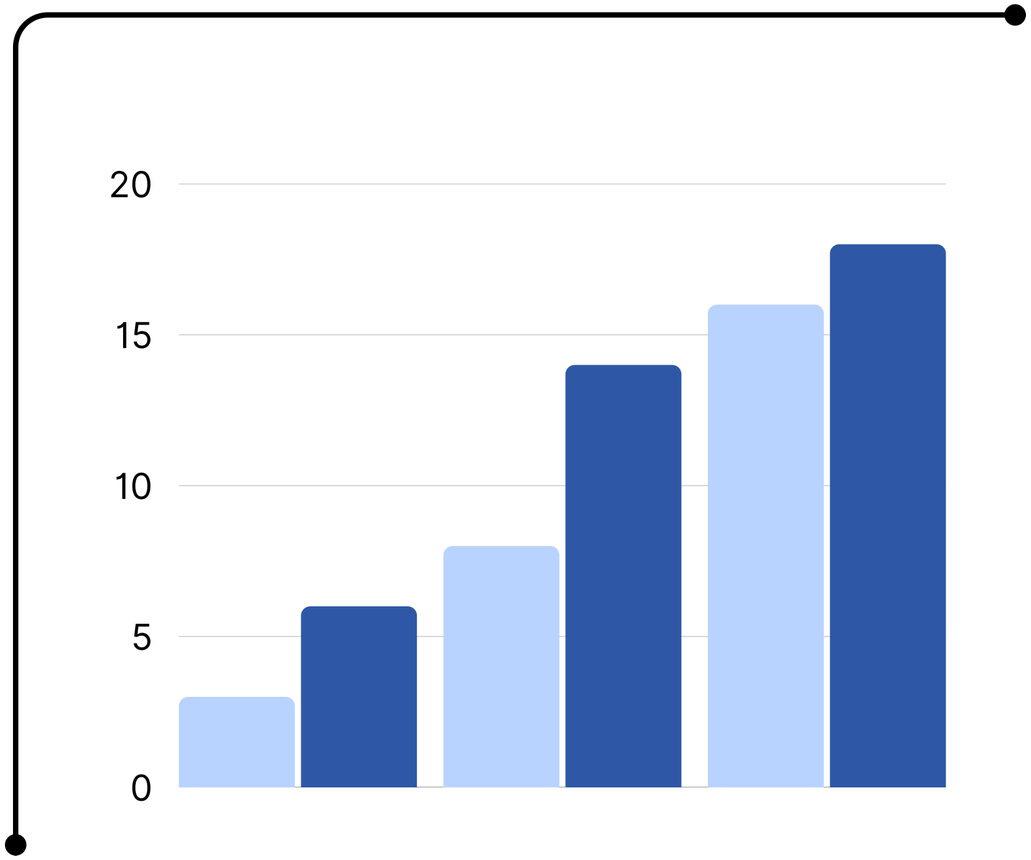

Resultados

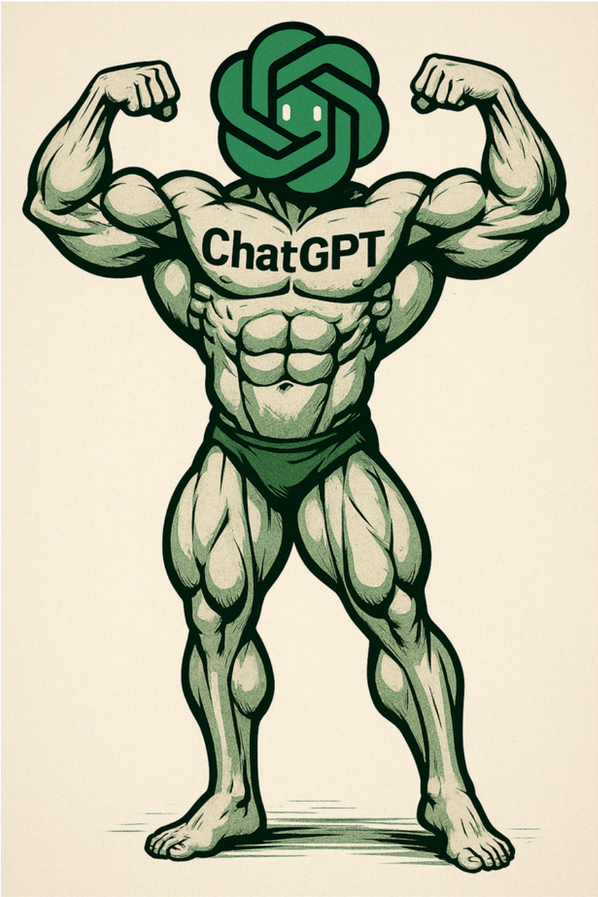

(Generado por ChatGPT)

Resultados

Los modelos GPT son sorprendentemente buenos en recomendaciones *Zero-Shot*.

GPT-4 se acerca incluso a modelos recomendadores supervisados.

Sin embargo, sufren ciertos problemas y sesgos.

Sesgos encontrados

Sesgo de posición

El modelo tiende a favorecer los ítems que aparecen primero en la lista del prompt, porque los procesa de manera secuencial.

Sesgo de popularidad

Los LLM tienden a recomendar ítems muy conocidos o populares

Sesgo de posición

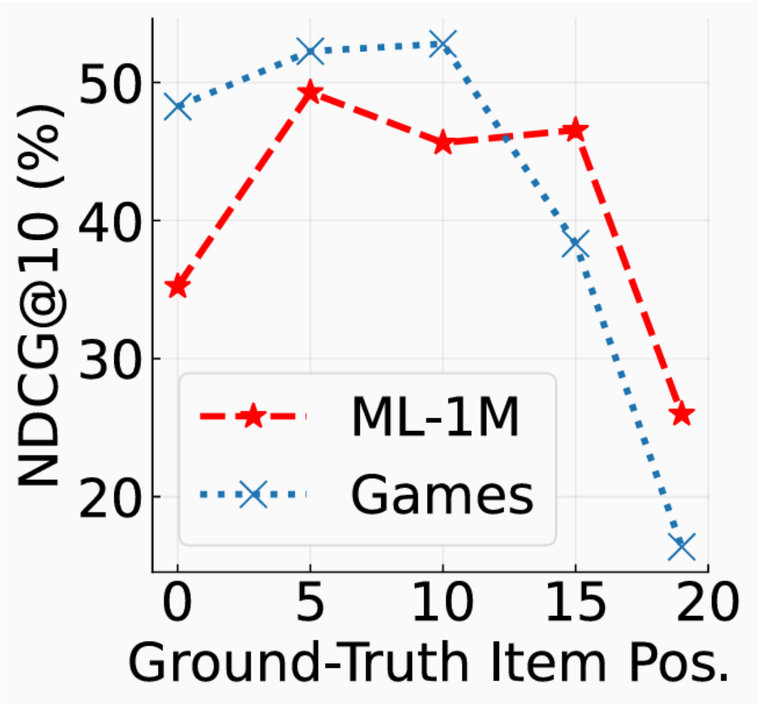

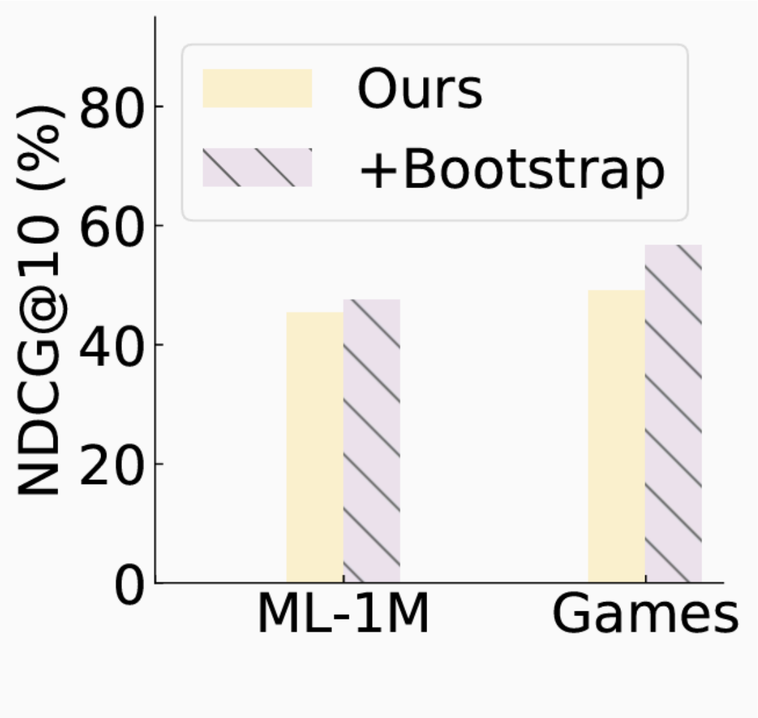

(Hou et al., 2024)

Sesgo de popularidad

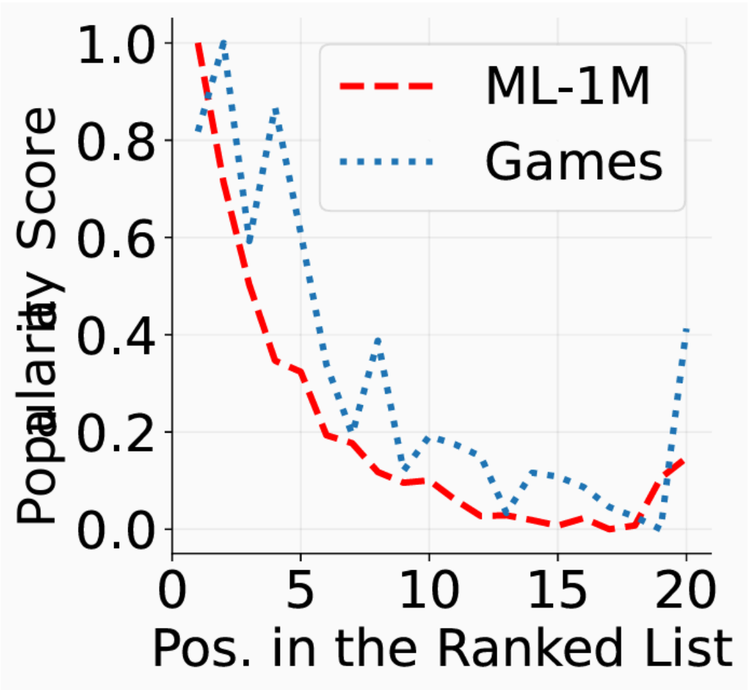

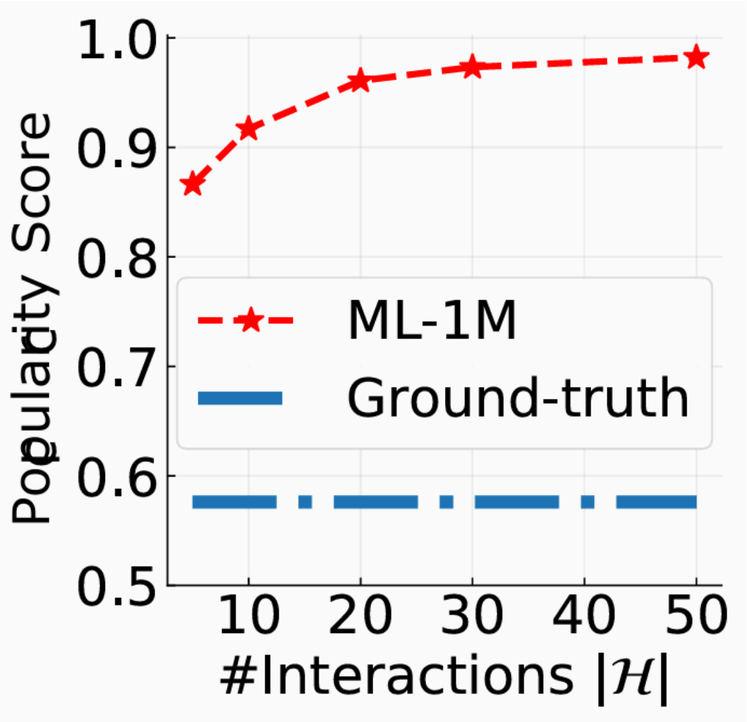

(Hou et al., 2024)

Percepción secuencial

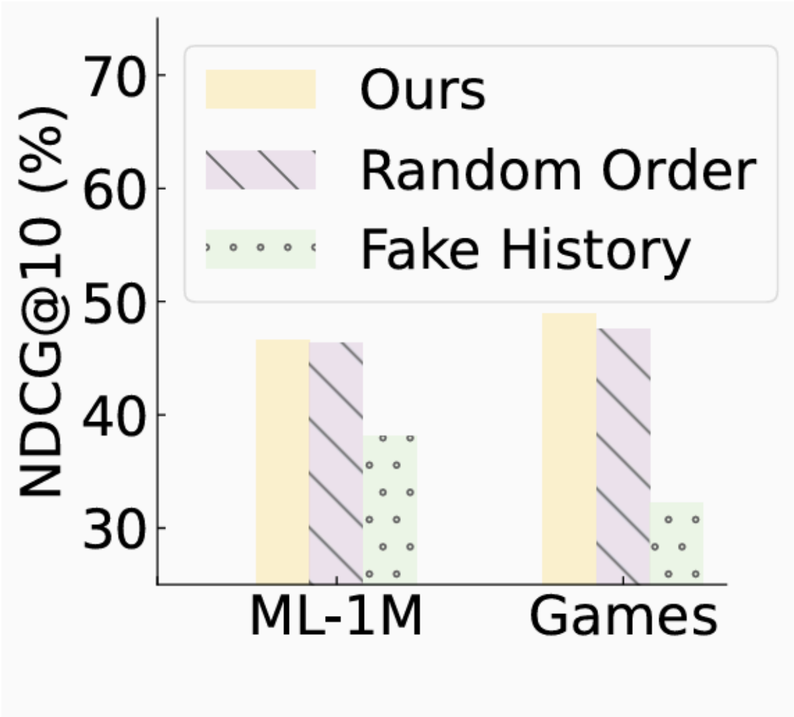

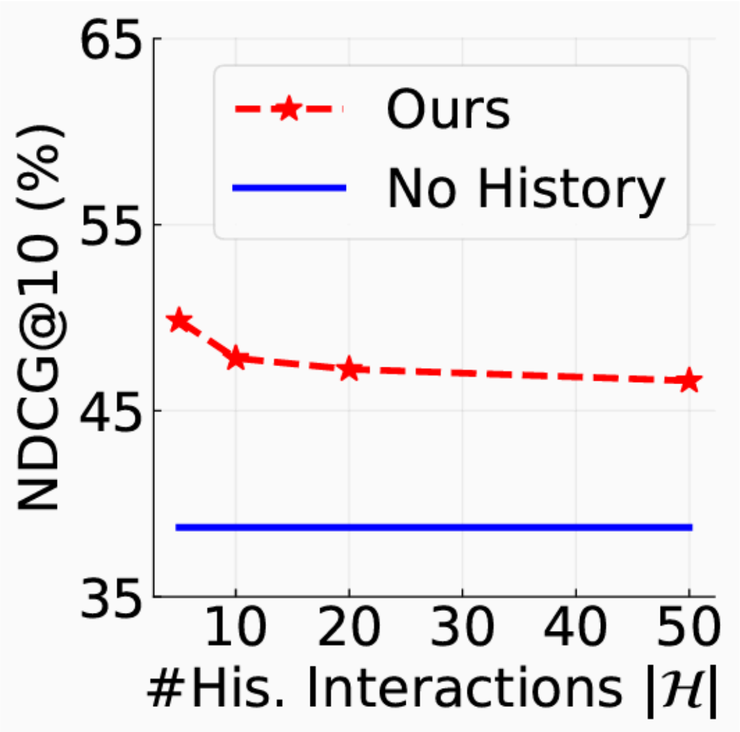

(Hou et al., 2024)

Comparación de LLMs

Method	ML-1M				Games			
	N@1	N@5	N@10	N@20	N@1	N@5	N@10	N@20
BM25 [50]	4.70	12.68	17.88	33.19	13.92	28.81	34.61	44.35
UniSRec [30]	7.37	18.80	26.67	37.93	18.95	33.99	40.71	48.42
Alpaca-7B [55]	4.00	13.92	23.09	31.54	5.50	14.16	21.67	28.68
Vicuna-13B [9]	6.50	14.75	22.64	33.42	7.00	17.73	24.30	31.22
LLaMA-2-70B-Chat [57]	8.00	25.42	31.19	34.52	21.50	32.30	37.83	41.97
ChatGPT (GPT-3.5)	**23.33**	**42.07**	**48.80**	**53.73**	23.83	45.69	50.31	55.45
GPT-4	15.50	40.65	46.74	48.42	**39.50**	**58.22**	**62.88**	**65.25**

(Hou et al., 2024)

Comparación de LLMs

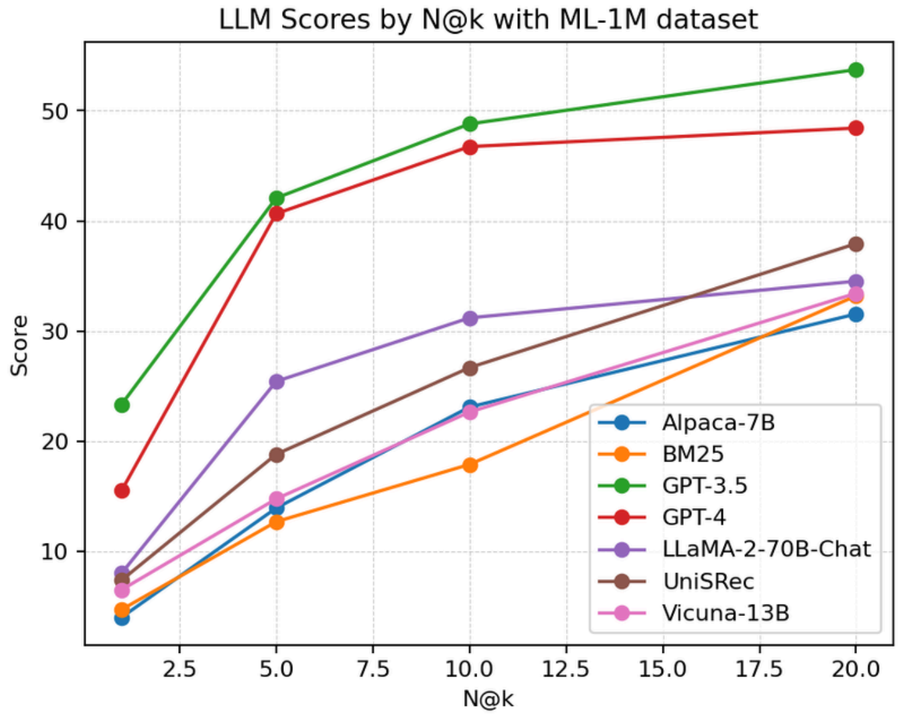

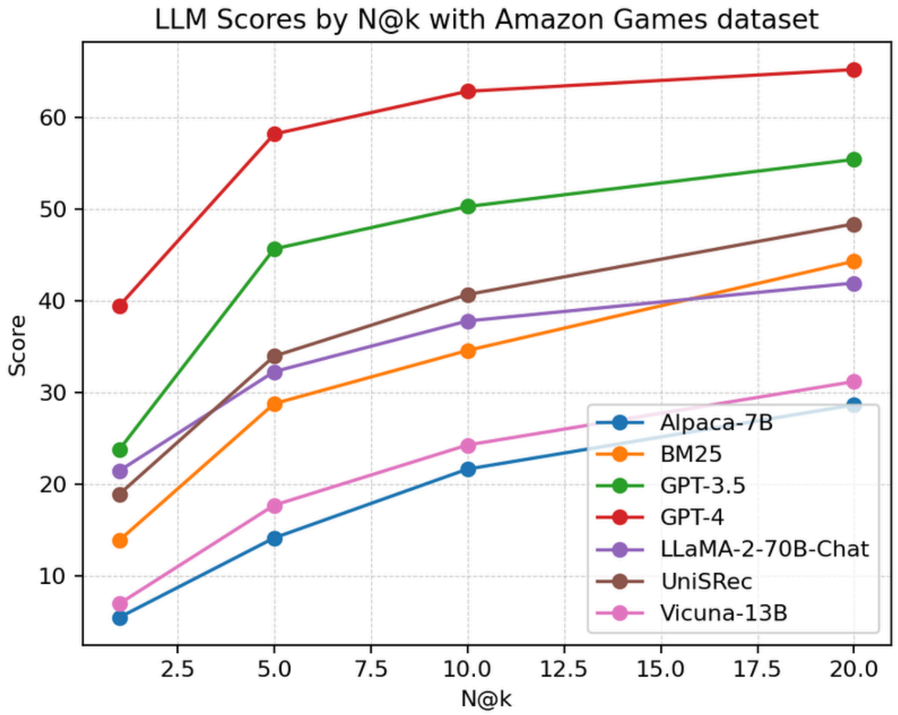

(Elaboración propia)

GPT-4 vs modelos entrenados y no entrenados

(candidatos aleatorios)

	Method	ML-1M				Games			
		N@1	N@5	N@10	N@20	N@1	N@5	N@10	N@20
full	Pop	22.91	45.16	52.33	55.36	28.35	47.42	52.96	57.45
	BPRMF [49]	34.60	59.87	64.29	65.39	44.92	62.33	66.27	68.94
	SASRec [33]	61.39	76.39	78.89	79.79	56.90	73.19	75.92	77.14
zero-shot	BM25 [50]	4.70	12.68	17.88	33.19	13.92	28.81	34.61	44.35
	UniSRec [30]	7.37	18.80	26.67	37.93	18.95	33.99	40.71	48.42
	VQ-Rec [29]	5.98	15.48	23.74	35.85	7.28	18.28	26.21	37.62
	Sequential	18.28	36.35	42.85	49.02	30.28	45.48	50.57	56.55
	Recency-Focused	19.57	37.73	44.23	50.01	**34.03**	**48.77**	**53.50**	**59.01**
	In-Context Learning	**21.77**	**39.59**	**45.83**	**51.62**	33.95	48.44	53.10	58.92

(Hou et al., 2024)

GPT-4 vs modelos entrenados y no entrenados

(candidatos aleatorios)

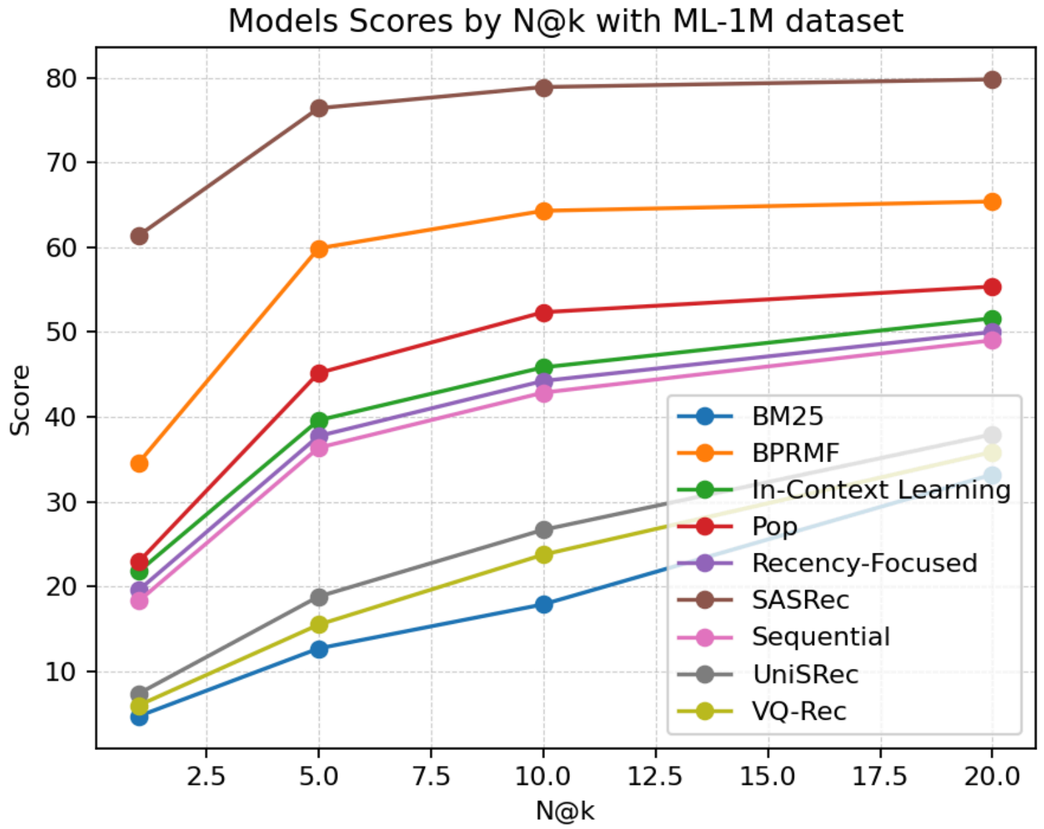

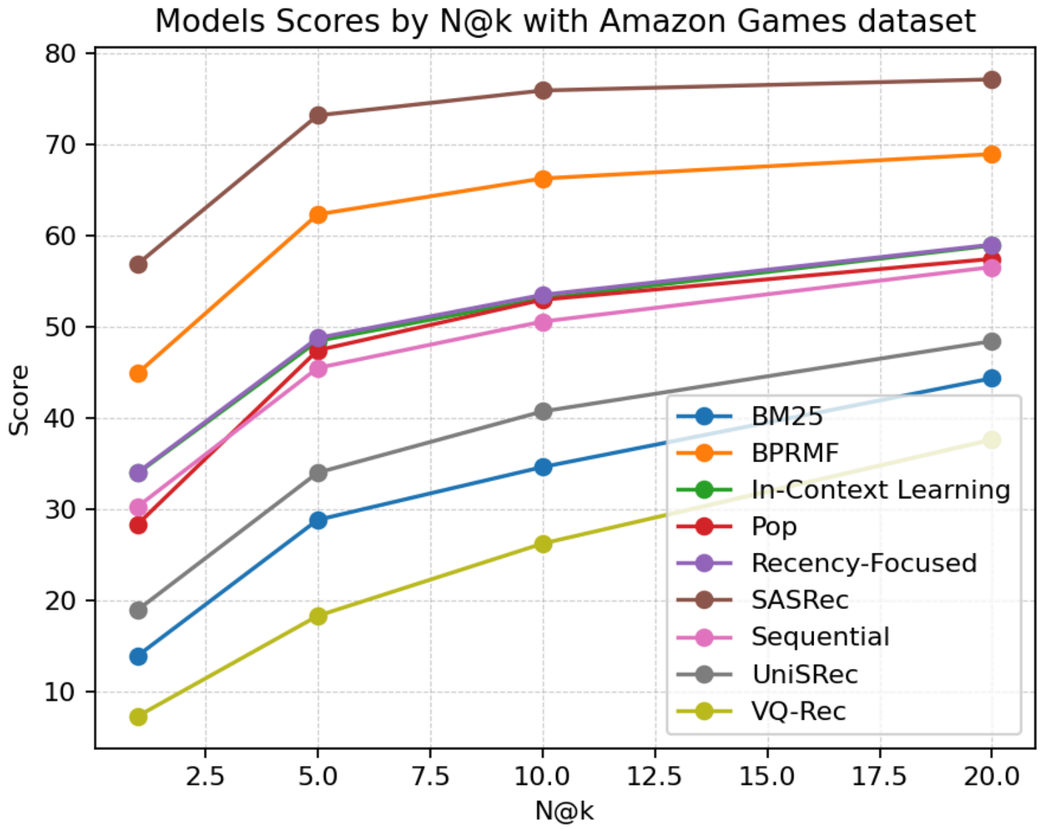

(Elaboración propia)

GPT-4 vs modelos entrenados y no entrenados

(candidatos generados)

	Method	ML-1M				Games			
		N@1	N@5	N@10	N@20	N@1	N@5	N@10	N@20
full	Pop	0.08	1.20	4.13	5.79	0.13	1.00	2.27	2.62
	BPRMF [49]	0.26	1.69	4.41	6.04	0.55	1.98	**2.96**	**3.19**
	SASRec [33]	**3.76**	**9.79**	**10.45**	**10.56**	**1.33**	**3.55**	**4.02**	**4.11**
zero-shot	BM25 [50]	0.26	0.87	2.32	5.28	0.18	1.07	1.80	2.55
	UniSRec [30]	0.88	3.46	5.30	6.92	0.00	1.86	2.03	2.31
	VQ-Rec [29]	0.20	1.60	3.29	5.73	0.20	1.21	1.91	2.64
	Ours	**1.74**	**5.22**	**6.91**	**7.90**	**0.90**	**2.26**	2.80	3.08

(Hou et al., 2024)

LLM are Zero-Shot Rankers for Recommender Systems

GPT-4 vs modelos entrenados y no entrenados

(candidatos generados)

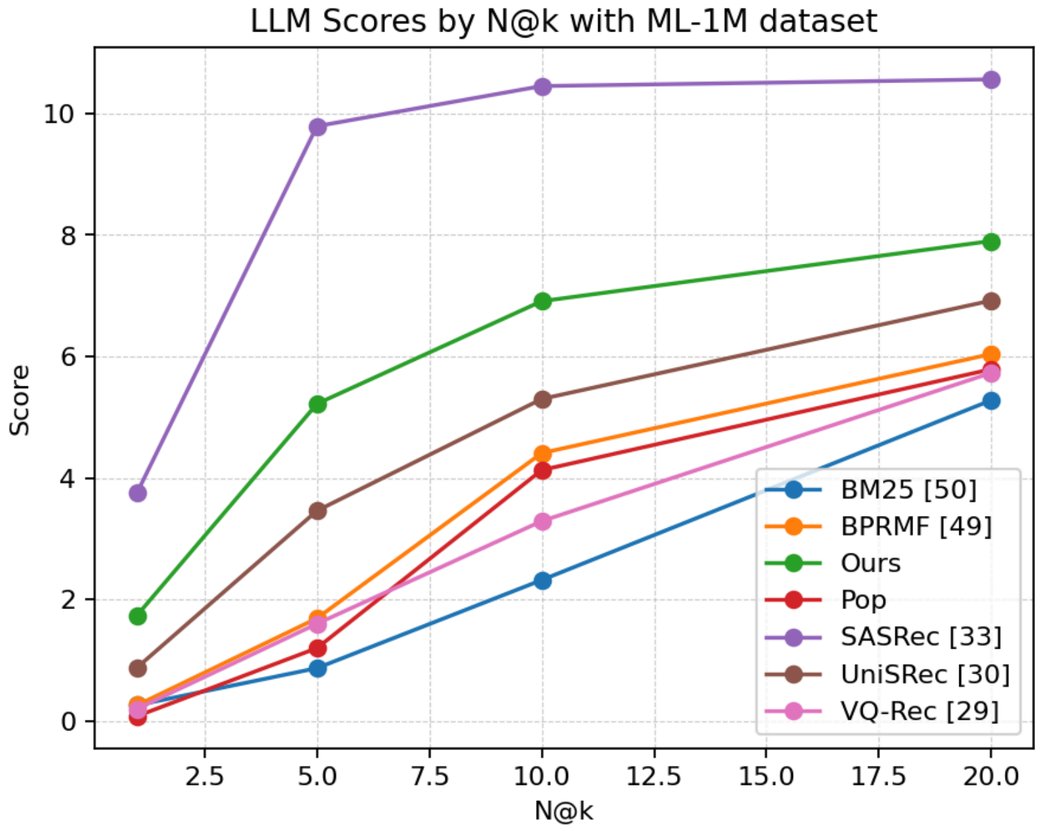

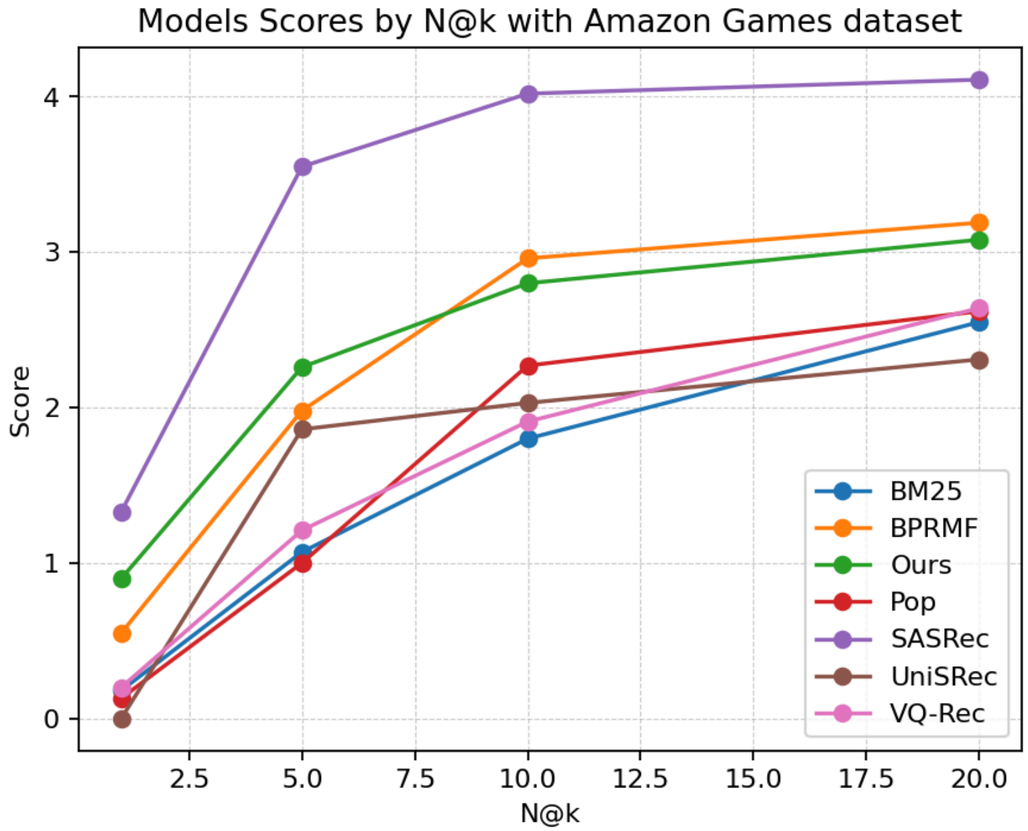

(Elaboración propia)

Key Takeaways

Los LLM tienen un potencial real como recomendadores *zero-shot*, capaces de ofrecer resultados razonables sin necesidad de entrenamiento adicional.

El diseño del prompt y las técnicas de mitigación de sesgos son esenciales para obtener un rendimiento competitivo.

Los LLMs no comprenden naturalmente la secuencia temporal de las interacciones; necesitan que esa información se les indique explícitamente en el texto.

(Imagen provista por Canva)

Conclusión

Aunque los modelos de lenguaje todavía no superan completamente a los sistemas entrenados, su desempeño sin entrenamiento es sorprendentemente alto, y con estrategias simples de ajuste pueden acercarse mucho.

¿Podríamos tener en el futuro sistemas recomendadores basados únicamente en lenguaje natural?

Referencias

[1] Covington, P., Adams, J., Sargin, E.: Deep neural networks for youtube recommendations. In: RecSys. pp. 191–198 (2016)
[2] Kang, W., McAuley, J.: Self-attentive sequential recommendation. In: ICDM (2018)
[3] Rendle, S., Freudenthaler, C., Gantner, Z., Schmidt-Thieme, L.: BPR: bayesian personalized ranking from implicit feedback. In: UAI (2009)
[4] Robertson, S.E., Zaragoza, H.: The probabilistic relevance framework: BM25 and beyond. Found. Trends Inf. Retr. 3(4), 333–389 (2009)
[5] Hou, Y., Mu, S., Zhao, W.X., Li, Y., Ding, B., Wen, J.: Towards universal sequence representation learning for recommender systems. In: KDD (2022)

Gracias

¿Preguntas?