




Pontificia Universidad
Católica de Chile
Sistemas Recomendadores
ICS3633



LLM-Powered User Simulator for Recommender System

Maximiliano Perry
Jenaro Prieto





Contexto



- Sistemas Recomendadores basados en RF → Efectivos
- Requieren Entrenamiento
- Falta de datos de entrenamiento online



Contexto



¿ Podríamos simular el comportamiento de los usuarios ?



Contexto





“Simulating user interaction behavior has become an urgent problem to be solved”

(Zijiant et al, 2024)



Problema de Recomendación


Comparar un ítem con el
historial de preferencias





Contribución: Lógica

Se identifica la lógica intrínseca de como el usuario interactúa con la recomendación y se propone un modelo que traduce dichas interacciones en explicaciones





Contribución: Modelo simulado

Se identifica la lógica intrínseca de como el usuario interactúa con la recomendación y se propone un modelo que traduce dichas interacciones en explicaciones

Se construye un ensemble model que, basado en reglas y modelos estadísticos para simular la interacción humana, manteniendo la consistencia y reduciendo el riesgo de inferencias erróneas





Contribución: Experimentación

Se identifica la lógica intrínseca de como el usuario interactúa con la recomendación y se propone un modelo que traduce dichas interacciones en explicaciones

Se construye un ensemble model que, basado en reglas y modelos estadísticos para simular la interacción humana, manteniendo la consistencia y reduciendo el riesgo de inferencias erróneas

Se experimenta para medir la efectividad del modelo propuesto





Pontificia Universidad
Católica de Chile
Sistemas Recomendadores
ICS3633

Estado del Arte




VirtualTaobao



Estado del Arte



VirtualTaobao




KuaiSim



Estado del Arte



VirtualTaobao



KuaiSim

Caja negra y sin marco evaluativo



Estado del Arte

Simulators	Real dataset	Simulation engine	Evaluation
RecoGym (Rohde et al. 2018)	×	Statistical model	case study
RecSim (Ie et al. 2019)	×	Statistical model	case study
VirtualTaobao (Shi et al. 2019)	✓	GAN	online
Adversarial (Chen et al. 2019)	✓	GAN	offline
KuaiSim (Zhao et al. 2023a)	✓	Transformer	offline
SUBER (Corecco et al. 2024)	✓	LLM	offline & case study
Agent4Rec (Zhang et al. 2024a)	✓	LLM	offline & case study
Ours	✓	LLM-based logical & statistical model	offline & case study

Fuente: Tabla 5, Zhang et al. (2024)



Estado del Arte



"Firstly, current simulators fail to explicitly model user preferences, which is a critical function for accurately predicting user choices."
(Zhang et al, 2024)

"Secondly, there is an absence of an efficient evaluative framework to assess the fidelity of simulated interactions with real user behavior."
(Zhang et al, 2024)

"Consequently, there is an urgent need for the advancement of user simulators that can operate with higher degrees of fidelity and transparency..." (Zhang et al, 2024)



Marco Teórico: RL-based RecSys

Agente

El sistema de recomendación
(la IA que decide qué mostrar)

Entorno

El usuario
(sus preferencias e historial)

Acción

El ítem o producto
recomendado

Recompensa

La interacción del usuario
(clic, compra, like o descarte)

Los sistemas tradicionales aprenden de forma estática; los basados en RL aprenden interactuando dinámicamente para maximizar el enganche a largo plazo del usuario



Marco Teórico: User Simulators

¿Por qué?

Entrenar con usuarios reales es excesivamente lento y costoso

Definición

Simulador: entorno virtual protegido que genera respuestas rápidas y masivas

Solución propuesta

Usar LLMs como simuladores de usuario, aprovechando su capacidad de razonamiento y generación de lenguaje natural

Ventaja clave

Los LLMs generan comportamientos realistas y diversos, superando a los modelos estadísticos de caja negra

Un simulador de usuario permite entrenar y evaluar sistemas de recomendación sin necesidad de interacción real con usuarios.



Marco Teórico: Modelos Base (SASRec y BERT)

BERT (Embeddings Semánticos)

Transforma palabras clave en embeddings dentro de un espacio semántico y comparar

Contexto en el paper

La solución no es solo un prompt de LLM; se apoya sobre estas dos tecnologías


SASRec (Self-Attentive Sequential Rec.)

Modelo estadístico que predice la probabilidad de la siguiente interacción basándose en el historial

Rol conjunto

BERT captura similitud semántica entre ítems y preferencias
SASRec captura patrones de comportamiento

Solución





Objetivo Modelo

Generar una predicción que le pueda gustar o no al usuario



Solución

Objetivo Modelo

Generar una predicción que le pueda gustar o no al usuario

¿Cómo lo hace?

Identifica lógica de interacción del usuario con la recomendación



Solución

Objetivo Modelo

Generar una predicción que le pueda gustar o no al usuario

¿Cómo lo hace?

Identifica lógica de interacción del usuario con la recomendación

- 1.Reconocer película
- 2.Identificar el género
- 3.Como se alinea ese género con mis gustos históricos
- 4....



¿ Cómo reducimos el costo computacional y las alucionaciones?



¿ Cómo reducimos el costo computacional y las alucinationes?

¿ Cómo podemos evaluar objetivamente si un modelo es efectivo para las predicciones en distintos sets de datos?



Metodología del Modelo



Solución: User Simulator

Objetivo

Inferir la relación de un usuario (y) con el ítem recomendado i en base a su historial de interacciones h

$$P(y_c | h, i_c)$$

$$h = \{(i_1, y_1), \dots, (i_n, y_n)\}$$



Solución: Descripción objetiva

Objetivo

Usar LLM para saber objetivamente por que un ítem podría gustarle o no a un usuario

$$D_{pos}^{obj}$$
$$D_{neg}^{obj}$$

Objective Description Prompt Template T_{obj}

Given a Movie named **NAME** and its characteristics, I need you to provide pros and cons, corresponding evidence and keywords from a customer perspective. Movie has the following attributes: **ATTRIBUTES**. Categories of the movie include **CATEGORIES**. Reasons, keywords, and evidence should be concise and reasonable. Keywords should appear positive or negative. Evidence should refer to the information given. Strictly follow the reply format, fill [], do not say anything else: Pros 1: [**pros 1**] Evidence: [**evidence of pros 1**] Keywords: [**keywords of pros 1**] Pros 2: [**pros 2**] Evidence: [**evidence of pros 2**] Keywords: [**keywords of pros 2**] Pros 3: [**pros 3**] Evidence: [**evidence of pros 3**] Keywords: [**keywords of pros 3**] Cons 1: [**cons 1**] Evidence: [**evidence of cons 1**] Keywords: [**keywords of**

cons 1] Cons 2: [**cons 2**] Evidence: [**evidence of cons 2**] Keywords: [**keywords of cons 2**] Cons 3: [**cons 3**] Evidence: [**evidence of cons 3**] Keywords: [**keywords of cons 3**]



Solución: Descripción subjetiva

Objetivo

Usar LLM para saber cualitativamente por que un ítem podría gustarle o no a un usuario

$$D_{pos}^{sub}$$
$$D_{neg}^{sub}$$

Subjective Description Prompt Template T_{sub}

A customer rates **RATING** to the movie with comments: **COMMENTS** The information of this movie is: name: **NAME**, attributes: **ATTRIBUTES**, categories: **CATEGORIES**. I need you to provide Pros, corresponding evidence and keywords of the rating based on given information. Evidence should refer to the information given. Strictly follow the reply format, fill [], do not say anything else: Pros 1: [**pros 1**] Keywords: [**keywords of pros 1**] Evidence: [**evidence of pros 1**] Pros 2: [**pros 2**] Keywords: [**keywords of pros 2**] Evidence: [**evidence of pros 2**] Pros 3: [**pros 3**] Keywords: [**keywords of pros 3**] Evidence: [**evidence of pros 3**]




Solución: Descripciones globales

$$D_{pos} = D_{pos}^{obj} \cup D_{pos}^{sub}$$

$$D_{neg} = D_{neg}^{obj} \cup D_{neg}^{sub}$$

Solución





Solución: Keywords Matching Model

Actualizar preferencias

Según coincidan recomendación con históricas

$$h_C := \{(i_k, y_k)\}_{k=1}^C$$

Guardar evaluados positivos y negativos

$$I_{pos} := \{i_k\}_{k=1}^{C_{pos}}$$

$$I_{neg} := \{i_k\}_{k=1}^{C_{neg}}$$

Modelo de preferencias

$$f_{mat}(I_{pos}, I_{neg}, i_c)$$



Solución: Keywords Matching Model

Comparamos gustos potenciales con históricos

$$\alpha_{pos} = \sum_{i \in I_{pos}} |D_{pos}^{i_c} \cap D_{pos}^i|$$

$$\alpha_{neg} = \sum_{i \in I_{neg}} |D_{neg}^{i_c} \cap D_{neg}^i|$$

Definimos si el usuario tendrá tendencia positiva o negativa

$$f_{mat}(I_{pos}, I_{neg}, i_c) = \begin{cases} 1 & \text{if } \alpha_{pos} > \alpha_{neg}, \\ rand\{0, 1\} & \text{if } \alpha_{pos} = \alpha_{neg}, \\ 0 & \text{if } \alpha_{pos} < \alpha_{neg}. \end{cases}$$



Solución: Similarity Calculation Model

Traducir gustos a BERT

Generar Embeddings

$$E_{pos} = AvePool(\{Bert(d) | d \in D_{pos}\})$$

$$E_{neg} = AvePool(\{Bert(d) | d \in D_{neg}\})$$

Comparar con historial usando similitud del coseno

$$\beta_{pos} = Max\{\phi(E_{pos}^{i_c}, E_{pos}^i) | i \in I_{pos}\}$$

$$\beta_{neg} = Max\{\phi(E_{neg}^{i_c}, E_{neg}^i) | i \in I_{neg}\}$$

Determina si le gustará o no según

$$f_{sim}(I_{pos}, I_{neg}, i_c) = \begin{cases} 1 & \text{if } \beta_{pos} > \beta_{neg}, \\ rand\{0, 1\} & \text{if } \beta_{pos} = \beta_{neg}, \\ 0 & \text{if } \beta_{pos} < \beta_{neg}. \end{cases}$$



Solución: Statistic Model & MDP Formulation

State

Posibles estados

$$(s \in \mathcal{S})$$

Action

Posibles acciones

$$(i_c \in \mathcal{A})$$

Transition Probabilities

Probabilidad de pasar a un nuevo estado


$$(\mathcal{P}(s'|s, i_c))$$

Reward Function

Función que recompensa cuando se recomienda acertadamente


$$\mathcal{R}(s, i_c, s') = \begin{cases} 1 & \text{if } f_{mat} + f_{sim} + f_{sta} \geq 2, \\ 0 & \text{if } f_{mat} + f_{sim} + f_{sta} < 2. \end{cases}$$

Solución





Evaluación



Dataset	Metric	PPO	TRPO	A2C	DQN
Yelp	A. Rwd↑	9.97	13.45	24.15	27.56
	T. Rwd↑	141.57	157.42	267.60	330.98
	Liking%↑	34.59	40.07	48.35	49.43
Amazon Music	A. Rwd↑	10.49	11.31	13.45	16.70
	T. Rwd↑	129.03	140.15	141.03	181.42
	Liking%↑	29.30	32.46	29.54	33.18
Amazon Games	A. Rwd↑	18.72	21.35	27.56	26.43
	T. Rwd↑	208.43	242.26	317.56	269.02
	Liking%↑	33.15	37.64	43.52	40.73
Amazon Movie	A. Rwd↑	29.42	27.47	31.72	38.60
	T. Rwd↑	310.69	301.40	354.34	416.18
	Liking%↑	38.59	36.70	42.37	44.50
Anime	A. Rwd↑	14.12	14.58	21.50	18.03
	T. Rwd↑	155.74	163.44	242.95	201.94
	Liking%↑	25.46	24.27	31.52	30.67

Análisis cuantitativo

- Los buenos resultados le benchmark sugiere que el simulador aporta un ambiente adecuado
- El simulador es Consistente
- Emula correctamente a usuarios

A2C (Mnih et al. 2016), DQN (Mnih et al. 2013), PPO (Schulman et al. 2017), and TRPO (Schulman et al. 2015)



Evaluación



Análisis cualitativo

- Explicita la razón de porque a un usuario le gustar o no un articulo

	historical items h			RL recommendations i_c		
	i^{t-3}	i^{t-2}	i^{t-1}	i_c^t	i_c^{t+1}	i_c^{t+2}
Name	City Diner	El Maguey	Popeyes Kitchen	IHOP	Gooley Cakes	Crusoe's Original
Category	Restaurants	Restaurants	Restaurants	Restaurants	Bakeries	Restaurants
Pros	family gathering	child-friendly	-	casual	variety	child-friendly
Cons	-	-	loud, crowded	loud	no in-store dining	no reservations
Rating	1	1	0	-	-	-



Evaluación

Solución a Caja Negra

Las respuestas de los LLM dan una solución clara

Reducción de tiempos y alucinaciones

Al no estar conectado a la red y usar palabras claves, se atacan estos dos dolores

Validación empírica

Se demostró validación en cinco datasets distintos

Próximos pasos

Por ahora solo se trabaja con “me gusta” y “no me gusta”, se espera avanzar en direcciones como el rating, interacción, retención de tiempo

Referencias

Canva. (2025). Canva: Visual communication platform [Software]. <https://www.canva.com>

Canva. (2025). Magic Studio: AI-powered design tools [Software]. <https://www.canva.com/magic>

Ollama. (2025). Ollama: Run large language models locally [Software]. <https://ollama.com>

Meta AI. (2024). LLaMA 3: Large Language Model Meta AI (Version 3) [Large language model]. <https://ai.meta.com/llama/>

Zhang, Z., Liu, S., Liu, Z., Zhong, R., Cai, Q., Zhao, X., Zhang, C., Liu, Q., & Jiang, P. (2024). LLM-Powered User Simulator for Recommender System. Jilin University; Kuaishou Technology; City University of Hong Kong; Xi'an Jiaotong University.

Kang, W.-C.; and McAuley, J. 2018. Self-attentive sequential recommendation. In 2018 IEEE international conference on data mining (ICDM), 197206. IEEE

Mnih, V.; Badia, A. P.; Mirza, M.; Graves, A.; Lillicrap, T.; Harley, T.; Silver, D.; and Kavukcuoglu, K. 2016. Asynchronous methods for deep reinforcement learning. In International conference on machine learning, 19281937.PMLR.


Mnih, V.; Kavukcuoglu, K.; Silver, D.; Graves, A.; Antonoglou, I.; Wierstra, D.; and Riedmiller, M. 2013. Playing atari with deep reinforcement learning. arXiv preprint arXiv:1312.5602

Schulman, J.; Levine, S.; Abbeel, P.; Jordan, M.; and Moritz, P. 2015. Trust region policy optimization. In International conference on machine learning, 18891897. PMLR.

Schulman, J.; Wolski, F.; Dhariwal, P.; Radford, A.; and Klimov, O. 2017. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347.



Pontificia Universidad
Católica de Chile
Sistemas Recomendadores
ICS3633



Muchas gracias