



UC | Chile

LLMEmb: LLM Can Be a Good Embedding Generator for Sequential Recommendation

RecSys Seminario 2026

Alonso Casanova¹ 

Bruno Cerda² 

Berioska C.Vargas³ 

^{1,2,3} Pontificia Universidad Católica de Chile

alonso.casanova@uc.cl, bcerca@estudiantes.uc.cl, bcontrerasv6@estudiantes.uc.cl



Table of contents

① Definición formal

② Estado del Arte

Modelos Secuenciales

Problemas

LLM para mejorar SRS

③ Solución

④ Evaluación

Evaluación

Métricas

⑤ Conclusión

Conclusión



Introducción



Introducción

Pregunta

¿Es posible integrar LLMs en sistemas recomendadores secuenciales?

SRS

- captura preferencias de usuarios
- preferencias de interacciones históricas
- predice el próximo ítem

Uso práctico

- ecommerce (Zhou et al. 2018)
- short video (Pan et al.2023)
- session-based (Fang et al., 2020)



Definición formal



Definición del problema de recomendación

- 1 Sea $\mathcal{V}$ un conjunto de ítems. Denotamos a un elemento como v_j .
- 2 Sea $\mathcal{U}$ un conjunto de usuarios. Denotamos a un elemento como u .
- 3 Sea $Q^{(u)} = \{v_1^{(u)}, \dots, v_{N_u}^{(u)}\}$ el historial de un usuario; la secuencia de ítems con los que el usuario ya ha interactuado, ordenada por temporalidad.

Formulamos el problema de recomendar el siguiente ítem como:

$$\arg \max_{v_j \in \mathcal{V}} P(v_{N_u+1} = v_j \mid Q^{(u)})$$



Definición formal

Estado del Arte

Solución

Evaluación

Conclusión

Estado del Arte



Modelos Backbone


Se generan embeddings para cada item, luego se modela la secuencialidad en base a los datos de los usuarios.

- **GRU4Rec**: Basado en RNN. Procesa el historial de forma consecutiva (Hidasi et al., 2016)
- **BERT4Rec**: Basado en el modelo BERT para PNL, es un modelo bidireccional (Sun et al., 2019).
- **SASRec**: Basado en transformadores, usando los mecanismos de auto-atención (Kang & McAuley, 2018).




Problemas

- Dificultad para recomendar artículos poco populares
- Esto se debe a una asimetría en la representación vectorial. Los vectores de ítems impopulares están lejos de los populares.
- LLM pueden generar representaciones más uniformes por conocimiento semántico.



Problema Cola larga




Distribución SASRec



LLM para mejorar SRS

- **LLM2X** consigue generar embeddings semánticos pero no orientado a RecSys causando una **brecha semántica** (Harte et al., 2023).
- **SAID** y **TSLREC** modelos LLM refinados para operar con RecSYS pero pasan por alto los atributos de los ítems (Hu et al., 2024; D. Liu et al., 2024).
- **MELT**: No usa LLM, se entrena red neuronal en base a interacciones (Kim et al., 2023).



Comparación LLM2X y SAID/TSLRec



Solución



Contribuciones

- **Generador de embeddings:** Utilizan un LLM para generar embeddings, lo cual permite reducir el problema "long tail".
- **SCFT:** Introducen finetuning contrastivo a nivel atributo para mejorar semánticas de los embeddings.
- **RAT:** Integran información colaborativa para prevenir pérdida de información semántica.
- **Experimentación:** Mediante 3 datasets distintos demuestran que LLMEmb mejora los resultados en SRS.




SCFT: Supervised Contrastive Fine Tuning

Objetivo: Enseñar al LLM a distinguir entre ítems contrastando sus atributos.

- $T_i = [I, A_1, \dots, A_K]$
 - I : Texto que prepara contexto de atributos de un ítem.
 - A_k : $\langle \text{Nombre atributo} \rangle \langle \text{Contenido} \rangle$
- Para pares positivos, se aplica augmentation mediante:
 - $\hat{T}_i^1 = [I, \text{RandomDrop}(\{A_j\}_{j=1}^K, r)]$
 - $\hat{T}_i^2 = [I, \text{RandomDrop}(\{A_j\}_{j=1}^K, r)]$
- Pesos de LLM están congelados, se entrena mediante LoRA.
- Para un par de embeddings, se aplica $\mathcal{L}_{SCFT}$:
 - $\mathcal{L}_{SCFT} = \mathcal{L}_{CL}^1 + \mathcal{L}_{CL}^2$
 - $\mathcal{L}_{CL}^1 = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(\hat{e}_i^1, \hat{e}_i^2)/\tau)}{\sum_{k=1}^B \mathbb{I}_{[i \neq k]} \exp(\text{sim}(\hat{e}_i^1, \hat{e}_k^2)/\tau)}$
 - Para $\mathcal{L}_{CL}^2$ simplemente se cambian de orden $\hat{e}^1$ y $\hat{e}^2$.



SCFT: Supervised Contrastive Fine Tuning





RAT: Recommendation Adaptation Training

- LLM, con sus pesos congelados (LoRA incluido), recibe como input T_i .
- Se aplica PCA en output de LLM (e_i^{LLM}), para obtener $\bar{e}_i^{LLM}$.
- Se reduce dimensionalidad nuevamente mediante un "Adapter" (MLP de 2 layers).
- Se entrena SRS backbone utilizando secuencia $\bar{Q}$ de embeddings e_i .
- Adapter y SRS Backbone son entrenados utilizando $\mathcal{L}_{RAT}$:
 - $\mathcal{L}_{RAT} = \mathcal{L}_{SRS} + \alpha \cdot \mathcal{L}_{align}$
 - $\mathcal{L}_{SRS}$ es Binary Cross Entropy (BCE)
 - $\mathcal{L}_{align}$ es contrastiva, similar a $\mathcal{L}_{SCFT}$ ($\mathcal{L}_{align} = \mathcal{L}_{align}^1 + \mathcal{L}_{align}^2$):
 - $\mathcal{L}_{align}^1 = -\frac{1}{S} \sum_{i=1}^S \log \frac{\exp(\text{sim}(e_i, \tilde{e}_i)/\gamma)}{\sum_{k=1}^S \mathbb{I}_{[i \neq k]} \exp(\text{sim}(e_i, \tilde{e}_k)/\gamma)}$
- $\mathcal{L}_{align}$ utiliza embeddings $\tilde{e}_i$ los cuales fueron obtenidos de un SRS Backbone pre-entrenado con embeddings regulares.




RAT: Recommendation Adaptation Training

Stage 2: Recommendation Adaptation Training (RAT)


❄️ Frozen

🔥 Updated





Inference





Definición formal

Estado del Arte

Solución

Evaluación

Conclusión

Evaluación



Evaluación

- 3 fuentes de datos realistas:
 - Yelp
 - Amazon Beauty
 - Amazon Fashion
- 3 integraciones SRS/LLMEmb:
 - GRU4Rec (Hidasi et al., 2016)
 - BERT4Rec (Sun et al., 2019)
 - SASRec (Kang and McAuley, 2018)
- 3 modelos LLM/SRS:
 - LLM2X (Harte et al., 2023)
 - SAID (Hu et al., 2024)
 - TLSRec (Liu et al., 2024a)


- 1 línea base MELT (Kim et al., 2023)
- nDCG@10
- HitRate@10

Group	% of Items	Popularity Level
Head (Top)	20%	Most popular
Tail (Bottom)	80%	Less popular




Métricas I


nDCG@10 comparison integrating GRU4Rec




HitRate@10 comparison integrating GRU4Rec




nDCG@10 comparison integrating Bert4Rec




HitRate@10 comparison integrating Bert4Rec



nDCG@10 comparison integrating SASRec






HitRate@10 comparison integrating SASRec





Métricas II

Dataset	Model	Overall		Tail	
		H@10	N@10	H@10	N@10
Yelp	LLMEmb	0.6647	0.4113	0.2951	0.1456
	- w/o SCFT	0.6538	0.4031	0.2474	0.1218
	- w/o adapter	0.6414	0.3968	0.2196	0.1055
	- w/o freeze	0.6257	0.3800	0.1710	0.0740
	- w/o align	0.6598	0.4060	0.2793	0.1310





Definición formal

Estado del Arte

Solución

Evaluación

Conclusión

Conclusión



Conclusión

- LLMEmb puede mejorar los tres modelos SRS de forma consistente; LLM2X, SAID y TSLRec.
- Usar LLaMA sin ajuste fino para embeddings demuestra la brecha semántica entre las tareas generales de los LLM y las de recomendación.
- En comparación con LLM2X y SAID, el modelo LLMEmb ofrece mayor rendimiento en ítems en *long-tail*, especialmente para el grupo 1-4.

Trabajo Futuro:

- LLMEmb tiene un rendimiento ligeramente inferior al de LLM2X para ítems más populares (p.e. 40+), se presenta un desequilibrio entre los ítems populares y los del *long-tail*.



References I

- Fang, H., Zhang, D., Shu, Y., & Guo, G. (2020). Deep learning for sequential recommendation: Algorithms, influential factors, and evaluations. *ACM Trans. Inf. Syst.*, 39(1). <https://doi.org/10.1145/3426723>
- Harte, J., Zorgdrager, W., Louridas, P., Katsifodimos, A., Jannach, D., & Fragkoulis, M. (2023). Leveraging large language models for sequential recommendation. *arXiv preprint arXiv:2309.09261*. <https://doi.org/10.48550/arXiv.2309.09261>
- Hidasi, B., Karatzoglou, A., Baltrunas, L., & Tikk, D. (2016). Session-based recommendations with recurrent neural networks. *arXiv preprint arXiv:1511.06939*. <https://doi.org/10.48550/arXiv.1511.06939>
- Hu, J., Xia, W., Zhang, X., Fu, C., Wu, W., Huan, Z., Li, A., Tang, Z., & Zhou, J. (2024). Enhancing sequential recommendation via llm-based semantic embedding learning. <https://doi.org/10.1145/3589335.3648307>
- Kang, W.-C., & McAuley, J. (2018). Self-attentive sequential recommendation. *arXiv preprint arXiv:1808.09781*. <https://doi.org/10.48550/arXiv.1808.09781>
- Kim, K., Hyun, D., Yun, S., & Park, C. (2023). Melt: Mutual enhancement of long-tailed user and item for sequential recommendation. *arXiv preprint arXiv:2304.08382*. <https://doi.org/10.48550/arXiv.2304.08382>
- Liu, D., Xian, S., Lin, X., Zhang, X., Zhu, H., Fang, Y., Chen, Z., & Ming, Z. (2024). A practice-friendly two-stage llm-enhanced paradigm in sequential recommendation. *arXiv preprint arXiv:2406.00333*. <https://doi.org/10.48550/arXiv.2406.00333>
- Liu, Q., Wu, X., Wang, W., Wang, Y., Zhu, Y., Zhao, X., Tian, F., & Zheng, Y. (2024). Llmemb: Large language model can be a good embedding generator for sequential recommendation [Accepted by AAAI'25]. *arXiv preprint arXiv:2409.19925*. <https://doi.org/10.48550/arXiv.2409.19925>
- Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019). Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer. *arXiv preprint arXiv:1904.06690*. <https://doi.org/10.48550/arXiv.1904.06690>



References II

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.
<https://doi.org/10.48550/arXiv.2302.13971>