



DECOUPLED SIDE INFORMATION FUSION FOR SEQUENTIAL RECOMMENDATION

Presentado por:


Isabella Peña

Baltazar Lutjens

Vicente Rodríguez




Contenidos



Contexto	01
Problema de recomendación	02
Contribuciones	03
Estado del arte y marco teórico	04

Detalle de la solución	05
Metodología	06
Resultados	07
Conclusiones & contribuciones	08



01

Contexto

Contexto





Contexto



Los sistemas de recomendación secuencial (SR) buscan predecir el siguiente ítem que un usuario elegirá, basándose en sus interacciones previas (p. ej. historial de compras, clics, vistas...)



Hoy en día los modelos SR

Se basan en redes transformer con autoatención (***self-attention***), como SASRec o BERT4Rec, que capturan dependencias temporales entre ítems




Sin embargo, los sistemas reales

Contienen información adicional (side information) sobre los ítems o usuarios


Entonces

¿Cómo integrar efectivamente esa información adicional o side information sin introducir ruido ni limitar la expresividad del modelo?



02

Problema de recomendación



Problema de Recomendación

El artículo busca resolver cómo fusionar de forma efectiva la información lateral (***side information***) dentro de los modelos secuenciales basados en atención, para mejorar la predicción del siguiente ítem.

Formulación del desafío

Dado un usuario con una secuencia de interacciones, donde cada interacción incluye un ítem y múltiples atributos, se busca predecir el siguiente ítem con mayor probabilidad de interacción.


El desafío radica en cómo **incorporar estos atributos en el mecanismo de atención** sin degradar la representación ni limitar la capacidad de aprendizaje del modelo.

Limitaciones de los enfoques actuales

Los modelos actuales suelen fusionar toda esa información al inicio, antes del mecanismo de atención. Esto se conoce como **early fusion**.

El problema es que:

- **Reduce el rango** de las matrices de atención (menor expresividad) → **cuello de botella**
- Produce **gradientes rígidos** (mismo peso para todos los atributos)
- Introduce **ruido entre información** heterogénea.



03

Contribuciones



Contribuciones



Nuevo enfoque para integrar información lateral dentro del mecanismo de atención.

- 01 Desacopla la atención de cada tipo de información (ítem, categoría, marca, etc.)
- 02 Mueve la fusión al interior del layer de atención (decoupled fusion)
- 03 Rompe el “*rank bottleneck*”, permitiendo matrices de atención de mayor expresividad
- 04 Introduce gradientes independientes, facilitando un aprendizaje más flexible
- 05 Se incorporan Auxiliary Attribute Predictors (AAP) que fortalecen la interacción entre atributos e ítems durante el entrenamiento.







Contribuciones

Beneficios

Mayor capacidad de representación (mayor rank de matrices de atención), menor ruido (atributos procesados por separado), y gradientes más flexibles (diferenciados) que permiten aprender qué tipo de información es más relevante en cada caso.





04

Estado del arte y marco teórico


Estado del arte



- 1 Partiendo con modelos de Márkov o factorización matricial.
El problema: no captaban patrones complejos
- 2 Surgen modelos basados en Deep Learning
 - RNNs (GRU4Rec): capturan dependencias cortas, pero no relaciones a largo plazo
 - CNNs (Caser): aprenden patrones locales
 - Transformers (SASRec, BERT4Rec): introducen self-attention, permitiendo capturar dependencias largas entre ítems



Estado del arte



3 Incorporación de Side Information: busca enriquecer las secuencias con atributos de ítems o usuarios

- FDSA (2019): redes paralelas para ítem y atributos, fusionadas al final.
- S^3 -Rec (2020): usa pre-entrenamiento con predicción de atributos (auto-supervisado)
- ICAI-SR (2021): modela relaciones ítem-atributo mediante un grafo y fusiona antes de la atención
- NOVA (2021): fusión no invasiva, usa atributos solo en key y query



Estado del arte




Limitaciones

- Limita el rango de las matrices de atención (menor expresividad)
- Obliga a gradientes compartidos entre atributos (poca flexibilidad)
- Introduce ruido de correlación cruzada entre ítems y atributos heterogéneos

DIF-SR surge como una solución para superar estas restricciones, moviendo la fusión al propio attention layer y tratándola de forma desacoplada y flexible





05

Detalle de la solución

Formulación del problema

Set de usuarios

$\mathcal{U}$

Set de ítems

$\mathcal{I}$

Formulación del problema

Set de usuarios

$\mathcal{U}$

Set de ítems

$\mathcal{I}$

$u \in \mathcal{U}$

Interacciones Históricas del Usuario

$$\mathcal{S}_u = [v_1, \dots, v_n]$$

Formulación del problema

$$u \in \mathcal{U}$$

Interacciones Históricas del Usuario

$$\mathcal{S}_u = [v_1, \dots, v_n]$$

$$v_i \in \mathcal{S}_u$$

i -ésima interacción con p tipos de información adicional

$$v_i = (I_i, f_i^{(1)}, \dots, f_i^{(p)})$$

Formulación del problema

Objetivo

Predecir el ítem $I_{pred} \in \mathcal{I}$ con que el usuario interactuará con mayor probabilidad.


$$I_{pred} = I^{(\hat{k})}$$

Índice del ítem $I^{(k)}$ que maximiza la probabilidad de que la próxima interacción sea con ese ítem dado el historial $\mathcal{S}_u$.


$$\hat{k} = \arg \max_k P(v_{n+1} = (I^{(k)}, \cdot) \mid \mathcal{S}_u)$$

Metodología

DIF-SR posee tres módulos principales:



Embedding Module




Decoupled Side Information Module




Prediction Module with APP

Metodología



Embedding Module



Embedding Module

Embedding de ítems

$$E^{ID} = \mathcal{E}_{id}([I_1, \dots, I_n])$$

Embedding de atributos

$$E^{f_i} = \mathcal{E}_{f_i}([f_1^{(i)}, \dots, f_n^{(i)}]) , \forall i \in \{1, \dots, p\}$$

Capa de *embedding*
correspondiente que codifica el
ítem y sus atributos en vectores

$\mathcal{E}$

Embedding Module

Embedding de ítems

$$E^{ID} = \mathcal{E}_{id}([I_1, \dots, I_n])$$

Embedding de atributos

$$E^{f_i} = \mathcal{E}_{f_i}([f_1^{(i)}, \dots, f_n^{(i)}]) , \forall i \in \{1, \dots, p\}$$

Lookup Embedding Matrices


$$M_{id} \in \mathbb{R}^{|\mathcal{I}| \times d}, M_{f_1} \in \mathbb{R}^{|f_1| \times d_{f_1}}, \dots, M_{f_p} \in \mathbb{R}^{|f_p| \times d_{f_p}}$$

Embedding Module


Output Embeddings

$$E^{id} \in \mathbb{R}^{n \times d}, E^{f_1} \in \mathbb{R}^{n \times d_{f_1}}, \dots, E^{f_p} \in \mathbb{R}^{n \times d_{f_p}}$$

Decoupled Side Information Fusion Module



Decoupled Side Information Fusion Module



Estructura de la capa

Representación del ítem de
entrada del bloque i

$$R_i^{(ID)} \in \mathbb{R}^{n \times d}$$


Formulación del proceso

$$R_{i+1}^{(ID)} = LN(FFN(DIF(R_i^{(ID)}, E^{f_1}, \dots, E^{f_p})))$$
$$R_1^{(ID)} = E^{ID}$$

FFN : Feed-Forward Network

LN : Layer Normalization

Decoupled Side Information Fusion Module




Soluciones de atención previas

$SASRec_F$

Se fusiona la información adicional directamente a la representación de ítems y se realiza **vanilla self-attention** en el *embedding* integrado.

Embedding Integrado

$$R \in \mathbb{R}^{n \times d}$$




Q

K

V

Decoupled Side Information Fusion Module



Soluciones de atención previas

SASRec_F

Query, Key and Value Projection Matrices for h heads


$$W_Q^i, W_K^i, W_V^i \in \mathbb{R}^{d \times d_h}, i \in [h]$$

n : Largo del input

d : Tamaño oculto

d_h : Multi-head query-key down-projection size ($d_h = d/h$)

Decoupled Side Information Fusion Module



Soluciones de atención previas

$SASRec_F$

Cálculo del Attention Score


$$SAS_att^i = (RW_Q^i)(RW_K^i)^\top$$

Output para cada i cabeza

$$SAS_head^i = \sigma \left(\frac{SAS_att^i}{\sqrt{d}} \right) (RW_V^i)$$

σ : Softmax Function

Decoupled Side Information Fusion Module




Soluciones de atención previas

$SASRec_F$

A pesar de que la solución permite que la **información adicional inflencie directamente el proceso de aprendizaje de la representación de ítems**, se observa que posee la desventaja de la **invasión en la representación de ítems**.

Decoupled Side Information Fusion Module



Soluciones de atención previas

NOVA

Para solucionar el problema anterior, se propone utilizar la **fusión no invasiva de información adicional**.

Embedding Integrado

$$R \in \mathbb{R}^{n \times d}$$




Embedding "puro" de ítems ID

$$R^{(ID)} \in \mathbb{R}^{n \times d}$$



Decoupled Side Information Fusion Module



Soluciones de atención previas

NOVA

Query, Key and Value Projection Matrices for h heads


$$W_Q^i, W_K^i, W_V^i \in \mathbb{R}^{d \times d_h}, i \in [h]$$

n : Largo del input

d : Tamaño oculto

d_h : Multi-head query-key down-projection size ($d_h = d/h$)

Decoupled Side Information Fusion Module



Soluciones de atención previas

NOVA

Cálculo del Attention Score

$$NOVA_{att}^i = (RW_Q^i)(RW_K^i)^\top$$


Output para cada i cabeza

$$NOVA_{head}^i = \sigma \left(\frac{NOVA_{att}^i}{\sqrt{d}} \right) (R^{(ID)} W_V^i)$$


σ : Softmax Function

Decoupled Side Information Fusion Module

II Soluciones de atención previas




Decoupled Side Information Fusion Module




Soluciones de atención previas


NOVA-SR




Decoupled Side Information Fusion Module



DIF Attention



Decoupled Side Information Fusion Module




DIF Attention

Problemas

- ▶ **NOVA resuelve el problema de la invasión** en la representación de ítems.
- ▶ **Limitaciones en el espacio de atención** compuesto.
- ▶ **Presenta degradación de la expresividad** respecto al rango de la matriz de atención y la flexibilidad del gradiente de entrenamiento.

Decoupled Side Information Fusion Module




DIF Attention

Mejoras

- ▶ Todos **los atributos** generan “**por sí mismos**” sus propias matrices de **atención desacopladas**, las cuales son **luego fusionadas**.
- ▶ El cálculo de atención desacoplado **mejora la expresividad del modelo**, **rompiendo el *rank bottleneck***.
- ▶ **Previene gradientes inflexibles**.
- ▶ **Previene relaciones cruzadas inesperadas** entre diferentes atributos y el ítem.


Decoupled Side Information Fusion Module



DIF Attention

Embedding “puro” de ítems ID

$$R^{(ID)} \in \mathbb{R}^{n \times d}$$



Query, Key and Value Projection Matrices for h heads


$$W_Q^i, W_K^i, W_V^i \in \mathbb{R}^{d \times d_h}, i \in [h]$$

n : Largo del input

d : Tamaño oculto

d_h : Multi-head query-key down-projection size ($d_h = d/h$)

Decoupled Side Information Fusion Module



DIF Attention

Attention Score para representación de ítems


$$att_{ID}^i = (R^{(ID)} W_Q^i) (R^{(ID)} W_K^i)^\top$$

Embeddings de atributos

$$E^{f_1} \in \mathbb{R}^{n \times d_{f_1}}, \dots, E^{f_p} \in \mathbb{R}^{n \times d_{f_p}}$$

$d_{f_j} \leq d, j \in [p]$: Para evitar sobre parametrizacion y reducir overhead

Decoupled Side Information Fusion Module



DIF Attention

Attention Score para representación de ítems

$$att_{ID}^i = (R^{(ID)} W_Q^i) (R^{(ID)} W_K^i)^\top$$

Query, Key and Value Projection Matrices for h heads


$$W_Q^{(f_j)i}, W_K^{(f_j)i}, W_V^{(f_j)i} \in \mathbb{R}^{d \times d_{hj}}, i \in [h], j \in [p]$$

n : Largo del input

d : Tamaño oculto

d_h : Multi-head query-key down-projection size ($d_{hj} = d_{f_j}/h$)

Decoupled Side Information Fusion Module



DIF Attention


Query, Key and Value Projection Matrices for h heads

$$W_Q^{(f_j)i}, W_K^{(f_j)i}, W_V^{(f_j)i} \in \mathbb{R}^{d \times d_{hj}}, i \in [h], j \in [p]$$

Matrices *multi-head attention* para cada atributo

$$att_j^i = \left(E^{f_j} W_Q^{(f_j)i} \right) \left(E^{f_j} W_K^{(f_j)i} \right)^\top, \forall j \in \{1, \dots, p\}$$

Decoupled Side Information Fusion Module



DIF Attention

Luego, se **fusionan todas las matrices** a través de la función de fusión $\mathcal{F}$.

Cálculo del Attention Score


$$DIF_att^i = \mathcal{F}(att_{ID}^i, att_{f_1}^i, \dots, att_{f_p}^i)$$

Output para cada i cabeza

$$DIF_head^i = \sigma \left(\frac{DIF_att^i}{\sqrt{d}} \right) (R^{(ID)} W_V^i)$$

σ : Softmax Function


Decoupled Side Information Fusion Module




DIF Attention

Finalmente, los outputs de todas las *attention heads* **son concatenados y alimentados a la *feed-forward layer*.**


Decoupled Side Information Fusion Module



DIF Attention




Decoupled Side Information Fusion Module



Análisis teórico

- ▶ Por teorema, la **fusión temprana** de información adicional **limita el rango de las matrices de atención** por d_h , que es un valor menor a lo normal.
- ▶ Las **matrices de atención de mayor rango** mejoran DIF-SR con una **expresividad más fuerte del modelo**.
- ▶ Si sólo se utiliza fusión aditiva simple:
 - En **SASRec**, los gradientes son iguales para **todos los input *embeddings* de ítems y atributos**.
 - En **NOVA**, los gradientes son iguales en **todos los *embeddings* de tipos de atributos**.

Prediction Module



Prediction Module

Item Loss

$$L_{id} = - \sum_{i=1}^{|\mathcal{I}|} y_i \log(\hat{y}_i)$$

Side Information Loss Function

$$L_{f_j} = - \sum_{i=1}^{|f_j|} y_i^{(f_j)} \log(\hat{y}_i^{f_j}) + (1 - y_i^{f_j}) \log(1 - \hat{y}_i^{f_j})$$

Combined Loss Function

$$L = L_{id} + \lambda \sum_{i=1}^p L_{f_j}$$

Prediction Module

Representación Final

$$R_L^{(ID)}$$

Último ítem

$$R_L^{(ID)}[n]$$

Probabilidad $|\mathcal{I}|$ -dimensional

$$\hat{y} = \textit{softmax} \left(M_{id} R_L^{(ID)}[n]^\top \right)$$

Ítem *embedding table* en la capa de *embedding*

$$M_{id} \in \mathbb{R}^{|\mathcal{I}| \times d}$$

Prediction Module

Predicción del atributo j
Probabilidad $|f_j|$ -dimensional


$$\hat{y}^{f_j} = \sigma \left(W_{f_j} R_L^{(ID)} [n]^\top + b_{f_j} \right)$$


Learnable parameters

$$W_{f_j} \in \mathbb{R}^{|f_j| \times d_{f_j}}$$

$$b_{f_j} \in \mathbb{R}^{|f_j| \times 1}$$

Metodología





06

Resultados

Rendimiento General

Dataset	Metric	GRU4Rec	Caser	BERT4Rec	GRU4Rec _F	SASRec	SASRec _F	S ³ Rec	NOVA	ICAI	DIF-SR
Beauty	Recall@10	0.0530	0.0474	0.0529	0.0587	0.0828	0.0719	0.0868	<u>0.0887</u>	0.0879	0.0908
	Recall@20	0.0839	0.0731	0.0815	0.0902	0.1197	0.1013	0.1236	<u>0.1237</u>	0.1231	0.1284
	NDCG@10	0.0266	0.0239	0.0237	0.0290	0.0371	0.0414	<u>0.0439</u>	<u>0.0439</u>	<u>0.0439</u>	0.0446
	NDCG@20	0.0344	0.0304	0.0309	0.0369	0.0464	0.0488	<u>0.0531</u>	0.0527	0.0528	0.0541
Sports	Recall@10	0.0312	0.0227	0.0295	0.0394	0.0526	0.0435	0.0517	<u>0.0534</u>	0.0527	0.0556
	Recall@20	0.0482	0.0364	0.0465	0.0610	<u>0.0773</u>	0.0640	0.0758	0.0759	0.0762	0.0800
	NDCG@10	0.0157	0.0118	0.0130	0.0199	<u>0.0233</u>	0.0235	0.0249	<u>0.0250</u>	0.0243	0.0264
	NDCG@20	0.0200	0.0153	0.0173	0.0253	0.0295	0.0286	<u>0.0310</u>	0.0307	0.0302	0.0325
Toys	Recall@10	0.0370	0.0361	0.0533	0.0492	0.0831	0.0733	0.0967	<u>0.0978</u>	0.0972	0.1013
	Recall@20	0.0588	0.0566	0.0787	0.0767	0.1168	0.1052	<u>0.1349</u>	0.1322	0.1303	0.1382
	NDCG@10	0.0184	0.0186	0.0234	0.0246	0.0375	0.0417	0.0475	<u>0.0480</u>	0.0478	0.0504
	NDCG@20	0.0239	0.0238	0.0297	0.0316	0.0460	0.0497	<u>0.0571</u>	0.0567	0.0561	0.0597
Yelp	Recall@10	0.0361	0.0380	0.0524	0.0361	0.0650	0.0413	0.0589	<u>0.0681</u>	0.0663	0.0698
	Recall@20	0.0592	0.0608	0.0756	0.0578	0.0928	0.0675	0.0902	<u>0.0964</u>	0.0940	0.1003
	NDCG@10	0.0184	0.0197	0.0327	0.0182	0.0401	0.0216	0.0338	<u>0.0412</u>	0.0400	0.0419
	NDCG@20	0.0243	0.0255	0.0385	0.0236	0.0471	0.0282	0.0416	<u>0.0483</u>	0.0470	0.0496

Estudio de mejora

Dataset	Metric	DIF-SASRec		DIF-BERT4Rec		Improv.	
		w/o	w	w/o	w	DIF-SASRec	DIF-BERT4Rec
Beauty	Recall@10	0.0828	0.0908	0.0529	0.0579	9.66%	9.45%
	Recall@20	0.1197	0.1284	0.0815	0.0915	7.27%	12.27%
	NDCG@10	0.0371	0.0446	0.0237	0.0279	20.22%	17.72%
	NDCG@20	0.0464	0.0541	0.0309	0.0363	16.59%	17.48%
Sports	Recall@10	0.0526	0.0556	0.0295	0.0394	5.70%	33.56%
	Recall@20	0.0773	0.0800	0.0465	0.0611	3.49%	31.40%
	NDCG@10	0.0233	0.0264	0.0130	0.0198	13.30%	52.31%
	NDCG@20	0.0295	0.0325	0.0173	0.0252	10.17%	45.66%
Toys	Recall@10	0.0831	0.1013	0.0533	0.0599	21.90%	12.38%
	Recall@20	0.1168	0.1382	0.0787	0.0851	18.32%	8.13%
	NDCG@10	0.0375	0.0504	0.0234	0.0324	34.40%	38.46%
	NDCG@20	0.0460	0.0597	0.0297	0.0387	29.78%	30.30%

Estudio de Ablación

Settings		Yelp		Sports		Beauty	
DIF	AAP	Recall@20	+ Δ	Recall@20	+ Δ	Recall@20	+ Δ
<i>x</i>	<i>x</i>	0.0663	-	0.0621	-	0.0996	-
<i>x</i>	✓	0.0663	+0%	0.0754	+21.42%	0.0991	-0.50%
✓	<i>x</i>	0.0968	+46.00%	0.0767	+23.51%	0.1240	+24.50%
✓	✓	0.1003	+51.28%	0.0800	+28.82%	0.1284	+28.92%



Efectos de diferentes Side Information

Side-info	Recall@10	Recall@20	NDCG@10	NDCG@20
Position	0.0655	0.0954	0.0405	0.048
Position + Categories	0.0698	0.1003	0.0419	0.0496
Position + City	0.0691	0.1001	0.0415	0.0493
Position + Categories + City	0.0699	0.1010	0.0421	0.0499


Sensibilidad a Hiperparametros

Tamaño de embedding


Tipo de función de fusión



¿Qué nos dicen las matrices de atención?



Conclusiones y contribuciones



Conclusion:

- El modelo mejora la integración de información auxiliar al incorporarla en la capa de atención, aumentando la flexibilidad y capacidad representacional.
- El modelo y el entrenamiento multitarea fortalecen el aprendizaje de representaciones de ítems.
- Los experimentos en múltiples datasets confirman mejor desempeño respecto a modelos tradicionales y con integración temprana.

Contribuciones

- Propuesta de un nuevo esquema de decoupled side information fusion.
- Implementación de un entrenamiento multitarea con predictores auxiliares que mejoran la interacción entre atributos e ítems.
- Demostración de que el enfoque es fácilmente integrable en otros modelos de recomendación basados en atención.





GRACIAS





Referencias

[11] Kang, W. C., & McAuley, J. (2018).

Self-Attentive Sequential Recommendation (SASRec). Proceedings of the IEEE International Conference on Data Mining (ICDM).

[25] Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., & Jiang, P. (2019).

BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer. Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM).

[16] Liu, Z., Huang, M., Wu, Z., Liu, J., & Li, Q. (2021).

NOVA: Negative Samples Enhanced Multi-view Self-Attentive Model for Sequential Recommendation. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval.

[33] Yuan, F., He, X., Karatzoglou, A., & Zhang, L. (2021).

ICAI-SR: Interactive Context-Aware Item Graph for Sequential Recommendation.

Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval.



Referencias

[37] Zhou, K., Wang, H., Zhao, W. X., & Wen, J. R. (2020).

S³-Rec: Self-Supervised Learning for Sequential Recommendation with Mutual Information Maximization.
Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM).

Repositorio oficial del paper:

GitHub – Decoupled Side Information Fusion for Sequential Recommendation (DIF-SR).

[Xie et al., 2022] Xie, Y., Chen, T., Li, J., & McAuley, J. (2022).

Decoupled Side Information Fusion for Sequential Recommendation (DIF-SR).
Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2022).

Universidad (2025).

Libro Guía del Curso: Seminario de Sistemas Recomendadores.
Pontificia Universidad Católica de Chile.



Pontificia Universidad
Católica de Chile

Noviembre 2025

GRACIAS

