Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación
IIC3633-1- Sistemas Recomendadores

“Enhancing User Intent Capture in Session-Based Recommendation with Attribute Patterns”

Integrantes:
Álvaro Javier Sotomayor Mestre
David Weijie Chen Chen
Juan Felipe Tachack Suarez

Contexto del Problema

- **La demanda de servicios de comercio electrónico ha crecido de forma explosiva.**
- **Muchos usuarios son anónimos o nuevos → no hay historial largo del usuario.**
- **En estos casos, solo vemos un periodo corto de interacción: una sesión.**
- **Necesitamos modelos que entiendan la intención del usuario dentro de la sesión, usando solo sus clics recientes.**

Problema de recomendación basada en sesión (SBR)

- **Tenemos un conjunto de ítems V (productos del catálogo).**
- **Cada sesión se representa como una secuencia corta:**

$$S = [v_1, v_2, \ldots, v_L], \text{con } v_i \in V$$

- **Objetivo principal: predecir el siguiente ítem que el usuario va a hacer click o comprar.**
- **En muchos casos, además del ítem tenemos atributos (marca, color, categoría, etc.).**

Formulación Formal del Problema de SBR

- **Sesion** $S = [v_1, v_2, \ldots, v_L]$
- **Cada ítem v_i puede tener atributos:** $\text{attr}(v_i) = [a_{v_i}^{(1)}, \ldots, a_{v_i}^{(M)}]$
- **Problema de recomendación: aprender una función de puntuación $f(s, v)$ que, dado S, asigne una puntuación alta a ítems v que sean buenos candidatos al siguiente clic.**
- **En evaluación, se usan métricas como Hits@K, NDCG@K, MRR@K.**

Dado el historial corto de una sesión, el modelo debe ordenar los ítems del catálogo según qué tan probable es que sean el siguiente paso del usuario.

Estado del Arte (I): Métodos Secuenciales

Idea:

- **Tratan la sesión como una secuencia ordenada de ítems.**
- **Usan modelos como RNN/GRU, atención o Transformers (por ejemplo, GRU4Rec, NARM, STAMP).**
- **Capturan la evolución de las preferencias siguiendo el orden cronológico.**

Limitación clave:

- **Se enfocan en dependencias locales (ítems adyacentes).**
- **Les cuesta capturar correlaciones complejas entre ítems que no están juntos en la secuencia, sobre todo cuando la sesión es corta.**

El modelo mira bien lo que pasó "recién", pero pierde relaciones A–D si hay poco contexto.

Estado del Arte (II): Métodos Basados en Grafos

Idea:

- **Construyen grafos de transición de ítems a partir de muchas sesiones (SR-GNN, GCE-GNN, etc.).**
- **Cada sesión genera un grafo local; luego se agregan en un grafo global de transición.**
- **Ventaja: capturan co-ocurrencias globales y estructura más rica.**

Limitación clave:

- **Durante la conversión secuencia → grafo se pierden señales temporales: dos sesiones distintas pueden terminar en el mismo grafo de sesión.**
- **Los grafos globales son densos y sensibles al ruido de clics aleatorios → las GNN sufren de over-smoothing (los embeddings de los ítems acaban pareciéndose demasiado).**

Estado del Arte (II): Métodos Basados en Grafos

Sesion 1 **Sesion 2**

“Distintas intenciones, mismo grafo: la variación de intención se pierde.”

Estado del Arte (II): Métodos Basados en Grafos

Over-smoothing: en GNN, cuando las representaciones de los nodos se vuelven demasiado parecidas por mezclar información de demasiados vecinos.

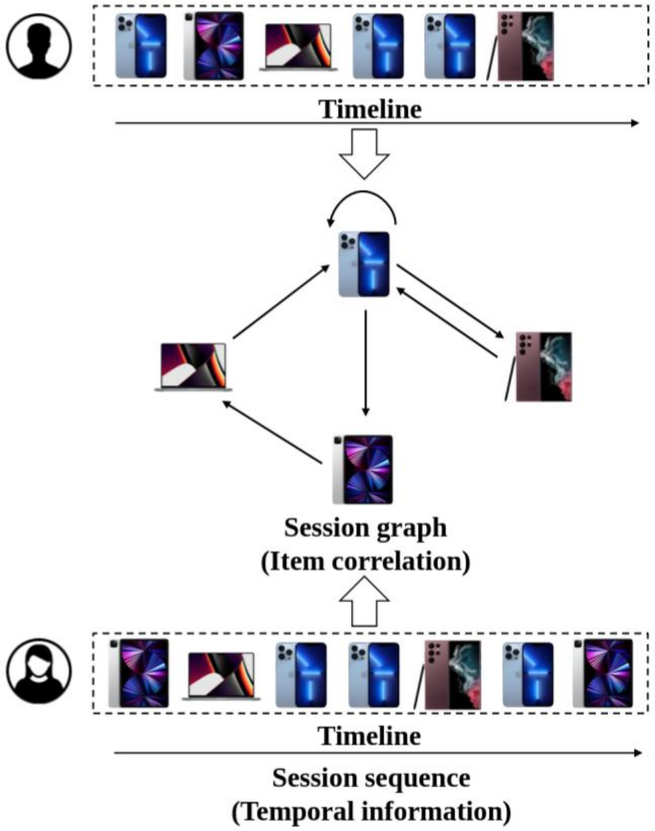

Atributos como Pistas de Intención del Usuario

Idea:

- **Los ítems tienen atributos (marca, color, categoría…).**
- **Se pueden construir grafos de atributos dentro de la sesión (por ejemplo, un grafo solo de colores o solo de marcas).**
- **Estos grafos de atributos se "anclan" al grafo de ítems para formar un grafo multiplex (varias capas conectadas).**

Ejemplos de patrones de atributos:

- ***Patrón de color:*** **plateado ↔ plateado ↔ azul ↔ azul**
  → ***revela que el usuario pasa de productos plateados a productos azules.***

- ***Patrón de marca:*** **Apple ↔ Apple ↔ Samsung**
  → ***sugiere un posible cambio de intención de marca (comparar Apple vs Samsung).***

Contribución: Frequent Attribute Pattern Augmented Transformer (FAPAT)

FAPAT, un modelo que:

- **Construye grafos de transición de atributos dentro de las sesiones.**
- **Extrae patrones de atributos frecuentes y compactos (graphlets) a partir de muchos datos.**
- **Usa esos patrones como una memoria estructurada que enriquece las representaciones de la sesión.**
- **Fusiona la información con un gate y un bloque Transformer para capturar mejor la intención del usuario.**

Comparación con Trabajos Previos

- **A diferencia de los modelos solo secuenciales, FAPAT incorpora patrones estructurales en atributos.**
- **A diferencia de los modelos solo basados en grafos globales, FAPAT evita el grafo hiper-denso y el over-smoothing usando patrones pequeños y frecuentes como memoria.**

Contribución: Resultados en Benchmarks e Industria

¿Qué ofrece frente a otros trabajos?

- **Construye grafos de transición de atributos dentro de las sesiones**
- **Extrae patrones de atributos frecuentes y compactos (pequeños subgrafos típicos).**
- **Usa estos patrones como una memoria externa para enriquecer las representaciones de la sesión.**
- **Fusiona la información de atributos, patrones y secuencia mediante un módulo de compuerta (*gate*) y un bloque Transformer.**

Contribución: Resultados en Benchmarks e Industria

En comparacion al estado del arte:

- **A diferencia de métodos puramente secuenciales, incorpora información estructural en atributos.**
- **A diferencia de métodos puramente basados en grafos globales, evita el grafo gigante y ruidoso: se queda con patrones frecuentes y manejables, reduciendo el over-smoothing.**

En resumen, FAPAT combina lo mejor del mundo secuencial (Transformers) con una memoria basada en patrones de atributos extraídos de grafos.

FAPAT: Frequent Attribute Pattern Augmented Transformer

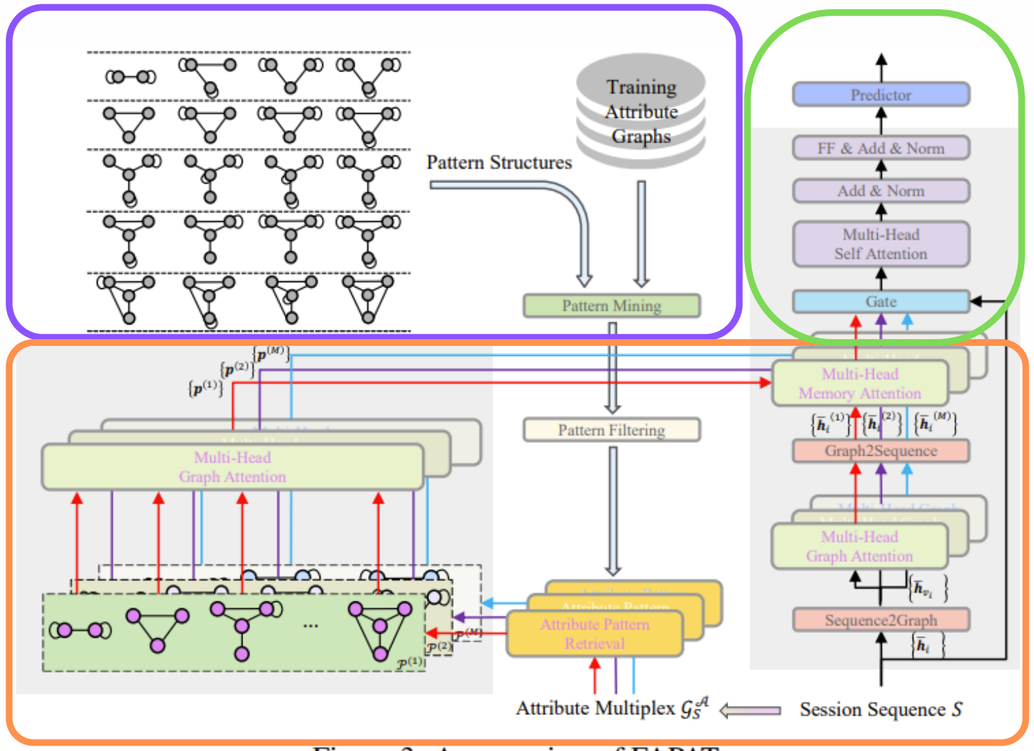

Figure 3: An overview of FAPAT.

El framework FAPAT propone aprovechar patrones frecuentes de atributos para mejorar la captura de intenciones del usuario dentro de sistemas de recomendación por sesión. El proceso consta de tres etapas principales:

1. **Adquisición de patrones frecuentes de atributos**
2. **Codificación de la secuencia consciente de intención (Intent-aware Sequence Encoding)**
3. **Predicción del siguiente ítem**

1. Frequent Attribute Pattern Acquisition

El objetivo es obtener patrones frecuentes en los grafos de atributos, evitando ruido y reduciendo la densidad de los grafos globales.

Cada ítem posee M atributos, y una sesión genera M secuencias de atributos.

Estas se convierten en un multiplex de grafos de atributos $\mathcal{G}_P^{(m)}$ desde los cuales se extraen patrones frecuentes.

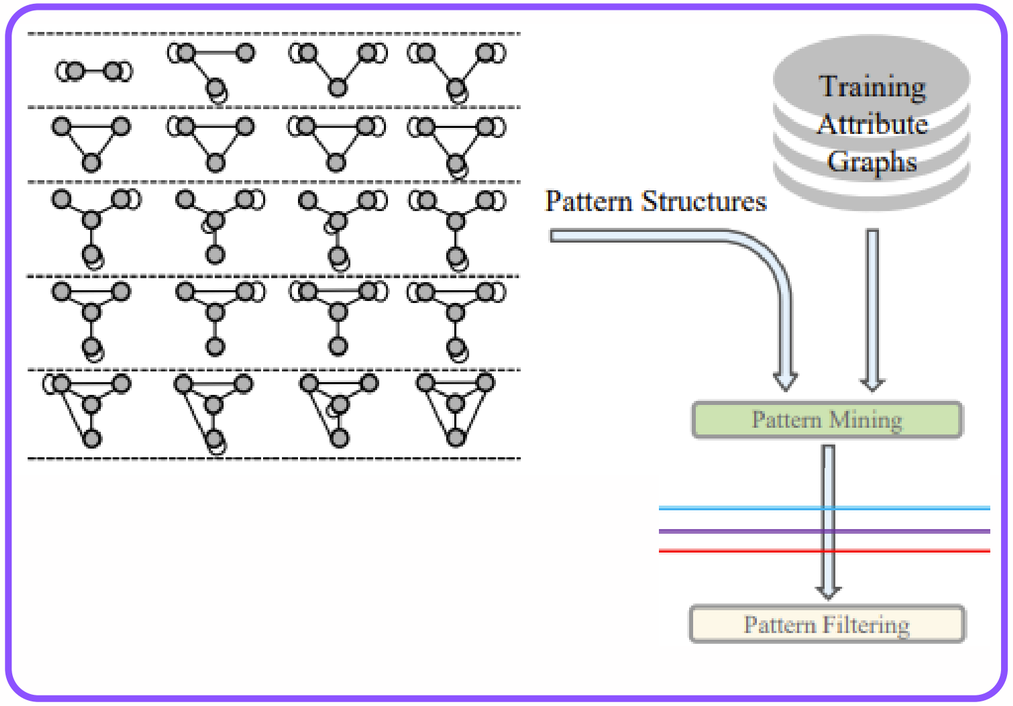

1.1 Graph Pattern Mining

Se quieren encontrar subgrafos frecuentes (graphlets), de no más de 4 nodos y con estructura tipo círculo o triángulo, que revelan relaciones fuertes entre valores de atributos.

Para ello, FAPAT usa el algoritmo gSpan para obtener patrones candidatos. Estos patrones representan estructuras como:

- **Colores que suelen aparecer juntos**
- **Marcas que coaparecen frecuentemente**
- **Tipos de productos asociados**

Estos patrones sirven luego como memoria estructural.

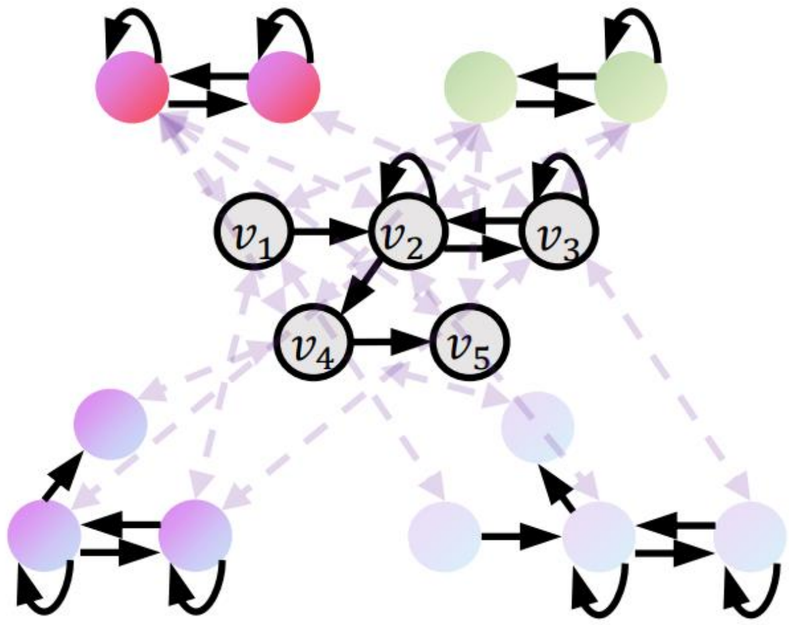

1.2 Loose Pattern Filtering

Muchos patrones complejos contienen patrones más pequeños. Para eliminar los redundantes, se usa el algoritmo VF2 de isomorfismo de subgrafos:

Si $P' \subseteq P$ entonces P'se elimina por ser "loose" (no aporta información adicional). El resultado final es un conjunto compacto de patrones frecuentes no redundantes.

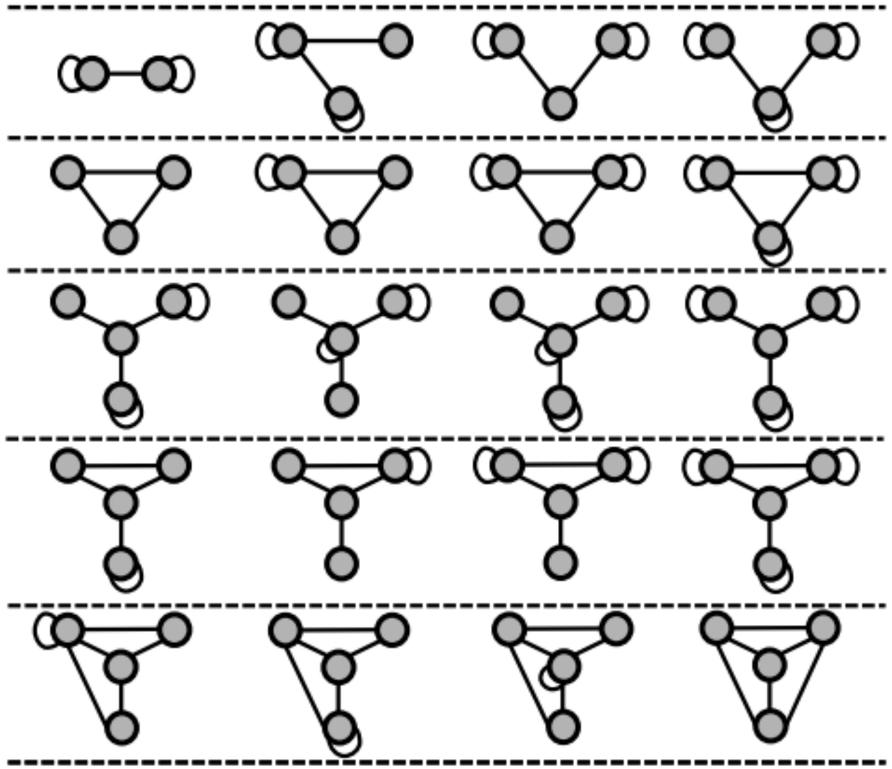

2. Intent-aware Sequence Encoding

El encoder de FAPAT combina:

- **Representación del grafo de la sesión**
- **Patrones frecuentes de atributos como memoria externa**
- **Atención con sesgo posicional relativo**
- **Transformers**

Incluye cuatro pasos: retrieval, representation, augmentation y aggregation.

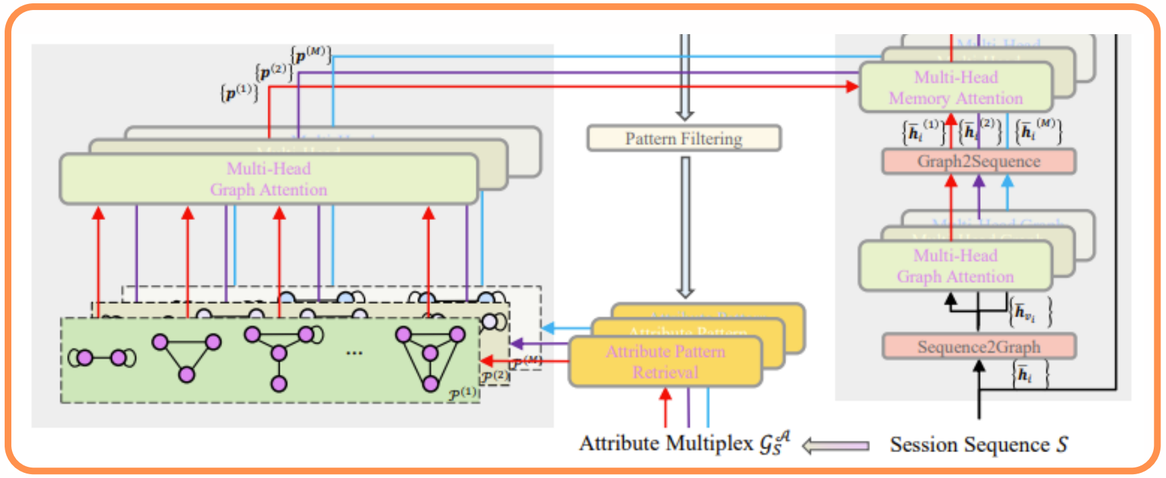

2.1 Relevant Graph Pattern Retrieval

Para el m-ésimo tipo de atributo $A^{(m)}$ (donde $1 \leq m \leq M$), denotamos un subgrafo arbitrario extraído del paso anterior como $\mathcal{G}_P^{(m)} = \left(V_P^{(m)}, E_P^{(m)}\right)$.

Luego, se comparan el grafo de atributos de la sesión $\mathcal{G}_S^{(m)}$ con un patrón candidato $\mathcal{G}_P^{(m)}$., calculando la similitud de Jaccard entre los nodos:

$$Jaccard\left(V_S^{(m)}, V_P^{(m)}\right) = \frac{\left(\left|V_S^{(m)} \cap V_P^{(m)}\right|\right)}{\left(\left|V_S^{(m)}\right| + \left|V_P^{(m)}\right| - \left|V_S^{(m)} \cap V_P^{(m)}\right|\right)} \quad (1)$$

Luego se seleccionan los I patrones más similares (los más relevantes para esta sesión) según los subgrafos que poseen la mayor similitud de Jaccard con el grafo de transición $\mathcal{G}_S^{(m)}$, como se ve en la ecuación anterior. Este cálculo se puede realizar en $O\left(\left|V_S^{(m)}\right| \times \left|V_P^{(m)}\right|\right)$, pero en la práctica es lineal debido a que $\left|V_P^{(m)}\right| \leq 4$.

2.2 Attribute Pattern Representation

Después de recuperar los patrones relevantes para el grafo de sesión multiplex correspondiente, se codifican mediante Multi-head Relational Graph Attention para un mayor aumento de memoria. Para un patrón $\mathcal{G}_P^{(m)}$ del m-ésimo atriuto, calculamos el peso de atención para dos nodos arbitrarios de la relación. $a_i^{(m)}$ y $a_j^{(m)}$ mediante:

$$\alpha_{ij}{}^{(m)} = softmax\left(\frac{LeakyReLU\left(r_{ij}{}^{(m)\top}\left(e_{a_j^{(m)}} \circ e_{a_i^{(m)}}\right)\right)}{\sum_{a_k^{(m)} \in \mathcal{N}\left(a_i^{(m)}\right)} LeakyReLU\left(r_{ik}{}^{(m)\top}\left(e_{a_k^{(m)}} \circ e_{a_i^{(m)}}\right)\right)}\right) \quad (2)$$

Donde $e_{a_i^{(m)}}$ denota el embedding de $a_i^{(m)}$, $\circ$ indica multiplicación elemento a elemento, $\mathcal{N}\left(a_i^{(m)}\right)$ representa los vecinos de $a_i^{(m)}$ (incluyéndose a sí mismo), y $r_{ij}^{(m)}$ corresponde al vector específico

2.2 Attribute Pattern Representation

Luego, la representación de $\overline{h}_{a_i^{(m)}}$ para el nodo $a_i^{(m)}$ en el patrón se agrega mediante:

$$\overline{h}_{a_i^{(m)}} = \sum \left(a_j^{(m)} \in \mathcal{N}\left(a_i^{(m)}\right)\right) \alpha_{ij}{}^{(m)} e_{a_i^{(m)}} (3)$$

Finalmente, tras calcular la representación de cada nodo en el subgrafo del patrón $\mathcal{G}_P^{(m)}$, se aplica una capa de pooling sobre todas las representaciones de nodos para agregar la presentación del patrón para $\mathcal{G}_P^{(m)}$:

$$p^{(m)} = Pool\left(\left\{\overline{h}_{a_i^{(m)}} \middle| v_i \in \mathcal{G}_P^{(m)}\right\}\right) (4)$$

Obteniendo así la representación del patrón completo, donde cada $p(m)$ será una memoria estática para la sesión.

2.3 Attribute Memory Augmentation

Mientras tanto, también empleamos graph attention para obtener las representaciones nativas del grafo de sesión multiplex $\mathcal{G}_S^{(m)}$. Aplicamos esto a cada grafo de transición de atributos $\mathcal{G}_S^{(m)}$ del m-ésimo atributo, calculando las representaciones de nodo $a_i^{(m)}$ usando la Ec. (2) y la Ec. (3), y denotamos la representación resultante del nodo como $\bar{h}_{v_i^{(m)}}$.

Para calcular la representación agregada de atributos de cada nodo v_i en el grafo de sesión original $\mathcal{G}_S$, combinamos sus diferentes representaciones de todos los grafos de transición de atributos mediante:

$$\bar{h}_{v_i} = \frac{1}{M}\sum_{m} \bar{h}_{v_i}^{(m)} + e_{v_i} \quad (5)$$

Donde e_{v_i} es el embedding del ítem.

2.3 Attribute Memory Augmentation

Supongamos que todos los patrones de atributos recuperados asociados con $\mathcal{A}^{(m)}$ son $\mathcal{P}^{(m)}$, cuyas representaciones de la Ec. (4) son $\{p^{(m)} | \, p^{(m)} \in \mathcal{P}^{(m)}\}$. Para preservar la información temporal al utilizar estos patrones, mapeamos las representaciones de grafos a representaciones de secuencia $\{\bar{h}_i^{(m)} | \, 1 \leq i \leq L\}$ con longitud L.

A continuación, concatenamos todas las representaciones de patrones $\{p^{(m)} | \, p^{(m)} \in \mathcal{P}^{(m)}\}$, todas las representaciones de sesión $\{\bar{h}_i^{(m)} | \, 1 \leq i \leq L\}$, y dos embeddings especiales e_{CLS} y e_{MASK} para separar las partes e indicar el ítem a predecir:

$$\left[\left[\mathop{\Big\|}_{p^{(m)} \in \mathcal{P}^{(m)}} \boldsymbol{p}^{(m)} \right] \Big\| \boldsymbol{e}_{\mathrm{CLS}} \Big\| \left[\mathop{\Big\|}_{1 \leq i \leq L} \bar{\boldsymbol{h}}_i^{(m)} \right] \Big\| \boldsymbol{e}_{\mathrm{MASK}} \right]$$

Esto permite que la memoria de patrones afecte la secuencia. La atención incorpora sesgo posicional relativo T5 para distinguir historia cercana vs. lejana.

2.4 User Intent Aggregation

Para agregar representaciones aumentadas por memoria de M atributos y conjuntos de patrones diferentes, empleamos un mecanismo de control (gating):

$$\widehat{h}_i = \sum (m = 1)^M \beta_i^{(m)} \widehat{h}_i^{(m)} + \overline{h}_i, s.t. \beta_i^{(m)} = softmax\left(W_\beta^{(m)} \overline{h}_i^{(m)} + b_\beta^{(m)}\right) (6)$$

Donde $W_\beta^m \in \mathbb{R}^{d \times d}$ y $b_\beta^{(m)} \in \mathbb{R}^d$ son parámetros entrenables (d es la dimensión de los estados ocultos), $\widehat{h}_i^{(m)}$son los resultados aumentados por memoria, y $\beta_i^{(m)}$controla la importancia de los patrones de atributos.

2.4 User Intent Aggregation

Si bien $\hat{h}_i$ combina información de atributos, descarta historias de largo alcance ya que $h_i^{(m)}$ solo accede a vecinos de un salto. Por lo tanto, incorporamos un bloque Transformer para agregar información global de la sesión:

$$\boldsymbol{H} = \text{Transformer}\left(\left[\hat{\boldsymbol{h}}_{\text{CLS}} \| \left[\mathop{\|}_{1 \leq i \leq L} \hat{\boldsymbol{h}}_i\right] \| \hat{\boldsymbol{h}}_{\text{MASK}}\right]\right), \tag{7}$$

Donde $\hat{h}_{CLS}$y $\hat{h}_{\text{MASK}}$ se toman directamente de la Ec. (6), ya que no pertenecen a la sesión original pero aún observan los patrones de memoria y las señales temporales relativas.

3. Next-item Recommendation

Una vez obtenidas las representaciones de secuencia, el siguiente paso es predecir el próximo ítem de interés. Adoptamos un enfoque de concatenar embeddings posicionales reversos adicionales de la siguiente manera:

$$\boldsymbol{z}_i = \tanh\left(\boldsymbol{W}_z\left[\boldsymbol{h}_i \parallel \boldsymbol{t}_{L-i+1}\right] + \boldsymbol{b}_z\right), 0 \leq i \leq L+1, \qquad (8)$$

Donde h_i es la representación del i-ésimo ítem $H[i]$ de la Ec. (7), y $W_z \in R^{(2d \times d)}$ y $b_z \in R^d$ son parámetros entrenables. Esta concatenación busca priorizar las intenciones más cercanas sobre los propósitos históricos de larga distancia.

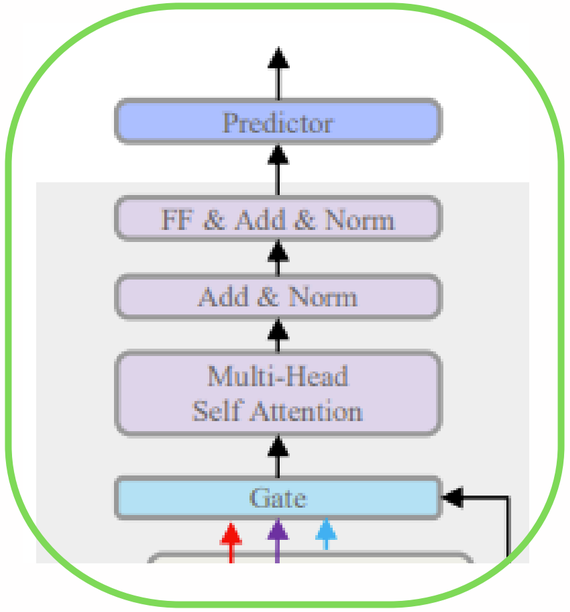

3. Next-item Recommendation

Utilizamos la representación de $MASK$ para calcular el soft attention y representar la sesión, y la intención más reciente del usuario mediante un promedio ponderado:

$$\boldsymbol{u} = \sum_{i=1}^{L} \gamma_i \boldsymbol{h}_i, \text{ s.t. } \gamma_i = \boldsymbol{r}_\gamma^\top \text{sigmoid}(\boldsymbol{W}_\gamma \boldsymbol{z}_i + \boldsymbol{z}_{\text{mask}} + \boldsymbol{b}_\gamma), \tag{9}$$

Donde $W_\gamma \in R^{(d \times d)}$ y $b_\gamma \in R^d$ son parámetros entrenables. Calculamos la predicción usando un enfoque basado en similitud (similar a la optimización BPR) en lugar de una capa lineal. Finalmente, la predicción se obtiene mediante:

$$\hat{y} = argmax_v(u^\top e_v)$$

Evaluación: Datasets

- **Public Benchmarks**
  - **Diginetica: contiene los registros de navegación y transacciones anonimizadas.**
  - **Tmall: contiene los registros de compras de usuarios anónimos.**
- **Amazon E-commerce Platform**
  - **Beauty: Items de la categoria de belleza de la plataforma de Amazon**
  - **Books: Items de la categoria de libros de la plataforma de Amazon**
  - **Electronics: Items de la categoria de electronicos de la plataforma de Amazon**

Evaluación: Resultados

Table 2: Performance evaluation for next-item prediction, where standard deviations are enclosed in brackets. The best and second-best results are respectively highlighted in bold and underlined. Methods that use attributes are marked with ‡, and * indicates the p-value < 0.0001 in t-test.

Model	diginetica						Tmall					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	31.57*	17.40*	13.08*	43.19*	20.33*	13.88*	13.71*	9.02*	7.56*	16.44*	9.71*	7.74*
GRU4Rec	36.77*	20.71*	15.80*	49.68*	23.97*	16.70*	18.82*	12.28*	10.25**	22.68*	13.25*	10.51*
NARM	35.98*	20.18*	15.36*	48.89*	23.44*	16.26*	22.74*	15.46*	13.19*	26.73*	16.47*	13.47*
STAMP	33.59*	18.89*	14.41*	45.87*	22.00*	15.26*	24.32*	16.55*	14.12*	28.40*	17.58*	14.41*
CSRM	33.97*	19.43*	14.98*	45.83*	22.42*	15.80*	25.13*	18.56*	16.48*	27.94*	19.27*	16.68*
S3-Rec‡	33.48*	18.58*	14.04*	45.97*	21.74*	14.90*	18.24*	12.30*	10.46*	22.31*	13.32*	10.74*
M2TRec‡	29.67*	16.30*	12.23*	41.23*	19.22*	13.02*	11.42*	7.56*	6.36*	13.75*	8.15*	6.52*
SR-GNN	35.21*	19.68*	14.94*	47.99*	22.90*	15.82*	18.21*	12.11*	10.20*	21.34*	12.91*	10.42*
GC-SAN	35.25*	19.72*	14.97*	47.87*	22.90*	15.85*	19.29*	12.80*	10.78*	23.18*	13.78*	11.05*
S2-DHCN	30.76*	17.04*	12.86*	42.39*	19.98*	13.66*	22.00*	13.36*	10.68*	27.23*	14.69*	11.05*
GCE-GNN	36.32*	20.77*	16.02*	48.67*	23.89*	16.87*	28.33*	20.01*	17.32*	30.24*	20.50*	17.45*
LESSR	33.68*	18.71*	14.14*	46.23*	21.88*	15.01*	20.99*	14.64*	12.13*	25.92*	13.96*	10.50*
MSGIFSR	34.74*	19.43*	14.76*	46.23*	21.88*	15.01*	23.18*	15.19*	12.69*	27.78*	16.35*	13.01*
FAPAT‡	**37.42**	**21.31**	**16.39**	**50.41**	**24.59**	**17.29**	**32.45**	**22.02**	**18.72**	**36.18**	**22.97**	**18.99**
Improv.	*3.03%*	*2.60%*	*2.31%*	*1.46%*	*2.59%*	*2.49%*	*14.19%*	*10.04%*	*8.08%*	*19.64%*	*12.05%*	*8.83%*

Evaluación: Resultados

Table 2: Performance evaluation for next-item prediction, where standard deviations are enclosed in brackets. The best and second-best results are respectively highlighted in bold and underlined. Methods that use attributes are marked with ‡, and * indicates the p-value < 0.0001 in t-test.

Model	diginetica						Tmall					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	31.57*	17.40*	13.08*	43.19*	20.33*	13.88*	13.71*	9.02*	7.56*	16.44*	9.71*	7.74*
GRU4Rec	36.77*	20.71*	15.80*	49.68*	23.97*	16.70*	18.82*	12.28*	10.25**	22.68*	13.25*	10.51*
NARM	35.98*	20.18*	15.36*	48.89*	23.44*	16.26*	22.74*	15.46*	13.19*	26.73*	16.47*	13.47*
STAMP	33.59*	18.89*	14.41*	45.87*	22.00*	15.26*	24.32*	16.55*	14.12*	28.40*	17.58*	14.41*
CSRM	33.97*	19.43*	14.98*	45.83*	22.42*	15.80*	25.13*	18.56*	16.48*	27.94*	19.27*	16.68*
S3-Rec‡	33.48*	18.58*	14.04*	45.97*	21.74*	14.90*	18.24*	12.30*	10.46*	22.31*	13.32*	10.74*
M2TRec‡	29.67*	16.30*	12.23*	41.23*	19.22*	13.02*	11.42*	7.56*	6.36*	13.75*	8.15*	6.52*
SR-GNN	35.21*	19.68*	14.94*	47.99*	22.90*	15.82*	18.21*	12.11*	10.20*	21.34*	12.91*	10.42*
GC-SAN	35.25*	19.72*	14.97*	47.87*	22.90*	15.85*	19.29*	12.80*	10.78*	23.18*	13.78*	11.05*
S2-DHCN	30.76*	17.04*	12.86*	42.39*	19.98*	13.66*	22.00*	13.36*	10.68*	27.23*	14.69*	11.05*
GCE-GNN	36.32*	20.77*	16.02*	48.67*	23.89*	16.87*	28.33*	20.01*	17.32*	30.24*	20.50*	17.45*
LESSR	33.68*	18.71*	14.14*	46.23*	21.88*	15.01*	20.99*	14.64*	12.13*	25.92*	13.96*	10.50*
MSGIFSR	34.74*	19.43*	14.76*	46.23*	21.88*	15.01*	23.18*	15.19*	12.69*	27.78*	16.35*	13.01*
FAPAT‡	**37.42**	**21.31**	**16.39**	**50.41**	**24.59**	**17.29**	**32.45**	**22.02**	**18.72**	**36.18**	**22.97**	**18.99**
Improv.	*3.03%*	*2.60%*	*2.31%*	*1.46%*	*2.59%*	*2.49%*	*14.19%*	*10.04%*	*8.08%*	*19.64%*	*12.05%*	*8.83%*

Evaluación: Resultados

Table 3: Performance evaluation for next-item prediction on our 100 million industrial data.

Model	Beauty				Books				Electronics			
	Hits@10	NDCG@10	Hits@20	NDCG@20	Hits@10	NDCG@10	Hits@20	NDCG@20	Hits@10	NDCG@10	Hits@20	NDCG@20
CSRM	89.74	75.28	92.61	76.01	78.69	56.70	82.88	57.77	62.28	44.35	67.47	45.67
S3-Rec‡	89.64	75.56	92.53	76.30	75.00	58.54	79.45	59.67	74.36	56.03	79.63	57.37
M2TRec‡	80.13	65.97	83.66	66.87	32.56	22.58	35.39	25.70	57.32	44.84	61.70	45.95
SR-GNN	88.69	70.42	91.74	71.20	66.55	47.55	69.77	48.37	74.86	54.30	79.66	55.52
GCE-GNN	89.34	73.15	91.29	73.65	77.61	57.60	80.03	58.22	72.93	53.74	78.49	55.15
LESSR	89.95	71.29	92.98	72.06	73.72	53.86	82.31	54.77	72.91	50.46	78.78	51.96
MSGIFSR	90.18	73.62	92.50	74.21	72.93	52.23	76.33	53.09	73.56	53.83	77.45	54.73
FAPAT‡	**92.72**	**76.29**	**94.10**	**76.87**	**81.62**	**61.08**	**85.12**	**61.97**	**78.36**	**56.81**	**82.81**	**57.94**
Improv.	*2.82%*	*0.97%*	*1.20%*	*0.75%*	*3.72%*	*4.34%*	*2.70%*	*3.85%*	*4.68%*	*1.39%*	*3.95%*	*0.99%*

Evaluación: Resultados

Table 3: Performance evaluation for next-item prediction on our 100 million industrial data.

Model	Beauty				Books				Electronics			
	Hits@10	NDCG@10	Hits@20	NDCG@20	Hits@10	NDCG@10	Hits@20	NDCG@20	Hits@10	NDCG@10	Hits@20	NDCG@20
CSRM	89.74	75.28	92.61	76.01	78.69	56.70	82.88	57.77	62.28	44.35	67.47	45.67
S3-Rec‡	89.64	75.56	92.53	76.30	75.00	58.54	79.45	59.67	74.36	56.03	79.63	57.37
M2TRec‡	80.13	65.97	83.66	66.87	32.56	22.58	35.39	25.70	57.32	44.84	61.70	45.95
SR-GNN	88.69	70.42	91.74	71.20	66.55	47.55	69.77	48.37	74.86	54.30	79.66	55.52
GCE-GNN	89.34	73.15	91.29	73.65	77.61	57.60	80.03	58.22	72.93	53.74	78.49	55.15
LESSR	89.95	71.29	92.98	72.06	73.72	53.86	82.31	54.77	72.91	50.46	78.78	51.96
MSGIFSR	90.18	73.62	92.50	74.21	72.93	52.23	76.33	53.09	73.56	53.83	77.45	54.73
FAPAT‡	**92.72**	**76.29**	**94.10**	**76.87**	**81.62**	**61.08**	**85.12**	**61.97**	**78.36**	**56.81**	**82.81**	**57.94**
Improv.	*2.82%*	*0.97%*	*1.20%*	*0.75%*	*3.72%*	*4.34%*	*2.70%*	*3.85%*	*4.68%*	*1.39%*	*3.95%*	*0.99%*

Evaluación: Resultados

Table 9: Performance evaluation for next-item prediction on *Beauty*.

Model	Beauty					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	72.00	57.20	52.42	75.91	58.19	52.70
GRU4Rec	73.95	58.19	53.13	78.54	59.36	53.45
NARM	88.09	70.44	64.68	91.50	71.31	64.93
STAMP	80.08	63.76	58.47	83.84	64.72	58.73
CSRM	89.74	75.28	70.56	92.61	76.01	70.77
S3-Rec‡	89.64	75.56	70.99	92.53	76.30	71.19
M2TRec‡	80.13	65.97	61.65	83.66	66.87	61.65
SR-GNN	88.69	70.42	64.44	91.74	71.20	64.65
GC-SAN	86.67	70.80	64.71	88.98	72.50	65.97
S2-DHCN	7.25	5.38	4.80	8.87	5.79	4.91
GCE-GNN	89.34	73.15	67.80	91.29	73.65	67.94
LESSR	89.95	71.29	65.18	92.98	72.06	65.40
MSGIFSR	90.18	73.62	65.18	92.50	74.21	65.65
FAPAT‡	**92.72**	**76.29**	**71.09**	**94.10**	**76.87**	**71.24**
Improv.	*2.82%*	*0.97%*	*0.14%*	*1.20%*	*0.75%*	*0.07%*

Evaluación: Resultados

Table 9: Performance evaluation for next-item prediction on *Beauty*.

Model	Beauty					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	72.00	57.20	52.42	75.91	58.19	52.70
GRU4Rec	73.95	58.19	53.13	78.54	59.36	53.45
NARM	88.09	70.44	64.68	91.50	71.31	64.93
STAMP	80.08	63.76	58.47	83.84	64.72	58.73
CSRM	89.74	75.28	70.56	92.61	76.01	70.77
S3-Rec‡	89.64	75.56	70.99	92.53	76.30	71.19
M2TRec‡	80.13	65.97	61.65	83.66	66.87	61.65
SR-GNN	88.69	70.42	64.44	91.74	71.20	64.65
GC-SAN	86.67	70.80	64.71	88.98	72.50	65.97
S2-DHCN	7.25	5.38	4.80	8.87	5.79	4.91
GCE-GNN	89.34	73.15	67.80	91.29	73.65	67.94
LESSR	89.95	71.29	65.18	92.98	72.06	65.40
MSGIFSR	90.18	73.62	65.18	92.50	74.21	65.65
FAPAT‡	**92.72**	**76.29**	**71.09**	**94.10**	**76.87**	**71.24**
Improv.	*2.82%*	*0.97%*	*0.14%*	*1.20%*	*0.75%*	*0.07%*

Evaluación: Resultados

Table 10: Performance evaluation for next-item prediction on *Books*.

Model	Books					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	36.51	24.32	20.49	41.90	25.69	20.87
GRU4Rec	47.21	31.86	27.02	53.55	33.47	27.46
NARM	76.09	54.22	47.13	80.83	55.43	47.36
STAMP	61.49	42.13	35.95	67.46	43.65	36.37
CSRM	78.69	56.70	49.54	82.88	57.77	49.83
S3-Rec‡	75.00	58.54	53.23	79.45	59.67	53.55
M2TRec‡	32.56	22.58	24.98	35.39	25.70	22.78
SR-GNN	66.55	47.55	41.32	69.77	48.37	41.55
GC-SAN	72.56	54.92	49.25	75.73	56.05	50.14
S2-DHCN	4.69	3.42	3.03	5.60	3.65	3.09
GCE-GNN	77.61	57.60	51.00	80.03	58.22	51.17
LESSR	73.72	53.86	47.36	82.31	54.77	47.61
MSGIFSR	72.93	52.23	45.66	76.33	53.09	45.66
FAPAT‡	**81.62**	**61.08**	**54.39**	**85.12**	**61.97**	**54.64**
Improv.	*3.72%*	*4.34%*	*2.18%*	*2.70%*	*3.85%*	*2.04%*

Evaluación: Resultados

Table 10: Performance evaluation for next-item prediction on *Books*.

Model	Books					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	36.51	24.32	20.49	41.90	25.69	20.87
GRU4Rec	47.21	31.86	27.02	53.55	33.47	27.46
NARM	76.09	54.22	47.13	80.83	55.43	47.36
STAMP	61.49	42.13	35.95	67.46	43.65	36.37
CSRM	78.69	56.70	49.54	82.88	57.77	49.83
S3-Rec‡	75.00	58.54	53.23	79.45	59.67	53.55
M2TRec‡	32.56	22.58	24.98	35.39	25.70	22.78
SR-GNN	66.55	47.55	41.32	69.77	48.37	41.55
GC-SAN	72.56	54.92	49.25	75.73	56.05	50.14
S2-DHCN	4.69	3.42	3.03	5.60	3.65	3.09
GCE-GNN	77.61	57.60	51.00	80.03	58.22	51.17
LESSR	73.72	53.86	47.36	82.31	54.77	47.61
MSGIFSR	72.93	52.23	45.66	76.33	53.09	45.66
FAPAT‡	**81.62**	**61.08**	**54.39**	**85.12**	**61.97**	**54.64**
Improv.	*3.72%*	*4.34%*	*2.18%*	*2.70%*	*3.85%*	*2.04%*

Evaluación: Resultados

Table 11: Performance evaluation for next-item prediction on *Electronics*.

Model	Electronics					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	37.87	26.91	23.42	42.07	27.97	23.71
GRU4Rec	58.46	40.69	35.02	64.42	42.21	35.44
NARM	61.10	41.20	32.05	77.36	44.56	33.75
STAMP	59.30	42.04	36.53	67.94	45.07	36.97
CSRM	62.28	44.35	38.59	67.47	45.67	38.96
S3-Rec‡	74.36	56.03	**50.16**	79.63	57.37	**50.53**
M2TRec‡	57.32	44.84	40.85	61.70	45.95	41.15
SR-GNN	74.86	54.30	47.66	79.66	55.52	48.00
GC-SAN	72.76	53.37	45.98	77.34	46.34	49.91
S2-DHCN	4.18	2.65	2.18	5.08	2.88	2.24
GCE-GNN	72.93	53.74	47.59	78.49	55.15	47.98
LESSR	72.91	50.46	43.26	78.78	51.96	43.67
MSGIFSR	73.56	53.83	47.77	77.45	54.73	48.02
FAPAT‡	**78.36**	**56.81**	49.80	**82.81**	**57.94**	50.12
Improv.	*4.68%*	*1.39%*	*-0.07%*	*3.95%*	*0.99%*	*-0.81%*

Evaluación: Resultados

Table 11: Performance evaluation for next-item prediction on *Electronics*.

Model	Electronics					
	Hits@10	NDCG@10	MRR@10	Hits@20	NDCG@20	MRR@20
FPMC	37.87	26.91	23.42	42.07	27.97	23.71
GRU4Rec	58.46	40.69	35.02	64.42	42.21	35.44
NARM	61.10	41.20	32.05	77.36	44.56	33.75
STAMP	59.30	42.04	36.53	67.94	45.07	36.97
CSRM	62.28	44.35	38.59	67.47	45.67	38.96
S3-Rec‡	74.36	56.03	**50.16**	79.63	57.37	**50.53**
M2TRec‡	57.32	44.84	40.85	61.70	45.95	41.15
SR-GNN	74.86	54.30	47.66	79.66	55.52	48.00
GC-SAN	72.76	53.37	45.98	77.34	46.34	49.91
S2-DHCN	4.18	2.65	2.18	5.08	2.88	2.24
GCE-GNN	72.93	53.74	47.59	78.49	55.15	47.98
LESSR	72.91	50.46	43.26	78.78	51.96	43.67
MSGIFSR	73.56	53.83	47.77	77.45	54.73	48.02
FAPAT‡	**78.36**	**56.81**	49.80	**82.81**	**57.94**	50.12
Improv.	*4.68%*	*1.39%*	*-0.07%*	*3.95%*	*0.99%*	*-0.81%*

Evaluación: Resultados

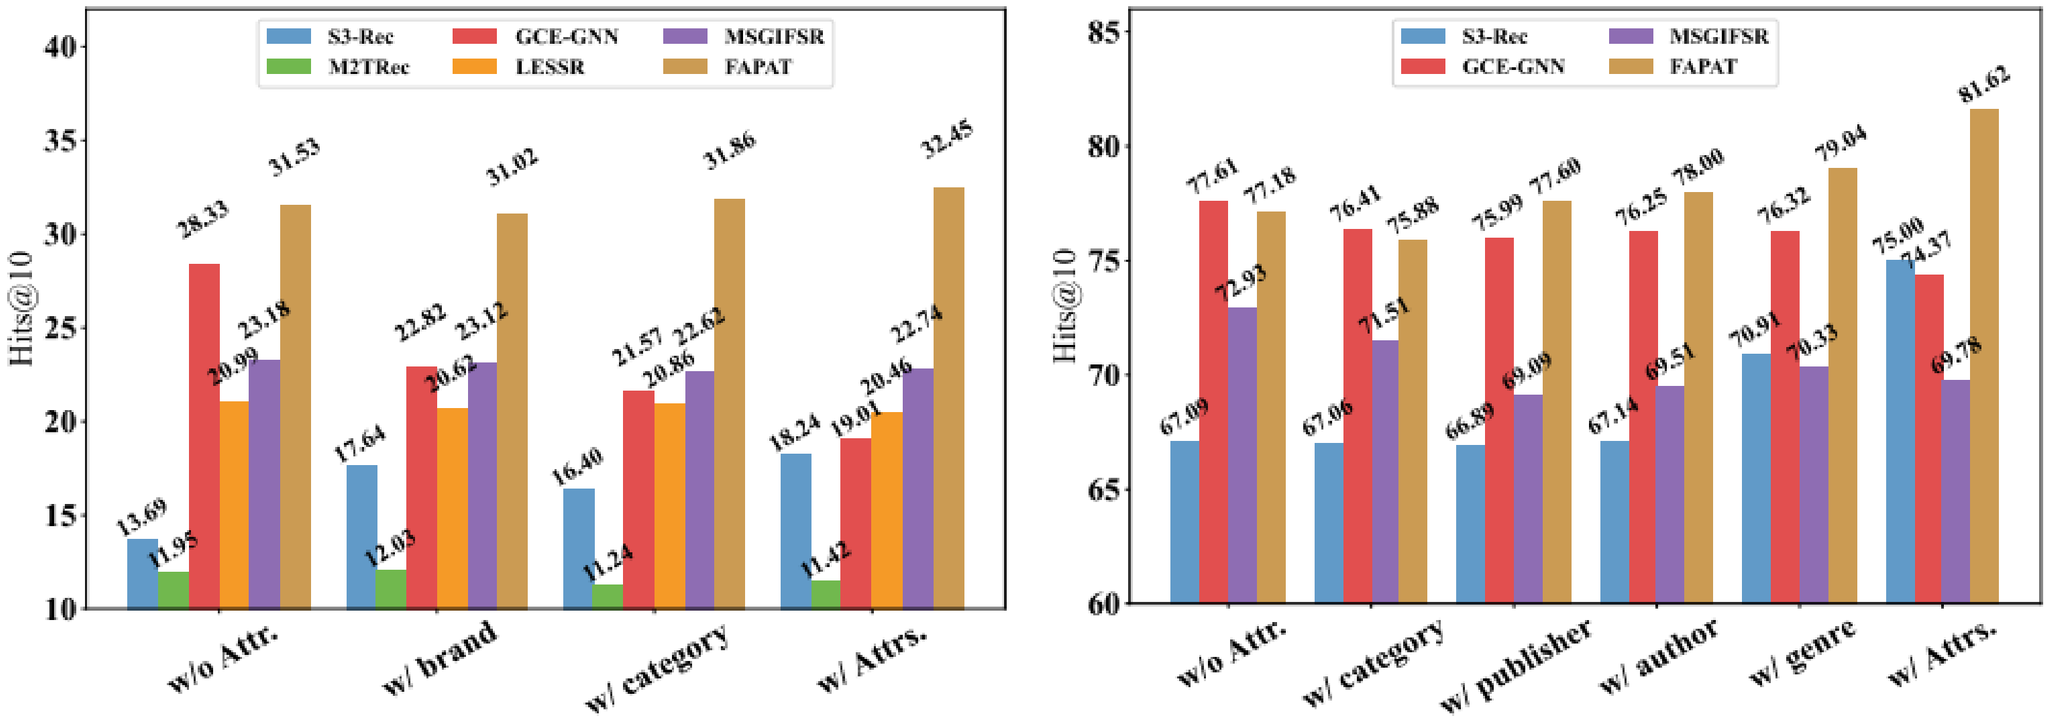

(a) Tmall (b) Books

Figure 5: Effects of different attribute settings.

Evaluación: Resultados

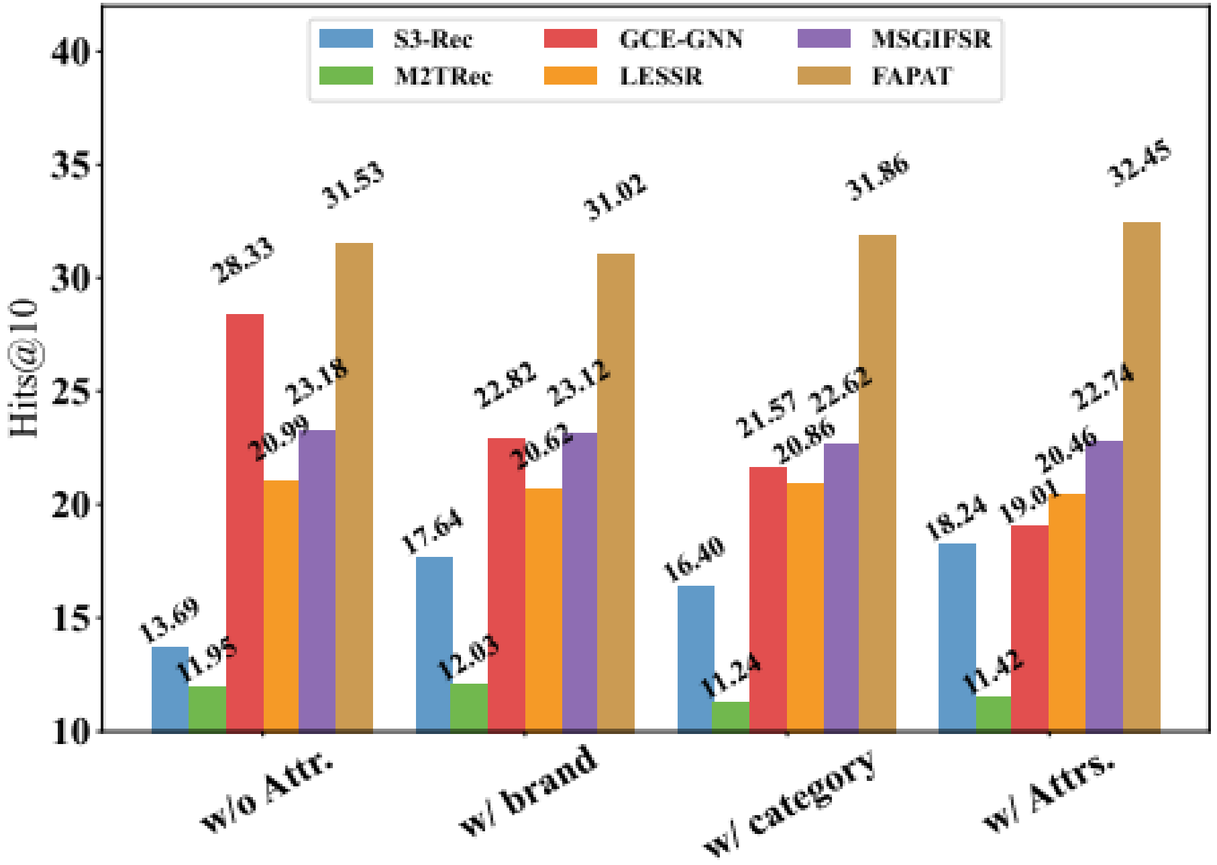

(a) Tmall

Evaluación: Resultados

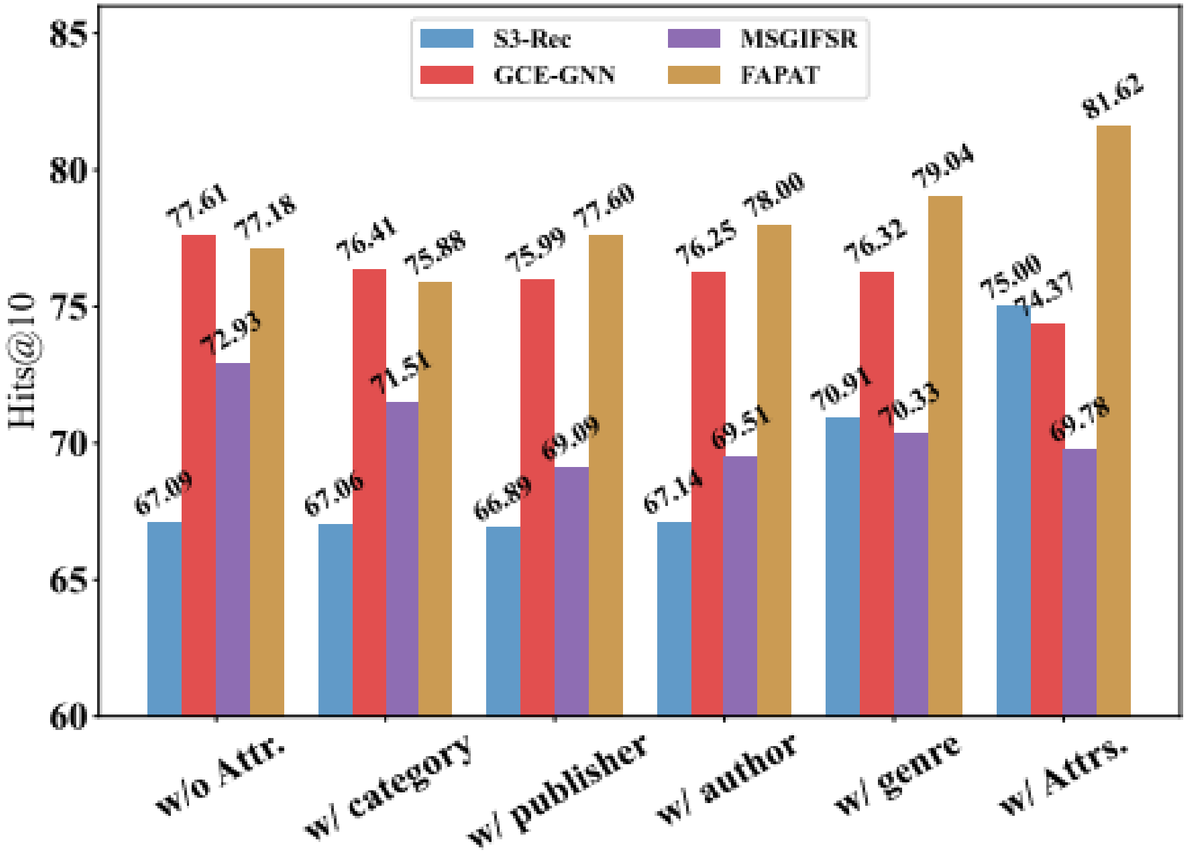

(b) Books

Evaluación: Resultados

Table 4: Results of encoder comparison, where * indicates the p-value < 0.05 in t-test.

Encoder	*diginetica*		*Tmall*		*Beauty*		*Books*	
	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10
FAPAT w/o Attr.	**36.82**	16.29	**31.53**	**18.86**	**88.70**	**67.11**	**77.18**	**49.66**
GraphFormer	36.05*	16.17	30.05*	18.58	88.48	65.65	77.03	47.86
Transformer	36.30*	16.02*	28.83*	18.30*	88.10	65.90	74.67	46.54

Evaluación: Resultados

Table 4: Results of encoder comparison, where * indicates the p-value < 0.05 in t-test.

Encoder	*diginetica*		*Tmall*		*Beauty*		*Books*	
	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10
FAPAT w/o Attr.	**36.82**	16.29	**31.53**	**18.86**	**88.70**	**67.11**	**77.18**	**49.66**
GraphFormer	36.05*	16.17	30.05*	18.58	88.48	65.65	77.03	47.86
Transformer	36.30*	16.02*	28.83*	18.30*	88.10	65.90	74.67	46.54

Evaluación: Resultados

Table 5: Attribute estimation evaluation.

Model	*diginetica*		*Tmall*		*Beauty*		*Books*	
	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10
CSRM	89.87*	87.91*	48.03*	34.97*	94.82	83.57	88.93	73.31
M2TRec‡	**94.10**	**89.76**	59.44	39.72	95.93	84.95	83.80	71.22
S3-Rec‡	89.66*	88.42*	44.95*	32.60*	95.35	84.79	88.11	75.63
GCE-GNN	89.89*	87.96*	55.88*	38.57*	95.44	84.16	89.78	75.68
LESSR	88.60*	86.24*	49.43*	32.61*	95.02	81.56	89.57	73.73
MSGIFSR	89.48*	87.19*	50.09*	33.95*	95.79	85.42	86.67	71.99
FAPAT‡	89.99*	88.23*	**59.49**	**40.56**	**95.94**	**86.87**	**90.77**	**76.83**
w/o Attr.	89.35*	87.50*	58.22*	40.08	95.07	81.65	89.29	74.12

Evaluación: Resultados

Table 5: Attribute estimation evaluation.

Model	*diginetica*		*Tmall*		*Beauty*		*Books*	
	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10	Hits@10	MRR@10
CSRM	89.87*	87.91*	48.03*	34.97*	94.82	83.57	88.93	73.31
M2TRec‡	**94.10**	**89.76**	59.44	39.72	95.93	84.95	83.80	71.22
S3-Rec‡	89.66*	88.42*	44.95*	32.60*	95.35	84.79	88.11	75.63
GCE-GNN	89.89*	87.96*	55.88*	38.57*	95.44	84.16	89.78	75.68
LESSR	88.60*	86.24*	49.43*	32.61*	95.02	81.56	89.57	73.73
MSGIFSR	89.48*	87.19*	50.09*	33.95*	95.79	85.42	86.67	71.99
FAPAT‡	89.99*	88.23*	**59.49**	**40.56**	**95.94**	**86.87**	**90.77**	**76.83**
w/o Attr.	89.35*	87.50*	58.22*	40.08	95.07	81.65	89.29	74.12

Evaluación: Resultados

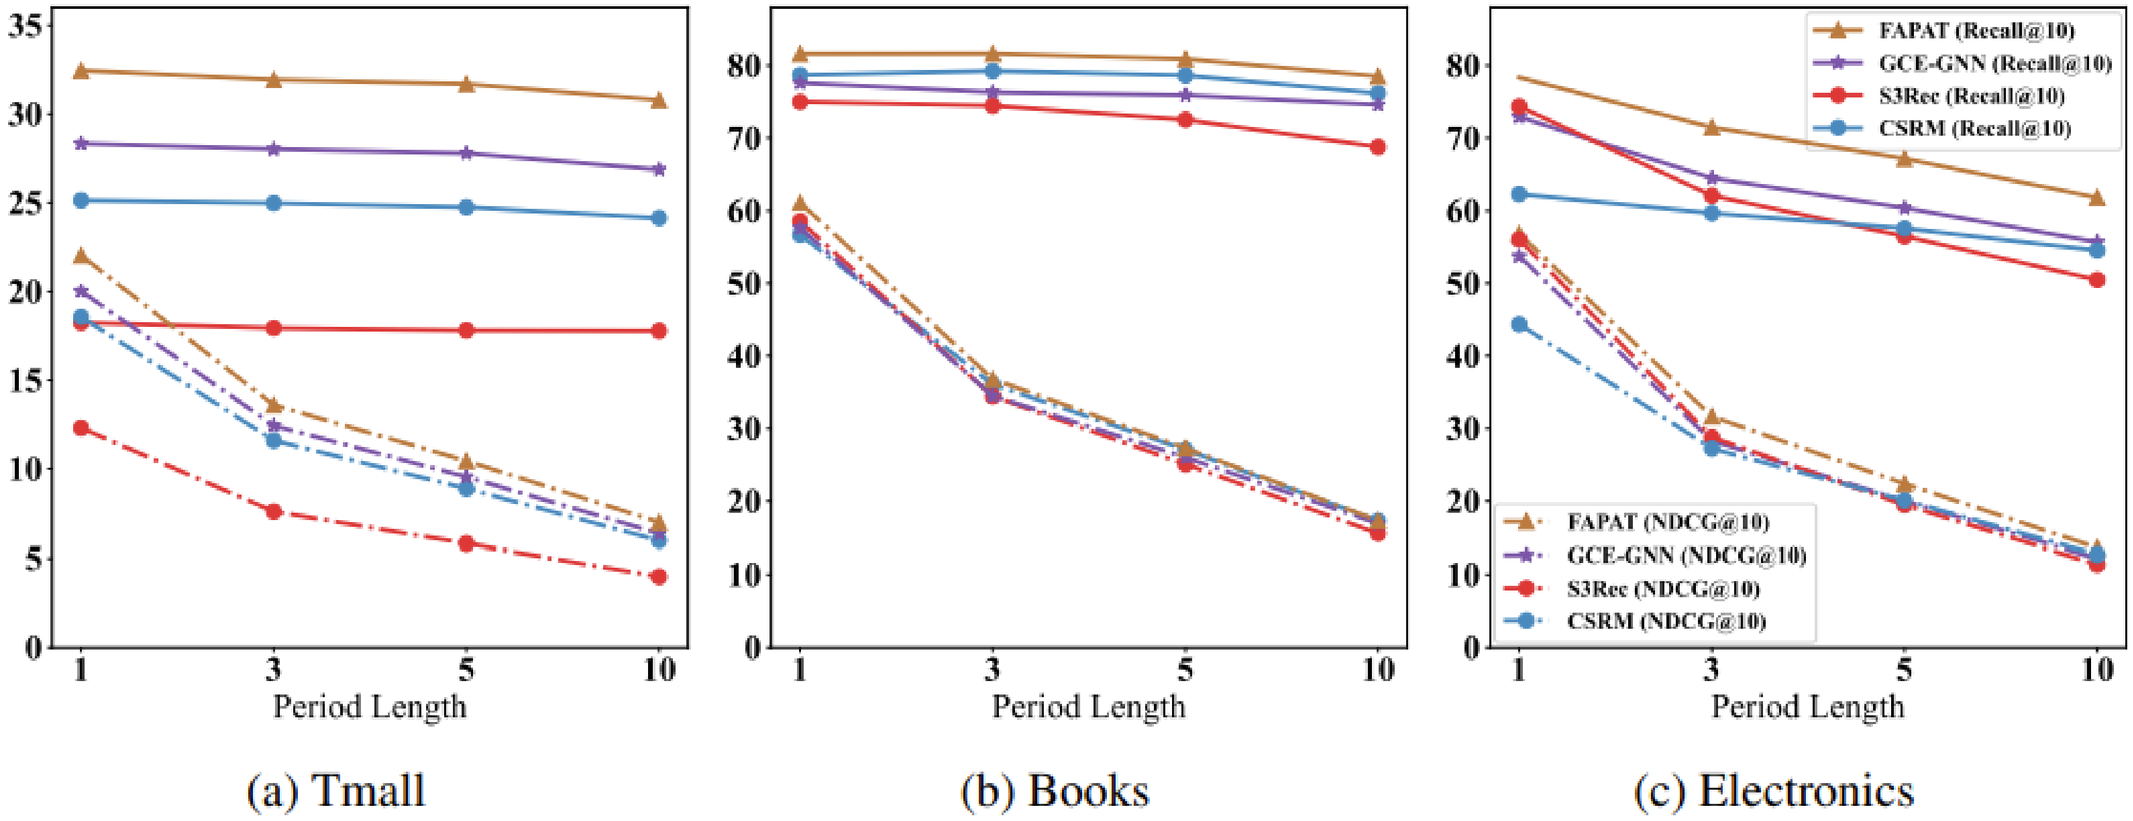

(a) Tmall (b) Books (c) Electronics

Figure 6: Period-item recommendation evaluation.

Conclusión

- **Capturar la intención del usuario requiere más que modelar secuencias: se deben integrar atributos y estructuras de correlación entre ellos.**
- **FAPAT demuestra que usar patrones frecuentes sirve como una forma efectiva de memoria de intención de compra.**
- **Beneficios clave:**
  - **Mejor precisión en dominios reales**
  - **Menor ruido que grafos globales**
  - **Generalizable a grandes catálogos con atributos ricos**

Referencias

- Luigi P. Cordella, Pasquale Foggia, Carlo Sansone, and Mario Vento. A (sub)graph isomorphism algorithm for matching large graphs. TPAMI, 26(10):1367–1372, 2004.
- Nils M. Kriege, Fredrik D. Johansson, and Christopher Morris. A survey on graph kernels. Appl. Netw. Sci., 5(1):6, 2020.
- Nino Shervashidze, S. V. N. Vishwanathan, Tobias Petri, Kurt Mehlhorn, and Karsten M. Borgwardt. Efficient graphlet kernels for large graph comparison. In AISTATS, volume 5, pages 488–495, 2009.
- Shu Wu, Yuyuan Tang, Yanqiao Zhu, Liang Wang, Xing Xie, and Tieniu Tan. Session-based recommendation with graph neural networks. In AAAI, pages 346–353, 2019.
- Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. BPR: bayesian personalized ranking from implicit feedback. In UAI, pages 452–461, 2009.

Referencias

- Xifeng Yan and Jiawei Han. gspan: Graph-based substructure pattern mining. In ICDM, pages 721–724, 2002.
- Xin Xia, Hongzhi Yin, Junliang Yu, Qinyong Wang, Lizhen Cui, and Xiangliang Zhang. Selfsupervised hypergraph convolutional networks for session-based recommendation. In AAAI, pages 4503–4511, 2021.
- Yuhuai Wu, Markus N. Rabe, DeLesley Hutchins, and Christian Szegedy. Memorizing transformers. In ICLR, 2022.
- Zihang Dai, Zhilin Yang, Yiming Yang, Jaime G. Carbonell, Quoc Viet Le, and Ruslan Salakhutdinov. Transformer-xl: Attentive language models beyond a fixed-length context. In ACL, pages 2978–2988, 2019.
- Ziyang Wang, Wei Wei, Gao Cong, Xiao-Li Li, Xianling Mao, and Minghui Qiu. Global context enhanced graph neural networks for session-based recommendation. In SIGIR, pages 169–178, 2020.

Anexos

Table 6: Statistics of datasets based on timestamps.

	Public		Industrial (E-commerce)		
	diginetica	Tmall	Beauty	Books	Electronics
#User	57,623	7,576	2.6 M	3.2 M	10.2 M
#Item	43,074	39,768	39.2 K	94.8 K	244.7 K
#Click	993,163	438,315	27.2 M	38.8 M	115.6 M
Avg. Len.	4.850	6.649	10.325	11.912	11.249
#Train	630,789	303,181	19.6 M	28.2 M	84.1 M
#Valid	78,708	33,735	2.4 M	3.5 M	10.5 M
#Test	78,907	35,481	2.5 M	3.8 M	10.6 M
#Attribute	category : 995	category : 821 brand : 4,304	category : 359 color : 1,101 brand : 4,359 size : 1,883	category : 18 publisher : 2,751 author : 27,651 genre : 2,634	type : 123 category : 881 color : 2,096 brand : 24,196
#Pattern	category : 1,866	category : 33,582 brand : 2,497	category : 970 color : 4,059 brand : 254 size : 1,091	category : 24 publisher : 4,370 author : 1,399 genre : 12,535	type : 9,289 category : 13,991 color : 146,402 brand : 14,043
Density	Local: 0.886 Global: 11.329 Shortcut: 2.512 Heterogeneous: 0.543 Pattern: 1.023	Local: 1.249 Global: 10.222 Shortcut: 4.983 Heterogeneous: 0.707 Pattern: 1.165	Local: 4.510 Global: 70.504 Shortcut: 29.827 Heterogeneous: 3.412 Pattern: 1.095	Local: 3.554 Global: 99.389 Shortcut: 26.649 Heterogeneous: 2.333 Pattern: 1.085	Local: 2.910 Global: 128.041 Shortcut: 19.865 Heterogeneous: 2.049 Pattern: 1.189

Anexos

Sequence-based methods

- **FPMC** aprende la representación de una sesión mediante métodos basados en cadenas de Márkov.
- **GRU4Rec** es el primer enfoque basado en RNN que simula un Proceso de Decisión de Márkov (MDP), pero con mejor capacidad de generalización.
- **NARM** es un modelo RNN basado en atención para aprender *session embeddings*.
- **STAMP** adopta un mecanismo de atención entre el último ítem y los historiales previos para representar los intereses de corto plazo del usuario.
- **CSRM** propone utilizar un codificador de memoria interna y una red de memoria externa para capturar correlaciones entre sesiones vecinas y así enriquecer las representaciones colaborativas.
- **S3-Rec** es el primer modelo preentrenado para *session-based recommendation (SBR)* que predice ítems, atributos y segmentos durante la etapa de preentrenamiento.
- **M2TRec** es un modelo Transformer *multi-task* consciente del *metadata*. En el artículo original, los autores ignoran los *item embeddings*.

Anexos

Graph-based methods

- **SR-GNN** es el primer modelo basado en GNN para la tarea SBR, el cual transforma los datos de la sesión en un grafo directo no ponderado y aprende la representación del grafo de transiciones de ítems.
- **GC-SAN** utiliza GNNs con compuertas (gated GNNs) para extraer información del contexto local y luego auto-atención para obtener la representación global.
- **S2-DHCN** transforma los datos de la sesión en hipergrafos y grafos de línea, y los codifica mediante GCNs para mejorar las representaciones de la sesión.
- **GCE-GNN** agrega dos niveles de embeddings de ítems provenientes de grafos de sesión y grafos globales mediante atención suave (soft attention).
- **LESSR** preserva el orden de las aristas y construye atajos para codificar las sesiones para las GNNs.
- **MSGIFSR** captura las intenciones del usuario desde múltiples granularidades para aliviar la carga computacional de la dependencia de largo alcance. En los experimentos, se busca el mejor modelo entre las unidades de intención consecutivas de nivel 1, nivel 2 y nivel 3.