





GENERATIVE-CONTRASTIVE GRAPH LEARNING FOR RECOMMENDATION

IIC3633: Sistemas Recomendadores
2025-2

Clemente Acevedo
Cristobal Fuentes
Vittorio Salvatore



Contexto

En RecSys, hemos visto varios métodos de Collaborative Filtering, utilizados tanto en Academia como industria.


Uno de estos métodos son las GNNs. Que exparsen la info. modelada como grafo.

Recientemente, han surgido modelos de Graph Contrastive Learning (GCL) para apoyar el problema de la sparseness de los datos


Contexto

En general, las augmentations vienen en dos sabores:

1. Structure Augmentation (Dropout)
2. Feature Augmentation (Random Noise to embeddings)




Problema: Estas augmentation no son buenas para RecSys





1. Pierde la estructura del grafo user-item.
2. El random noise ocurre de forma uniforme para cada nodo, lo que ignora las características especiales de cada nodo.


Contribución: Variational Graph Generative- Contrastive Learning (VGCL) framework for recommendation




Marco Teórico: GNN's




Marco Teórico: Contrastive Learning



Marco Teórico: Contrastive Learning




Marco Teórico: Variational Auto-Encoders




Estado del arte de Graph Contrastive Learning for RecSys

SimGCL (2023)




Random Noise Unif a los embeddings


SGL (2021)



Dropout nodes & edges

Solución: Variational Graph Generative-Contrastive Learning (VGCL) framework for recommendation





Tiene de dos partes:

1. Un VAE a nivel de nodos.
2. Un módulo de Cluster-aware contrastive learning con *sampling* a partir del VAE.

3.1 Variational Graph Reconstruction

La meta es representar el embedding de cada nodo como una distribución Normal Multivariada via μ , σ . ¿Cómo?

Definiciones:

Sea $\mathbf{X}$ el espacio de los datos, $\mathbf{Z}$ el espacio de embeddings, $\mathbf{A}$ la matriz de Adyacencia del Grafo Users-Items, $\mathbf{E}^0$ embeddings iniciales de los nodos, parámetros de los modelos ϕ_μ , ϕ_σ y $q_\phi(\mathbf{z} | \mathbf{x})$ distribución del encoder.

Se encodea cada nodo i tal que $q_\phi(\mathbf{z}_i | \mathbf{A}, \mathbf{E}^0) \sim \mathcal{N}(\mathbf{z}_i | \mu_i, \sigma_i)$ (Multinomial) con los parámetros

$$\mu = GNN(\mathbf{A}, \mathbf{E}^0, \phi_\mu), \quad \sigma = GNN(\mathbf{A}, \mathbf{E}^0, \phi_\sigma)$$

3.1 Variational Graph Reconstruction

Se encodea cada nodo i tal que $q_\phi(z_i | A, E^0) \sim \mathcal{M}(z_i | \mu_i, \sigma_i)$ (Multinomial) con los parámetros

$$\mu = GNN(A, E^0, \phi_\mu), \quad \sigma = GNN(A, E^0, \phi_\sigma)$$

Para las GNN's se utilizó LightGCN, más específicamente:

$$\mu = \frac{1}{L} \sum_{l=1}^L \mu^l, \sigma = MLP(\mu)$$

$$\mu_i^l = \sum_{j \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i|} \sqrt{|\mathcal{N}_j|}} \mu_i^{l-1}, \quad \sigma = \exp(\mu \mathbf{W} + \mathbf{b})$$

3.1 Variational Graph Reconstruction

Reparametrization trick:

$$\mathbf{z}_i = \boldsymbol{\mu}_i + \boldsymbol{\sigma}_i \cdot \boldsymbol{\varepsilon}$$

Para poder actualizar en backprop.

Es así como conseguimos la distribución de los nodos del encoder:

$$q_{\phi}(\mathbf{z}_i \mid \mathbf{A}, \mathbf{E}^0) \sim \mathcal{N}(\mathbf{z}_i \mid \boldsymbol{\mu}_i, \boldsymbol{\sigma}_i)$$

3.1 Variational Graph Reconstruction

Decoder

¿Cómo construimos el grafo de nuevo a partir de las distribuciones?

$$p(\mathbf{A}_{ij} = 1 | \mathbf{z}_i, \mathbf{z}_j) = \sigma(\mathbf{z}_i^T \mathbf{z}_j)$$

Con σ sigmoide.

La idea es que si dos embedding (distribuciones) son parecidas entonces probablemente son vecinos en el grafo.


3.1 Variational Graph Reconstruction

Loss function

Para esta parte del encoder-decoder variacional se utiliza la perdida:

$$\mathcal{L}_{ELBO} = -\mathbb{E}_{\mathbf{Z} \sim q_{\phi}(\mathbf{Z}|\mathbf{A}, \mathbf{E}^0)} [\log(p_{\theta}(\mathbf{A}|\mathbf{Z}))] + KL[q_{\phi}(\mathbf{Z}|\mathbf{A}, \mathbf{E}^0) || p(\mathbf{Z})].$$

Con el primer termino siendo la diferencia entre encoder-decoder (ver el -) y el segundo termino siendo la divergencia Kullback-Leibler con la priori.




3.2 Cluster-aware Contrastive Learning

Contrastive View Construction

La razón por la que estábamos haciendo esto: Conseguimos las contrastive views sampleando de cada distribución.

$$\begin{aligned} \mathbf{z}'_i &= \mu_i + \sigma_i \cdot \varepsilon', \\ \mathbf{z}''_i &= \mu_i + \sigma_i \cdot \varepsilon'', \end{aligned} \quad \text{Con } \varepsilon', \varepsilon'' \sim \mathcal{N}(0, \text{Id.})$$

Este es la idea principal que nos permite hacer contrastive view construction sin distorsionar el grafo original y manteniendo la varianza individual de cada nodo.



3.2 Cluster-aware Contrastive Learning

Para conseguir mejor rendimiento, el paper utiliza dos losses.

Node-level Contrastive Loss: InfoNCE para users e items

$$\mathcal{L}_N^U = \sum_{a \in \mathcal{B}_u} -\log \frac{\exp(\mathbf{z}'_a{}^T \mathbf{z}''_a / \tau_1)}{\sum_{b \in \mathcal{B}_u} \exp(\mathbf{z}'_a{}^T \mathbf{z}''_b / \tau_1)},$$

$$\mathcal{L}_N^I = \sum_{i \in \mathcal{B}_i} -\log \frac{\exp(\mathbf{z}'_i{}^T \mathbf{z}''_i / \tau_1)}{\sum_{j \in \mathcal{B}_i} \exp(\mathbf{z}'_i{}^T \mathbf{z}''_j / \tau_1)},$$

$$\mathcal{L}_N = \mathcal{L}_N^U + \mathcal{L}_N^V$$

Contrastive-level Contrastive Loss : InfoNCE de nuevo

Se implementó una loss del cluster para incentivar consistencia de los pares de nodos en el mismo cluster.

Se supone que hay K_u clusters de usuarios y K_i clusters de items, con lo que se calcula

- **p(a, b)** prob. dos usuarios mismo cluster; **p(i, j)** prob. dos items mismo cluster.


$$\mathcal{L}_C^U = \sum_{a \in \mathcal{B}_u} \frac{-1}{SP(a)} \log \left(\frac{\sum_{b \in \mathcal{B}_u, b \neq a} p(a, b) \exp(\mathbf{z}'_a \mathbf{z}''_b / \tau_2)}{\sum_{b \in \mathcal{B}_u, b \neq a} \exp(\mathbf{z}'_a \mathbf{z}''_b / \tau_2)} \right),$$

$$\mathcal{L}_C^I = \sum_{i \in \mathcal{B}_i} \frac{-1}{SP(i)} \log \left(\frac{\sum_{j \in \mathcal{B}_i, j \neq i} p(i, j) \exp(\mathbf{z}'_i \mathbf{z}''_j / \tau_2)}{\sum_{j \in \mathcal{B}_i, j \neq i} \exp(\mathbf{z}'_i \mathbf{z}''_j / \tau_2)} \right),$$

$$\text{where } SP(a) = \sum_{b \in \mathcal{B}_u, b \neq a} p(a, b) \text{ and } SP(i) = \sum_{j \in \mathcal{B}_i, j \neq i} p(i, j)$$

$$\mathcal{L}_C = \mathcal{L}_C^U + \mathcal{L}_C^I,$$

Resumen propuesta



$$\min \mathcal{L} = \mathcal{L}_{ELBO} + \alpha \mathcal{L}_{cl} + \lambda ||\mathbf{E}^0||^2$$

3.4 Model Analysis

Space Complexity

Mismo tamaño que otros modelos de CGL de recomendaciones.

Time complexity

Más veloz que otros modelos de GCL con data augmentation para recomendaciones.

SGL, SimGCL son $O(2|E|ds)$ y VGCL es $O(6|E|ds)$

con $|E|$ numero de edges, d dim embedding, s grado promedio del grafo.

Experimentos: Datasets

Table 1: The statistics of three datasets.

Datasets	Users	Items	Interactions	Density
Douban-Book	13,024	22,347	792,062	0.272%
Dianping	59,426	10,224	934,334	0.154%
Movielens-25M	92,901	8,826	2,605,952	0.318%

Splits 80/20

Filtración usuarios < 10
interacciones

Movielens: 5 → positive

Métricas y Modelos escogidos

Métricas, $N = 10, 20$ para cada dataset

- Recall@N
- NDCG@N

Modelos:

- BPR-MF: método basado en CF
- Light-GCN: método basado en GNN
- Multi-VAE, CVGA: métodos basados en VAE
- SGL-ED, NCL, SimGCL: métodos basados en GCL

Evaluación Modelos

Models	Douban-Book				Dianping				Movielens-25M			
	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20
BPR-MF	0.0869	0.0949	0.1296	0.1045	0.0572	0.0443	0.0934	0.0557	0.2152	0.2011	0.3163	0.2343
LightGCN	0.1042	0.1195	0.1516	0.1278	0.0679	0.0536	0.1076	0.0660	0.2258	0.2192	0.3263	0.2509
Multi-VAE	0.0941	0.1073	0.1376	0.1155	0.0645	0.0508	0.1046	0.0632	0.2188	0.2101	0.3185	0.2418
CVGA	0.1058	0.1305	0.1492	0.1359	0.0719	0.0562	0.1128	0.0690	0.2390	0.2306	0.3454	0.2641
SGL-ED	0.1103	0.1357	0.1551	0.1419	0.0719	0.0560	0.1111	0.0686	0.2298	0.2239	0.3274	0.2541
NCL	0.1121	0.1377	0.1576	0.1439	0.0727	0.0571	0.1124	0.0701	0.2281	0.2222	0.3274	0.2531
SimGCL	<u>0.1218</u>	<u>0.1470</u>	<u>0.1731</u>	<u>0.1540</u>	<u>0.0768</u>	<u>0.0606</u>	<u>0.1208</u>	<u>0.0743</u>	<u>0.2428</u>	<u>0.2356</u>	<u>0.3491</u>	<u>0.2690</u>
VGCL	0.1283	0.1564	0.1829	0.1638	0.0778	0.0616	0.1234	0.0757	0.2463	0.2400	0.3507	0.2725

Negritas: Mejor rendimiento

Subrayado: Segundo mejor rendimiento

Evaluación Modelos


Models	Douban-Book				Dianping				Movielens-25M			
	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20
BPR-MF	0.0869	0.0949	0.1296	0.1045	0.0572	0.0443	0.0934	0.0557	0.2152	0.2011	0.3163	0.2343
LightGCN	0.1042	0.1195	0.1516	0.1278	0.0679	0.0536	0.1076	0.0660	0.2258	0.2192	0.3263	0.2509
Multi-VAE	0.0941	0.1073	0.1376	0.1155	0.0645	0.0508	0.1046	0.0632	0.2188	0.2101	0.3185	0.2418
CVGA	0.1058	0.1305	0.1492	0.1359	0.0719	0.0562	0.1128	0.0690	0.2390	0.2306	0.3454	0.2641
SGL-ED	0.1103	0.1357	0.1551	0.1419	0.0719	0.0560	0.1111	0.0686	0.2298	0.2239	0.3274	0.2541
NCL	0.1121	0.1377	0.1576	0.1439	0.0727	0.0571	0.1124	0.0701	0.2281	0.2222	0.3274	0.2531
SimGCL	<u>0.1218</u>	<u>0.1470</u>	<u>0.1731</u>	<u>0.1540</u>	<u>0.0768</u>	<u>0.0606</u>	<u>0.1208</u>	<u>0.0743</u>	<u>0.2428</u>	<u>0.2356</u>	<u>0.3491</u>	<u>0.2690</u>
VGCL	0.1283	0.1564	0.1829	0.1638	0.0778	0.0616	0.1234	0.0757	0.2463	0.2400	0.3507	0.2725

VGCL mejora en >25% sobre BPR-MF en NDCG@20


VGCL mejora en 6% sobre SimGCL, el segundo mejor en Douban-Book

Evaluación Modelos

BPR-MF vs LightGCN



Multi-VAE vs CVGA



Estudio de Ablación


Models	Douban-Book		Dianping		Movielens-25M	
	R@20	N@20	R@20	N@20	R@20	N@20
LightGCN	0.1512(-)	0.1271(-)	0.1076(-)	0.0660(-)	0.3263(-)	0.2509(-)
SimGCL	0.1731(14.48%)	0.1540(+21.16%)	0.1208(+12.27%)	0.0743(+12.58%)	0.3491(+6.99%)	0.2690(+7.21%)
VGCL-w/o C	0.1776(+17.46%)	0.1575(+23.92%)	0.1222(+13.57%)	0.0750(+13.64%)	0.3477(+6.56%)	0.2705(+7.81%)
VGCL-w/o V	0.1722(+13.89%)	0.1547(+21.72%)	0.1218(+13.20%)	0.0746(+13.03%)	0.3493(+7.05%)	0.2702(+7.69%)
VGCL	0.1829(+20.97%)	0.1638(+28.87%)	0.1233(+14.59%)	0.0756(+14.55%)	0.3507(+7.48%)	0.2725(+8.61%)

VGCL-w/o C: Sin implementación del cluster-level

VGCL-w/o V: Sin implementación del variational graph

Estudio de Ablación

Tanto w/o C y w/o V
consistentemente rinden
mejor que SimGCL
Pero siempre rinden peor
que VGCL




Investigación con grupos de usuarios

U1-U4: Grupos de usuarios
divididos en cantidad de
interacciones



U1 diff = 4.2%

U4 diff = 8.4%


Mayor densidad = Mayor
desviación estándar



(a) Douban-Book Dataset



(b) Dianping Dataset



Referencias

- Kingma, D. P., & Welling, M. (2013). Auto-encoding variational Bayes [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.1312.6114> arXiv
- Wu, J., Wang, X., Feng, F., He, X., Chen, L., Lian, J., & Xie, X. (2021). Self-supervised graph learning for recommendation [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2010.10783> arXiv
- Yu, J., Yin, H., Xia, X., Chen, T., Cui, L., & Nguyen, Q. V. H. (2022). Are graph augmentations necessary? Simple graph contrastive learning for recommendation [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2112.08679> arXiv
- Yang, Y., Wu, Z., Wu, L., Zhang, K., Hong, R., Zhang, Z., Zhou, J., & Wang, M. (2023). Generative contrastive graph learning for recommendation [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2307.05100>



CONCLUSIONES

3.1 Variational Graph Reconstruction

La meta es representar el embedding de cada nodo como una distribución Normal Multivariada via μ , σ . ¿Cómo?

Conceptos y definiciones:

Sean X el espacio de los datos, Z el espacio de embeddings.

- Suponemos que los datos $x \sim p_\theta(x|z)$ (decoder)
- Priori $p_\theta(x)$ de los datos.
- Posteriori $p_\theta(z | x)$
- Aproximación de la posteriori $q_\phi(z | x) \approx p_\theta(z | x)$ (encoder)

Sin embargo, no conocemos la posteriori, así que usamos $q_\theta(x|z)$ para inferirla

