

When Recommender Systems Snoop into Social Media, Users Trust them Less for Health Advice

**Yuan Sun, Magdalayna Drivas,
Mengqi Liao, S. Shyam Sundar**

Presentado por Emilio Latorre, Jorge De Goyeneche y Victoria Jiménez

Contexto

Social Media

Los sistemas recomendadores **(RS)** se han vuelto parte importante de la vida digital, aprendiendo de la **actividad** del usuario para ofrecer sugerencias personalizadas. Sin embargo, enfrentan el problema del **cold start**.

La integración de información de **redes sociales** (gracias al **inicio de sesión** vía red social) surge como solución, al aprovechar las conexiones entre usuarios para generar recomendaciones.

Salud

La influencia social es clave en la **salud**, ya que las recomendaciones personalizadas pueden incentivar la **actividad física**, la **buena alimentación** y el **descanso**.

El contenido compartido por **personas cercanas** y las publicaciones con **muchos “me gusta”** son más eficientes en promover un cambio y generan mayor confianza, lo que ha impulsado a los sistemas de recomendación a **integrar** datos de redes sociales.

FALTA DE EVIDENCIA

No se ha comprobado con suficiente **evidencia empírica** que usar datos de redes sociales en *RS* de salud preventiva sea realmente **efectivo**.

DESEO DE INDIVIDUALIZACIÓN

Los usuarios valoran recibir consejos de salud **personalizados y únicos**. Por ende basarse en las acciones de otros puede generar rechazo.

SUPRESIÓN DE IDENTIDAD

Si los usuarios perciben que el algoritmo deja afuera o suprime ciertas **identidades sociales**, las recomendaciones pueden tener efectos negativos.

RESISTENCIA AL CAMBIO

Falta entender cómo ciertos algoritmos de personalización pueden causar **reacciones adversas**, dificultando modificar hábitos.

Problema de Recomendación

Objetivo

Comprender los **efectos psicológicos negativos** de las recomendaciones de salud personalizadas.

Diseñar *RS* de salud que reduzcan experiencias indeseables y **mejoren la adherencia** del usuario.

Explorar cómo las **características tecnológicas** de los sistemas pueden aumentar la aceptación de las recomendaciones de salud.

Usuarios

$U = \{u_1, u_2, \dots, u_{341}\}$

Demográficos = $\{\text{edad}(u), \text{género}(u), \text{etnia}(u)\}$

Preferencias ejercicio = $\{\text{intensidad}(u), \text{lugar}(u), \text{propósito}(u)\}$

$\text{intensidad} \in \{\text{desafiante}, \text{balanceado}, \text{casual}\}$

$\text{lugar} \in \{\text{bajo techo}, \text{al aire libre}\}$

$\text{propósito} \in \{\text{divertirse}, \text{ser más saludable}\}$

Amigos r. sociales = amigos en redes sociales del usuario u

Actividad r. sociales = items vistos/"calificados" por el usuario u

Items

$I = \{\dots\}$

Lugar: bajo techo/al aire libre

Intensidad : desafiante, balanceado, casual

Propósito : divertirse, ser más saludable

PROBLEMA DE RECOMENDACIÓN

In-app **Content-based Filtering**

Preferencias $P(u)$ **explícitamente** entregadas

In-app **Collaborative Filtering**

Encontrar usuarios similares en gustos

In-app **Demographic Filtering**

Encontrar usuarios demográficamente similares

$$R(u): I \rightarrow \mathbb{R}$$

Recomendación

Social Media Content-based Filtering

Actividad del usuario en redes sociales

Social Media Collaborative Filtering

Conexiones del usuario en redes sociales

Social Media Demographic Filtering

Información demográfica extraída del perfil de red social

Contribuciones

CONTRIBUCIONES

Identifica la amenaza a la **identidad y la privacidad** como percepciones clave que pueden reducir la **confianza y aceptación** de las recomendaciones de salud, mostrando cómo los sistemas algorítmicos pueden afectar el autoconcepto del usuario y ampliar la comprensión de la confianza en este contexto.

Demuestra, mediante evidencia empírica, que **ofrecer opciones** al usuario puede **reducir los efectos negativos** de los sistemas de recomendación de salud, subrayando la relevancia de otorgarles mayor control y agencia en la personalización.

Ofrece lineamientos útiles para **diseñadores** que buscan desarrollar sistemas de recomendación capaces de fomentar de manera efectiva comportamientos saludables.

**Estado del arte y
marco teórico**

REDES SOCIALES EN SALUD

Kim & Sundar (2014): **Señales sociales** se asocian positivamente con **logro de metas de fitness**

Daskalova et al. (2021): **Recomendaciones de cohortes** mejoran **motivación** vía comparación social

IDENTIDAD Y CATEGORIZACIÓN

Breakwell (1988): **Amenaza a identidad** lleva a **resistencia** al **cambio** de comportamiento

Wang & Sundar (2021): **Unicidad** percibida facilita **aceptación** de **consejos** médicos

PRIVACIDAD

Goldman & Hudson (2000): **Datos** de **salud** son altamente **sensibles** y estigmatizantes

Koohang et al. (2018): Usuarios tienen **baja confianza** en **RRSS** para proteger **datos**

Cho et al. (2020): Social **login** genera **preocupaciones** especialmente en apps sensibles

CONTROL DEL USUARIO

Harper et al. (2015): **Configurar** parámetros de redes sociales **conduce a mejores evaluaciones**

Jin et al. (2019): **Control** contextual incrementa **calidad** percibida

Marathe & Sundar (2011): **Customización** genera mayor **sentido de agencia**

Marco teórico

HAI-TIME (Sundar, 2020)

CUE ROUTE (SEÑALES)

Efectos de como describes el sistema

- Heurísticas
- Atajos mentales

Ej: "Basado en edad/genero"

Me están categorizando, es una amenaza a mi identidad

ACTION ROUTE (ACCIONES)

Efectos de que te permite hacer el sistema

- Sense of agency
- El usuario actúa

Ej: "Puedes cambiar de método"

Tengo el control, mayor agencia, me da mas confianza

H1a: El filtrado demográfico resultará en una mayor amenaza percibida a la identidad que otros enfoques de personalización.

H1b: El filtrado demográfico estará más negativamente asociado con la confianza del usuario.

H2a: El filtrado basado en contenido usando datos in-app llevará a una menor amenaza percibida a la identidad comparado con otros enfoques de personalización.

H2b: Lo cual a su vez llevará a una mayor confianza del usuario.

H3: Habrá una diferencia significativa entre el filtrado colaborativo basado en redes sociales y el filtrado colaborativo basado en datos in-app sobre la percepción de bandwagon.

H4a: Los enfoques de personalización basados en datos de redes sociales llevarán a un mayor riesgo de privacidad percibido.

H4b: Y a una menor confianza del usuario que aquellos basados en datos in-app del usuario.

H5a: Proveer elección al usuario aumentará el sentido de agencia.
H5b: Y mitigará la amenaza a la identidad.

H6: Proveer elección al usuario afectará la usabilidad percibida del sistema de recomendación.

Estudio

Diseño del estudio

Experimento factorial 6 x 2 variables

Cada participante ve una condición

Controlado aleatorizado

Muestra N = 341

- CloudResearch
- 59% mujeres, Edad M=43 (22–65)
- 60% educación universitaria

Diseño del estudio

Factor 1: Personalización

IN APP DATA

- Demográfico
- Colaborativo
- Basado en contenido

SOCIAL MEDIA DATA

- Demográfico
- Colaborativo
- Basado en contenido

Factor 2: Capacidad de elección

CON ELECCIÓN

SIN ELECCIÓN

Diseño del estudio

Welcome to MyFitness!

Powered by artificial intelligence (AI), MyFitness is able to recommend a personalized fitness plan **based on your own preferences for the type, intensity, and frequency of exercise.**



Continue

Primera pantalla MyFitness

Diseño del estudio

CHOOSE AN OPTION

	Fitness content liked by my social media friends
	What I have viewed and liked on social media
	Users who are similar to my age, gender & ethnicity
	My social media friends who are similar to my age, gender & ethnicity
	Users who share similar fitness preferences
	Stick to the current approach

Figure 2: User Choice Design

Diseño del estudio




Figure 3: Personalized Fitness Plan

Diseño del estudio

Table 1: Manipulation of Personalization Approach

	Demographic filtering; In-app data	Content-based filtering; In-app data	Collaborative filtering; In-app data	Demographic filtering; Social Media data	Content-based filtering; Social Media data	Collaborative filtering; Social Media data
Home Page	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized fitness plan based on users who are similar to you in age, gender, and ethnicity.	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized fitness plan based on your preferences for the type, intensity, and frequency of exercise.	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized fitness plan based on users who share similar preferences for the type, intensity, and frequency of exercise with you.	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized fitness plan based on your social media friends who are similar to you in age, gender, and ethnicity.	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized workout plan based on the fitness content that you have viewed and liked on social media.	Welcome to MyFitness! Powered by artificial intelligence (AI), MyFitness is able to recommend to you a personalized workout plan based on the fitness content your social media friends have viewed and liked on social media.
Loading Page	We are searching for your personalized fitness plan based on users similar to you in terms of age, gender, and ethnicity...	We are searching for your personalized fitness plan based on your own preferences for the type, intensity, and frequency of exercise...	We are searching for your personalized fitness plan based on users who have similar preferences for type, intensity, and frequency of exercise...	We are searching for your personalized fitness plan based on your social media friends who are similar to you in terms of age, gender, and ethnicity...	We are searching for your personalized fitness plan based on the fitness content you have viewed and liked on social media...	We are searching for your personalized fitness plan based on the fitness content your social media friends have viewed and liked...
Result Page	Based on the exercises liked by users who are similar to you in age, gender, and ethnicity, we recommend the following fitness plan:	Based on what you have told us about your preference for the type, intensity, and frequency of exercise, we recommend you the following fitness plan:	Based on users who have similar preferences for type, intensity, and frequency of exercise, we recommend the following fitness plan:	Based on your social media friends who are similar to you in terms of age, gender, and ethnicity, we recommend the following fitness plan:	Based on the fitness content you have viewed and liked on social media, we recommend the following fitness plan:	Based on the fitness content your social media friends have viewed and liked, we recommend the following fitness plan:



Variables a medir

CHEQUEOS DE MANIPULACIÓN

- Identificación del método (opción múltiple)
- Presencia de elección (Sí/No)

MEDIADORES (LIKERT 7 PUNTOS)

- Percepción de Bandwagon
- Amenaza a Identidad
- Sentido de Agencia
- Riesgo de Privacidad Percibido

DATOS CONDUCTUALES

VARIABLES DEPENDIENTES (LIKERT 7 PUNTOS)

- Confianza Cognitiva
- Confianza Conductua
- Intenciones de Segui
- Usabilidad – reverso

VARIABLES DE CONTROL (PRE-TEST):


- Uso Avanzado de Tecnología (12 ítems, $\alpha=.92$)
- Heurística de Máquina (5 ítems, $\alpha=.92$)

DATOS CUALITATIVOS

Resultados


Manipulación

RESULTADOS



Manipulación

RESULTADOS



Cambio de RS

RESULTADOS



Amenaza a la identidad

RESULTADOS
H1, H2

Table 2: Contrasts, Means and SE for Effects of Personalization Approaches on Threat to Identity

Personalization Approaches	Mean	Std. Error
Social Media Collaborative Filtering	3.25 _a	0.29
Social Media Demographic Filtering	2.73 _{ab}	0.26
In-app Demographic Filtering	2.62 _{ab}	0.24
In-app Collaborative Filtering	2.29 _{ab}	0.24
Social Media Content-based Filtering	2.16 _{ab}	0.26
In-app Content-based Filtering	2.15 _b	0.25

Note: Means with no subscript in common differ at $p < .05$ using Bonferroni post-hoc comparisons.

Al realizar un análisis ANCOVA, se encontró que el efecto principal de personalización no es significativo para concluir un mayor efecto arrastre.

$$F(5, 158) = 1.82, p = .11, \text{partial } \eta^2 = .05.$$

Table 3: Contrasts, Means and SE for Effects of Personalization Approaches on Perceived Privacy Risk

Personalization Approaches	Mean	Std. Error
Social media Collaborative Filtering	4.78 _a	0.28
Social media Content Filtering	4.52 _{ab}	0.26
Social media Demographic Filtering	4.29 _{abc}	0.29
In-app Content Filtering	3.49 _{bc}	0.24
In-app Demographic Filtering	3.45 _{bc}	0.25
In-app Collaborative Filtering	3.16 _b	0.27

Note: Means with no subscript in common differ at $p < .05$ using Bonferroni post-hoc comparisons.

Tipos de Confianza

RESULTADOS
H4

01.

Confianza cognitiva (Cognitive Trust)

Qué tanto creo que el sistema es competente, preciso, capaz y razonable.

02.

Confianza conductual (Behavioral Trust)

Mi disposición real a actuar confiando en el sistema.

03.

Seguir el consejo (Follow Advice)

La intención concreta de aceptar las recomendaciones del sistema.

Table 4: ndirect Effects of Personalization Approaches on Trust Outcomes via Privacy Risk

Mediation Path	B ^a	SE	CI ^b	
			Lower CI	Upper CI
Personalization Approach Comparison ^c → Privacy Risk → Cognitive Trust	-.52	.22	-.99	-.15
Personalization Approach Comparison ^c → Privacy Risk → Behavioral Trust	-.56	.25	-1.1	-.15
Personalization Approach Comparison ^c → Privacy Risk → Follow Advice	-.45	.22	-.94	-.10


^aUnstandardized path coefficient

^bBias-correlated and accelerated 95% confidence interval (CI)

^cPersonalization approach comparison is coded as 0 = In-app collaborative filtering, 1 = Social media-based collaborative filtering


Privacidad y Confianza

RESULTADOS
H4




Sentido de Agencia

RESULTADOS
H5




Amenaza a la Identidad

RESULTADOS
H5



Amenaza a la Identidad

RESULTADOS
H5



Al realizar un análisis ANCOVA, se encontró que el efecto principal de dar elección al usuario no es significativo para concluir un mayor uso y retención.

$$F(1, 327) = .05, p = .82, \text{partial } \eta^2 = .00.$$

Peligro de privacidad

Aunque la autenticación social resulta cómoda, varios participantes expresaron preocupación por la privacidad y el uso de información sensible en contextos de salud.

Falta de precisión

Algunos usuarios perciben que usar datos sociales para salud puede resultar impreciso debido a la desconexión entre su vida social y su bienestar real.

Deseo objetivo

En general quieren recomendaciones de salud, pero no sienten que las RRSS sean suficientes para suplir las necesidades.

Datos Cualitativos

Key Takeaways

RESULTADOS

01.

Personalización basada en redes sociales reduce la confianza.

02.

Darle al usuario poder de elección aumenta la confianza.

03.

Implicación para diseño: evitar depender de datos sociales.

Conclusión

Usar datos de redes sociales para personalizar recomendaciones de salud reduce la confianza de los usuarios por preocupaciones de privacidad e identidad. En cambio, permitir que las personas elijan cómo se personalizan sus recomendaciones aumenta su sensación de control y confianza.

Para aplicaciones de salud es mejor evitar depender de datos sociales y ofrecer opciones claras de personalización.

Referencias principales

- [1] Giuseppe Agapito, et al. 2016. DIETOS: A recommender system for adaptive diet monitoring and personalized food suggestion. In 2016 IEEE 12th International Conference on Wireless and Mobile Computing, Networking and Communications (WiMob). IEEE, 1–8.
- [2] Jisoo Ahn, et al. 2021. Website interactivity and processing: Menu customization and sense of agency are keys to better interaction design. International Journal of Human-Computer Studies 147 (2021), 102581.
- [3] Esma Aïmeur, et al. 2006. Privacy-preserving demographic filtering. In Proceedings of the 2006 ACM Symposium on Applied Computing. 872–878.
- [4] Sumaia Mohammed Al-Ghuribi and Shahrul Azman Mohd Noah. 2019. Multi-criteria review-based recommender system – The state of the art. IEEE Access 7 (2019), 169446–169468.
- [5] Veronica Barassi. 2020. Child data citizen: How tech companies are profiling us from before birth. MIT Press.

Referencias conclusión

[12] Moira Burke and Robert E Kraut. 2016. The relationship between Facebook use and well-being depends on communication type and tie strength. *Journal of Computer-Mediated Communication* 21, 4 (2016), 265–281.

[14] Ann E Caldwell, Kevin S Masters, John C Peters, Angela D Bryan, Jim Grigsby, Stephanie A Hooker, Holly R Wyatt, and James O Hill. 2018. Harnessing centred identity transformation to reduce executive function burden for maintenance of health behaviour change: The Maintain IT model. *Health Psychology Review* 12,3 (2018), 231–253.

[24] Nicholas Eng, Yuan Sun, and Jessica Gall Myrick. 2022. Who is your Inspiration? An exploration of strong and weak ties with emotions, body satisfaction, and the Theory of Planned Behavior. *Health Communication* (2022), 1–13.

[56] Chiara Longoni, Andrea Bonezzi, and Carey K Morewedge. 2019. Resistance to medical artificial intelligence. *Journal of Consumer Research* 46, 4 (2019), 629–650.

[78] Rashmi R Sinha, Kirsten Swearingen, et al. 2001. Comparing recommendations made by online systems and friends. *DELOS* 106 (2001).

When Recommender Systems Snoop into Social Media, Users Trust them Less for Health Advice

**Yuan Sun, Magdalayna Drivas,
Mengqi Liao, S. Shyam Sundar**

Presentado por Emilio Latorre, Jorge De Goyeneche y Victoria Jiménez