PAAC: POPULARITY-AWARE ALIGNMENT & CONTRAST
MITIGATING POPULARITY BIAS IN COLLABORATIVE FILTERING

Autores: Miaomiao Cai, Lei Chen, Yifan Wang, Haoyue Bai, Peijie Sun, Le Wu, Min Zhang, and Meng Wang

Diego Valenzuela, Cristóbal Tolorza, Bastián Guacucano

EL SESGO DE POPULARIDAD EN SISTEMAMS DE RECOMENDACIÓN

Problema: Los métodos basados en CF sufren de un significativo Sesgo de Popularidad.

Causa Principal: La distribución desigual de los ítems en los datasets del mundo real

Impacto Negativo:

- Gran diferencia en la precisión de la recomendación entre ítems populares y no populares.
- Dificulta la comprensión precisa de las preferencias del usuario.
- Exacerba el "Efecto Matthew".

DESAFÍOS CLAVE AL MITIGAR EL SESGO

Problema de Investigación: Cómo mitigar el Sesgo de Popularidad en los sistemas de recomendación para mejorar el rendimiento, especialmente para los ítems no populares.

Desafíos a abordar por la solución:

- Representaciones Insuficientes/Sobreajuste
- Separación de Representación

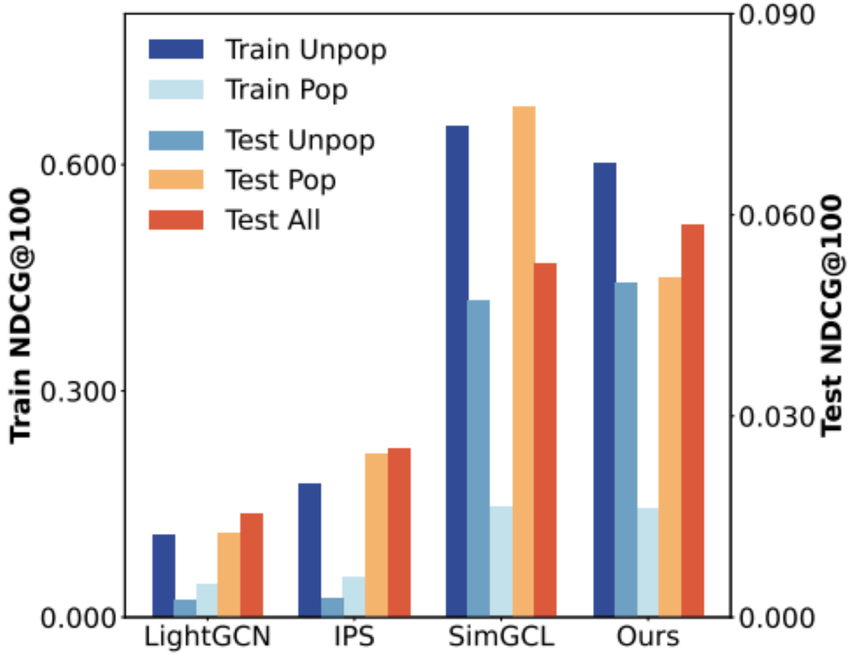

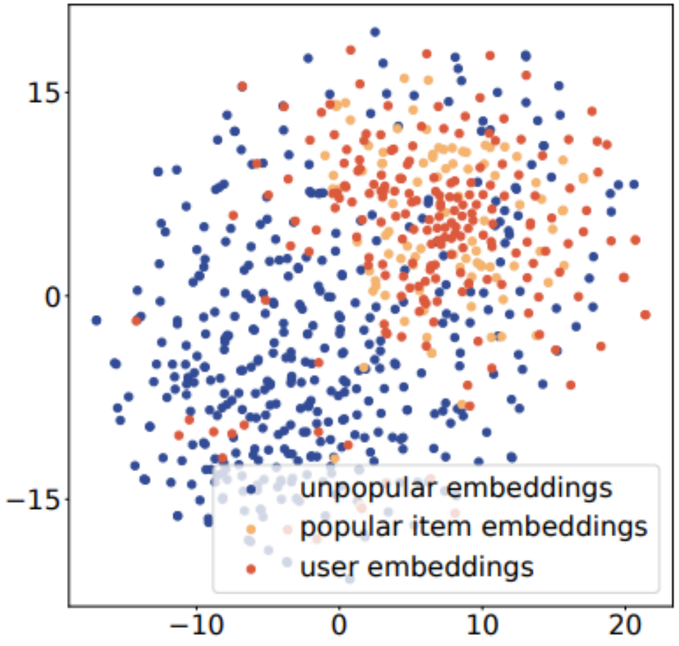

PAAC: ALINEACIÓN Y CONTRASTE CONSCIENTES DE LA POPULARIDAD

Contribuciones Clave:

- Módulo de Alineación Supervisada Consciente de la Popularidad (Supervised Alignment Module).

- Módulo de Contraste de Re-ponderación (Re-weighting Contrast Module).

- Validación: Se demuestra la efectividad y lógica de PAAC para mitigar el sesgo de popularidad mediante experimentos exhaustivos en tres datasets reales (Amazon-book, Yelp2018, y Gowalla).

MARCO TEÓRICO

- Filtrado Colaborativo con aprendizaje de alto orden usando LightGCN [28].

- Aprendizaje Contrastivo utilizando la pérdida InfoNCE [30].

ESTADO DEL ARTE

- Énfasis en Ítems No Populares: Intentos de aumentar los pesos de entrenamiento o las puntuaciones de predicción para ítems no populares (IPS [1], MACR [18]).

- Decorrelación de Popularidad: Se intenta separar la correlación entre las representaciones de ítems y su popularidad (MACR, InvCF [22].

- Métodos Basados en CL: Modelos que mejoran la consistencia general de la representación (SimGCL, Adap-r).

DETALLE DE LA SOLUCIÓN

ETAPAS

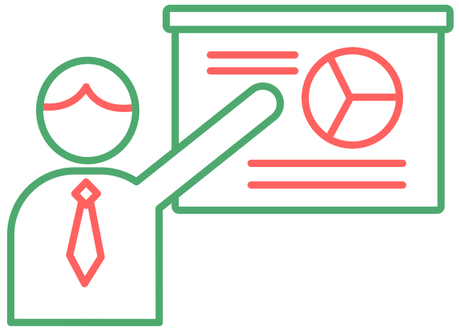

Módulo de Alineamiento Supervisado

Disminuir el over-fitting utilizando las características similares entre los elementos.

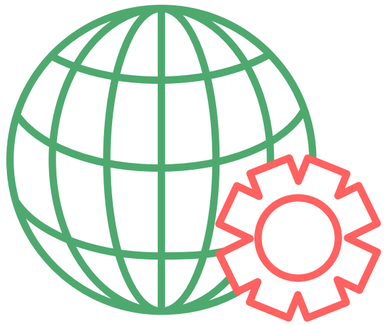

Módulo de Contraste Re-ponderado

Arreglar el problema de la separación de representaciones entre items populares y no populares.

Optimización Final del Modelo

Entrenamiento del modelo a elegir con los nuevos parámetros introducidos.

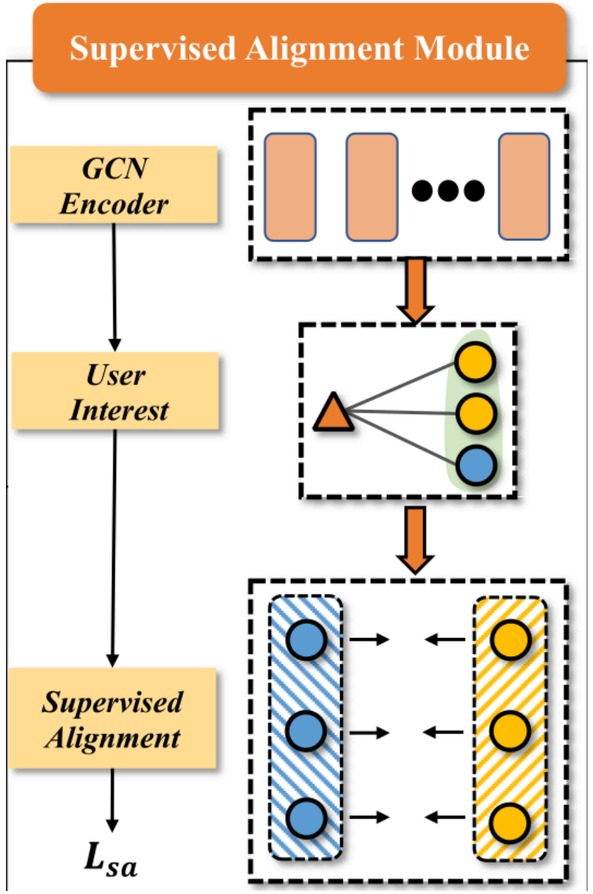

MÓDULO DE ALINEAMIENTO SUPERVISADO

$$\mathcal{L}_{sa} = \sum_{u \in \mathcal{U}} \frac{1}{|I_u|} \sum_{i \in I_u^{pop}, i' \in I_u^{unpop}} \|f(i) - f(i')\|^2,$$

Función de pérdida (Lsa), calculada con la distancia entre los items populares (Ipop) y los items no populares (Iunpop) del usuario U.
Al hacer esto el modelo sugiere que existen características parecidas entre los items, así aumentando la representación de los items no populares

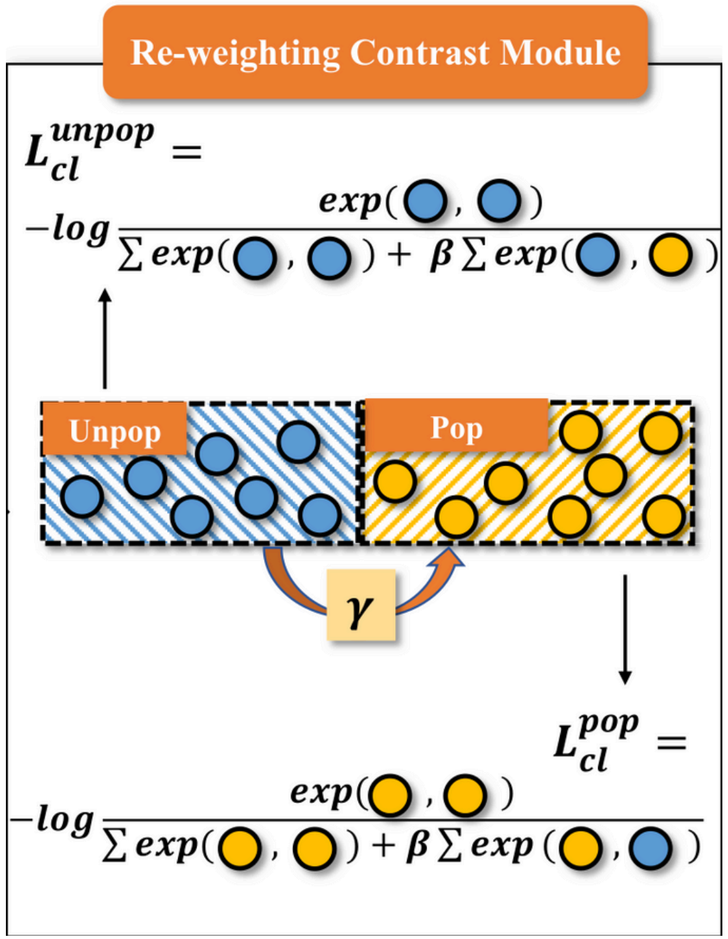

MÓDULO DE CONTRASTE RE-PONDERADO

$$\mathcal{L}_{cl}^{item} = \gamma * \mathcal{L}_{cl}^{pop} + (1-\gamma) * \mathcal{L}_{cl}^{unpop},$$

Función de pérdida (Lcl), calculada al re-ponderar las muestras positivas (con γ) y negativas (con β) en la pérdida contrastiva.
Al hacer esto, el modelo evita que los grupos de ítems populares y no populares se alejen entre sí, mitigando así la "separación de representaciones".

Funciones de pérdida a repoderar

$$\mathcal{L}_{cl}^{pop} = \sum_{i \in I^{pop}} \log \frac{exp(h_i' h_i'' / \tau)}{\sum_{j \in I^{pop}} exp(h_i' h_j'' / \tau) + \beta \sum_{j \in I^{unpop}} exp(h_i' h_j'' / \tau)}$$

$$\mathcal{L}_{cl}^{unpop} = \sum_{i \in I^{unpop}} \log \frac{exp(h_i' h_i'' / \tau)}{\sum_{j \in I^{unpop}} exp(h_i' h_j'' / \tau) + \beta \sum_{j \in I^{pop}} exp(h_i' h_j'' / \tau)}$$

Algorithm 1: The Algorithm of *PAAC*

Input: user-item interactions $\mathcal{R}$, recommendation encoder $f(\cdot)$, learning rate η, hyperparameters $\lambda_1, \lambda_2, \lambda_3, \beta, \gamma$;
Output: recommendation encoder $f(\Theta)$;

```
randomly initialize recommendation encoder parameter Θ;
for epoch = 1, 2, ..., T do
    for batch data B in R do
        calculate user and item representations;
        sample user u's interactions I_u in B;
        divide items I_u to I_u^pop and I_u^unpop by Eqn. (4);
        calculate supervised alignment loss L_sa by Eqn. (5);
        divide items I_B to I^pop and I^unpop by Eqn. (6);
        calculate re-weighting contrast loss L_cl by Eqn. (10);
        calculate recommendation loss L_rec by Eqn. (1);
        calculate PAAC total loss L by Eqn. (11);
        update Θ ← Θ − η * ∇_Θ L;
        if early stopping then
            break;
        end if
    end for
end for
return recommender encoder f(Θ).
```

OPTIMIZACIÓN FINAL DEL MODELO

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda_1 \mathcal{L}_{sa} + \lambda_2 \mathcal{L}_{cl} + \lambda_3 \|\Theta\|_2^2$$

Función de pérdida total (L), calculada como una suma ponderada de la pérdida de recomendación (Lrec), la pérdida de alineamiento (Lsa) y la pérdida de contraste (Lcl).
Al hacer esto, el modelo se entrena con una estrategia multi-tarea, optimizando simultáneamente la precisión de la recomendación y la mitigación de los dos tipos de sesgo de popularidad (overfitting y separación).

Algorithm 1: The Algorithm of *PAAC*

Input: user-item interactions $\mathcal{R}$, recommendation encoder $f(\cdot)$, learning rate η, hyperparameters $\lambda_1, \lambda_2, \lambda_3, \beta, \gamma$;
Output: recommendation encoder $f(\Theta)$;

```
randomly initialize recommendation encoder parameter Θ;
for epoch = 1, 2, ..., T do
    for batch data B in R do
        calculate user and item representations;
        sample user u's interactions I_u in B;
        divide items I_u to I_u^pop and I_u^unpop by Eqn. (4);
        calculate supervised alignment loss L_sa by Eqn. (5);
        divide items I_B to I^pop and I^unpop by Eqn. (6);
        calculate re-weighting contrast loss L_cl by Eqn. (10);
        calculate recommendation loss L_rec by Eqn. (1);
        calculate PAAC total loss L by Eqn. (11);
        update Θ ← Θ − η * ∇_Θ L;
        if early stopping then
            break;
        end if
    end for
end for
return recommender encoder f(Θ).
```

OPTIMIZACIÓN FINAL DEL MODELO

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda_1 \mathcal{L}_{sa} + \lambda_2 \mathcal{L}_{cl} + \lambda_3 \|\Theta\|_2^2$$

λ1: Controla la fuerza del Alineamiento Supervisado (Lsa).

λ2: Controla la fuerza del Contraste Re-ponderado (Lcl)

λ3: Es el coeficiente de Regularización L2.

EVALUACIÓN

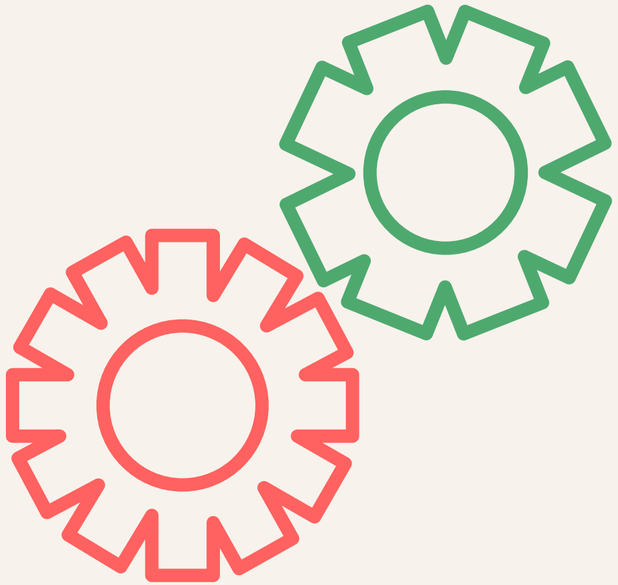

RQ1

¿Cómo se compara PAAC con métodos existentes para reducir el sesgo?

RQ2

¿Qué papel juegan los distintos componentes de PAAC?

RQ3

¿Cómo alivia PAAC el sesgo de popularidad?

RQ1

- PAAC supera a LightGCN y a baselines fuertes como SimGCL y Adap-τ en los 3 datasets (Yelp2018, Gowalla, Amazon-book) en métricas Recall@20, HR@20 y NDCG@20.

- En Yelp2018: +8.70% NDCG@20, +10.81% HR@20 vs mejor baseline.

- En Gowalla: mejoras más pequeñas (≈3–6%), pero aún positivas, incluso en un dataset muy disperso.

"PAAC MEJORA LA CALIDAD GLOBAL DE RECOMENDACIÓN".

Table 1: Performance comparison on three public datasets with $K = 20$. The best performance is indicated in bold, while the second-best performance is underlined. The superscripts $*$ indicate $p \leq 0.05$ for the paired t-test of *PAAC* vs. the best baseline (the relative improvements are denoted as Imp.).

Model	Yelp2018			Gowalla			Amazon-book		
	Recall@20	*HR*@20	*NDCG*@20	*Recall*@20	*HR*@20	*NDCG*@20	*Recall*@20	*HR*@20	*NDCG*@20
MF	0.0050	0.0109	0.0093	0.0343	0.0422	0.0280	0.0370	0.0388	0.0270
LightGCN	0.0048	0.0111	0.0098	0.0380	0.0468	0.0302	0.0421	0.0439	0.0304
IPS	0.0104	0.0183	0.0158	0.0562	0.0670	0.0444	0.0488	0.0510	0.0365
MACR	0.0402	0.0312	0.0265	0.0908	0.1086	0.0600	0.0515	0.0609	0.0487
γ-Adjnorm	0.0053	0.0088	0.0080	0.0328	0.0409	0.0267	0.0422	0.0450	0.0264
InvCF	0.0444	0.0344	0.0291	0.1001	0.1202	0.0662	0.0562	0.0665	0.0515
Adap-τ	0.0450	0.0497	0.0341	0.1182	0.1248	0.0794	0.0641	0.0678	0.0511
SimGCL	0.0449	0.0518	0.0345	0.1194	0.1228	0.0804	0.0628	0.0648	0.0525
PAAC	**0.0494***	**0.0574***	**0.0375***	**0.1232***	**0.1321***	**0.0848***	**0.0701***	**0.0724***	**0.0556***
Imp.	**+9.78 %**	**+10.81%**	**+8.70%**	**+3.18%**	**+5.85%**	**+5.47%**	**+9.36%**	**+6.78%**	**5.90%**

RQ2

- Compararon:
  - PAAC completo
  - PAAC sin alineamiento supervisado
  - PAAC sin re-ponderación contrastiva
  - SimGCL
- Resultado:
  - PAAC completo es siempre el mejor.
  - Quitar alineamiento → peor en ítems impopulares.
  - Quitar re-ponderación → aumenta separación entre populares e impopulares.

"AMBOS MÓDULOS (ALINEAMIENTO Y CONTRASTE RE-PONDERADO) SON NECESARIOS."

Table 2: Ablation study of *PAAC*, highlighting the best-performing model on each dataset and metrics in bold. Specifically, *PAAC*-w/o P removes the re-weighting contrastive loss of popular items, *PAAC*-w/o U eliminates the re-weighting contrastive loss of unpopular items, and *PAAC*-w/o A omits the popularity-aware supervised alignment loss.

Model	Yelp2018			Gowalla			Amazon-book		
	Recall@20	*HR*@20	*NDCG*@20	*Recall*@20	*HR*@20	*NDCG*@20	*Recall*@20	*HR*@20	*NDCG*@20
SimGCL	0.0449	0.0518	0.0345	0.1194	0.1228	0.0804	0.0628	0.0648	0.0525
***PAAC*-w/o P**	0.0443	0.0536	0.0340	0.1098	0.1191	0.0750	0.0616	0.0639	0.0458
***PAAC*-w/0 U**	0.0462	0.0545	0.0358	0.1120	0.1179	0.0752	0.0594	0.0617	0.0464
***PAAC*-w/0 A**	0.0466	0.0547	0.0360	0.1195	0.1260	0.0815	0.0687	0.0711	0.0536
PAAC	**0.0494***	**0.0574***	**0.0375***	**0.1232***	**0.1321***	**0.0848***	**0.0701***	**0.0724***	**0.0556***

RQ3

- Separan los ítems en “Populares” (top 20%) vs “No populares” (80% restante).
- PAAC:
  - Sube NDCG@20 en ítems NO populares en +7% a +9% vs SimGCL.
  - Reduce la brecha entre populares vs no populares (Δ) hasta 87.5% menos en Yelp2018.
- Incluso si PAAC baja un poco la precisión en los ítems súper populares, el rendimiento global sube porque mejora mucho los impopulares.

“PAAC NO SÓLO FAVORECE LO POPULAR. EQUILIBRA”.

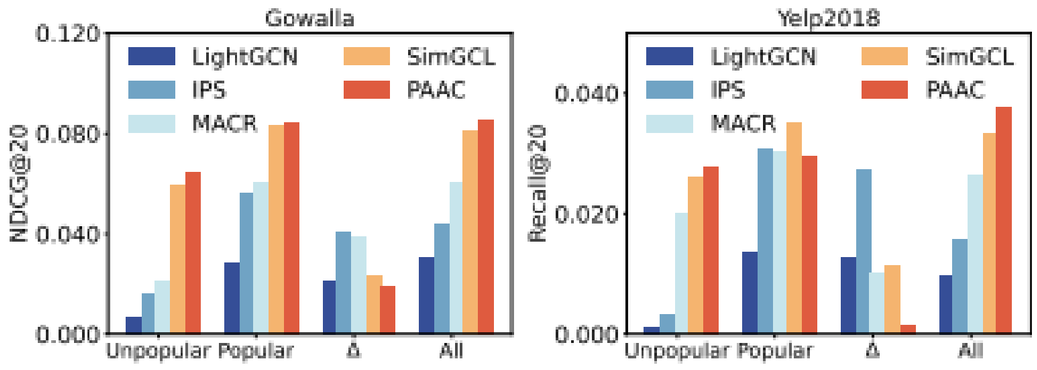

Figure 3: Performance comparison over different item popularity groups. In particular, Δ indicates the accuracy gap between different groups.

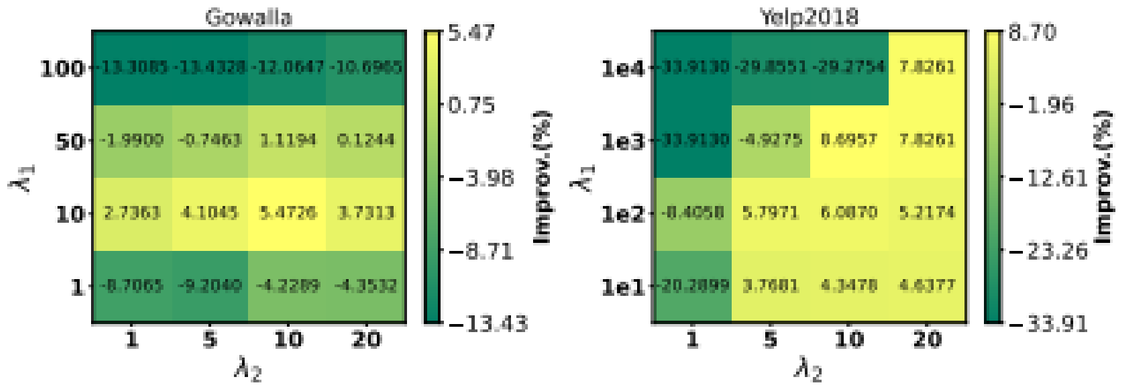

Figure 4: Performance comparison w.r.t. λ_1 and λ_2 on the Yelp2018 and Gowalla dataset in $NDCG@20$. The values indicate the percentage improvement relative to the best baseline.

¡MUCHAS GRACIAS POR SU ATENCIÓN!

BORCELLE

Anexo

$$\mathcal{L}_{cl} = \frac{1}{2} \times (\mathcal{L}_{cl}^{item} + \mathcal{L}_{cl}^{user})$$

$$\mathcal{L}_{rec} = -\frac{1}{|\mathcal{R}|} \sum_{(u,i,j) \in O^{+}} ln\sigma(s(u,i) - s(u,j))$$

Referencias

- [1] Stephen Bonner and Flavian Vasile. 2018. Causal embeddings for recommendation. RecSys (2018), 104–112.
- [18] Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980 (2014).
- [22] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. 2018. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748 (2018).
- [30] Chenyang Wang, Yuanqing Yu, Weizhi Ma, M. Zhang, C. Chen, Yiqun Liu, and Shaoping Ma. 2022. Towards Representation Alignment and Uniformity in Collaborative Filtering. KDD (2022), 1816–1825.