



Unbiased Recommender Learning from Implicit Feedback via Weakly Supervised Learning

By Hao Wang, Zhichao Chen, Haotian Wang, Yanchao Tan, Licheng Pan, Tianqiao Liu,
Xu Chen, Haoxuan Li, Zhouchen Lin




Por:

Florencia Schiappacasse, Alinna Vidal, Gustavo Gonzalez.

Motivación



¿Si un usuario no hace click en una recomendación, es porque el contenido no le gusta o simplemente porque no lo ha visto?



Contexto

Los sistemas de recomendación son herramientas que capturan las preferencias del usuario para ofrecer contenido personalizado. La industria prefiere trabajar con feedback implícito.




Limitación: Missing Negative Feedback (MNF)



Problema de Recomendación

¿Qué es el Implicit Feedback y por qué es difícil?

Sistema de recomendación



Predecir si el usuario u
aceptará el ítem i

Feedback implícito



Solo observamos
interacciones positivas

Problema crítico



No confirmamos negativos
verdaderos

Riesgo ideal a minimizar:


$$R_{\text{ideal}}(g) = \mathbb{E}_{p(x,y)} [\ell(g(x), y)]$$

Missing Negative Feedback (MNF)

Positivos ocultos vs Negativos verdaderos


¿Una ausencia de interacción significa NO INTERÉS o NO VISIBILIDAD?

Datos observados



Positivos confirmados + No etiquetados

Pregunta clave



¿El usuario nunca compró el ítem X porque no le gusta, o porque no lo conoce?

¡Imposible distinguir sin información adicional!

Descomposición Matemática

Class Prior κ_p : La proporción desconocida de positivos ocultos

- **Distribución de datos:** $p_{\text{data}}(x) = \kappa_p \cdot p_p(x) + \kappa_n \cdot p_n(x)$

- κ_p : Proporción de positivos reales (DESCONOCIDA).

- $\kappa_n = 1 - \kappa_p$: Proporción de negativos.

- **Riesgo ideal:** $R_{\text{ideal}}(g) = \kappa_p R_p(g) + \kappa_n R_n(g)$

- $R_p(g)$: Error esperado en positivos.

- $R_n(g)$: Error esperado en negativos.

 **Desafío:** $p_n(x)$ es inaccesible $\longrightarrow$ No podemos calcular $R_n(g)$

Contribución 1: WeaklyRec


Framework basado en Positive-Unlabeled (PU) Learning



Reformular el problema de recomendación como un problema de
PU Learning




Datos observados



Positivos confirmados +
Unlabeled

Objetivo



Estimador **insesgado** del riesgo ideal



¡Sin necesidad de negativos confirmados!



Estimador Insesgado

Eliminar negativos matemáticamente

$$Unlabeled = k_p \times p_p(x) + k_n \times p_n(x)$$

(Una mezcla que podemos descomponer)

↓ MANIPULACIÓN ALGEBRAICA ↓

$$R_{weak}(g) = \kappa_p \times E[\ell(g)] + E[\ell(g, -1)]$$



(Sin negativos confirmados)

✓ Insesgado (Teorema 1)

✓ Consistente (Teorema 3)

Contribución 2: PPT - Progressive Proximal Transport

Progressive Proximal Transport - Estimar k_p automáticamente



Comparación: WeaklyRec+PPT vs SOTA

Ventajas vs métodos existentes

RMF/UBPR

- ✗ Requiere Propensity Scores
- ✗ Sesgado
- ⚠ Computacionalmente costoso

uPU/nnPU

- ✓ Insesgado
- ✓ Teoría sólida
- ✗ Requiere k_p conocido

WeaklyRec+PPT

- ✓ Insesgado
- ✓ k_p Automático
- ✓ Sin supuestos fuertes



Estado del arte:

La única solución que combina
insesgadez + automatización.


Estado del arte


IMPLICIT-REC

Usa información implícita para tomar decisiones. Esto usualmente genera que cada interacción sea clasificada como positiva. Problemas al diferenciar lo que no le gusta al usuario, con lo no visto.

NEGATIVE SAMPLING

Clasificar a todos los items no vistos como negativos, lo cual genera sesgo.





Estado del arte

CONSTRUCCIÓN DEL RIESGO SIN SESGO

Hay métodos que intentar disminuir el sesgo como CDR, SDR y UIDR.

Otros como RMF, UBPR y CJMF son insesgados via propensity reweighting, pero sus estimadores pueden tomar valores negativos, lo que lleva a divergencia.

Uno e los mejores métodos es **UPL** que es **insesgado** y combina la **pérdida point-wise y pair-wise**.

Todos estos métodos **dependen de su aproximación del propensity score** (probabilidad de que una interacción sea observada).





Marco Teórico

POSITIVE-UNLABELED LEARNING

Es un tipo de **weakly supervised learning**, donde los datos estan clasificados positivamente o no están clasificados (unlabeled.) Existe uPU, nnPu y distPU entre otros.

Los datos no clasificados pueden ser divididos de la siguiente forma:

$$p_u(x) = \kappa_p \cdot p_p(x) + \kappa_n \cdot p_n(x)$$

OPTIMAL TRANSPORT

Marco matemático que mide la discrepancia entre dos distribuciones, calculando su costo mínimo de transporte.

$$\mathbb{W}(\alpha, \beta) := \min_{\pi \in \Pi(\alpha, \beta)} \langle \mathbf{C}, \pi \rangle,$$

$$\Pi(\alpha, \beta) := \{ \pi \in \mathbb{R}_+^{n \times m} : \pi \mathbf{1}_m = \mathbf{a}, \pi^\top \mathbf{1}_n = \mathbf{b} \},$$



Distribuciones empíricas $\alpha_{1:n}$ and $\beta_{1:m}$


Plan π

Coste de transporte $\mathbb{W}(\alpha, \beta)$

$\mathbf{C}$ distancia entre α y β

Π set de planes viables

$\mathbf{a}$ y $\mathbf{b}$ vectores de masas



Solución

DESCOMPONER DATA:

Como los datos provienen de una mezcla de usuarios que interactuaron y los que no, la distribución de datos se puede escribir como:

$$p_{\text{data}}(x) = \kappa_p \cdot p_p(x) + \kappa_n \cdot p_n(x)$$

- κ_p : Proporción de positivos reales (DESCONOCIDA).
- $\kappa_n = 1 - \kappa_p$: Proporción de negativos.
- p_p : Probabilidad de observar una interacción x dado que esa interacción es positiva
- p_n : Probabilidad de observar una interacción x dado que es negativa

Solución

DESCOMPONER RIESGO IDEAL:

Y el riesgo ideal como:

$$R_{\text{ideal}}(g) = k_p \mathbb{E}_{p_p}[\ell(g(x), +1)] + k_n \mathbb{E}_{p_n}[\ell(g(x), -1)]$$

$$R_{\text{ideal}}(g) = \kappa_p \cdot R_p(g) + \kappa_n \cdot R_n(g)$$

- $\ell(g(x), +1)$: Mide cuánto se equivoca el modelo si asume que la interacción x es positiva.
- $\ell(g(x), -1)$: Mide cuánto se equivoca el modelo si asume que la interacción x es negativa.
- $\mathbb{E}_{p_p}[\ell(g(x), +1)]$: Error esperado en muestras positivas.
- $\mathbb{E}_{p_n}[\ell(g(x), -1)]$: Error esperado en muestras negativas.

Solución

DESCOMPONER RIESGO IDEAL:


Y el riesgo ideal como:

$$R_{\text{ideal}}(g) = k_p \mathbb{E}_{p_p}[\ell(g(x), +1)] + k_n \mathbb{E}_{p_n}[\ell(g(x), -1)]$$

$$R_{\text{ideal}}(g) = \kappa_p \cdot R_p(g) + \kappa_n \cdot R_n(g)$$

PROBLEMA

No tenemos muestras negativas confirmadas



Solución




ELIMINAR LOS NEGATIVOS USANDO DATOS NO ETIQUETADOS

Los datos no etiquetados son una mezcla de positivos ocultos y negativos.

$$p_u(x) = \kappa_p \cdot p_p(x) + \kappa_n \cdot p_n(x)$$

- κ_p : Proporción de positivos ocultos
- $\kappa_n = 1 - \kappa_p$: Proporción de negativos.
- p_p : Probabilidad de observar una interacción x dado que esa interacción es positiva
- p_n : Probabilidad de observar una interacción x dado que esa interacción es negativa
- p_u : Distribución de datos no etiquetados.



Solución



ELIMINAR LOS NEGATIVOS USANDO DATOS NO ETIQUETADOS

Los datos no etiquetados son una mezcla de positivos ocultos y negativos.

$$k_n R_n(g) = \mathbb{E}_{p_u}[\ell(g(x), -1)] - k_p \mathbb{E}_{p_p}[\ell(g(x), -1)]$$

- k_p : Proporción de positivos reales.
- $\mathbb{E}_{p_u}[\ell(g(x), -1)]$: Error promedio de tratar todos los datos no etiquetados como negativos.
- $\mathbb{E}_{p_p}[\ell(g(x), -1)]$: Error de clasificar las muestras positivas etiquetadas como negativas.
- $k_n R_n(g)$: Error esperado en muestras negativas.

Solución


DEFINICIÓN DE LAJUSTADO:

Se define una medida de error ajustada, como la diferencia entre el error de una muestra positiva y el de una negativa

$$\ell^{\circ}(g(x)) = \ell(g(x), +1) - \ell(g(x), -1)$$

- $\ell(g(x), +1)$: Mide cuánto se equivoca el modelo si asume que la interacción x es positiva.
- $\ell(g(x), -1)$: Mide cuánto se equivoca el modelo si asume que la interacción x es negativa.

Captura cuánto más costoso es clasificar x como positivo versus como negativo.



Solución




CONTRUIR RIESGO WEAKLYREC

Sustituyendo lo anterior, se obtiene el riesgo WeaklyRec, que ya no necesita negativos.

$$R_{weak}(g) = \mathbb{E}_{p_u}[\ell(g(x), -1)] + k_p \mathbb{E}_{p_p}[\ell^\circ(g(x))]$$

- k_p : Proporción de positivos ocultos
- $\ell^\circ(g(x))$: Diferencia de errores.
- $\mathbb{E}_{p_p}[\ell^\circ(g(x))]$: Error promedio extra que se está introduciendo por clasificar positivos como negativos
- $\mathbb{E}_{p_u}[\ell(g(x), -1)]$: Error promedio de tratar todos los datos no etiquetados como negativos.

R_{weak} es la estimación del riesgo ideal sin necesitar ningún negativo confirmado.



Solución



CONTRUIR RIESGO WEAKLYREC

Sustituyendo lo anterior, se obtiene el riesgo WeaklyRec, que ya no necesita negativos.

$$\bar{R}_{weak}(g) = \frac{k_p}{n_p} \sum \ell^{\circ}(g(x_i^p)) + \frac{1}{n_u} \sum \ell(g(x_i^u), -1)$$

- k_p : Proporción de positivos ocultos
- $\ell^{\circ}(g(x_i^p))$: Diferencia de errores sobre cada positivo.
- n_p : Número de muestras positivas etiquetadas.
- n_u : Número de muestras no etiquetadas.
- $\ell(g(x_i^u), -1)$: Error de tratar cada no etiquetado como negativo

Solución


CONTRUIR RIESGO WEAKLYREC

Sustituyendo lo anterior, se obtiene el riesgo WeaklyRec, que ya no necesita negativos.

$$\bar{R}_{weak}(g) = \frac{k_p}{n_p} \sum \ell^\circ(g(x_i^p)) + \frac{1}{n_u} \sum \ell(g(x_i^u), -1)$$

PROBLEMA

No sabemos cuanto vale κ_p



Solución



PROBLEMA DEL CLASS PRIOR K_P

El estimador requiere conocer K_p , la proporción de muestras positivas ocultas dentro de los datos no etiquetados, pero este valor es desconocido en la práctica.

Se usa PPT.

$$\begin{aligned}\boldsymbol{\pi}^*(\alpha, \beta; w) &:= \arg \min_{\boldsymbol{\pi} \in \Pi(\alpha, \beta; w)} \langle \mathbf{C}, \boldsymbol{\pi} \rangle, \\ \Pi(\alpha, \beta; w) &:= \{ \boldsymbol{\pi} \in \mathbb{R}_+^{n \times m} : \boldsymbol{\pi} \mathbf{1}_m = \mathbf{a}, \boldsymbol{\pi}^\top \mathbf{1}_n \leq w * \mathbf{b}, \\ &\quad \mathbf{1}_n^\top \boldsymbol{\pi} \mathbf{1}_m = 1 \},\end{aligned}$$


Solución

ESTIMACIÓN DEL CLASS PRIOR K_P

El w° que PPT encuentra al minimizar el costo de transporte incide directamente en cuántos positivos ocultos hay en los datos no etiquetados.

$$\bar{k}_p = \frac{1}{w^\circ}$$

- $\bar{k}_p$: Estimación del class prior.
- w° : El peso óptimo encontrado por PPT (El valor de w que minimiza el costo de transporte entre las muestras positivas etiquetadas y las no etiquetadas)





Implementación



El modelo base es Matrix Factorization, donde los embeddings de usuarios U e ítems V se concatenan para representar cada interacción. En cada iteración:

- Se separa el mini-batch en muestras positivas y no etiquetadas.
- Para cada muestra se buscan los vectores de usuario y de ítem en las tablas U y V , y se concatenan.
- Se calcula la matriz de distancias.
- Se resuelve el PPT para cada valor candidato w .
- Se elige el w que tuvo el menor costo de transporte, y ese valor revela directamente la proporción de positivos ocultos en los datos no etiquetados.
- Se calcula el riesgo WeaklyRec.
- Actualizar U y V con Adam (Adaptive Moment Estimation)





Evaluación

DATOS UTILIZADOS

3 datasets, con negative feedback para evaluar el modelo.

- Yahoo! R3 (Musica)
- Coat (Ropa)
- KuaiRec (Videos cortos)

PREPROCESAMIENTO

Dividido en entrenamiento, validación, y testing en un ratio de 0.8:0.1:0.1

- Rating mayor o igual a 4 como positivo en Yahoo! R3 y Coat
- Rating mayor o igual a 3 como positivo en KuaiRec

PROTOCOLO DE ENTRENAMIENTO

Se usó matrix factorization como el modelo de recomendación primario

Implementación en Pytorch

- Learning rate {0.005, 0.01, 0.05}
- Batch size {256, 512, 1024, 2048}
- Embedding size {8, 16, 32}



Unbiased Recommender Learning from Implicit Feedback via Weakly Supervised Learning

Table 1: Recommendation performances in terms of NDCG@k on Yahoo! R3, Coat and KuaiRec.

Dataset	Yahoo! R3			Coat			KuaiRec		
Metrics	NDCG@1	NDCG@3	NDCG@5	NDCG@1	NDCG@3	NDCG@5	NDCG@1	NDCG@3	NDCG@5
RMF	0.632 $\pm$ 0.003	0.666 $\pm$ 0.003	0.706 $\pm$ 0.003	0.374 $\pm$ 0.026	0.403 $\pm$ 0.020	0.442 $\pm$ 0.021	0.211 $\pm$ 0.007	0.209 $\pm$ 0.005	0.212 $\pm$ 0.003
CRMF	0.633 $\pm$ 0.004	0.667 $\pm$ 0.003	0.706 $\pm$ 0.003	0.377 $\pm$ 0.022	0.401 $\pm$ 0.018	0.445 $\pm$ 0.023	0.212 $\pm$ 0.005	0.218 $\pm$ 0.004	0.222 $\pm$ 0.002
WMF	0.707 $\pm$ 0.003	0.737 $\pm$ 0.003	0.772 $\pm$ 0.002	0.389 $\pm$ 0.025	0.425 $\pm$ 0.023	0.466 $\pm$ 0.027	0.226 $\pm$ 0.009	0.244 $\pm$ 0.008	0.261 $\pm$ 0.008
UBPR	0.755 $\pm$ 0.003	0.794 $\pm$ 0.001	0.826 $\pm$ 0.001	0.476 $\pm$ 0.024	0.509 $\pm$ 0.014	0.541 $\pm$ 0.007	0.248 $\pm$ 0.009	0.265 $\pm$ 0.006	0.281 $\pm$ 0.006
CUBPR	0.755 $\pm$ 0.003	0.794 $\pm$ 0.002	0.826 $\pm$ 0.002	0.478 $\pm$ 0.026	0.509 $\pm$ 0.013	0.542 $\pm$ 0.007	0.254 $\pm$ 0.007	0.268 $\pm$ 0.007	0.284 $\pm$ 0.007
UPL	0.759 $\pm$ 0.003	0.798 $\pm$ 0.002	0.829 $\pm$ 0.003	0.512 $\pm$ 0.019	0.508 $\pm$ 0.013	0.539 $\pm$ 0.012	0.250 $\pm$ 0.006	0.265 $\pm$ 0.006	0.281 $\pm$ 0.005
RecVAE	0.650 $\pm$ 0.002	0.683 $\pm$ 0.004	0.719 $\pm$ 0.005	0.465 $\pm$ 0.021	0.499 $\pm$ 0.017	0.545 $\pm$ 0.009	0.422 $\pm$ 0.006	0.434 $\pm$ 0.005	0.448 $\pm$ 0.007
DCF	0.762 $\pm$ 0.003	0.796 $\pm$ 0.003	0.826 $\pm$ 0.002	0.544 $\pm$ 0.0025	0.538 $\pm$ 0.019	0.566 $\pm$ 0.007	0.448 $\pm$ 0.007	0.457 $\pm$ 0.008	0.466 $\pm$ 0.004
ORACLE	0.652 $\pm$ 0.004	0.692 $\pm$ 0.003	0.732 $\pm$ 0.003	0.443 $\pm$ 0.019	0.470 $\pm$ 0.012	0.507 $\pm$ 0.011	0.204 $\pm$ 0.004	0.225 $\pm$ 0.005	0.246 $\pm$ 0.005
CDR	0.669 $\pm$ 0.005	0.695 $\pm$ 0.003	0.727 $\pm$ 0.004	0.398 $\pm$ 0.015	0.420 $\pm$ 0.014	0.457 $\pm$ 0.014	0.491 $\pm$ 0.012	0.425 $\pm$ 0.005	0.412 $\pm$ 0.004
SDR	0.666 $\pm$ 0.001	0.688 $\pm$ 0.001	0.719 $\pm$ 0.001	0.452 $\pm$ 0.030	0.467 $\pm$ 0.022	0.502 $\pm$ 0.018	0.493 $\pm$ 0.006	0.419 $\pm$ 0.010	0.400 $\pm$ 0.010
UIDR	0.679 $\pm$ 0.030	0.705 $\pm$ 0.032	0.737 $\pm$ 0.033	0.382 $\pm$ 0.015	0.400 $\pm$ 0.011	0.436 $\pm$ 0.014	0.493 $\pm$ 0.085	0.446 $\pm$ 0.060	0.435 $\pm$ 0.050
WeaklyRec	0.784* $\pm$ 0.003	0.814* $\pm$ 0.003	0.843* $\pm$ 0.002	0.552* $\pm$ 0.031	0.555* $\pm$ 0.019	0.589* $\pm$ 0.015	0.498 $\pm$ 0.008	0.486 $\pm$ 0.007	0.488* $\pm$ 0.004

Note: The results are reported in mean $\pm$ std with 5 runs. The best and second best metrics are bolded and underlined, respectively. ”*” marks the metrics that WeaklyRec surpasses the best baseline with p-value < 0.05 over paired samples t-test.

Unbiased Recommender Learning from Implicit Feedback via Weakly Supervised Learning

Table 2: Recommendation performances in terms of Recall@k on Yahoo! R3, Coat and KuaiRec.

Dataset	Yahoo! R3			Coat			KuaiRec		
Metrics	Recall@1	Recall@3	Recall@5	Recall@1	Recall@3	Recall@5	Recall@1	Recall@3	Recall@5
RMF	0.042 $\pm$ 0.002	0.132 $\pm$ 0.005	0.226 $\pm$ 0.003	0.054 $\pm$ 0.017	0.170 $\pm$ 0.018	0.285 $\pm$ 0.022	0.008 $\pm$ 0.001	0.022 $\pm$ 0.002	0.037 $\pm$ 0.001
CRMF	0.042 $\pm$ 0.002	0.132 $\pm$ 0.004	0.226 $\pm$ 0.004	0.055 $\pm$ 0.014	0.168 $\pm$ 0.018	0.289 $\pm$ 0.030	0.009 $\pm$ 0.002	0.029 $\pm$ 0.003	0.047 $\pm$ 0.001
WMF	0.094 $\pm$ 0.002	0.203 $\pm$ 0.003	0.288 $\pm$ 0.002	0.061 $\pm$ 0.011	0.192 $\pm$ 0.025	0.311 $\pm$ 0.035	0.015 $\pm$ 0.003	0.058 $\pm$ 0.007	0.104 $\pm$ 0.008
UBPR	0.125 $\pm$ 0.002	0.265 $\pm$ 0.000	0.344 $\pm$ 0.001	0.113 $\pm$ 0.008	0.270 $\pm$ 0.009	0.375 $\pm$ 0.013	0.023 $\pm$ 0.004	0.069 $\pm$ 0.005	0.115 $\pm$ 0.005
CUBPR	0.126 $\pm$ 0.003	0.265 $\pm$ 0.002	0.344 $\pm$ 0.002	0.113 $\pm$ 0.009	0.270 $\pm$ 0.009	0.378 $\pm$ 0.010	0.024 $\pm$ 0.002	0.071 $\pm$ 0.008	0.119 $\pm$ 0.009
UPL	0.129 $\pm$ 0.002	0.268 $\pm$ 0.002	0.346 $\pm$ 0.003	0.118 $\pm$ 0.009	0.256 $\pm$ 0.011	0.369 $\pm$ 0.010	0.022 $\pm$ 0.003	0.070 $\pm$ 0.004	0.117 $\pm$ 0.006
RecVAE	0.054 $\pm$ 0.002	0.149 $\pm$ 0.001	0.234 $\pm$ 0.002	0.096 $\pm$ 0.012	0.267 $\pm$ 0.021	0.389 $\pm$ 0.031	0.110 $\pm$ 0.001	0.183 $\pm$ 0.002	0.214 $\pm$ 0.002
DCF	0.131 $\pm$ 0.003	0.262 $\pm$ 0.003	0.339 $\pm$ 0.004	0.134 $\pm$ 0.014	0.272 $\pm$ 0.024	0.386 $\pm$ 0.027	0.119 $\pm$ 0.001	0.231 $\pm$ 0.005	0.288 $\pm$ 0.004
ORACLE	0.055 $\pm$ 0.003	0.162 $\pm$ 0.004	0.258 $\pm$ 0.004	0.085 $\pm$ 0.009	0.233 $\pm$ 0.009	0.350 $\pm$ 0.015	0.011 $\pm$ 0.001	0.052 $\pm$ 0.005	0.101 $\pm$ 0.006
CDR	0.066 $\pm$ 0.002	0.157 $\pm$ 0.003	0.235 $\pm$ 0.006	0.064 $\pm$ 0.012	0.185 $\pm$ 0.018	0.297 $\pm$ 0.017	0.140 $\pm$ 0.004	0.191 $\pm$ 0.002	0.207 $\pm$ 0.003
SDR	0.061 $\pm$ 0.001	0.149 $\pm$ 0.003	0.223 $\pm$ 0.002	0.085 $\pm$ 0.017	0.224 $\pm$ 0.014	0.337 $\pm$ 0.013	0.138 $\pm$ 0.002	0.184 $\pm$ 0.007	0.191 $\pm$ 0.010
UIDR	0.075 $\pm$ 0.021	0.168 $\pm$ 0.035	0.245 $\pm$ 0.037	0.060 $\pm$ 0.009	0.163 $\pm$ 0.011	0.268 $\pm$ 0.013	0.133 $\pm$ 0.037	0.206 $\pm$ 0.038	0.235 $\pm$ 0.033
WeaklyRec	0.146* $\pm$ 0.002	0.280* $\pm$ 0.003	0.354* $\pm$ 0.002	0.131 $\pm$ 0.016	0.302* $\pm$ 0.019	0.425* $\pm$ 0.019	0.137 $\pm$ 0.002	0.245* $\pm$ 0.005	0.296* $\pm$ 0.004

Note: The results are reported in mean $\pm$ std with 5 runs. The best and second best metrics are bolded and underlined, respectively. ”*” marks the metrics that WeaklyRec surpasses the best baseline with p-value < 0.05 over paired samples t-test.



Conclusiones

GENERAL

Point-wise (CRMF) tienen limitaciones (sensibles a propensity scores pequeños, la corrección genera sesgo)

Pair-wise (UBPR y CUBPR) comparte las limitaciones anteriores, pero al penalizar ratings bajos para items sin label tiene una mejor preformance

UPL que combina ambas es más efectiva.

Weakly-Rec tiene una mejor performance en todos los datasets y métricas. Esto se puede deber a que no tiene sesgo y a que opera de manera independiente de los propensity scores.




Figure 2: Varying risk estimator results on KuaiRec.




Figure 3: Varying error measure (ℓ) results on KuaiRec.

Conclusiones

KuaiRec

El risk estimator propuesto por el paper asegura la **no negatividad de cada término individual**, lo que genera una mejor predicción que distPU y nnPU. Al no tener límite inferior uPU es sensible al overfitting.

Para que WeaklyRec funcione bien, **el surrogate risk debe ser convexo**. Sigmoid no cumple esto

Unbiased Recommender Learning from Implicit Feedback via Weakly Supervised Learning




Figure 5: Results with varying ratios of unlabeled data for model training. The colored lines and shadowed areas represent mean values and 90% confidence intervals, respectively.

Además se ve como mejoran las métricas Recall y NDCG al aumentar el porcentaje de involved unlabeled data.

Referencias

UPL

Ren, Y., Tang, H., Rong, J., & Zhu, S. (2023, July). Unbiased pairwise learning from implicit feedback for recommender systems without biased variance control. In Proceedings of the 46th international ACM SIGIR conference on research and development in information retrieval (pp. 2461-2465). <https://dl.acm.org/doi/abs/10.1145/3539618.3592077>

RMF

Saito, Y., Yaginuma, S., Nishino, Y., Sakata, H., & Nakata, K. (2020, January). Unbiased recommender learning from missing-not-at-random implicit feedback. In Proceedings of the 13th international conference on web search and data mining (pp. 501-509). <https://dl.acm.org/doi/abs/10.1145/3336191.3371783>

distPU

Yunrui Zhao, Qianqian Xu, Yangbangyan Jiang, Peisong Wen, and Qingming Huang. 2022. Dist-PU: Positive Unlabeled Learning from a Label Distribution Perspective. In CVPR. IEEE, 14441–14450.

nnPU

Ryuichi Kiryo, Gang Niu, Marthinus Christoffel du Plessis, and Masashi Sugiyama. 2017. Positive-Unlabeled Learning with Non-Negative Risk Estimator. In NeurIPS. 1675–1685.

Referencias

UBPR

Saito, Y. (2020, September). Unbiased pairwise learning from biased implicit feedback. In Proceedings of the 2020 ACM SIGIR on International Conference on Theory of Information Retrieval (pp. 5-12).

<https://dl.acm.org/doi/abs/10.1145/3409256.3409812>

CJMF

Zhu, Z., He, Y., Zhang, Y., & Caverlee, J. (2020, September). Unbiased implicit recommendation and propensity estimation via combinational joint learning. In Proceedings of the 14th ACM conference on recommender systems (pp. 551-556).

<https://dl.acm.org/doi/abs/10.1145/3383313.3412210>

CDR

Song, Z., Chen, J., Zhou, S., Shi, Q., Feng, Y., Chen, C., & Wang, C. (2023, October). CDR: Conservative doubly robust learning for debiased recommendation. In Proceedings of the 32nd ACM international conference on information and knowledge management (pp. 2321-2330).

<https://dl.acm.org/doi/abs/10.1145/3583780.3614805>

Referencias

SDR

Li, H., Zheng, C., & Wu, P. (2022). StableDR: Stabilized doubly robust learning for recommendation on data missing not at random. arXiv preprint arXiv:2205.04701.

<https://arxiv.org/abs/2205.04701>

UIDR

Haoxuan Li, Chunyuan Zheng, Shuyi Wang, Kunhan Wu, Hao Wang, Peng Wu, Zhi Geng, Xu Chen, and Xiao-Hua Zhou. 2024. Relaxing the Accurate Imputation Assumption in Doubly Robust Learning for Debiased Collaborative Filtering. In ICML.

<https://openreview.net/forum?id=Ln3moCobjO>

Paper original:

Wang, H., Chen, Z., Wang, H., Tan, Y., Pan, L., Liu, T., ... & Lin, Z. (2025, October). Unbiased recommender learning from implicit feedback via weakly supervised learning. In Forty-second International Conference on Machine Learning.

<https://openreview.net/forum?id=0E5rZOGA13>



Extra



ADAM: ADAPTIVE MOMENT ESTIMATION

Es un método para la optimización estocástica. Se utiliza en el último paso del flujo de trabajo computacional para actualizar las tablas de búsqueda de embeddings de usuarios y artículos (U y V) mediante el cálculo de gradientes

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are element-wise. With β_1^t and β_2^t we denote β_1 and β_2 to the power t .

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1]$: Exponential decay rates for the moment estimates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$v_0 \leftarrow 0$ (Initialize 2nd moment vector)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)

$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$ (Update parameters)

end while

return θ_t (Resulting parameters)

Fuente: Diederik P. Kingma and Jimmy Ba. 2015. Adam: A Method for Stochastic Optimization. In ICLR.

Unbiased Recommender Learning from Implicit Feedback via Weakly Supervised Learning




Figure 4: PT transport plan (a-c) and cost (d) with different w . Circular (rectangular) markers indicate positive (negative) samples. Blue (red) markers indicate labeled (unlabeled) samples.

Table 3: Varying fixed class prior results.

$\hat{\kappa}_p$	W	ΔW	NDCG@3	Δ NDCG@3	NDCG@5	Δ NDCG@5	Recall@3	Δ Recall@3	Recall@5	Δ Recall@5
0.2	6.1143	-	0.4022	-	0.4232	-	0.2102	-	0.2732	-
0.005	5.5727	8.85%↓	0.4696	16.75%↑	0.4717	11.46%↑	0.2293	9.08%↑	0.2857	4.57%↑
0.01	5.5727	8.85%↓	0.4731	17.62%↑	0.4781	12.97%↑	0.2326	10.65%↑	0.2930	7.24%↑
0.02	5.5716	8.87%↓	0.4847	20.51%↑	0.4867	15.00%↑	0.2419	15.08%↑	0.2954	8.12%↑
0.05	5.5620	9.03%↓	0.4847	20.51%↑	0.4871	15.09%↑	0.2455	16.79%↑	0.2979	9.04%↑
0.1	5.5951	8.49%↓	0.4427	10.06%↑	0.4564	7.84%↑	0.2296	9.22%↑	0.2886	5.63%↑

Note: Δ denotes the relative deviation from the results with $\hat{\kappa}_p = 0.2$.

κ_p proporción de positivos no etiquetados dentro de β
 w controla cuántas muestras de β se emparejan con α

Diferentes valores de w resultan en estrategias distintas
 El comportamiento de w nos permite predecir la clase priors, de forma **$\kappa_p = 1/w$**
 Se debe analizar el dataset para obtener el κ_p ideal

