



You Don't Bring Me Flowers: Mitigating Unwanted Recommendations Through Conformal Risk Control

Seminario - Presentación de Papers

Martín Cortés Manuel Delpiano Yampai Ludueña

Semestre 2026-1

Curso Sistemas Recomendadores (IIC3633)
Pontificia Universidad Católica de Chile

“¿Cuántos de ustedes han marcado

‘No me interesa’

en Redes Sociales y siguen recibiendo

el mismo contenido?”

↓ Hablemos de eso.

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

Contexto I: El Conflicto del Engagement Algorítmico

NETFLIX


Streaming



E-commerce



Redes sociales



Funcionamiento estándar para la personalización masiva


Contexto II: La Paradoja de la Escasez del Feedback Negativo

La Realidad del Comportamiento del Usuario


El contenido indeseado abunda, pero el feedback explícito de rechazo es muy escaso.

Datos Duros (KuaiRand)

- **>95 % de usuarios:** reporta a lo más 1/100 videos.
- **60 % de usuarios:** reporta a lo más 1/ 1000 videos.
- **Skip como escape:** mayoría **salta** videos y no Reporta.



(a) Distribution of $W_{\%}$ on reported (right) and unreported (left) videos.



(b) Reported videos watch time segmented by $W_{\%}$ (log-scale).

Distribución $W_{\%}$: reportados vs no reportados.


Contexto III: Interfaz tediosa y Teorías Populares

Diseño


Los botones del estilo “No me interesa” generalmente exigen múltiples interacciones dentro de los menús de la interfaz, lo que desalienta su uso.

El Fenómeno de las “Folk Theories”

- Sin transparencia ni efecto inmediato, los usuarios **inventan** cómo funciona el algoritmo.
- Ejemplos: **shadowban**, “**el celular escucha**”, y otras creencias populares.



Shadowban



Celular escucha

Necesidad Crucial: Se requiere un método que garantice matemáticamente un límite máximo de riesgo indeseado, devolviéndole el control real y transparente al usuario.

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo


Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

El Problema de Recomendación



Objetivo

Maximizar utilidad de la recomendación **sin** superar la tolerancia del usuario al contenido indeseado.

Desafío

Encontrar el umbral λ que filtre lo riesgoso, pero **sin vaciar** la lista ni destruir la personalización.

Formulación central (Paper)

$$\lambda^* = \arg \max_{\lambda} \mathbb{E}[l(S_{\lambda}(U, k))] \quad \text{s.t.} \quad \mathbb{E}[R(S_{\lambda}(U, k))] \leq \alpha$$

- α : límite de riesgo fijado por el usuario.
- $R(\cdot)$: fracción de ítems indeseados en el top- k .
- λ : filtro de seguridad post-hoc sobre el ranker.

El paper resuelve esto con CRC + REPLACE

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

Cuatro Pilares de Contribución

Cuatro Pilares de Contribución

1



Análisis comprehensivo
de datos reales.

Cuatro Pilares de Contribución

1



Análisis comprehensivo
de datos reales.

2



Un método basado en
Conformal Risk Control.

Cuatro Pilares de Contribución

1



Análisis comprehensivo
de datos reales.

2



Un método basado en
Conformal Risk Control.

3



Una heurística práctica.

Cuatro Pilares de Contribución

1



Análisis comprehensivo
de datos reales.

2



Un método basado en
Conformal Risk Control.

3



Una heurística práctica.

4



Experimentos y
ablaciones.

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

¿Qué es Conformal Prediction (CP)?

Es un marco estadístico moderno para la cuantificación de incertidumbre en modelos de Machine Learning.

- **Predicciones por Conjuntos:** En vez de predecir un único valor exacto (que puede estar errado), genera un grupo o vecindad de posibles respuestas correctas.
- **Propiedades Clave:** Ofrece garantías de cobertura válidas para muestras finitas y es **libre de distribución** (*distribution-free*), lo que significa que no asume que los datos sigan curvas perfectas o normales.

La Evolución desde Cobertura hacia Pérdidas Generales

Desarrollado recientemente por Angelopoulos et al. (2023), Conformal Risk Control expande los límites de CP.

- **Más allá de acertar el valor:** CP solo busca que la respuesta correcta “esté dentro” del conjunto generado.
- **Control de Riesgo Dinámico:** CRC permite controlar matemáticamente cualquier función de pérdida monótona indeseada (como la tasa de falsos descubrimientos o la proporción de insultos en un texto).
- **Alineación Temporal:** Es la primera vez en la literatura que se adaptan estas metodologías para embridar la proporción de contenido molesto en sistemas recomendadores activos.

Tabla 1: Comparativa de Estrategias de Mitigación de Daños

Estrategia	Post-Hoc?	Garantía Formal?	Limitación Principal
Moderación de Contenido	Sí	No	Depende de clasificadores imperfectos y propensos a error.
Restricciones de Equidad	No	Parcial	Requiere re-entrenar el modelo base globalmente.
Aprendizaje por Feedback	No	No	Complejo de converger bajo dinámicas cambiantes de usuario.
CRC + REPLACE (Paper)	Sí	Sí	Requiere historial mínimo de ítems vistos (Cold start).

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

Fórmula 1: Cuantificación del Riesgo Empírico (R_H)

$$R_H(S_\lambda(U, k)) = \frac{|\{i \in S_\lambda(U, k) : H(U, I = i) = 1\}|}{|S_\lambda(U, k)|}$$

Explicación Técnica

- $H \in \{0, 1\}$: variable binaria de reporte del usuario.
- Riesgo = fracción de ítems flagueados sobre el total del top- k .

Intuición en Lenguaje Cotidiano

Esta fórmula mide el “**porcentaje de insatisfacción**”. Si el sistema te recomienda una grilla de 20 videos en tu teléfono, y el usuario marca 2 de ellos con el botón “Reportar”, el nivel de riesgo real en esa sesión fue de un 10 %. Lo que se busca es que este porcentaje nunca supere la tolerancia que fue configurada.

Fórmula 2: Calibración del Umbral Seguro ($\hat{\lambda}$)

$$\hat{\lambda} = \inf \left\{ \lambda : \frac{n}{n+1} \hat{R}(\lambda) + \frac{1}{n+1} \leq \alpha \right\}$$

Explicación Técnica

- Calibración sobre un *held-out* de tamaño n .
- $\hat{\lambda}$ = mínimo umbral donde el riesgo ajustado ($+\frac{1}{n+1}$) cae bajo α .

Intuición en Lenguaje Cotidiano

Es como un **“filtro de seguridad”** ajustable. Para calibrarlo, el sistema revisa un grupo de pruebas con n videos pasados. Se comienza con el filtro abierto y se va cerrando (subiendo la exigencia λ) hasta que el promedio de videos molestos decae por debajo del límite α . El ajuste exacto donde logra frenar el peligro con éxito se convierte en el nuevo estándar de navegación.

Teorema 1: Garantía Formal del Conformal Risk Control

Teorema 1 (Angelopoulos et al., 2023)

Si $R_H(S_\lambda)$ es:

- No creciente en λ ,
- Continua por la derecha,
- $R_H(S_{\lambda_{\text{máx}}}) \leq \alpha$ y $\sup_\lambda R_H(S_\lambda) \leq 1$ c.s.

Entonces eligiendo $\hat{\lambda}$ según la Fórmula 2:

$$\mathbb{E}[R_H(S_{\hat{\lambda}}(U, k))] \leq \alpha$$

Implicación práctica

El sistema garantiza, en expectativa y con **cobertura libre de distribución**, que el contenido indeseado nunca supere el límite α definido por el usuario.

El Gran Defecto de la Eliminación Pura (REMOVE)

La Proposición 2 y la Pérdida de Inventario

¿Qué ocurre si simplemente aplicamos el umbral $\hat{\lambda}$ y se elimina todo lo que parezca mínimamente sospechoso?

Proposición 2 (Paper, Sec. 5)

Dado $\alpha \in [0, 1]$, existen distribuciones para las cuales un filtro tipo T_λ NO puede garantizar $R_H \leq \alpha$ a menos que $|T_\lambda(U)| = 0$.

Contraejemplo del paper

Con items $\{A, B, C, D\}$, scores $f(u, D) = 5$ y $f(u, \cdot) = 1$ para el resto. Si $\alpha = 0,1$, el único λ válido es $\lambda > 5$, lo que obliga a $T_\lambda(U) = \emptyset$.

Fórmula 3: Creación de la Reserva Alternativa Segura ($T^{(safe)}$)

$$T^{(safe)} = \{i' \in \mathcal{I}_U : H(U, I = i') = 0 \wedge W_{\%}(U, i') > \beta\}$$

Explicación Técnica


- Items del historial $\mathcal{I}_U$ con $H = 0$ y $W_{\%} > \beta$.
- Sustento formal: **Property 1**, $P(H = 1 \mid H_{1st} = 0, C > \beta) = 0$.

Intuición en Lenguaje Cotidiano

Esta es la “**bóveda de clásicos confiables**”: videos que ya se observaron, no se reportaron, y se miraron lo suficiente. Si el sistema necesita rellenar espacio con algo 100 % seguro, los saca de aquí.

Evidencia Empírica de Property 1 (Paper, Tabla 2 y Fig. 2)

1ª → 2ª vez	I (%)	U (%)	WT 1ª	WT 2ª
No → No	99.79	100.0	2.71	10.48
No → Sí	0.11	8.69	0.50	10.73
Sí → Sí	0.07	6.33	7.74	7.85
Sí → No	0.03	1.49	1.36	6.46



El hallazgo clave

Los videos reportados recién en la 2ª vista tuvieron watch-time de **solo 0.50s** la 1ª vez. Filtrar con $\beta > 0$ blinda el pool seguro.

Fórmula 4: El Pool de Reemplazo Combinado ($T_{\lambda}^{(replace)}$)

$$T_{\lambda}^{(replace)}(U) = T_{\lambda}(U) \cup T^{(safe)}(U)$$


Explicación Técnica

- Pool final = unión del filtrado por umbral T_{λ} + el seguro $T^{(safe)}$.
- Preserva la monotonicidad exigida por el Teorema 1 (CRC).

Intuición en Lenguaje Cotidiano

Por ejemplo, **“lista de invitados”** para una fiesta segura. Primero se colocan a los conocidos nuevos que pasaron el exigente test de seguridad de la entrada (T_{λ}). Si faltan personas para llenar el salón de eventos, abres las puertas y agregas a amigos de toda la vida en los que confías plenamente ($T^{(safe)}$). Así, aseguras una fiesta llena y libre de problemas.


Visualización Conjuntista de REPLACE



Garantiza que la lista **nunca queda vacía**

$$T^{(replace)} = T_\lambda \cup T^{(safe)}$$

Pipeline de Dos Etapas: Visión General



Característica clave

Todo el proceso es **post-hoc**: no requiere reentrenar el ranker base f .

Algoritmo 1: Pipeline Unificado REPLACE

Require: Usuario U , candidatos generales $\mathcal{I}$, tolerancia al daño α , ranker s , tamaño objetivo k

- 1: $\hat{\lambda} \leftarrow \text{RiskControl}(\alpha)$ ▷ Exigencia estadística usando datos históricos
- 2: $T_{\hat{\lambda}}(U) \leftarrow \{i \in \mathcal{I} : s(U, i) \geq \hat{\lambda}\}$ ▷ Filtro: remueve lo sospechoso
- 3: $T^{(safe)}(U) \leftarrow \{i' \in \mathcal{I}_U : H(i') = \mathbf{o} \wedge W_{\%} > \beta\}$ ▷ Inventario de respaldo seguro
- 4: $T_{\hat{\lambda}}^{(replace)}(U) \leftarrow T_{\hat{\lambda}}(U) \cup T^{(safe)}(U)$ ▷ Fusión de sets candidatos
- 5: **return** Top- k según ordenamiento del ranker base

Proposición 3 (Paper, Sec. 5.1)

Si **Property 1** se cumple, el conjunto $T_{\lambda}^{(replace)}$ preserva la *monotonidad del riesgo* requerida por el Teorema 1 (CRC).

⇒ Las garantías matemáticas se conservan al aplicar REPLACE.

Complejidad Computacional Optimizada

- **Offline:** Cálculo del umbral $\hat{\lambda}$ en $O(Q)$ (Q = tamaño del set de calibración).
- **Online:** Filtrado y construcción del pool en $O(|\mathcal{I}|)$.
- **Dominante:** Ordenamiento final del top- k en $O(|\mathcal{I}| \log |\mathcal{I}|)$.

Viable para producción masiva sin reentrenar el ranker base.

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

¿Por qué KuaiRand?

La gran mayoría de los datasets de la industria omiten o agregan el feedback de rechazo por motivos comerciales. KuaiRand es una excepción única que guarda los registros individuales de clics en “Reportar”.

Estadísticas Post-Filtrado

- **Usuarios de la muestra:** 5.657
- **Videos únicos:** 117.695
- **Interacciones totales:** > 3.000.000
- **Partición:** 70 % Entrenamiento, 15 % Validación (Calibración), 15 % Testeo ciego.

Para comprobar que el método funciona de verdad sin importar qué algoritmo corra por detrás, los autores probaron el filtro sobre cuatro modelos avanzados de recomendación:

1. **LightGCL (2023):** Modelo basado en gráficos relacionales que utiliza aprendizaje por contraste para descubrir patrones de afinidad limpios.
2. **GFormer (2023):** Una arquitectura híbrida que potencia las estructuras de grafos con capas de atención tipo Transformer.
3. **SiReN (2022):** Un recomendador especializado de signo consciente (*sign-aware*), que modela por separado las conexiones positivas y los lazos de odio/rechazo.
4. **SIGFormer (2024):** Estado del arte en procesamiento de grafos con signos explícitos de feedback negativo mediante Transformers.

Respuesta a la Pregunta de Investigación 1 (RQ1)


¿El algoritmo realmente obedece la cota fijada por el usuario en entornos de prueba reales?

- **Comportamiento empírico riguroso:** En los experimentos, al graficar el riesgo real medido contra el límite teórico deseado, todos los puntos se ubicaron sobre o por debajo de la diagonal de tolerancia.
- **Fiabilidad absoluta:** Esto demuestra empíricamente que el Teorema de Control Conformal no falla; el usuario recupera el dominio matemático y la predictibilidad sobre los contenidos dañinos que ve en pantalla.

Resultados II: El Impacto Crítico en nDCG y Recall

RQ2: ¿Qué sacrificamos al proteger al usuario?

¿Cuánta utilidad pierde la plataforma al activar el filtro de seguridad?



Estrategia	nDCG@20 ($\alpha \rightarrow 0$)	Items entregados
Sin control	~0.60	20/20
REMOVE	~0.00	0/20
REPLACE	~ 0.30	~ 18/20

Conclusión: REPLACE mantiene el inventario y la utilidad mientras REMOVE colapsa.

Resultados III: RQ3 — Comparativa entre Modelos


¿Cuántos ítems hay que reemplazar para lograr el riesgo deseado?

Test sobre 4 rankers state-of-the-art (con $\alpha \rightarrow 0$).

Modelo	% ítems reemplazados
LightGCL (2023)	~60 %
GFormer (2023)	~70 %
SiReN (2022)	~85 %
SIGFormer (2024)	~90 %

Hallazgo sorprendente


Los modelos sign-aware reemplazaron más, no menos.




Resultados III: RQ4 — Rol del Filtro Temporal β

¿Importa cuánto vió el usuario un video la primera vez?


Ablación sobre el parámetro β (Paper, Fig. 5).




(a) Reduction in $R_H(S_\lambda(U, k))$



(b) nDCG @ 20



(c) # of previously seen items



(d) Size of $S_\lambda(U)$

$\beta = 0$ (sin filtro)

Puntos sobre la diagonal $\rightarrow$ control falla.

$\beta \geq 50\%$

Puntos bajo la diagonal $\rightarrow$ riesgo controlado.

Resultados IV: Sesgo entre Usuarios (RQ5)

¿El algoritmo trata igual a todos los usuarios?

Comparación entre usuarios *low-reporting* y *high-reporting*.


El Descubrimiento del Sesgo

Como $\hat{\lambda}$ es un **promedio global**, los usuarios *high-reporting* arrastran la exigencia para todos.

Consecuencia Práctica

Los usuarios pasivos sufren un freno demasiado conservador.

Futuro: personalizar λ por usuario.



Limitaciones Reconocidas por los Autores (Paper, Sec. 8)

Metodología

- **Umbral global:** $\hat{\lambda}$ es un promedio; sesga contra usuarios low-reporting.
- **Preferencias estáticas:** no modela cambio temporal del gusto del usuario.
- **Posición ignorada:** todos los items contribuyen igual al riesgo.

Evaluación

- Un único dataset (KuaiRand) $\rightarrow$ validez externa limitada.
- Property 1 no se ha probado en otras plataformas.

Trabajo futuro propuesto

Personalización del umbral, modelos dinámicos de usuario, garantías probabilísticas (no solo en expectativa), y validación bajo el DSA Art. 40 con plataformas como Twitter/Facebook.

Contexto del Problema

El Problema de Recomendación

Contribución del Artículo

Estado del Arte y Marco Teórico

Detalle de la Solución (Explicación Dual)

Evaluación Experimental y Resultados

Referencias Bibliográficas

-  G. De Toni, E. Purificato, E. Gomez, B. Lepri, A. Passerini, C. Consonni.
You Don't Bring Me Flowers: Mitigating Unwanted Recommendations Through Conformal Risk Control.
19th ACM Conference on Recommender Systems (RecSys 2025). arXiv:2507.16829v1 [cs.IR].
-  A. N. Angelopoulos, S. Bates, A. Fisch, L. Lei, T. Schuster.
Conformal risk control.
International Conference on Learning Representations (ICLR), 2023.
-  C. Gao, S. Li, Y. Zhang, et al.
Kuairand: An unbiased sequential recommendation dataset with randomly exposed videos.
ACM Conference on Information and Knowledge Management (CIKM), 2022.

¡Muchas gracias por su atención!

Espacio abierto para consultas y debate técnico.